


北京邮电大学

硕士学位论文



题目： 公平感知的音乐推荐系统
设计与实现

学 号： 2022140689

姓 名： 赵世龙

学科专业： 计算机技术

学习方式： 全日制

导 师： 张玉洁

学 院： 计算机学院（国家示范性软件学院）

2025年6月5日

中国·北京

密级：公开

北京邮电大学

硕士学位论文(专业学位)



题目： 公平感知的音乐推荐系统
设计与实现

学 号： 2022140689

姓 名： 赵世龙

学科专业： 计算机技术

学习方式： 全日制

导 师： 张玉洁

学 院 计算机学院(国家示范性软件学院)

2025 年 6 月 4 日



BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

Master Thesis

Design and Implementation of Fairness-aware Music Recommendation System

Student ID: 2022140689

Author: Zhao ShiLong

Subject: Computer Technology

Supervisor: Zhang Yujie

Institute: School of Computer Science

(National Pilot Software Engineering School), BUPT

4 June 2025

答辩委员会名单

职务	姓 名	职 称	工 作 单 位
主席	刘晓鸿	副教授	北京邮电大学
委员	孟祥武	教授	北京邮电大学
委员	张玉洁	副教授	北京邮电大学
委员	刘洋	高级工程师	中国石化工程建设有限公司
秘书	张永萍	工程师	北京邮电大学
答辩日期	2025 年 5 月 17 日		

摘 要

音乐推荐系统作为现代数字平台的核心组件,极大的丰富了用户的音乐体验,促进了音乐内容的消费与传播。然而随着其广泛的应用,内容数据分布的不均衡引发的一系列公平性问题也日益凸显,这为构建公平感知的音乐推荐系统带来了许多挑战。具体而言,用户之间的数据不均衡导致了推荐模型对于弱势用户群体的推荐性能不足,使其难以获得与主流用户同等质量的推荐效果,进而恶化系统的用户生态;音乐类型之间的数据不均衡导致了推荐模型过分关注热门的音乐类型,使得推荐内容日益同质化,不同类型的音乐缺少平等的曝光机会,进而恶化系统的内容生态;此外数据不均衡产生的热度信息之间关联,对这些关联的忽视也同样影响了推荐性能,进而影响用户体验与留存。针对上述问题,本文提出了一些系列创新模型与方法,主要内容如下:

(1)针对改善弱势用户群体用户体验的需求,已有研究在建模敏感信息对用户行为个性化影响方面存在不足,本文提出了个性化敏感信息学习网络。该网络通过相关注意力机制学习用户视角下的敏感信息,并利用敏感信息融合模块将其与全局敏感信息相结合,从而更全面地建模敏感信息的类型。在此基础上,通过 POSO 网络为不同类型的用户进行个性化建模。这一方法有效弥补了已有研究的不足。与原有方法相比,在两个真实数据集 ML-1M 和 LastFM360K 上,该网络在基本保持性能指标 HitRate、NDCG、Recall 的基础上,显著提升了弱势群体在 MinHR 指标下的用户体验。

(2)针对改善推荐内容多样性的需求,已有研究对标签热度的关注不足,本文提出了基于 MACR 的多样性召回网络(DMACR)。该网络通过将标签热度信息引入 MACR 框架,构建了因果图 DMACR,并结合多任务学习与反事实推理,消除了标签热度对推荐结果的影响。这一方法有效弥补了已有研究的不足。在两个真实数据集 ML-10M 和 Mind-small 上,该网络在保持性能指标 HitRate、NDCG、Recall 的基础上,显著提升了 Gini 指标下的标签多样性,为不同音乐类型提供了更加均衡的曝光机会。

(3) 针对挖掘热度信息的需求,已有研究中对热度信息多尺度关联挖掘的不足,通过将多尺度热度信息引入序列推荐模型,构建了多尺度热度信息融合的序列推荐模型。SeqPE 通过热度编码网络对热度信息进行非线性聚类,并通过热度融合网络学习不同热度信息之间的关联,从而动态调整推荐结果。实验结果表明,在两个真实数据集

LFM-1b 和 KuaiRec 上实现了性能指标 NDCG、Recall 的提升。

(4) 基于上述研究成果，设计并实现了一个公平感知的音乐推荐系统，旨在为用户提供公平、多样且准确的推荐服务。系统采用 C/S 架构，结合多种推荐模型，为用户提供精准、公平且多样化的音乐推荐服务。系统测试结果表明，各项功能均按预期工作，性能稳定可靠。

关键词：推荐系统；公平性推荐；多样性推荐；热度感知推荐；序列推荐

ABSTRACT

Music recommendation systems, as a core component of modern digital platforms, have significantly enriched users' music experiences and promoted the consumption and dissemination of music content. However, with their widespread application, the imbalance in content data distribution has increasingly highlighted a series of fairness issues, posing many challenges for the construction of fairness-aware music recommendation systems. Specifically, the data imbalance among users leads to insufficient recommendation performance for vulnerable user groups by the recommendation models, making it difficult for them to obtain recommendation results of the same quality as mainstream users, thereby worsening the user ecosystem of the system. The data imbalance among music genres causes recommendation models to focus excessively on popular music types, resulting in increasingly homogeneous recommendation content. Different types of music lack equal exposure opportunities, thereby worsening the content ecosystem of the system. In addition, the associations generated by data imbalance in popularity information, and the neglect of these associations, also affect recommendation performance, thereby affecting user experience and retention. In response to the above problems, this thesis proposes a series of innovative models and methods, the main contents of which are as follows:

Music recommendation systems, as a core component of modern digital platforms, have greatly enriched users' music experiences and promoted the consumption and dissemination of music content. However, with their widespread application, a series of fairness issues caused by data imbalance have become increasingly prominent, posing many challenges for the construction of fairness-aware music recommendation systems. Specifically, data imbalance among users leads to insufficient recommendation performance for disadvantaged user groups, making it difficult for them to obtain recommendation results of the same quality as mainstream users. Data imbalance among music genres causes recommendation models to focus excessively on popular music types,

resulting in increasingly homogeneous recommendation content and a lack of equal exposure opportunities for different types of music. In addition, the associations between the popularity information generated by data imbalance, and the neglect of these associations, also affect recommendation performance, thereby impacting user experience and retention. In response to the above issues, this thesis proposes a series of innovative models and methods, the main contents of which are as follows:

(1) To meet the demand for improving the user experience of vulnerable user groups, existing research has deficiencies in modeling the personalized impact of sensitive information on user behavior. This thesis proposes a personalized sensitive information learning network. The network learns sensitive information from the user's perspective through a related attention mechanism and combines it with global sensitive information through a sensitive information fusion module, thereby more comprehensively modeling the types of sensitive information. On this basis, the POSO network is used for personalized modeling of different types of users. This method effectively makes up for the deficiencies of existing research. Compared with the original method, on two real datasets ML-1M and LastFM360K, the network significantly improves the user experience of vulnerable groups under the MinHR indicator while basically maintaining the performance indicators of HitRate, NDCG, and Recall.

(2) To meet the demand for improving the diversity of recommendation content, existing research pays insufficient attention to label popularity. This thesis proposes a diversity recall network based on MACR (DMACR). The network introduces label popularity information into the MACR framework, constructs a causal graph DMACR, and combines multi-task learning with counterfactual reasoning to eliminate the impact of label popularity on recommendation results. This method effectively makes up for the deficiencies of existing research. On two real datasets ML-10M and Mind-small, the network significantly improves label diversity under the Gini indicator while maintaining the performance indicators of HitRate, NDCG, and Recall, providing more balanced exposure opportunities for different types of music.

(3) In response to the need to mine popularity information, existing

research is insufficient in mining multi-scale popularity information associations. By introducing multi-scale popularity information into the sequence recommendation model, a sequence recommendation model with multi-scale popularity information fusion is constructed. SeqPE clusters popularity information nonlinearly through a popularity encoding network and learns the associations between different popularity information through a popularity fusion network, thereby dynamically adjusting recommendation results. Experimental results show that performance indicators such as NDCG and Recall are improved on two real datasets LFM-1b and KuaiRec.

(4) Based on the above research results, a fairness-aware music recommendation system is designed and implemented, aiming to provide users with fair, diverse, and accurate recommendation services. The system adopts a C/S architecture and combines various recommendation models to provide users with precise, fair, and diversified music recommendation services. System test results show that all functions work as expected and the performance is stable and reliable.

KEY WORDS: Recommendation; Fairness Recommendation; Diversity Recommendation; Popular-aware sequential Recommendation

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 研究现状.....	1
1.2.1 个性化敏感信息偏好的公平排序网络	1
1.2.2 基于 MACR 的多样性召回网络.....	2
1.2.3 基于多尺度热度融合的序列推荐网络	4
1.3 研究内容与主要贡献.....	5
1.3.1 个性化敏感偏好的公平排序网络.....	6
1.3.2 基于 MACR 框架的多样性召回网络.....	6
1.3.3 多尺度热度信息融合的序列推荐网络	6
1.3.4 公平感知的音乐推荐系统的设计与实现	7
1.4 论文组织结构.....	7
第二章 个性化敏感偏好的公平排序网络	9
2.1 引言.....	9
2.2 基于个性化敏感偏好的公平排序网络	10
2.2.1 问题描述.....	10
2.2.2 问题分析.....	10
2.2.3 个性化敏感信息编码层.....	13
2.2.4 敏感信息融合层.....	13
2.2.5 网络的特征提取层.....	15
2.2.6 预测层.....	15
2.3 实验设计与对比分析.....	16
2.3.1 实验数据集.....	16
2.3.2 评价指标.....	17
2.3.3 基线模型.....	17
2.3.4 实验结果.....	17
2.4 本章小结.....	22
第三章 基于 MACR 框架的多样性召回网络	23
3.1 引言.....	23
3.2 基于 MACR 框架的多样性召回网络.....	24
3.2.1 问题描述.....	24
3.2.2 基础知识.....	24
3.2.3 DMACR 因果图	25
3.2.4 DMACR 网络结构	26

3.3 实验设计与对比分析.....	29
3.3.1 实验数据集.....	29
3.3.2 评价指标.....	30
3.3.3 基线模型.....	30
3.3.4 实验结果.....	31
3.4 本章小结.....	35
第四章 多尺度热度信息融合的序列推荐网络	37
4.1 引言.....	37
4.2 多尺度热度信息融合的序列推荐网络	37
4.2.1 问题描述.....	38
4.2.2 热度信息编码层.....	38
4.2.3 多尺度热度融合层.....	39
4.2.4 序列信息学习层.....	40
4.2.5 预测层.....	41
4.3 实验设计与对比分析.....	42
4.3.1 实验数据集.....	42
4.3.2 评价指标.....	42
4.3.3 基线模型.....	43
4.3.4 实验结果.....	43
4.4 本章小结.....	47
第五章 公平感知的音乐推荐系统需求分析与设计	49
5.1 系统目标.....	49
5.2 需求分析.....	49
5.3 系统设计.....	50
5.3.1 架构设计.....	50
5.3.2 模块设计.....	51
5.3.3 模块详细设计.....	52
5.3.4 数据库设计.....	55
5.4 本章小结.....	58
第六章 公平感知的音乐推荐系统实现与测试	59
6.1 系统实现.....	59
6.1.1 服务端实现.....	59
6.1.2 客户端实现.....	62
6.2 系统功能测试.....	64
6.2.1 登录与注册模块测试.....	64
6.2.2 用户中心模块测试.....	65
6.2.3 广场推荐模块测试.....	66
6.2.4 猜你喜欢推荐模块测试.....	66

6.3 性能测试.....67

6.4 本章小结.....67

第七章 总结与展望69

7.1 总结.....69

7.2 展望.....70

参考文献.....71

第一章 绪论

1.1 研究背景及意义

随着互联网技术的迅猛发展与数字音乐市场的持续扩容,音乐类应用已深度融入大众日常场景。针对海量音频资源库,基于用户画像与交互数据推断个体偏好的智能推荐系统,正逐步成为现代数字生活的核心组成部分。然而,内容领域数据分布失衡所引发的公平性问题逐渐显现,这为构建一个公平感知的音乐推荐系统带来了诸多挑战。

就用户群体之间的公平而言,由于不同用户群体对音乐内容的消费数据量存在显著差异,且推荐系统具有拟合数据量较多的用户群体的倾向。这种倾向导致传统的推荐系统难以满足数据量较少的弱势用户的推荐需求。例如对于老年用户而言可能会发现推荐系统大量为其推荐年轻人欢迎的音乐,而忽视了其自身的音乐消费习惯。该问题不仅直接损害用户满意度,更会通过马太效应形成双重困境:弱势群体因推荐偏差导致的体验降级,将引发其活跃度衰减与流失行为,而用户基数的持续萎缩又会反向加剧训练数据的分布倾斜,最终造成社区生态的恶化。

就音乐类型之间的公平而言,不同类型作品受关注程度存在显著差异,这种现状使得算法机制更偏向于推送流行度较高的音乐品类,从而使用户逐渐陷入由单一音乐类型构筑的信息茧房中。这种高度趋同的内容分发模式,不仅削弱了用户主动探索不同风格音乐的积极性,也使得不同类型的音乐内容缺乏公平的曝光机会,最终造成内容生态的恶化。

就音乐推荐的性能而言,不同的作品与作者受关注程度的不同也就为其带来了不同的热度信息。不同的热度信息之间的关联和不同维度的热度信息之间是存在一定关联的,而对这些热度信息的关联挖掘的缺失会削弱推荐性能进而削减用户使用体验,进而影响用户的长期留存,不利于维持一个多样化的音乐环境与用户环境。

综上所述,构建一个公平感知的音乐推荐系统面临的挑战可以归纳为以下三点:如何建立保护弱势用户群体的音乐推荐系统;如何有效削弱热门类型对模型的过度影响以增加推荐结果的多样性;如何有效的挖掘不同维度之间的热度信息之间的关联进而提高推荐准确度进而提升用户留存的可能。

1.2 研究现状

1.2.1 个性化敏感信息偏好的公平排序网络

1.2.1.1 推荐系统中公平性问题

在信息爆炸的时代背景下,推荐系统已渗透至各大网络平台,悄然重塑着人

们的认知模式^[11-7]。然而，推荐系统中数据分布的天然倾斜导致推荐结果容易受到偏见和不公平性的影响。已有的研究已经证实不同群体的推荐性能存在显著差异^[8-11]。例如，在广告推荐中，具有相似偏好的用户之间出现了基于种族的偏见^[11]；在职业推荐系统中，条件相似的男性和女性也存在显著的推荐结果差异^[10]。这种偏见与数据驱动的推荐系统相伴而生，无处不在。因此，如何缓解数据偏差引起的公平性问题，让推荐系统惠及所有人群，已成为一个广泛关注的课题。

学界早期尝试通过设立合理的正则项来实现更公平的推荐结果^[12]。Yao 等人提出了四个公平性指标，用于衡量基于二元敏感属性的协同过滤推荐中不利用户和有利用户预测行为之间的差异。这些指标被用作公平性正则化项，以优化推荐中的群体公平性。然而，正则项对数据的假设往往并不总是合理的，这可能会对推荐性能产生负面影响。

随后，表示学习因为其简单性和通用性被引入到公平推荐系统的研究中^[2, 13-17]。A. Bose 与 W. Hamilton 通过对抗学习的方式引入特定的损失函数，以减少用户向量中的敏感信息^[14]。Wu 等人的研究通过对抗学习结合正则项的方式进一步的去除敏感信息^[18]。Zhao 等人的研究中在通过定义用户预期敏感信息的互信息作为损失函数，减少用户嵌入与敏感信息的相关性^[15]。Wu 等人的研究则是从图视角去除图视角下的敏感信息对于用户嵌入的影响^[17]。基于对抗学习的公平表示学习通常尝试从用户嵌入中去除敏感信息，但这种方式往往忽视了敏感信息在推荐中的积极作用，导致性能有所损失。

近年来，一些研究试图通过个性化门控网络来优化不同敏感信息用户的推荐体验^[19]。这些网络可以根据用户的敏感信息动态调整参数，以优化劣势用户的体验，同时尽量减少对优势用户推荐效果的影响。然而，这种方法通常使用固定的敏感信息作为门控信息，忽视了敏感信息对不同用户影响的个性化差异。

1.2.2 基于 MACR 的多样性召回网络

1.2.2.1 多样性推荐

近年来推荐的多样性受到了越来越多的研究关注^[20]。推荐中的多样性概念最初由 Ziegler 等人引入^[20]，其使用了一种名为最大边际相关性（MMR）的贪婪算法，该算法来自信息检索领域。Carbonell 和 Goldstein 提出了 MMR^[21]，将相关性和多样性作为独立指标，并结合了边际相关性的概念和权衡参数。

随后，提出了几种后处理方法来使推荐结果多样化^[22-25]。例如，Qin 和 Zhu 通过使用评分函数和熵正则化的线性组合来解决这个问题^[24]。Ashkan 等人将贪婪解决方案中的加权和替换为乘法，消除了需要调整参数以平衡效用和多样性的需求^[22]。Sha 等人引入了一个次模目标函数，结合了相关性、用户意图的覆盖度和项目间的多样性^[25]。他们引入了两个超参数来平衡目标。

除了重排方法,另一组方法被称为学习排序(LTR)^[26,27],它被提出来直接生成推荐列表。具体来说,Cheng等人使用启发式方法为每个用户标记一组多样化且相关的项目,并开发了一个优化准确性和多样性性能的多样化协同过滤算法。Li等人引入了一个基于估计交互概率和类别意图的评分函数的排名模型^[28]。然而,这些方法需要多样化的排名列表作为真实情况用于学习,这在推荐场景中通常是不可用的。提出了几种算法来降低DPP的计算复杂性,这些算法使用了期望最大化(EM)算法、贪婪算法或张量分解技术^[21,29-31]。经典的多样性推荐算法更加关注对于推荐结果多样性的提升更加忽视了多样性缺失的来源即流行度信息对于推荐结果的影响。

1.2.2.2 因果推断技术

因果推断是系统分析原因与其效应之间关系的科学^[32]。最近,因果推断逐渐引起了人们的关注,并被应用于广泛的机器学习任务,如场景图生成^[33,34]、视觉解释^[35]、节点分类^[32]。引入因果推断到推荐系统的主要目的是消除偏差^[36,37]。其消除流行性偏差的手段主要包括以下几种不同的方式。

逆概率加权。第一类工作基于逆概率加权(IPW)^[38,39]。在中D.Liang^[39]等人的工作中提出了一个由两个模型组成的框架:一个曝光模型和一个偏好模型。一旦估计了曝光模型,偏好模型就用加权点击数据进行拟合,其中每个点击都由第一模型中估计的曝光的倒数加权,从而用于缓解流行度偏差。这种方法可以很好的平衡低热度的推荐性能然而,由于其对于原始分布的改变可能影响整体的推荐性能。

因果导向数据。CasualE^[40]方法通过结合控制政策下的大规模偏置反馈数据和随机政策下的小规模无偏反馈数据,利用领域适应技术来预测用户在随机曝光下的推荐结果。然而,该方法存在一些局限性,如对高质量随机政策数据的需求较高,可能导致数据收集困难和成本增加;在控制政策和随机政策之间数据分布差异较大时,模型的泛化能力可能受限;正则化参数的选择对模型性能影响较大,增加了模型调优的复杂性。此外,CausalE^[40]对未观察到的混杂变量较为敏感,可能影响因果推断的准确性。

因果嵌入。另一系列工作基于概率,在中D.Liang^[41]的研究中,作者提出了ExpoMF,这是一种用于隐式数据的协同过滤的概率方法,直接将用户对项目的曝光纳入协同过滤。ExpoMF^[41]联合建模用户对项目的曝光及其随后的点击决策,从而自然地降低预期但最终未被点击项目的权重。曝光被建模为一个潜在变量,模型从数据中推断其值。项目的流行度可以作为曝光协变量添加,从而用于缓解流行度偏差。这类工作基于概率,因此不能推广到更普遍的设置。此外,它们忽略了流行度如何影响每个特定的交互。与本文功能做类似,Zheng等人也试图

通过因果方法减轻流行度偏差^[42]。不同之处在于，本文以细粒度的方式分析因果关系，考虑项目的流行度、用户从众性，并建模它们对推荐的影响。缺乏对流行度偏差机制的系统性看法。MACR 框架^[43]使用了更细力度的方式分别建模了由于商品热度的因素、用户依赖性因素对于推荐结果的影响，通过反事实推理的方式消除流行性偏差对于结果的影响，这种方式虽然有助于提高推荐模型的多样性，但是方式过于间接没有直接考虑到标签热度本身对于结果的影响。

1.2.3 基于多尺度热度融合的序列推荐网络

1.2.3.1 序列推荐

序列推荐^[44, 45]通过用户行为的时间序列信息，对项目间的迁移相关性进行建模，捕捉用户兴趣的动态演变，以预测其未来行为。早期研究主要基于矩阵分解和马尔可夫链，利用用户在 k 阶交互中的后续选择来考虑偏好的时序变化^[44]。随着深度学习的发展，循环神经网络（RNN）及其变体（如门控循环单元 GRU）被引入，以更好地模拟序列中的长期依赖关系^[45]。然而，基于 RNN 的方法只能进行串行计算，限制了其效率。

为了克服这一限制，Tang 等人^[46]提出了 Caser 模型，通过卷积神经网络（CNN）在两个方向上进行过滤计算，捕捉用户行为模式。Caser 使用水平和垂直卷积滤波器来捕获点级、联合级和跳跃行为的顺序模式，从而在一个统一的框架中概括了几种现有的最先进的方法。Caser 在现实生活数据集上的 top-N 顺序推荐方面优于现有的先进方法。尽管 CNN 在捕捉局部兴趣方面表现出色，但在处理长期依赖关系时仍存在不足。NextItNet 作为一种基于卷积神经网络的序列推荐模型，通过因果卷积和扩张卷积来捕捉用户行为序列中的长期依赖关系，进一步提高了推荐的准确性和效率^[47]。NextItNet 通过并行计算显著提升了训练速度，使其在处理大规模数据时更具优势。

随后，自注意力机制的引入为序列推荐带来了新的突破。SASRec^[48]利用 Transformer 架构中的自注意力机制，能够动态学习用户历史行为的重要性，从而更准确地预测下一个最可能出现的物品。SASRec 在稀疏和密集数据集上均优于多种先进模型，且计算效率高，适合大规模应用。

尽管现有方法在捕捉用户行为的动态模式方面取得了显著进展，但它们大多忽略了作者热度信息对于推荐结果的影响。高热度作者的作品往往更容易被推荐，而低热度作者的作品则难以获得足够的曝光机会。为了解决这一问题，本文提出了 SeqPE 模型。SeqPE 通过热度编码网络对内容的热度信息进行多尺度编码，并通过热度融合网络学习不同尺度热度之间的差距信息，如高热度作者的低热度作品

1.2.3.2 热度感知推荐

近年来,出现了一系列的研究尝试利用热度信息来提升推荐性能。一些研究者主张将热度作为信号利用,在这些研究中 Lex 等人试图通过建立临时的热度信息^[49],通过分析时间窗口内的流行度以反映流行度的时间特征, Walter 等人的研究中试图将热度信息应用于通常推荐之中^[50-52]。在 Berg 等人的研究^[53]中提出了基于图神经网络的方法通过节点的度来衡量项目的流行度。

对于另一些研究者而言主张通过去流行性偏差的方式去除热度对于推荐结果的影响。D. Liang 与 T. Schnabel 的研究^[38, 54]主张通过逆概率加权的方式对流行性本身对推荐结构的影响进行去偏差。Zhang 等人的研究^[37]对热度信息进行逆向调整利用因果推断的方式减少流行度偏差。Qian 等人的研究^[55]中提出了通过对比学习与因果推断的方式去除热度信息对结果的影响。

然而这些对于热度感知的算法往往缺乏对于内容提供者的热度信息关注,也缺乏对于多尺度的热度信息之间的融合。使得热度感知模型难以学习到多维度热度对于推荐结果的影响。

1.3 研究内容与主要贡献

已有的工作虽然针对于 1.1 中提出的挑战提供了解决方案,然而仍然存在一些局限性。例如在公平推荐中忽视了敏感信息对用户行为的个性化影响;在多样性推荐中忽视了流行性偏差对于推荐结果的多样性的影响;在序列推荐中忽视对于热度信息之间的关联的挖掘进而限制了用户推荐的准确性。

本文的主要工作针对音乐推荐系统面临的上述问题做了如下工作,(1) 通过挖掘敏感信息对于用户行为的个性化影响,提升了弱势群组用户的推荐性能进而构建公平的用户环境提供前提。(2) 通过将标签热度纳入到因果图的方式为音乐推荐系统从海量的音乐库中召回多样化的音乐内容,为不同类型的音乐提供更加均衡的曝光机会,进而为维护多样化的音乐环境提供机会。(3) 通过挖掘不同热度信息之间的关联与多尺度热度之间的关联为用户提供更加优秀的推荐效果进而保障用户的长期留存,维护公平的用户环境。

最后,基于上述的研究,本文目标设计实现了一种公平感知的音乐推荐系统旨在为音乐软件打造更加多样且公平的用户环境与音乐环境。系统中的不同的模型之间的结构关系如图 1-1 所示。




图 1-1 研究点之间的关系

1.3.1 个性化敏感偏好的公平排序网络

本文提出了一种基于个性化敏感偏好的公平排序模块，旨在提升推荐系统的公平性和推荐效果。研究内容包括设计用户偏好度提取模块以捕捉用户的敏感信息对于用户行为的个性化影响，以及构建个性化敏感偏好与敏感信息嵌入融合模块来优化推荐结果。论文详细设计了包含个性化敏感信息编码层、敏感信息融合层、网络特征提取层和预测层的完整模型架构，并通过在 ML1M 和 LastFM-360K 两个真实数据集上的实验验证了模型的有效性。

1.3.2 基于 MACR 框架的多样性召回网络

本文提出了一种基于 MACR 框架的多样性召回网络 DMACR，旨在通过因果推理和反事实推断解决推荐系统中的标签同质性和过滤泡泡问题。研究内容包括构建一个新的因果图模型，该模型扩展了传统因果图，引入了商品标签热度对排名分数的影响，以更准确地捕捉用户偏好和商品特性。在训练阶段，DMACR 通过多任务学习框架同时最小化用户-物品匹配损失和各种因素的热度损失。在测试阶段，利用反事实推断调整推荐分数，消除热度对推荐分数的直接影响，从而促进推荐结果的多样性为不同的类型的音乐提供更加均衡的曝光机会。实验在两个真实世界的数据集上验证了 DMACR 在提升推荐准确性和多样性方面的有效性。

1.3.3 多尺度热度信息融合的序列推荐网络

本文提出了一种新的序列推荐模型 SeqPE，旨在通过多尺度热度信息融合的方式提升序列推荐中的推荐性能。SeqPE 模型通过 HotEncoder 网络对内容的热度信息进行多尺度编码，并通过热度融合网络学习不同热度信息之间的联系，进而提升推荐性能。实验结果表明，SeqPE 模型在两个真实世界的数据集（LFM-1b 和 KuaiRec）上表现出色，体现出了优秀的推荐性能与鲁棒性。

1.3.4 公平感知的音乐推荐系统的设计与实现

本文结合前面所提到的三个研究点,设计并实现了一个公平感知的音乐推荐系统,通过结合用户敏感信息和历史行为,采用多模块协同设计,实现了精准、公平且多样化的音乐推荐服务。系统包括多样性召回模块、公平排序模块和多尺度热度信息融合的序列推荐模型,分别用于筛选多样化候选集、提供个性化推荐和为序列推荐提供更加优秀的性能。同时,系统还具备用户管理、历史记录查看和音乐播放等功能模块,以提升用户体验。在功能测试中,系统验证了用户验证与授权、推荐服务、个人信息管理和音乐播放等功能的正确性和稳定性,确保在高并发场景下仍能为用户提供流畅、高效的音乐推荐服务。

1.4 论文组织结构

本论文共分为七个章节,各个章节内容如下:

第一章,绪论。章节负责概览整个研究,分别介绍论文的选题背景,国内外相关研究现状,对于研究的主要研究内容分别介绍,最终介绍整体文章结构。

第二章,个性化敏感偏好的公平排序网络。介绍了用户对于公平推荐的需求,同时介绍了现有的公平推荐的不足处,并且通过实验进行了进一步分析后提出 FPOSO 模型用于解决这一问题。最后在两个数据集上进行实验,观察到模型的性能提升,通过消融实验分析网络结构中的不同部分对于结果的影响,通过超参数实验进一步分析其对于推荐性能的影响。

第三章,基于 MACR 框架的多样性召回网络。介绍了用户对于推荐多样性的需求与现有对于多样性推荐的方案的不足,基于 MACR 的因果图进一步提出了考虑了标签热度的因果图,并且设计了多任务学习框架以实现该因果图。在两个数据集上进行了实验验证了模型在性能与多样性上的提升,并且通过消融实验探索了模型不同分支之间的关系,通过超参数进一步分析了其中的超参数对于推荐结果的影响。

第四章,多尺度热度信息融合的序列推荐网络。介绍了现有的推荐对于多尺度信息与热度信息的挖掘不足,通过热度的非线性聚类与多尺度的融合更加灵活的捕获热度信息之间的关联,通过两个数据集验证了其在改善用户体验上的有效性,并且通过消融实验探索了模型不同结构之间的关系,通过超参数进一步分析了其中的超参数对于推荐结果的影响。

第五章,公平感知的音乐推荐系统需求分析与设计。对于公平感知的音乐推荐系统进行了需求分析。随后将需求分解为具体的技术模块,细化了执行流程与数据库结构。

第六章,公平感知的音乐推荐系统实现与测试。介绍了公平感知的音乐推荐系统的具体实现与测试,包括其服务端实现与客户端实现,为了验证其有效性设

计了多个测试实例用于验证其有效性，并且设计了性能实验验证其能否在合理范围内响应用户请求。

第七章，总结与展望。概括全文内容，总结每一部分的创新型的同时，探讨研究的局限性与未来的可行的发展方向。

第二章 个性化敏感偏好的公平排序网络

2.1 引言

随着信息爆炸,推荐系统已被广泛部署在大多数平台并渗透到我们的日常生活中^[1-5]。这些系统遍布了我们身边的各个角落,包括了网购、外卖、招聘等等,可以说推荐系统塑造了我们对于生活各个领域的认知。虽然推荐系统能够更好地帮助用户找到潜在有趣的项目,但推荐结果也容易受到偏见和不公平性的影响。例如,当前的推荐结果实证显示,对于不同的群体的推荐性能具有一定的差异^[8,9]。职业推荐甚至对同等合格的男性和女性显示出明显的基于性别的歧视^[10]。广告推荐结果在具有相似偏好的用户之间形成了对于不同种族的偏见^[11]。由于算法中的偏见在这些以人为中心的人工智能应用中无处不在,如何评估和提高算法公平性以惠及所有用户已成为一个热门研究课题^[56,57]。给定特定的敏感属性,研究人员已经设计了用于在监督设置中测量公平性的指标^[56,58]。这些指标鼓励在受保护群体中被分类为正面的敏感属性值的比例与未受保护群体相同。

在本文的研究中,遵循两个众所周知的概念即机会平等原则和罗尔斯的 Max-Min 公平性原则在推荐中引入 Max-Min 机会公平性^[59]。以最大化弱势群组的推荐性能,以便保证没有群体被推荐模型忽视。这种公平性目标的优势有两个:1) 通过遵循平等机会,通过真正推荐率衡量公平性,公平性直接与项目获得的反馈或经济收益以及用户满意度对齐;2) 通过遵循罗尔斯的 Max-Min 公平性来接受不平等,公平性不需要降低服务较好的项目的效用,因此可以更好地保持整体效用。因此,本文旨在通过优化 Max-Min 机会公平性^[59],在不降低整体满意度的前提下提高项目公平性。

在已有的研究中 POSO^[19]通过利用敏感信息作为 Gate 网络的门控信息的方式,实现了对不同的用户群体分组建模的方式在 Max-Min 公平性原则取得了很好的表现。不过虽然 POSO 模型^[19]在推荐系统中取得了显著的成效,但是其在处理敏感信息方面存在一定的局限性。具体来说,POSO 模型对敏感属性的建模相对固定,然而敏感信息对于每一位用户的影响程度的差异导致了固定的建模会忽视这些用户的差异。实际上,敏感信息对用户行为的影响是复杂且多变的。直接利用或剔除敏感信息都可能对推荐系统的公平性和性能产生影响。更为关键的是,这种影响对每个用户而言都是独特的。考虑到敏感信息对用户行为影响的无限可能性,在推荐系统中对敏感信息的处理就需要更加精细化与个性化。

为解决上述问题,本章提出了一种新的公平排序模块,旨在提升推荐系统的

公平性和精确性。该模块通过引入个性化敏感偏好建模,动态捕捉用户对敏感信息的独特偏好,从而为推荐决策提供更精准的依据。同时,该模块还融合了个性化敏感信息与全局敏感信息,进一步增强了对敏感信息的建模能力,避免了单一依赖个性化或全局敏感信息而导致的性能不足。此外,通过优化的个性化门控网络,实现了对不同用户群体的差异化建模,进一步提升了推荐的公平性和精确性。

综上所述,本章的主要贡献如下:

(1) 设计了一种新的个性化敏感偏好建模方法,能够精准捕捉用户对敏感信息的偏好程度,解决了现有模型对敏感信息建模不灵活的问题

(2) 设计了敏感信息融合模块,有效结合个性化和全局敏感信息,提升了模型对敏感信息的建模能力,优化了推荐性能。

(3) 在两个公开数据集与四个基准模型进行了实验,验证模型的推荐性能与公平性的同时讨论了不同的网络结构与超参数对于结果的影响

2.2 基于个性化敏感偏好的公平排序网络

本章首先对于介绍公平性问题的描述,之后介绍针对这个问题做出的数据分析,在数据分析的基础上对模型的整体结构与各个部分进行详细的介绍。

2.2.1 问题描述

公平推荐旨在保护弱势用户的推荐效果,来预测用户接下来将点击哪个项目。这里,给出了该问题的公式如下。

假设 $I = \{i_1, i_2, \dots, i_m\}$ 表示 item 的候选集。 $U = \{u_1, u_2, \dots, u_n\}$ 表示所有的 user。而 $P = \{p_1, p_2, \dots, p_n\}$ 表示所有的 user 的敏感信息。

模型根据用户的交互历史,学习评分函数 $r(u, v|\theta)$,建模用户偏好,取得 top-n 的项目推荐。优化过程为

$$top(n) = \operatorname{argmax}_{i \in I}^m r(u, i|\theta) \quad (2-1)$$

2.2.2 问题分析

在推荐系统中,模型偏见的产生往往源于用户群体间数据量的不平衡。根据 POSO 中提到这种不平衡往往会产生一种“个性化的淹没”现象,这意味着这种数据不平衡无法通过直接向模型添加敏感信息本身进行平衡^[19]。此外,不同用户群体的兴趣偏好存在显著差异,因此对于这种现象的忽视会影响最终的推荐效果。如图 2-1 所示,男性用户更倾向于“战争”(War)标签的电影,而女性用户则更偏好“浪漫”(Romance)标签的电影。




图 2-1 ML1M 数据集中不同电影标签覆盖不同请别的比例

为了缓解这一现象 POSO 网络提出使用敏感信息（比如性别信息）对不同用户群体进行分开建模，这样构建模型可以对于数据量较少的群体得到更好的推荐效果，根据实验，这样的建模方式的确对于提高弱势群组的用户体验就有一定的效果，然而这种推荐仍然是存在一定的局限性。其忽视了一个关键问题，即敏感信息本身对于用户行为的影响是个性化的。

为了验证敏感程度对于不同用户的影响程度不同，本研究通过如下方案去验证是否存在这个现象，本文使用经典的推荐模型中的用户嵌入去预测用户的敏感信息。定义了用户的敏感性得分 S_u 公式如下

$$S_u = |f(e_u) - 0.5| \tag{2-2}$$

敏感度越高，说明公式能够更准确地通过用户嵌入来判断用户的敏感信息；反之，如果敏感度较低，就难以通过用户行为嵌入推测其敏感信息，即用户对敏感信息并不敏感。在使用传统的矩阵分解模型进行训练后，利用简单的两层深度神经网络对用户的敏感信息（此处以性别信息为例）进行预测，并构建了一个 AUC 值为 0.75 的预测模型。之后，绘制了用户敏感度的分布图。




图 2-2 在 ML1M 数据集上使用传统的 MF 模型训练后产生嵌入通过简单的两层 DNN 网络预测用户的敏感信息并且生成 AUC=0.75 的预测模型后的用户敏感度的分布图

如图 2-2 所示,约 10%的用户表现出对性别不敏感的现象,即敏感信息对于他们的行为和决策影响较小,另有一大部分用户对敏感信息的敏感度非常高,这些用户的性别预测值与 0 或 1 的差距较小,表明性别对他们的行为和决策有着显著的影响。这一现象进一步突显了敏感信息对不同用户的消费行为的影响是多样且复杂的。因此直接使用用户的敏感信息作为 POSO 中的门控信息就会难以捕获到其中的差异。导致一部分的用户体验下降,因此本文希望能够在保证公平性的前提下提升这部分用户的用户体验。

理想情况下,模型应为不同偏好程度的用户分别构建专属的推荐模型,以预测他们的行为。这种方案虽然能够完全保留个性化内容,但由于用户和商品的数量庞大,显然不可行。那么,是否可以通过将用户分为多个类别进行分别建模呢?显然,这不仅需要建立多个模型,还可能面临数据不足的问题。同时,难以直接对敏感信息对商品或用户行为的影响进行分类。因此,本文主张首先通过个性化敏感偏好学习模块,学习敏感偏好对用户行为的影响程度,并将其与全局敏感信息嵌入融合,生成新的门控信息,以进一步提升 POSO 网络的性能。这样,才能更灵活地表达不同用户和商品对敏感信息的偏好程度。

综上所述为了进一步的利用个性化的敏感信息本文提出了 FPOSO 模型,模型结构如图 2-3。




图 2-3 网络结构图

2.2.3 个性化敏感信息编码层

在推荐系统中，用户的个性化偏好经常受到敏感信息（如年龄、性别、地域等）的影响。为了更好地捕捉这些敏感信息对用户偏好的影响，本模型引入了个性化敏感信息提取层，旨在通过注意力机制动态学习用户对不同敏感属性的偏好权重。

这一层的核心思想是：不同用户对相同的敏感信息有不同的敏感性。例如，有些用户可能对性别信息更加敏感，而其他用户的行为中可能与性别并无关联。因此，模型通过这一层提取每个用户在特定敏感信息维度上的个性化偏好表示，为后续的推荐决策提供更准确的依据。

$$E_{personalprotect} = Attention(E_u, E_p, E_p) \tag{2-3}$$

在上述公式中， $E_{personalprotect}$ 表示用户的个性化敏感信息表示， $Attention$ 模块用于动态学习用户在特定敏感信息维度上的权重分布。其中 E_u 表示用户嵌入向量，刻画用户的基本特征； E_p 表示敏感属性嵌入向量，包含如年龄、性别、地域等敏感信息的表示；通过注意力机制可以很好的通过能够表示用户过往经历的用户嵌入查询用户的敏感信息嵌入，以得到更加个性化的用户敏感信息的嵌入。

2.2.4 敏感信息融合层

在推荐系统中，用户的个性化敏感信息嵌入能够有效地捕捉用户在敏感信息维度上的个性化偏好。然而，由于推荐系统数据稀疏的普遍性，单独依赖个性化

敏感信息嵌入的训练可能存在不足，导致模型性能受限。为了解决这一问题，本文设计了一种敏感信息融合模块，旨在将个性化敏感信息嵌入与全局敏感信息嵌入进行有效融合，从而增强模型的表现能力

如图 2-4 所示，融合模块的结构主要由三个步骤组成：输入拼接、特征过滤与非线性融合。




图 2-4 融合模块网络结构

2.2.4.1 输入拼接

模块的输入包括用户的个性化敏感信息嵌入 $E_{personalprotect}$ 和用户的全局敏感信息嵌入 E_u 。考虑到输入拼接考虑两者的相互关系，本文引入了特征相似度表示，即两者的逐元素交互结果 $E_{personalprotect} \odot E_p$ 。最终，模块的初始输入特征表示为

$$E_{concat} = Concat(E_{personalprotect}, E_p, E_{personalprotect} \odot E_p) \quad (2-4)$$

其中， $Concat(\cdot)$ 表示向量拼接操作， $\odot$ 表示逐元素乘法。通过这种方式，将个性化敏感信息嵌入、全局敏感信息嵌入及其交互特征进行联合建模，为后续融合提供丰富的信息基础。

由于拼接后的特征表示 E_{concat} 包含多种信息，可能存在一定的冗余或无效特征。为了有效过滤

2.2.4.2 特征过滤

这些信息，本文采用了 $LeakyRelu$ 激活函数进行特征筛选，具体表达为：

$$E_{filtered} = LeakyRelu(E_{concat}) \quad (2-5)$$

其中， $LeakyRelu$ 能够在激活过程中允许负值通过，从而缓解因为特征稀疏

导致的信息损失问题，同时保持模型的训练稳定性。

2.2.4.3 非线性融合

在特征过滤的基础上，本文进一步使用前馈神经网络（FNN）对筛选后的特征进行非线性变换，生成最终的敏感信息融合表示：

$$E_{merge} = DNN(E_{filtered}) \quad (2-6)$$

其中，DNN 由多层全连接神经网络组成，能够建模不同特征之间的非线性关系，并学习到更具表达能力的敏感信息表示。

2.2.5 网络的特征提取层

在大型推荐系统中往往会由于特征维度的问题，往往会面临特征淹没的问题，因此在 POSO 的研究提出了^[19]基于个性化特征的 gate 网络，用于放大特定信息对于整体网络的影响能力，同时以类似^[60]的方式达到为不同的用户人群分类建模的效果。

本文借鉴 POSO 网络中个性化 Gate 门机制，旨在通过这一机制实现强势群体与弱势群体的差异化建模。个性化 Gate 网络的实现可以分为三个主要步骤：特征投影、门控信号生成与门控信号融合。

首先，特征投影通过前馈神经网络（FFN）来实现输入特征的信息提取，其形式为：

$$e^0(x) = \text{concat}(E_i, E_u) \quad (2-7)$$

$$e^i(x) = FFN(e^{i-1}(x)) \quad (2-8)$$

接着，对 Gate 信息进行投影处理，并通过 Sigmoid 激活函数进行非线性映射，之后乘以 2，得到一个可以调节特征信息大小的门控信号，再通过对位相乘的方式调节每一位特征信号的强弱

$$g^0(x) = E_{merge} \quad (2-9)$$

$$g^t(x) = 2 * \sigma(FFN(g^{t-1}(x))) \quad (2-10)$$

$$\hat{x} = \sum_{i=1}^N [g^t(x)]_i e^i(x) \quad (2-11)$$

其中， $g^t(x)$ 为门控信号， $\hat{x}$ 为最终输出的特征表示， $e^i(x)$ 表示特征信号的各个维度，乘法操作符 * 表示逐元素乘法。

通过上述过程，个性化 Gate 网络能够根据每个用户的特征对其偏好进行灵活调整，进一步增强特征信息对模型的影响力，从而在多样化的用户群体中实现更精确的推荐建模。

2.2.6 预测层

预测层作为模型的核心输出模块，负责将上层网络生成的最终特征映射为用户对物品的偏好评分。在该层中，偏好评分的生成过程通过全连接层实现，全连接层将高维特征表示转化为最终的评分预测。为了优化模型的排序性能，本文采

用了交叉熵（Bayesian Personalized Ranking）损失函数^[61]，该损失函数旨在优化正负样本之间的排名差距，从而提升推荐系统在排序任务中的精确度。BPR 损失通过对正样本和负样本之间的偏好关系进行建模，鼓励模型产生更加个性化的推荐结果，即能够更好地反映用户的真实偏好。作为模型的关键组成部分，预测层的性能直接决定了推荐排序的效果，因此其设计与优化对整体推荐系统的表现至关重要。

$$p_{ui} = FFN(\hat{x}) \quad (2-12)$$

$$Loss_{bpr} = -\sum_{(u,i,j) \in D} \ln(\sigma(p_{pos} - p_{neg})) \quad (2-13)$$

其中， p_{ui} 表示用户 u 对物品 i 的预测评分， $\hat{x}$ 是输入特征， D 是训练数据集， p_{pos} 和 p_{neg} 分别是正样本和负样本的预测评分， $\sigma(\cdot)$ 是 sigmoid 激活函数。该损失函数通过最大化正样本的评分与负样本评分之间的差异，推动模型生成更高质量的排序结果。

2.3 实验设计与对比分析

为了评估本文提出的 FPOSO 模型的有效性，本文在两个常用于评估推荐模型的真实数据集上进行了系统性的实验。本节旨在回答以下研究问题。

RQ1: 与现有的模型相比，本文提出的 FPOSO 效果如何？

RQ2: 模型的各部分是否起到了应有的作用，如果起到了每部分的影响又都是怎样的？

RQ3: 模型在不同的超参数的条件下的表现如何？

2.3.1 实验数据集

本文在两个真实世界的公开数据集上进行实验，分别是 ML1M 与 LastFM360K，数据集具体信息如表 2-1。

ML1M 数据集是一个经典的推荐系统数据集^[62]，来自 MovieLens 项目。数据集包含来自 6000 多位匿名用户的 100 万条评分记录，每条记录表示用户对不同电影的评分，评分范围从 1 到 5 分。这些评分数据记录了用户与电影之间的互动，为用户-项目推荐任务提供了可靠的测试数据。在本实验中本文选用所有的>4 分的数据作为用户的正样本，随机选取其余样本作为负样本，在本研究中本文将使用其用户的性别属性作为敏感信息。

LastFM-360K 数据集是一个广泛用于音乐推荐系统研究的数据集^[63]，包含了 360,000 个用户对音乐的偏好数据。数据来源于 Last.fm 平台，其中用户与歌曲的互动行为包括点击、收听以及评分等。该数据集包含用户信息、歌曲元数据、标签信息等，能够用于研究个性化推荐、社交推荐以及多样性、公平性等问题。在本实验中本文首先去除了所有的 plays 小于 20 的记录，随后去除了所有的交互次数少于 50 次的用户与歌曲，随机选取其余样本作为负样本，在本研究中本文

将使用其用户的性别属性作为敏感信息。

表 2-1 数据统计表

Dataset	Users	Items	Interactions	Sparsity
ML1M	5,961	3,083	178,672	99.0%
LastFM-360K	57,293	21,110	2,478,555	99.8%

2.3.2 评价指标

$NDCG@k$ ^[64]: $NDCG@k$ 是一种衡量推荐结果排序质量的指标, 用于评价推荐系统是否将用户最感兴趣的项目排在靠前位置。其计算基于累积增益 (Cumulative Gain, CG), 即推荐列表中每个项目的相关性得分。通过将较高的分数分配给靠前的位置, 衡量推荐物品的排列顺序是否正确。

$$DCG@k = \sum_{i=1}^k \frac{2^{rel_i} - 1}{\log_2(i+1)} \quad (2-14)$$

$$IDCG@k = \sum_{i=1}^k \frac{1}{\log_2(i+1)} \quad (2-15)$$

$$NDCG@k = \frac{DCG@k}{IDCG@k} \quad (2-16)$$

$Recall@k$ ^[65]: $Recall@k$ 用来衡量推荐系统在前 k 个推荐项中找回用户真实感兴趣的项目的比例, 主要关注推荐列表的覆盖率。

$HR@k$: $HR@k$ 用来衡量推荐系统在前 k 个推荐项中是否包含至少一个用户真正感兴趣的项目, 它是一个二元指标。

$Min-HR@k$: 这一项指标主要用于基于 Max-Min 公平的定义衡量弱势群组在模型中的性能表现, 这里会计算性能表现较差的用户群组的用户 $HR@k$ 作为衡量推荐系统的公平属性。

2.3.3 基线模型

NCF ^[66]: 经典的推荐算法, 通过深度神经网络的方式为用户计算出合适的推荐内容;

DP ^[12]: 经典的正则公平算法, 通过正则项约束的方式, 惩罚不同敏感信息中差异较大的推荐, 从而达到更加平均的推荐效果;

$FairRec$ ^[18]: 最先进的公平表示学习算法, 通过对抗学习的方式去除用户嵌入中的敏感信息, 从而保证不同用户群组之间具有相似的推荐效果。

$POSO$ ^[19]: 最先进的个性化 gate 网络算法, 通过固定的敏感信息作为 gate 网络的门控信息, 以达到为不同群组的用户分开建模的效果。对于 Min-Min 公平性具有很好的表现。

2.3.4 实验结果

2.3.4.1 对比实验分析

本实验中旨在观察不同模型对于公平性与准确性的变化,可以将 NCF 模型作为基础模型对比不同的改造方式对于 NCF 模型的性能与公平性之上的变化作为效果对比的参照。

表 2-2 ML-1M 数据集评估表

Target	NCF	DP	FairRec	POSO	FPOSO
NDCG@5	0.0522	0.0492	0.0520	<u>0.0528</u>	0.0566
NDCG@10	0.0625	0.0596	0.0618	<u>0.0629</u>	0.0641
Recall@5	0.0354	0.0338	0.0360	<u>0.0369</u>	0.0418
Recall@10	0.0719	0.0718	0.0718	<u>0.0721</u>	0.0721
HR@5	0.1774	0.1835	0.1742	<u>0.1850</u>	0.1940
HR@10	<u>0.2926</u>	0.3021	0.2869	0.2908	0.2896
Min-HR@10	0.2486	0.2709	0.2498	0.2521	<u>0.2551</u>

表 2-3 LastFM-360K 数据集评估表

Target	NCF	DP	FairRec	POSO	FPOSO
NDCG@5	0.0426	0.0419	0.0419	0.0435	<u>0.0433</u>
NDCG@10	0.0372	0.0365	0.0370	<u>0.0380</u>	0.0382
Recall@5	0.0174	0.0179	0.0170	<u>0.0179</u>	0.0180
Recall@10	0.0295	0.0299	0.0294	<u>0.0302</u>	0.0307
HR@5	0.1756	0.1817	0.1729	0.1795	<u>0.1800</u>
HR@10	0.2753	0.2772	0.2728	<u>0.2800</u>	0.2843
Min-HR@10	0.2713	<u>0.2771</u>	0.2726	0.2751	0.2811

从上述数据可以看出,不同模型在各项指标上的表现有所差异,展现了各自的优势和局限。

在公平性指标 Min-HR 角度而言,本文发现无论在更加稠密的 ML-1M 数据集中还是在相稀疏的 LastFM-360K 数据集中 FPOSO 模型均具有较为优秀的表现。这代表在各种情况下均能很好保护弱势群组用户的用户体验。

从性能指标的角度可以看到 FPOSO 在多个指标中均具有优秀的表现,在公平性指标中表现较好的 DP 模型由于正则项的假设与数据分布不同的原因,其性能指标中的表现相对较弱,相对而言基于 Gate 门的网络 POSO 模型与 FPOSO 模型的性能表现更加优秀,这表示其在保护弱势群组用户的用户体验的同时,也具有优秀的推荐性能。

综合来看,相比于传统的公平推荐算法而言 FPOSO 能在保证公平性的前提下,进一步提高推荐性能,在不牺牲优势用户的前提下,提升弱势群组的推荐效果。

2.3.4.2 消融实验分析

为了验证模型每一部分的可靠性。因此，考虑添加一部分消融实验以达到验证的目的，首先将整体实验分为以下三个部分，因此将消融模块分为了三个部分，分别是 NCF，即最基础的 baseline 模型，FOSO-P（仅仅使用个性化敏感信息嵌入作为门控信息），FOSO-S（仅仅通过敏感信息嵌入作为门控信息这里类似 POSO 的结构），FOSO-A（通过个性化敏感信息嵌入与通用的敏感信息嵌入融合的信息作为整体的门控信息输入）

表 2-4 ML1M 数据集中消融实验的数据

Target	NCF	FOSO-S	FOSO-P	FOSO-A
NDCG@5	0.0522	<u>0.0528</u>	0.0527	0.0566
NDCG@10	0.0625	<u>0.0629</u>	0.0628	0.0641
Recall@5	0.0354	<u>0.0369</u>	0.0363	0.0418
Recall@10	0.0719	<u>0.0721</u>	0.0719	0.0721
HR@5	0.1774	<u>0.1850</u>	0.1769	0.1940
HR@10	0.2926	0.2908	<u>0.2909</u>	0.2896
Min-HR@10	0.2486	<u>0.2521</u>	0.2457	0.2551

表 2-5 LastFM-360K 数据集中消融实验的数据

Target	NCF	FOSO-S	FOSO-P	FOSO-A
NDCG@5	0.0426	0.0430	0.0435	<u>0.0433</u>
NDCG@10	0.0372	0.0372	<u>0.0380</u>	0.0382
Recall@5	0.0174	0.0178	<u>0.0179</u>	0.0180
Recall@10	0.0295	0.0295	<u>0.0302</u>	0.0307
HR@5	0.1756	0.1801	<u>0.1795</u>	0.1800
HR@10	0.2753	0.2758	<u>0.2800</u>	0.2843
Min-HR@10	0.2713	0.2716	<u>0.2751</u>	0.2811

在消融实验的分析中，本文主要探讨了各个模型的不同配置对推荐系统性能的影响，重点分析了敏感信息嵌入的引入及其个性化与通用嵌入方式的组合对推荐效果的贡献。

首先，NCF 作为基准模型，其不直接使用任何敏感信息特征，作为对比组，从实验结果来看，NCF 在性能指标与公平性指标上表现都不太优秀。这表明，推荐系统如果没有利用敏感信息，就难以捕捉到用户潜在的、与敏感特征相关的偏好，因此导致了推荐效果的低下。

接着，FOSO-P 模型仅使用了个性化的敏感信息嵌入作为门控信息，这种方式相比 NCF 在性能指标上具有明显提升。个性化敏感信息能够有效捕捉每个用

户特定的敏感偏好，并通过个性化的门控机制来调整推荐过程中的敏感信息权重，从而提升了推荐结果的相关性。然而，单纯依赖个性化敏感信息嵌入仍然存在局限，尤其是在不同用户群体间的表现差异较大。这意味着在实际应用中，仅考虑个性化敏感信息并不足以全面的建模不同用户群体的兴趣。


相比之下，FPOSO-S 模型仅使用了通用的敏感信息嵌入作为门控信息，且模型中并未考虑个性化因素。从实验结果来看，FPOSO-S 的表现略优于 FPOSO-P，表明通用敏感信息为推荐系统提供了一种较为广泛的视角，使得系统能够在没有强烈个性化的前提下仍能保持较高的推荐质量。这一结果提示，虽然通用敏感信息能够提高推荐性能，但由于缺乏个性化调整，依然难以全面的建模用户兴趣。

FPOSO-A 模型通过融合个性化敏感信息和通用敏感信息作为门控输入，达到了所有配置中的最佳表现。该模型的表现超越了其他所有模型，表明个性化与通用敏感信息的结合能够在不同用户的需求和敏感性方面提供更为精准的调整，从而全面提高推荐质量，并在某些情况下有效地提升劣势群体的推荐准确性。在两个不同的数据集中也可以看出相比于 FPOSO-P 与 FPOSO-S 其拥有更好的鲁棒性，这一结果验证了敏感信息融合的必要性。同时也能看出两种不同的信息的互补属性。


综上所述，消融实验的分析表明，敏感信息的引入和个性化与通用信息的融合在推荐系统中的有效性。逐步的消融不难看到不同部分在整体模型的作用。也为后续的模型优化提供新的思路

2.3.4.3 超参数分析实践


为了在测试集上取得最佳的性能且研究不同参数对模型推荐性能的影响，本文对可能影响模型推荐效果的所有参数在参数空间中进行网格调参，并通过控制变量法探索模型对不同参数的敏感度。具体地，敏感信息的维度在值集[8,16,32,64] 感信息维度。



(a) NDCG 指标



(b) Recall 指标



(c) Min-HR 指标

图 2-5 ML1M 数据集敏感信息维度与指标变化图

实验数据显示了敏感特征嵌入维度对推荐系统在多项指标上的显著影响。总体而言，随着嵌入维度的增加，推荐系统的性能呈现出规律性的变化，不同指标的趋势反映了维度变化对推荐排序、召回能力以及群组公平性的差异化影响。

从 NDCG 的趋势来看，嵌入维度的增加能够在初期显著提升推荐排序的效果，尤其是在低维度场景下，性能改善较为明显。然而，当维度达到一定水平后，NDCG@10 的增益逐渐趋于平缓，表明模型捕捉用户偏好的能力随着维度的增加逐渐接近瓶颈，边际效应减弱。

Recall 与 NDCG 的变化趋势相似，同样表现为在低维度时提升较为显著，而在高维度场景下增幅有限。这表明模型的召回能力在低维度嵌入时受限较大，通过增加维度可以快速改善；但在维度较高时，系统整体性能已接近饱和，召回能力的提升幅度逐步减小。

相比之下，Min-HR 的趋势更加线性且稳定，随着嵌入维度的增加始终保持

显著提升。这表明提高嵌入维度对弱势群组的覆盖率具有持续的优化作用，特别是在捕捉个性化需求及保护敏感特征方面，高维嵌入的表现更加突出。

综上所述，不同嵌入维度对推荐系统性能的影响呈现出阶段性特征。在低维度场景中，增加维度对整体性能的提升更为显著，适用于对排序和召回效果要求较高的场景；而在高维度场景中，尽管整体性能的增益趋于饱和，但弱势群组的公平性指标仍保持稳定提升，适用于对公平性目标要求较高的场景。因此，嵌入维度的选择应该综合考虑性能需求、公平需求与计算资源的平衡。

2.4 本章小结

为了更加全面地捕捉用户与敏感信息之间的偏好程度，并通过动态的个性化机制避免敏感信息在建模中的过度平均化，从而提升推荐系统的性能和公平性。

具体而言，该模块首先通过是个性化敏感信息编码层对个性化敏感信息偏好信息进行深度编码生成更加个性化的敏感信息嵌入。敏感信息嵌入的引入不仅增强了对用户敏感性偏好的建模能力，根据用户的具体特征动态调整敏感信息在推荐结果中的影响权重。同时通过敏感信息融合层，融合了个性化的敏感信息与全局的敏感信息，更加全面的表达了敏感信息对于个体和群体的影响。最后将融合后的嵌入信息送入个性化 gate 网络用于控制特征信息。

综合来看，本文中的设计有效在保证 Max-Min 公平的基础下，有效的提高了推荐算法的性能。在未来的工作中，计划进一步关注模型对于多敏感信息的公平性的支持保证平衡不同的敏感信息对于结果的影响。

第三章 基于 MACR 框架的多样性召回网络

3.1 引言

现有音乐推荐系统普遍存在标签同质性和过滤泡泡问题,即系统倾向于推荐热门内容,导致用户被单一、同质化的信息包围,无法接触到多样化的音乐。这种现象的成因主要有两方面:一是推荐模型过度依赖历史数据,容易陷入自我强化的循环;二是热门标签对推荐结果的影响较大,进一步加剧了推荐的集中化。这种过滤泡泡现象不仅限制了用户的视野,也影响了推荐系统的公平性和用户体验。

尽管已有研究尝试解决多样性问题,但现有方法大多存在局限性。例如,后处理技术(如重排序、引入公平性目标等)往往以牺牲推荐性能为代价,且难以从根本上改变推荐模型的学习过程。此外,现有因果推理方法(如 MACR)虽然通过消除流行度偏差提升了多样性,但未考虑标签热度对推荐结果的直接影响,导致多样性提升效果有限。因此,现有方法在提升推荐多样性的同时,难以平衡推荐性能和多样性之间的关系。

为解决上述问题,本文提出了一种新颖的多样性召回网络——DMACR (Diverse Model-Agnostic Counterfactual Reasoning Network)。该模型的核心创新在于引入了一个新的因果图模型,扩展了传统因果图,将商品标签热度对排名分数的影响纳入考虑,从而更准确地捕捉用户偏好和音乐特性。如图 3-1 所示,DMACR 模型在训练阶段通过多任务学习框架,同时最小化用户-物品匹配损失、各种因素的热度损失;在测试阶段,利用反事实推理调整推荐分数,消除热度对推荐分数的直接影响,从而提升推荐系统的多样性和公平性。这种设计不仅有效解决了现有方法的局限性,还为推荐系统中的因果关系分析提供了新的理论视角。特别地,DMACR 采用公式化的去偏技术,通过缓存向量的方式,避免了用户与音乐向量的直接交叉计算,使其能够高效地应用于大规模召回阶段。这种方法不仅提升了推荐的多样性,还保持了推荐的准确性,特别适用于音乐推荐系统这种需要处理海量数据的场景。

综上所述,本章的主要贡献如下

(1) 提出了一种新的因果图模型,扩展了传统因果图,将标签热度对推荐结果的影响纳入考虑,为音乐推荐系统中的因果关系分析提供了新的理论视角。

(2) 构建了 DMACR 模型,通过因果推理和反事实推断,有效提升了音乐推荐结果的多样性和公平性,同时保持了推荐的准确性。

(3) 通过实验验证了模型的有效性,在两个真实数据集上的实验结果表明,

DMACR 在关键指标上优于现有模型，显著提升了推荐列表的标签多样性。




图 3-1 反事实推理的例子

3.2 基于 MACR 框架的多样性召回网络

本章首先介绍问题定义，随后介绍因果推断的基础知识，随后介绍去偏公式推导，最后介绍整体的网络结构。

3.2.1 问题描述

多样性召回网络旨在商品向量与用户向量不融合且保证推荐的准确率的前提下，提高推荐内容中标签多样性。

假设 $I = \{i_1, i_2, \dots, i_m\}$ 表示所有的 item。 $U = \{u_1, u_2, \dots, u_n\}$ 表示所有的 user。而 $T = \{t_1, t_2, \dots, t_m\}$ 表示商品 I 的标签。

模型根据用户的交互历史学习评分函数 $r(u|\theta)$ ，建模用户偏好，取得 top-n 的项目召回。优化过程为

$$top(n) = \underset{i \in I}{argmax}^m r(u, i|\theta) \quad (3-1)$$

3.2.2 基础知识

本文所提方法主要基于因果图与因果效应，下面就相关概念和基本知识予以介绍^[32]。

因果图是一个有向无环图，记作 $G=(V,E)$ ，其中 V 表示变量集合， E 表示变量之间的因果关系。在因果图中，往往使用大写字母表示一个变量(例如性别、商品类目、标签)，小写字母用于表示其观测值(比如男、书籍类、舞蹈类视频)。一条边意味着祖先节点是原因(Cause)，后继节点是效应(Effect)。以图 2 为例， $I \rightarrow Y$ 表示从 I 到 Y 存在直接效应。此外，路径 $I \rightarrow K \rightarrow Y$ 意味着 I 通过中介变量 K 对 Y 有间接效应。根据因果图， Y 的值可以从其祖先节点的值计算得

出，公式如下： $Y_{i,k} = Y(I = i, K = K(I = i))$ ，其中 $Y(\cdot)$ 表示 Y 的值函数。同样，中介变量的值可以通过 $K = K(I = i)$ 计算。特别是可以将 $K(I)$ 和 $Y(I, K)$ 实例化为神经网络，并组合成一个从输入 I 预测 Y 值的解决方案。

因果效应. 原因对目标变量的因果效应是目标变量因祖先变量单位变化而变化的程度。例如， I 对 Y 的总效应 (TE) 定义为： $TE(I \rightarrow Y) = Y(I = i, K = k_i) - Y(I = i^*, K = k_{i^*})$ ，其中 i^* 可以被视作 I 这个值的平均水平。

而 TE 可以分解为直接效应 NDE($I \rightarrow Y$) 与间接效应 TIE($I \rightarrow K \rightarrow Y$)。




图 3-2 因果图示例

3.2.3 DMACR 因果图

在本研究中，首先基于 MACR 框架提出的推荐行为的因果关系，构建了一个基础的 MACR 因果图模型。该模型包含了用户嵌入 U 、物品嵌入 I 、用户-物品匹配特征 M 以及排序分数 Y 等关键变量。此模型揭示了推荐系统中用户与物品之间的基本交互关系，并指出了匹配函数 $M(U, I)$ 和评分函数 $Y(M, U, I)$ 在推荐过程中的核心作用。这个因果图既考虑了用户与商品的匹配程度 $M(U, I)$ ，又考虑的商品的流行程度与用户的一致性对于结果的影响。

但是根据实验验证表明，尽管引入用户一致性和物品流行度因素的因果图模型在一定程度上改善了推荐结果的多样性，但其效果并不如预期有效。因此，提出了一个新的假设：标签本身的热度可能是影响推荐多样性的关键因素。基于这一假设本研究进一步完善了因果图模型构建了 DMACR 因果图。引入了标签热度因素，并构建了一个新的因果图模型，该模型不仅考虑了用户一致性和物品流行度，还涵盖了标签热度对推荐结果的潜在影响。通过这一改进，旨在提供一个更为全面的框架，以捕捉推荐系统中的复杂因果关系。同时也可以表示 $TE(I \rightarrow Y)$ 为公式 3-2

$$TE = Y(U = u, I = i, T = t, M_{U=u, I=i}) - Y(U = u^*, I = i^*, T = t^*, M_{U=u^*, I=i^*}) \tag{3-2}$$

随后将构建了一个阻断了 U 与 I 对于 M 的影响的 DMACR 反事实因果图以此来表达 $I \rightarrow Y$ 对于推荐结果的直接影响。

$$NDE = Y(U = u, I = i, T = t, M_{U=u^*, I=i}) - Y(U = u^*, I = i^*, T = t^*, M_{U=u^*, I=i^*}) \tag{3-3}$$

通过让全体的效应减去 I 的直接影响可以得到去偏后的推荐分数。

$$TIE = Y(U = u, I = i, T = t, M_{U=u, I=i}) - Y(U = u, I = i, T = t, M_{U=u^*, I=i^*}) \tag{3-4}$$




图 3-3 MACR 因果图、DMACR 因果图、DMACR 反事实因果图与 DMACR 去偏因果图

3.2.4 DMACR 网络结构

为了实证构建的因果图的有效性，本文基于 DMACR 因果图构建了 DMACR 模型，DMACR 模型整合了用户-物品匹配和标签热度的影响，旨在通过直接的因果关系调整，提升推荐系统的公平性和多样性。接下来的部分将详细介绍 DMACR 模型的结构和实现细节。




图 3-4 DMACR 模型架构

3.2.4.1 流行性偏差分支

在推荐系统中，流行性偏差是一个普遍存在的问题，它导致推荐结果倾向于热门物品，从而限制了推荐的多样性。为了解决这一问题，DMACR 模型保留 MACR 框架^[43]中的两个流行性分支用于建模流行度本身对于推荐结果的影响。通过阻断物流行度对排序分数的直接影响，从而减少流行物品在推荐列表中的过度出现。具体来说，通过调整模型的因果图结构，将物品流行度的影响从排序分数的直接计算中分离出来，实现了对流行性偏差的有效控制。

为了量化和调控流行度对推荐结果的具体影响,本研究采用前馈神经网络(FFN)来量化商品流行度对用户行为的影响,以及用户的依从性。该网络通过一系列层次化的结构,将用户和商品的特征向量作为输入,并通过隐藏层的非线性变换,最终在输出层预测用户对商品点击的条件概率。具体地,定义了两个预测概率: $P_{item-popular}$ 表示给定商品 i 被点击的条件概率,而 $P_{user-popular}$ 表示用户 u 的依从性,即用户 u 点击任意商品的条件概率。

公式如下:

$$P_{item-popular} = \sigma(W_{pi} * e_i + b_{pi}) \quad (3-5)$$

$$P_{user-popular} = \sigma(W_{pu} * e_u + b_{pu}) \quad (3-6)$$

其中 $\sigma(\cdot)$ 表示 sigmoid 激活函数,将用于将神经网络的输出值转化为概率值;其中 $W_{pi}b_{pi}$ 和 $W_{pu}b_{pu}$ 分别表示针对商品嵌入 e_i 和用户嵌入 e_u 的神经网络的权重矩阵与偏置矩阵。为了优化 FFN 的参数采用了交叉熵损失函数的方式优化

$$L_{item-popular} = \frac{1}{N} \sum_{i=1}^N (y_i * \log(P_{item-popular}) + (1 - y_i) * \log(1 - P_{item-popular})) \quad (3-7)$$

$$L_{user-popular} = \frac{1}{N} \sum_{i=1}^N (y_i * \log(P_{user-popular}) + (1 - y_i) * \log(1 - P_{user-popular})) \quad (3-8)$$

$$L_{popular-total} = \alpha * L_{item-popular} + \beta * L_{user-popular} \quad (3-9)$$

其中, N 是样本总数, y_i 是第 i 个样本的真实标签,表示商品是否被点击; $P_{item-popular}$ 和 $P_{user-popular}$ 分别是模型预测的商品点击概率和用户依从性概率。通过最小化这一损失函数,模型能够学习到更准确的用户点击行为预测。

3.2.4.2 标签流行性偏差分支

在 MACR 框架中由于更加注重于对流行性偏差的影响,诚然这种流行性偏差的确会在一定程度上影响推荐结果的多样性,然而这种关联比较间接的,将标签的热度对于推荐结果的影响引入到因果图中,可能在去流行性影响的基础上增加推荐结果的多样性。为了实现这一目的在 MACR 的基础上引入了标签流行性偏差分支以建模标签热度对于推荐结果的影响,进而在后续的工作中使用反事实推理消除标签热度对于推荐结果的影响。

为了量化标签本身对于推荐结果的影响,标签流行性偏差分支通过前馈神经网络(FFN)来预测标签热度对用户点击行为的影响。考虑到一个商品可能与多个标签相关联,采用了平均池化策略来均衡地考虑每个标签对推荐结果的贡献,平均池化通过计算的平均值来减少特征向量的空间维度,同时平滑输入数据,减少噪声的影响。整体公式如下:

$$E_{t_i} = -\frac{1}{|R_{it}|} \sum_{t \in R_{it}} E_t \quad (3-10)$$

$$P_{tag-popular} = \sigma(W_{t_i} * e_{t_i} + b_{t_i}) \quad (3-11)$$

其中 R_{it} 表示商品 i 的标签集合, E_t 表示标签 t 的标签嵌入, $|R_{it}|$ 表示商品 i 的标签数量, $\sigma(\cdot)$ 表示 sigmoid 激活函数, 将用于将神经网络的输出值转化为概率值; 其中 $W_{t_i}b_{t_i}$ 分别表示针对商品 i 的标签热度的神经网络的权重矩阵与偏置矩阵。为了优化 FFN 的参数采用了交叉熵损失函数的方式优化

$$L_{tag-popular} = \frac{1}{N} \sum_{i=1}^N (y_i * \log(P_{tag-popular}) + (1 - y_i) * \log(1 - P_{tag-popular})) \quad (3-12)$$

其中, N 是样本总数, y_i 是第 i 个样本的真实标签, 表示商品是否被点击; $P_{tag-popular}$ 分别是模型预测的商品热度对于推荐结果的影响。通过最小化这一损失函数, 模型能够学习到更准确的用户点击行为预测。

3.2.4.3 用户-商品匹配分支

推荐系统的核心在于准确预测用户与商品之间的匹配程度。本分支采用了经典的矩阵分解(MF)推荐系统的策略, 通过对用户 u 和商品 i 进行向量化处理, 计算了用户与商品之间的匹配得分。这一过程的核心在于计算用户向量和商品向量的内积, 以得到一个初步的匹配得分, 公式如下:

$$p_{match} = e_i^T * e_u \quad (3-13)$$

其中, e_u 和 e_i^T 分别代表用户 u 和商品 i 的向量化表示, 而 p_{match} 表示推荐结果的匹配程度, 通过这种方式, 用户匹配程度分支旨在提升推荐系统的性能, 确保推荐列表中的商品能够更好地符合用户的实际偏好和需求。但鉴于本文的研究重点在于多样性和偏差问题, 对用户匹配程度分支的讨论到此为止。

3.2.4.4 反事实推理

正如本章的引言中所述, 消除偏差的关键是分别建模总和直接效应(TE)与总间接效应(NDE)并且利用其差距完成去偏, 本节将利用神经网络来完成这一目标。

首先沿用 MACR 框架中的观点采取了乘法假设即认为不同因果效应的累计方式为乘法关系。首先会对于现实世界进行建模, 在如图 3-3 所示现实世界的推荐结果分别受到商品与用户的匹配程度、物品的流行程度、用户的流行偏好度、标签的热度四个方面的影响因此假设现实世界的评分结果如下:

$$Y(U = u, I = i, T = t, M_{U=u, I=i}) = p_{match} * p_{user-popular} * p_{item-popular} * p_{tag-popular} \quad (3-14)$$

模型训练的过程也会依据上述的公式完成推理, 为了修正这些效果对于推荐结果的影响, 构建了一个反事实世界(NDE)在这个反事实世界中用户对于商品的点击行为仅仅根据物品的流行程度、用户的流行偏好度、标签的热度和不受前两者影响的匹配程度影响, 由于反事实世界无法观察的特性, 设置了一个超参数 C 用于表示在反事实世界中匹配程度得分 $P_{match-score-NDE}$ 由此得到了反事实世界中的推荐结果

$$Y(U = u, I = i, T = t, M_{U=u^*, I=i^*}) = C * p_{user-popular} * p_{item-popular} *$$

$$p_{tag-popular} \quad (3-15)$$

由此, 根据引言中推理的去偏公式 3-4 可以表示为:

$$TIE = (p_{match} - C) * p_{user-popular} * p_{item-popular} * p_{tag-popular} \quad (3-16)$$

3.3 实验设计与对比分析

为了评估本章节提出的 DMACR 模型的有效性, 在两个常用于评估推荐模型的真实数据集上进行了系统性的实验。本节旨在回答以下研究问题。

RQ1: 与现有的模型相比, 本文提出的 DMACR 效果如何?

RQ2: 模型的各部分是否起到了应有的作用, 如果起到了每部分的影响又都是怎样的?

RQ3: 模型在不同的超参数 C 的条件下的表现如何?

3.3.1 实验数据集

ML10M 数据集^[62]是推荐系统领域一个重要的研究数据集, 来自明尼苏达大学的 MovieLens 项目。该数据集包含约 10,000,000 条评分记录, 记录了约 69,000 位匿名用户对约 10,000 部电影的评分信息, 评分范围从 1 到 5 分。ML10M 数据集提供了详细的用户与电影之间的交互数据, 是用户-项目推荐任务中广泛使用的基准测试数据, 支持协同过滤、矩阵分解等推荐算法的研究。这里使用电影的类型标签作为多样性的标签。

MIND-small 数据集^[67]是微软发布的新闻推荐数据集 MIND 的精简版本, 专为研究个性化新闻推荐设计。数据来源于真实的用户行为日志, 包含用户点击历史、新闻内容和候选新闻点击行为等信息。相比完整版本, MIND-small 数据集规模小, 包含约 50,000 名用户、7,000 篇新闻和 230,000 条点击记录, 适合快速实验。它广泛用于点击率预测、新闻召回和排序优化, 支持文本、类别和多模态研究, 这里将新闻的类型作为类别信息。

表 3-1 数据统计表

Dataset	Users	Items	Interactions	Sparsity
ML10M	6,9166	8,790	5,000,415	99.1%
MIND-small	15,509	2,713	155,937	99.6%

3.3.2 评价指标

$NDCG@k$ 是一种衡量推荐结果排序质量的指标，用于评价推荐系统是否将用户最感兴趣的项目排在靠前位置。其计算基于累积增益，即推荐列表中每个项目的相关性得分。过将较高的分数分配给较靠前的位置来衡量所推荐物品的排列顺序是否正确

$$DCG@k = \sum_{i=1}^k \frac{2^{rel_i} - 1}{\log_2(i+1)} \quad (3-17)$$

$$IDCG@k = \sum_{i=1}^k \frac{1}{\log_2(i+1)} \quad (3-18)$$

$$NDCG@k = \frac{DCG@k}{IDCG@k} \quad (3-19)$$

$Recall@k$ 用来衡量推荐系统在前 k 个推荐项中找回用户真实感兴趣的项目的比例，主要关注推荐列表的覆盖率。

$HR@k$ 用来衡量推荐系统在前 k 个推荐项中是否包含至少一个用户真正感兴趣的项目，它是一个二元指标。

$Gini@k$ 是衡量推荐系统中标签分布均匀性的指标。其值越低，表示推荐结果中标签分布越不均匀，推荐内容可能集中在少数标签上；值越高，说明标签分布更均匀，推荐结果多样化更高。

$$c_{i,t} = \frac{|T(i,t)|}{m_i} \quad (3-20)$$

$$p_{u,t} = \frac{1}{|R_u|} \sum_{i \in R_u} c_{i,t} \quad (3-21)$$

$$Gini@k = \frac{1}{|D_u|} \sum_{u \in D_u} (1 - \sum_{t \in T} p_{u,t}^2) \quad (3-22)$$

其中 m_i 表示商品 i 包含的标签数量， $|T(i,t)|$ 表示商品 i 中包含标签 t 的数量， $c_{i,t}$ 代表项目 i 对标签 t 的贡献用于平衡多标签的商品对于不同标签的贡献， R_u 为模型为用户 u 推荐的 top- k 项目集合， $p_{u,t}$ 表示用户 u 对标签 t 的归一化贡献， D_u 表示推荐系统中用户的集合， T 表示所有包含的标签的集合。

3.3.3 基线模型

MF^[1]: 矩阵分解是一种广泛应用于推荐系统的算法，主要用于处理用户-项目评分矩阵。

IPS^[38, 39]: 逆概率加权是一种基于因果推断的方法，通常用于处理推荐系统中数据倾斜的问题。

CasualE^[40]: CasualE 是一种域适应算法, 它从去偏数据集中学习以帮助模型更好地泛化到有偏训练数据。在的实验中, 将训练集分成去偏和有偏两部分来实现这种方法。

MACR^[43]: MACR 是一种因果去偏框架旨在通过反事实推理消除推荐系统中的流行度偏差。

3.3.4 实验结果

3.3.4.1 对比实验分析

在本实验中, 针对推荐系统领域中因偏差问题导致的准确性与多样性问题进行了深入研究, 设计并评估了五种推荐方法的性能, 包括传统矩阵分解 (MF)、倾向评分修正 (IPS)、因果推断模型 (CasualE)、基于因果推断的去偏方法 (MACR) 以及在 MACR 基础上改进的 DMACR。实验的核心目标是验证 DMACR 方法在推荐准确性、多样性维度的改进效果。DMACR 的主要创新点在于将标签热度对于结果的影响引入到了原来的反事实推断中, 进一步优化推荐系统对用户兴趣偏好的捕捉能力, 同时减少热门标签对推荐排序结果的干扰, 提升冷门标签的曝光机会。

选取了两个具有代表性的数据集, 分别是规模较大的 ML10M 数据集和规模较小的 MIND-small 数据集, 以全面考察各方法在不同场景下的性能表现。实验过程中, 使用 Recall@20、HR@20 和 NDCG@20 等指标评估推荐结果的准确性, 同时通过 Gini@20 量化推荐结果的多样性。此外, 还对比分析了不同数据集的特性对推荐性能的影响, 从而验证 DMACR 方法的通用性和稳定性。

表 3-2 ML10M 数据集评估表

Target	MF	IPS	CasualE	MACR	DMACR
Recall@20	0.008	0.003	0.006	<u>0.040</u>	0.043
HR@20	0.051	0.031	0.049	0.140	<u>0.138</u>
NDCG@20	0.006	0.004	0.006	<u>0.024</u>	0.025
Gini@20	0.822	0.828	0.823	<u>0.831</u>	0.846

表 3-3 MIND-small 数据集评估表

Target	MF	IPS	CasualE	MACR	DMACR
Recall@20	0.022	0.014	0.022	<u>0.022</u>	0.026
HR@20	0.040	0.025	0.040	<u>0.041</u>	0.044
NDCG@20	0.009	0.005	0.009	<u>0.009</u>	0.011
Gini@20	0.835	0.825	0.832	0.829	<u>0.832</u>

在本研究中, 深入比较了 DMACR 模型与现有的 MACR 框架、IPS 和 CasualE 模型的性能。MACR 框架通过因果推理和反事实推理来消除推荐系统中的流行度偏差, 但在处理标签热度对多样性的影响方面不够直接, 这在 Gini@20 指标上

尤为明显，MACR 的得分为 0.831，而 DMACR 则显著提升至 0.846。IPS 模型通过逆倾向得分调整推荐结果，以减轻流行度偏差的影响，但这种方法可能会过度调整，影响推荐结果的自然分布。在 ML-10M 数据集上，IPS 的 Recall@20 和 HR@20 指标分别为 0.008 和 0.051，显著低于 DMACR 的 0.043 和 0.138。CasualE 模型尝试通过域适应技术在去偏数据集上学习，以期更好地泛化到有偏训练数据，但在捕捉用户多维兴趣的细微变化方面存在局限，尤其在稀疏数据集 ML10M 上，其 NDCG@20 指标分别为 0.006，而 DMACR 模型则达到了 0.025。

在两个具有代表性的数据集——ML-10M 和 MIND-small 上分别进行了实验。ML-10M 数据集包含丰富的用户行为信息，标签分布明显偏向头部内容，在 ML-10M 数据集上，DMACR 在性能指标上均优于其他方法，尤其在 Gini@20 指标上表现出色，表明其能够有效缓解热门标签的集中化倾向。而 MIND-small 数据集由于规模较小，标签与新闻点击分布均衡。导致在 MIND-small 数据集上，针对流行度的算法表现相对平庸，但是 DMACR 相比较于其他因果推断模型依然在性能指标上保持领先，多样性指标上相对变化较小，但是相比其他因果推断模型而言仍然有所提升，表现了其鲁棒性。

综上所述，DMACR 模型在保持推荐准确性的基础上提高了推荐结果的多样性为不同类型的商品提供了更加均衡的曝光机会。

3.3.4.2 消融实验分析

实验目的为探索模型中的每一个部分是如何影响推荐的结果的，因此将会分别消融模型中的不同的结构来分析不同部分对于推荐结果的影响的。在实验中将 DMACR-a 代表完整的模型，DMACR-oi 代表消融掉商品去偏分支，DMACR-ou 代表去消融掉用户的对于热度的偏好，DMACR-ot 代表去消融掉标签热度去偏分支。

表 3-4 ML10M 数据集评估表

Target	DMACR-ou	DMACR-oi	DMACR-ot	DMACR-a
Recall@20	0.027	0.008	0.040	0.043
HR@20	0.092	0.047	0.140	0.138
NDCG@20	0.015	0.006	0.024	0.025
Gini@20	0.833	0.544	0.831	0.846


根据实验结果，去除不同分支后，模型性能表现出现了显著差异。去除用户去偏分支（DMACR-ou）时，Recall@20 和 HR@20 均有所提升，表明该分支对提高召回率和推荐多样性具有积极作用。具体而言，用户去偏分支的消除增强了推荐系统对个体用户偏好的聚焦，避免了因用户偏好的去偏而引起的潜在信息损失，进一步提升了多样性和覆盖率。这表明用户偏好的去偏处理有助于在不同用户群体之间实现更好的推荐平衡和个性化推荐。相比之下，去除 item 去偏分支

(DMACR-oi) 导致了性能的显著下降, Recall@20 和 HR@20 大幅度降低, 特别是在 Recall@20 上下降幅度明显, 说明该分支对降低推荐结果的集中度、提升推荐多样性至关重要。Item 去偏分支的作用主要体现在去除热门物品的过度推荐, 避免了推荐列表中过度集中于热门物品, 从而提升了推荐系统的公平性和多样性, 同时从去除该分支后性能下降的严重程度也可以看出该分支作为整个框架的主干, 具有非常重要的作用。去除 tag 热度去偏分支 (DMACR-ot) 后, 虽然召回率略有下降, 但推荐的多样性和排序质量仍然较高, 显示出该分支对优化推荐的多样性发挥了重要作用。Tag 去偏分支在降低热门标签的影响、提高长尾物品的推荐概率方面发挥了关键作用, 表明它在提升推荐的多样性和减少热门标签集中度方面起到了积极作用。


总之, 各个分支对模型的影响是相辅相成的, 去除任何一个分支都会对推荐系统的性能产生不同程度的影响。同时通过消融实验也能看出其中商品热度分支具有最大的重要性, 因此对于分支任务损失权重的探索也将是未来需要探索的工作。而完整的 DMACR-a 模型通过有效结合这三个去偏分支, 展现出更为优异的推荐效果也证明了三者之间是缺一不可的关系。

3.3.4.3 超参数实验分析


在本次实验中, 模型 DMACR 在不同超参数 C 的取值下, 展现出了多方面的表现和趋势。超参数 C 在去偏过程中的作用尤为重要, 越高的 C 值意味着更强的去偏力度, 可能会对模型的各项指标产生不同的影响。接下来将对 HR@20、Recall@20、NDCG@20 和 Gini@20 这四个核心指标进行综合分析, 并总结出对模型性能的整体影响及其可能的改进方向。




(a) HR 指标



(b) Recall 指标



(c) NDCG 指标



(d) Gini 指标

图 3-5 不同的超参数 C 之下 DMACR 在数据集中的性能表现

在 DMACR 模型中，超参数 C 的调整对推荐系统的性能有着显著的影响。随着 C 值的增加，观察到模型在不同指标上呈现出独特的变化趋势。具体来说，命中率随着 C 的增大而逐渐下降，这表明在增强去偏力度的同时，模型可能会

牺牲一部分对广泛用户群体的覆盖能力。召回率在不同 C 值下保持相对稳定, 显示出模型即使在去偏策略下也能维持较高的信息召回能力。排序质量虽有波动, 但整体变化不大, 说明模型在去偏的同时仍能保持较高的排序准确性。最引人注目的是多样性的变化, 它随着 C 的增加先上升后下降, 表明适当的去偏力度可以优化推荐结果的多样性, 但过度的去偏可能会适得其反。这些变化趋势揭示了在追求推荐系统公平性和多样性时需要仔细平衡的复杂性。

基于实验结果, 可以得出以下结论: DMACR 模型通过调整超参数 C 在推荐系统的召回率、排序质量和多样性之间提供了一个灵活的权衡机制。随着 C 值的增加, 模型在提升多样性方面表现出色, 但可能会以牺牲一定的命中率为代价。这表明在实际应用中, 需要根据业务需求和用户期望来精细调整 C 值, 以实现最佳的性能平衡。此外, 召回率和排序质量的稳定性表明, DMACR 模型在去偏的同时能够保持推荐的相关性和准确性, 这对于维护用户体验至关重要。最终, 实验结果支持了 DMACR 模型作为一种有效的工具, 用于解决推荐系统中的多样性和公平性问题, 同时强调了在实际部署中找到最优 C 值的重要性。未来的工作可以进一步探索动态调整 C 值的策略, 以及考虑用户特定特征的个性化去偏方法, 以实现更精准的推荐和更高的用户满意度。

3.4 本章小结

本文介绍了 DMACR 模型, 一种新颖的多样性召回网络, 旨在通过因果推理和反事实推断增强推荐结果的多样性并有效破解过滤泡泡问题, 为不同类型的商品提供了更加均衡的曝光机会。DMACR 框架的核心创新在于引入了一个新的因果图模型, 该模型扩展了传统因果图, 纳入商品标签对排名分数的影响, 以更准确地捕捉用户偏好和商品特性。在训练阶段, DMACR 通过多任务学习框架, 同时最小化用户-物品匹配损失、用户热度损失、商品热度损失和标签热度损失。测试阶段则利用反事实推理调整推荐分数, 以消除标签直接影响并促进多样性。这些创新使得 DMACR 在提升推荐准确性和多样性方面表现出色。

DMACR 在性能指标上优于现有模型, 显著提升了推荐列表的标签多样性, 增强了推荐系统的多样性。实验结果证实了 DMACR 的鲁棒性和通用性, 为解决推荐系统中的多样性问题提供了新途径。特别是在实验中, DMACR 展现出在提升推荐准确性和多样性方面的显著优势, 这表明其能够有效地捕捉用户潜在兴趣偏好, 并缓解热门标签的集中化倾向, 增强了推荐结果的多样性与公平性。

第四章 多尺度热度信息融合的序列推荐网络

4.1 引言

随着信息爆炸时代的到来,推荐系统已成为现代互联网平台的核心技术之一,广泛应用于音乐、视频、电商等多个领域。然而,现有的推荐系统在追求推荐准确性的同时,往往忽略了热度信息(尤其是内容提供者的热度)对推荐结果的影响。因此,如何在推荐系统中更好地融合多尺度热度信息,提升推荐的准确性,同时保持对不同数据特性的适应性,已成为当前研究的一个重要问题。

近年来,序列推荐系统的研究虽然取得了显著进展,研究者们通过引入先进的建模技术,逐步提升了对用户行为序列的建模能力,从而更好地捕捉用户兴趣的动态演变。然而,尽管这些方法在提升推荐准确性方面取得了显著进展,但它们大多忽略了热度信息对推荐结果的影响。与此同时,现有的热度感知网络虽然在一定程度上利用了热度信息来提升推荐性能,但这些方法往往缺乏对内容提供者(如作者、艺术家等)热度的关注,难以全面反映内容的多维度热度特征及其对用户偏好的影响。这种局限性限制了推荐系统的推荐性能

为了克服现有研究的不足,本文提出了一种多尺度热度信息融合的序列推荐模型(SeqPE)。该模型通过热度编码网络对内容热度进行多尺度编码,并通过热度融合网络学习不同维度热度信息之间的关系,从而更准确地捕捉用户兴趣的动态演变。SeqPE 不仅能够充分利用内容本身的热度信息,还能通过融合内容提供者的热度信息,为用户提供更精准且多样化的推荐内容。此外,该模型在两个真实世界的数据集(LFM-1b 和 KuaiRec)上进行了广泛的实验验证,结果表明 SeqPE 在稀疏和稠密数据场景下均表现出色,显著提升了推荐的准确性。消融实验进一步验证了模型各部分的有效性,证明了多尺度热度信息融合对推荐性能的重要作用

综上所述,本文的主要贡献包括:

- (1) 提出了一种新的序列推荐模型 SeqPE,通过多尺度热度信息融合有效解决了序列推荐中不同尺度热度的编码与融合问题;
- (2) 通过广泛的实验验证了 SeqPE 模型在稀疏数据和稠密数据场景下的优越性能,证明了其在推荐准确性的显著优势;

4.2 多尺度热度信息融合的序列推荐网络

本节将详细介绍所提出的多尺度热度融合网络模型 Seq-PE,模型整体结构如图 4-1 所示,本节中首先对问题进行描述,之后介绍模型的各个主要部分,最后

介绍优化过程。




图 4-1 网络结构图

4.2.1 问题描述

定义用户的交互序列 $S_u = \{i_1, i_2, \dots, i_t\}$ 对应按照时间顺序用户 u 第 t 次交互的项目，所有的用户与商品之间的交互序列的集合为 S ， $X = \{x_1, x_2, \dots, x_m\}$ 表示排序的候选集合,每一个商品 x_i 其自身的在交互时的点击次数与对应作者的点击次数分别定义为 h_t^{item} 和 h_t^{author} 。所有的用户 $|U|$ 和所有的商品 $|I|$ 构成了用户集合 U 与商品集合 I 。模型根据用户的顺序交互历史 S 学习评分函数 $r(x, s|\theta)$,建模用户偏好，取得 top-n 的项目推荐。优化过程为

$$top(n) = argmax_{x \in X}^m r(x, s|\theta) \tag{4-1}$$

4.2.2 热度信息编码层

在热度信息编码层，将会对序列推荐系统中，用户的历史交互序列对应的热度信息进行编码，旨在让模型可以学习到用户对于商品的热度趋势偏好，并且加强不同热度之间的联系。在现有的研究中往往将热度信息作为单一维度的连续特征，往往直接引入或者使用分桶法引入。忽视了热度信息的非线性特征，本节中提出了一种热度编码器(HotEncoder)旨在将连续的热度信息编码为抽象的 K 个热度聚类以学习到更加丰富的热度信息。

热度信息由于数据倾斜的特点往往具有较大的方差，这往往导致模型的训练过程中经常出现梯度不稳定的问题，为了缓和这一问题 HotEncoder 的第一层引入了 Layer Normalization 机制用于归一化同一个用户交互热度的输入。公式如下：

$$h_{norm} = \frac{h-\mu}{\sigma+\epsilon} * \gamma + \beta \tag{4-2}$$

其中 $h = \{h_1, h_2, \dots, h_t\}$ 为用户交互的每一个商品对应的热度信息，即商品交互时的点击次数，其中 μ 与 σ 分别为这一层交互的均值与方差， γ 与 β 分别为 Layer Normalization 的可学习参数用于调节输入的分布以得到更加稳定的输入。

完成归一化后为了保证热度编码学习的过程中不是单纯的分桶信息热度信息仅仅与相邻的热度信息聚类，因此引入了非线性编码层。该层通过前馈神经网络(FFN)与 GeLU 激活函数为归一化后的热度信息提供非线性。公式如下：

$$\hat{h} = GeLu(FFN(h_{norm})) \tag{4-3}$$

为了将热度信息聚类为离散类别，在 HotEncoder 的第三层引入了聚类层。该层通过前馈神经网络(FNN)和 Softmax 激活函数，将非线性编码后的特征映射到 K 个预定义类别中。Softmax 激活函数不仅能够将输出值归一化为概率分布，还能够进一步引入非线性，从而实现更灵活的聚类效果。聚类层的计算公式如下：

$$h_i = Softmax(FNN(\hat{h})) \tag{4-4}$$

通过 Softmax 激活函数，能够将热度信息分解为多个离散类别，从而为后续的推荐模型提供更明确的热度主题信息。通过上述三层的编码机制，HotEncoder 能够有效地捕捉热度信息中的复杂关系，并将其分解为多个离散类别。这种多尺度编码机制不仅能够提高模型对热度信息的表达能力，还能够为后续的推荐模型提供更丰富的特征表示。




图 4-2 热度编码层结构图

4.2.3 多尺度热度融合层

在序列推荐系统中，用户的行为不仅受到单个内容热度的影响，还受到内容

提供者（如作者、艺术家等）热度的综合影响。例如，用户可能因为喜欢某个作者而对其作品产生兴趣，即使这些作品的热度相对较低；反之，用户也可能因为某个高热度的作品而对该作者的其他低热度作品产生兴趣。这种复杂的关系表明，单纯依赖内容本身的热度或作者的热度是不够的，需要一种机制来综合考虑两者之间的关系。

为了更全面地捕捉不同热度信息对用户偏好的影响，设计了一个多尺度热度融合层。该层的核心目标是将作者热度和商品热度两个维度的热度信息进行融合，从而为后续的推荐模型提供更丰富的特征表示。这种融合机制不仅能够捕捉到高热度作者的高热度作品，还能够特别关注那些低热度作者的高热度作品，或者高热度作者的低热度作品。例如，一个新晋作者可能发布了一首高热度的歌曲，或者一个知名作者可能发布了一部低热度但质量很高的作品。通过这种融合机制，模型能够更好地理解用户对不同类型内容的偏好，从而生成有效的推荐信号。

具体而言，将作者热度、商品热度以及它们之间的差值进行拼接，这一过程不仅保留了作者热度和商品热度的原始信息，还通过它们之间的差值捕捉了两者之间的复杂关系。热度融合层的输入包括作者热度编码 H_i^{author} 和商品热度编码 H_i^{item} ，这两个编码向量分别表示作者和商品的热度信息，通过 HotEncoder 网络生成。为了捕捉作者热度和商品热度之间的复杂关系，引入了它们之间的差值 $H_i^{\text{author}} - H_i^{\text{item}}$ 。通过将这三个特征向量进行拼接，得到了一个综合的热度特征表示：

$$h_{\text{fusion}} = \text{concat}(h_i^{\text{author}}, h_i^{\text{item}}, h_i^{\text{author}} - h_i^{\text{item}}) \quad (4-5)$$

为了进一步提取这些特征的非线性关系，通过一个前馈神经网络（FFN）将拼接后的特征向量投影到一个低维空间，得到最终的热度融合特征表示：

$$E_{\text{fusion}}^{\text{hot}} = \text{ReLu}(\text{FFN}(h_{\text{fusion}})) \quad (4-6)$$

其中，FFN 表示前馈神经网络，用于将拼接后的特征向量投影到一个低维空间。通过这种方式，模型能够更加灵活地学习到不同的热度信息及其之间的复杂关系，从而为后续的推荐模型提供更丰富的特征表示。通过引入多尺度热度融合层，模型不仅能够保留作者热度和商品热度的原始信息，还能够捕捉两者之间的复杂关系。这种多尺度的热度融合机制使得模型能够更准确地反映不同热度信息对用户偏好的影响。

4.2.4 序列信息学习层

在序列推荐系统中，为了更全面地捕捉用户行为序列中的信息，设计了一个序列信息学习层。该层的核心目标是将用户的行为序列信息、位置信息和热度信息进行融合，然后通过多头自注意力机制和残差前馈网络进行学习，从而为后续的推荐模型提供更丰富的特征表示。

具体而言, 首先将用户的行为序列中的每个商品映射到一个低维的嵌入空间, 得到商品嵌入 E_i 。接着, 结合位置编码 $E_{position}$ 和热度融合向量 E_{fusion}^{hot} , 得到综合的输入表示:

$$E_{input} = E_i + E_{position} + E_{fusion}^{hot} \quad (4-7)$$

其中, 位置编码 $E_{position}$ 通过正弦和余弦函数生成, 能够为模型提供序列中每个位置的唯一标识。热度融合向量 E_{fusion}^{hot} 通过热度融合层生成, 捕捉了作者热度和商品热度之间的复杂关系。

接下来, 输入表示 E_{input} 被送入多头注意力机制。多头注意力机制允许模型在不同的表示子空间中并行地学习信息。具体来说, 模型会同时关注序列中的多个位置, 计算每个位置与其他位置的相关性, 从而捕捉到序列中的长距离依赖关系。多头注意力机制的输出经过 Dropout 处理, 以防止过拟合, 然后通过 LayerNorm 进行归一化, 增强模型的稳定性和收敛速度。

$$E_{attn} = \text{LayerNorm}(\text{MultiHeadAttention}(E_{input})) \quad (4-8)$$

最后, 通过残差连接将多头注意力机制的输出与输入相加, 保留原始信息, 增强模型的表达能力: 随后, E_{attn} 进入前馈网络 (Feed-Forward Network, FFN), 进一步提取非线性特征。FFN 是一个简单的两层全连接网络, 为每个位置独立地应用相同的变换, 增加了模型的非线性表达能力。FFN 的输出同样经过 Dropout 处理, 然后通过 LayerNorm 进行归一化, 并通过残差连接与 E_{attn} 相加:

$$E_{ffn} = \text{LayerNorm}(E_{attn} + \text{FFN}(E_{attn})) \quad (4-9)$$

通过堆叠多个这样的层 (每层包含多头注意力机制、Dropout、LayerNorm 和残差连接), 模型能够逐步提取更复杂的特征和模式。这种设计不仅能够捕捉用户行为序列中的长距离依赖关系, 还能通过热度信息和位置信息增强模型的表达能力, 从而提高推荐的准确性和多样性。多头注意力机制、LayerNorm 和残差网络的结合使得模型能够更有效地处理用户的行为序列, 为推荐系统提供了更强大的建模能力

4.2.5 预测层

在序列推荐系统中, 预测层负责根据用户的行为序列生成最终的推荐结果。具体而言, 预测层从用户行为序列中提取最后一个位置的特征表示 S_{out}^{h-1} , 并将其与目标物品的嵌入向量 I_{order} 计算相关性得分:

$$P_{score} = \sigma(S_{out}^{h-1} I_{order}^T) \quad (4-10)$$

其中, S_{out}^{h-1} 是经过多头自注意力和前馈网络处理后的最后一个位置的特征表示, I_{order}^T 是目标物品 i 的嵌入向量的转置。为了优化模型的性能, 使用交叉熵损失函数来计算预测得分与真实标签之间的差异。交叉熵损失函数定义如下:

$$L_{train} = -\frac{1}{N} \sum (y_i \log P_{score} + (1 - y_i) \log(1 - P_{score})) \quad (4-11)$$

其中, y_i 是真实标签, 表示用户是否与物品 i 有交互; P_{score} 是模型预测的物品 i 的得分, 其中 $\sigma(\cdot)$ 代表 Sigmoid 函数表示用户与物品 i 交互的概率; N 是候选物品的总数。通过最小化交叉熵损失, 模型能够更好地学习用户的行为模式, 提高推荐的准确性。

4.3 实验设计与对比分析

为了评估本文提出的 SeqPE 模型的有效性, 在两个常用于评估多行为推荐模型的真实数据集上进行了系统性的实验。本节旨在回答以下研究问题。

- RQ1: 与现有的模型相比, 本文提出的 SeqPE 性能如何?
- RQ2: 模型的各部分是否起到了应有的作用, 如果起到了每部分的影响又都是怎样的?
- RQ3: 模型在不同的超参数 K 的条件下的表现如何?

4.3.1 实验数据集

LFM-1b 数据集^[68]是一个大规模音乐收听行为数据集, 记录了大量用户在音乐平台上的收听行为。该数据集以丰富的用户与音乐的交互信息为特点, 涵盖了用户对不同音乐内容的偏好和行为模式。它不仅包含用户与音乐的直接交互, 还整合了音乐相关的元数据, 如艺术家、专辑等信息, 形成了一个复杂的用户-物品交互网络。LFM-1b 的多样性和丰富性使其成为音乐推荐系统研究中的重要资源, 尤其适合探索用户兴趣建模和个性化推荐算法。

KuaiRec 数据集^[69]是一个高稠密度的用户与视频交互数据集, 由短视频平台快手与中科大合作发布。该数据集记录了用户在平台上的视频观看行为, 反映了用户对不同类型内容的偏好和互动模式。其高稠密度的特点使其在推荐系统研究中具有独特价值, 尤其适合探索无偏推荐、交互式推荐和强化学习等前沿技术。此外, KuaiRec 还提供了丰富的辅助信息, 如视频类别和用户社交关系, 为多维度的推荐系统研究提供了支持。

表 4-1 数据统计表

Dataset	Users	Items	Interactions	Sparsity
LFM-1b	1,2439	11,4686	196,8348	99.86%
KuaiRec	5,870	4,920	121,0845	95.80%

4.3.2 评价指标

$NDCG@k$ ^[64]: $NDCG@k$ 是一种衡量推荐结果排序质量的指标, 用于评价推荐系统是否将用户最感兴趣的项目排在靠前位置。其计算基于累积增益, 即推荐列表中每个项目的相关性得分。过将较高的分数分配给较靠前的位置来衡量所推荐物品的排列顺序是否正确

$$DCG@k = \sum_{i=1}^k \frac{2^{rel_i-1}}{\log_2(i+1)} \tag{4-12}$$

$$IDCG@k = \sum_{i=1}^k \frac{1}{\log_2(i+1)} \tag{4-13}$$

$$NDCG@k = \frac{DCG@k}{IDCG@k} \tag{4-14}$$

Recall@k^[65]: Recall@k 用来衡量推荐系统在前 k 个推荐项中找回用户真实感兴趣的项目的比例，主要关注推荐列表的覆盖率。

4.3.3 基线模型

FPMC^[44]: FPMC 是一种结合了马尔可夫链和矩阵分解的个性化推荐模型。它通过捕捉用户最近的行为序列和物品之间的转移概率，为用户提供个性化推荐。

NextItNet^[46]: NextItNet 是一种基于卷积神经网络（CNN）的序列推荐模型。通过堆叠多个有孔卷积层（Holed Convolutional Layers），NextItNet 能够扩大感受野，同时利用残差块结构简化深度网络的优化。

GRU4Rec^[45]: GRU4Rec 是一种基于门控循环单元（GRU）的会话推荐模型。它能够有效捕捉用户在会话中的行为模式，并通过门控机制动态调整信息流动。

SASRec^[48]: SASRec 是一种基于自注意力机制的序列推荐模型。它利用 Transformer 架构中的自注意力机制，能够捕捉用户行为序列中的长期依赖关系，而不仅仅是最近的行为。

4.3.4 实验结果

4.3.4.1 对比实验分析

在性能实验中，通过 LFM-1b 和 KuaiRec 两个数据集对不同推荐模型进行了评估。LFM-1b 数据集具有稀疏的用户-项目交互特性，而 KuaiRec 数据集则表现出较高的交互稠密性。这种差异为模型的性能表现提供了不同的挑战和机遇。

表 4-2 LFM-1b 数据集评估表

Target	FPMC	NextItNet	GRU4Rec	SASRec	SeqPE
Recall@5	0.174	0.026	0.278	0.291	0.292
Recall@10	0.201	0.044	0.274	0.340	0.340
Recall@20	0.229	0.068	0.306	0.386	0.386
NDCG@5	0.142	0.016	0.189	0.210	0.216
NDCG@10	0.151	0.022	0.232	0.226	0.232
NDCG@20	0.158	0.028	0.239	0.238	0.244

表 4-3 KuaiRec 数据集评估表

Target	FPMC	NextIttNet	GRU4Rec	SASRec	SeqPE
Recall@5	0.018	0.035	0.057	0.056	0.058
Recall@10	0.025	0.054	0.081	0.080	0.084
Recall@20	0.038	0.084	0.114	0.113	0.117
NDCG@5	0.013	0.023	0.040	0.039	0.041
NDCG@10	0.016	0.029	0.048	0.047	0.050
NDCG@20	0.019	0.037	0.056	0.056	0.058

在稀疏数据场景（LFM-1b）下，模型需要在有限的用户行为信息中有效捕捉用户偏好，同时避免过拟合。实验结果显示，SeqPE 在 Recall@5、Recall@10、Recall@20 以及 NDCG@5、NDCG@10、NDCG@20 等指标上均取得了与 SASRec 相当甚至略高的成绩，尤其在 NDCG@5 和 NDCG@20 上表现更为突出。这表明 SeqPE 在稀疏数据场景下具有较强的泛化能力和准确的推荐性能，能够有效应对数据稀疏性带来的挑战。在稠密数据场景（KuaiRec）下，模型可以利用更丰富的用户行为信息来学习用户偏好，但同时也需要处理更复杂的模式和噪声。实验结果表明，SeqPE 在 Recall 和 NDCG 的各项指标上均优于其他模型，尤其是在 Recall@20 和 NDCG@20 等指标上，其优势更为明显。这表明 SeqPE 不仅能够充分利用稠密数据中的信息，还能在复杂的用户行为模式中保持高效的推荐性能。

综上所述，SeqPE 在稀疏和稠密数据场景下均展现出卓越的性能，证明了其不同数据特性和复杂度下的强大鲁棒性和适应性。这一实验结果表明，SeqPE 能够有效应对不同数据分布和交互密度的挑战，为推荐系统在多样化应用场景中的实际部署提供了有力支持。

4.3.4.2 消融实验分析

本实验旨在探究不同特征对序列推荐模型性能的影响。实验共涉及四个模型：SeqPE-n，作为基线模型，不使用任何额外信息；SeqPE-oi，在 SeqPE-n 的基础上仅使用 item 热度分支；SeqPE-oa，在 SeqPE-n 的基础上仅使用作者热度分支；以及 SeqPE-a，同时使用 item 热度分支和作者热度分支。

表 4-4 KuaiRec 数据集中消融实验评估表

Target	SeqPE-n	SeqPE-oa	SeqPe-oi	SeqPE-a
Recall@5	0.056	0.057	0.056	0.058
Recall@10	0.080	0.082	0.081	0.084
Recall@20	0.113	0.113	0.114	0.117
NDCG@5	0.039	0.040	0.039	0.041
NDCG@10	0.047	0.048	0.047	0.050
NDCG@20	0.056	0.056	0.056	0.058


实验结果显示，SeqPE-a 在所有评估指标上均表现最佳，表明同时使用 item 热度分支和作者热度分支能够显著提升模型的推荐能力和推荐质量。具体来看，SeqPE-a 在 Recall@5、Recall@10 和 Recall@20 指标上均优于 SeqPE-n，分别达到了 0.058、0.084 和 0.117，相较于 SeqPE-n 的 0.056、0.080 和 0.113 有明显提升。在 NDCG@5、NDCG@10 和 NDCG@20 指标上，SeqPE-a 也分别达到了 0.041、0.050 和 0.058，优于 SeqPE-n 的 0.039、0.047 和 0.056。此外，SeqPE-oi 和 SeqPE-oa 在部分指标上也略优于 SeqPE-n，表明仅使用 item 热度分支或作者热度分支对推荐能力有一定的促进作用。具体来看，SeqPE-oi 在 Recall@10 和 Recall@20 指标上略高于 SeqPE-n，而 SeqPE-oa 在 Recall@5 和 Recall@10 指标上略高于 SeqPE-n。在 NDCG@10 指标上，SeqPE-oi 与 SeqPE-n 持平，SeqPE-oa 略高于 SeqPE-n

实验结果表明，同时使用 item 热度分支和作者热度分支能够显著提升序列推荐模型的性能，这在短期、中期和长期推荐能力上均有体现。


4.3.4.3 超参数实验分析

本实验旨在探究热度聚类的潜在主题个数 K 对推荐系统性能的影响。实验选择了四个不同的 K 值：16、32、64 和 128，并记录了对应的 Recall@20 和 NDCG@20 指标值。实验的目的是通过分析这些指标随 K 值变化的趋势，找到最优的潜在主题个数，以平衡推荐的召回率和精确度，从而提升推荐系统的整体性能。

...



(a) Recall 指标



(b) NDCG 指标

图 4-3 KuaiRec 数据集上的 K 值实验图

实验结果显示,随着潜在主题个数 K 的增加,Recall@20 和 NDCG@20 指标呈现出先上升后趋于平稳甚至略有下降的趋势。具体来看,Recall@20 从 $K = 16$ 时的 0.110 提升到 $K = 64$ 时的 0.116,表明更多的潜在主题能够更好地覆盖用户的兴趣点,从而提高推荐的相关性。然而,当 K 进一步增加到 128 时,Recall@20 略微下降到 0.115,这可能是由于过多的潜在主题导致推荐列表中包含过多不相关的项,从而降低了推荐的精确度和召回率。同样地,NDCG@20 也呈现出类似的趋势,从 $K = 16$ 时的 0.0536 提升到 $K = 64$ 时的 0.0578,但当 K 增加到 128 时,NDCG@20 略微下降到 0.057,这进一步说明过多的潜在主题可能会引入噪声,分散有效。

实验结果揭示了热度聚类的潜在主题个数 K 对推荐系统性能的显著影响。在 K 较小时, 增加 K 能够有效提升推荐的相关性和多样性, 这表明更多的潜在主题有助于更好地覆盖用户的兴趣点。然而, 当 K 进一步增加时, 推荐性能出现了轻微的下降, 这可能是因为过多的潜在主题导致推荐列表中包含过多不相关的项, 从而降低了推荐的精确度和归一化折损累积增益。因此, 选择合适的潜在主题个数 K 对于优化推荐系统性能至关重要。未来的研究可以进一步探索其他特征对推荐系统性能的影响, 并在更大规模的数据集上验证模型的可扩展性和鲁棒性, 以期进一步提升推荐系统的整体性能。

4.4 本章小结

本文提出了一种多尺度热度信息融合的序列推荐模型 (SeqPE), 旨在解决现有序列推荐系统中热度信息尤其是内容提供者热度被忽视的问题, 从而提升推荐系统的准确性和性能。SeqPE 通过热度编码网络对内容热度进行多尺度编码, 并通过热度融合网络更精准地捕捉用户兴趣的动态演变。实验结果表明, SeqPE 在两个真实世界的数据集 (LFM-1b 和 KuaiRec) 上均表现出色, 显著提升了推荐的准确性, 尤其是在稀疏数据场景和稠密数据场景下均展现出卓越的性能。消融实验进一步验证了模型各部分的有效性, 证明了多尺度热度信息融合对推荐性能的重要作用。

在实验部分, SeqPE 模型通过广泛的对比实验验证了其有效性。实验结果表明, SeqPE 在 Recall 和 NDCG 等推荐指标上均优于现有的先进模型, 尤其是在稀疏数据场景 (LFM-1b) 和稠密数据场景 (KuaiRec) 下均展现出卓越的性能。消融实验进一步证明了热度信息在提升模型性能中的关键作用, 同时合适的热度聚类潜在主题个数对推荐性能至关重要。

第五章 公平感知的音乐推荐系统需求分析与设计

5.1 系统目标

在本章中本文将结合前面章节中的内容设计一个公平感知的音乐推荐系统旨在为音乐应用打造一个良好的用户环境与音乐环境。具体而言，一方面在流量入口的推荐场景为弱势用户群体提供准确且多样的音乐推荐服务以鼓励其使用应用，另一方面在用户长期消费的推荐场景为用户提供准确且多样的推荐服务以增加其用户体验与留存的可能性，进而促进音乐软件用户生态的健康发展。

在推荐服务设计方面，系统将采用多模块协同的方式实现公平且多样化的推荐。首先，基于 DMACR 模型实现 u2i 召回，从海量音乐曲库中筛选出与用户兴趣相关的候选音乐集。接着，在首页推荐环节，运用 FPOSO 模型，综合考虑用户个性化偏好及敏感信息，为不同用户群体提供公平且吸引人的推荐内容，确保弱势群体也能获得良好的推荐体验。

此外，在长消费场景下即猜你喜欢推荐场景，同样采用 DMACR 作为召回模型的同时借助 SeqPE 模型进行序列推荐，通过多尺度热度信息融合的方式根据用户的行为历史挑选中用户更加需要的下一首音乐。

5.2 需求分析

基于上述目标，针对系统面对的多个不同应用场景，绘制用户在这些场景下对系统功能性需求的用例图，如图 5-1 所示。




图 5-1 公平感知音乐推荐系统用例图

基于用例图，系统需要实现的主要功能包括以下几点：

用户验证与授权：系统需要实现对用户注册、登录以及登出的支持。用户完成注册并登录系统后，系统才能根据对应的用户 ID 获取相关数据，为用户提供音乐推荐等服务，保障用户的信息安全，也为用户提供更加个性化的服务。用户登出后，系统不再调取用户的相关数据。

音乐召回功能：系统在实现上述功能中存在以下问题：音乐推荐系统曲库庞大，在“广场推荐”和“猜你喜欢”的推荐中，对于结构复杂的排序模型而言，遍历曲库查找满足用户需求的音乐并不现实，巨大的计算量将导致用户难以即时获得推荐。因此，系统还需实现音乐召回功能。DMACR 模型为广场推荐和猜你喜欢提供召回源头的。其可以通过因果推断的方式削弱热度标签的影响，使得在保障准确率的前提下为用户提供更加多样化的召回内容。

广场推荐：针对用户在广场浏览音乐的场景，作为整个应用的流量入口，该场景下应用需要系统能够提供公平的推荐，为不同的敏感信息的用户提供合适的推荐，保障不同用户的用户体验，为构建合理的用户生态提供基础。

猜你喜欢：针对用户交互历史探索用户的下一首偏好，在这种长消费场景下用户更多关注音乐推荐能否提供能使用的推荐内容。

我的界面：用户在“我的”中可以查看并修改自己的个人信息以及浏览自己的历史收听音乐和历史浏览内容。此外，还提供用户的消费历史、个人信息设置等功能。

音乐播放界面：用户点击感兴趣的音乐后进入音乐播放界面，可以查看音乐的封面、基础信息，并播放音乐。该界面提供音乐封面、基础信息、播放三个功能，为用户提供良好的音乐播放体验。

5.3 系统设计

5.3.1 架构设计

音乐推荐系统的整体架构设计如图 5-2 所示。系统采用了经典的 C/S 架构，主要包含客户端和服务端两个部分。

服务端：服务端基于 Python 3.8 进行开发，后端服务采用 Flask 2.0 框架构建。使用关系型数据库 MySQL 存储用户个人信息、浏览记录、用户-音乐交互信息等结构化数据。对于音频文件与封面图片等非结构化文件，使用 MinIO 进行存储管理。同时，引入 Redis 作为缓存机制，用于缓存用户召回结果与模型特征，以提升系统性能和响应速度。

客户端：客户端采用 Flutter 框架开发，并以 APP 的形式呈现给用户，确保界面美观以及使用流畅，为用户提供良好的交互体验。



图 5-2 系统架构图

在具体使用过程中，用户首先需在 APP 中完成个人信息注册，系统会为其分配一个随机生成的用户 ID。完成注册后，用户登录 APP，即可在相应的功能模块中获取服务。在音乐推荐环节，服务端接收客户端发来的请求，根据用户 ID 从数据库中获取相关数据，经过推荐模型的处理后，将推荐结果以 JSON 格式返回给客户端，客户端解析后将相关内容呈现给用户。对于内容发布功能，服务端接收客户端的请求，从相关接口获取发布的内容数据，并将其存储到对应的内容数据库中。在内容浏览功能中，服务端从内容数据库中选取最新发布的数据返回给客户端，为用户提供最新的发布内容。与此同时，用户与系统的相关交互记录会被保存到数据库中，推荐模型可依据这些最新的交互数据为用户进行更精准的推荐，保障推荐的准确性和实时性。

为保障系统的安全性，对于用户个人信息以及相关的交互数据，在进行加密存储的同时，严格限制访问权限。此外，对系统的全部操作日志进行记录和存储，便于查找潜在的安全问题以及发生错误时的追踪分析。

5.3.2 模块设计

系统的功能模块架构如图 5-3 所示，涵盖了用户验证与授权、广场推荐、猜你喜欢、音乐召回、我的界面以及音乐播放界面等关键模块。用户验证与授权模块是系统的基础，支持用户注册、登录及登出操作，用户注册后获得唯一 ID，

登录系统后可享受个性化音乐推荐等服务，登出后系统停止访问用户数据，确保信息安全。广场推荐模块针对用户浏览广场音乐的场景，提供公平推荐，根据不同用户的敏感信息为他们提供合适的音乐推荐，提升用户体验。猜你喜欢模块旨在通过为用户提供更加精准的推荐效果以达成用户留存的效果。音乐召回模块解决了曲库庞大导致的推荐效率问题，基于 DMACR 模型，通过因果推断削弱热度标签的影响，在保障推荐准确率的同时，为用户提供更多样化的召回内容，为广场推荐和猜你喜欢提供丰富的候选音乐。我的界面模块允许用户查看和修改个人信息，浏览历史收听音乐和浏览内容记录，还提供消费历史和个人信息设置等功能。音乐播放界面模块则为用户提供音乐封面、基础信息查看以及播放控制等基本功能，确保用户在播放音乐时获得良好的体验。




图 5-3 功能架构图

5.3.3 模块详细设计

5.3.3.1 用户验证与授权

在使用的过程中，用户首先需要在 APP 中完成账号，用户首先点击注册按钮后开始注册流程，在注册界面用户需要填写用户的基础信息，邮箱，密码并且二次输入密码验证密码。信息填写完毕后，系统会为用户生成唯一的用户 ID。这个用户 ID 系统该用户的唯一标识。注册完成的用户可以在登录界面输入邮箱和密码进行账号验证，如果密码正确则获得 token 进入系统，否则提示账号或者密码错误。

5.3.3.2 音乐召回

音乐召回模块的核心目的为从广大的音乐库中完成针对于每一位用户完成 u2i 的召回任务，在离线阶段会使用定时任务在 DMACR 模型完成更新后，根据 DMACR 的公式将处理后的音乐向量全部送入 faiss 数据库中以备后续推荐任务

中使用。并且将处理后的所有的用户向量写入 Redis 数据库中为后续推荐任务作为索引使用。

在线召回服务中后端服务会首先查询对应的用户 id 在 Redis 是否存在足够的召回结果用于召回服务，如果召回结果足够则直接返回给排序服务用于召回，如果召回结果不足，则在 Redis 数据库中查询对应的用户嵌入，将其作为索引在 faiss 数据库中查询合适数量的音乐 id，将其补入 Redis 后并且将召回结果返回给排序服务。




图 5-4 召回服务流程图

5.3.3.3 广场推荐

在广场推荐的过程中(单曲推荐)模块中，希望可以找到可以最能满足各个类型的用户吸引更多用户的音乐内容，在用户进入广场且客户端缓存的内容不足以满足需要展示的数量的时候会发起广场推荐请求。

首先客户端会向广场排序服务请求排序服务，会向服务端发送需要的音乐数量与起始的音乐的偏移。服务端会先向广场排序服务发出对应的求情，随后广场排序服务会首先首先在 Redis 中查询需要的查询的范围是否被缓存过，如果已经

缓存过直接返回，否则向召回服务请求需要排序的音乐集合，随后从 Redis 中抽取对应的用户需要的敏感信息特征。将特征与候选集合传入到每日训练好的 FPOS0 模型中完成排序任务后，写入 Redis 中缓存后并且返回给客户端用于展示。服务端接收到排序服务对应的音乐 id 列表后会为其配上对应的前端展示需要的信息如图片 URL、音乐 ID、音乐 URL 等信息后返回给客户端用于展示。




图 5-5 广场排序服务顺序图

5.3.3.4 猜你喜欢

对于更加长期的消费场景，更加希望可以为用户提供更加精准的推荐服务。在用户从广场中点击单曲进入播放界面后，客户端将会向后端服务请求猜你喜欢推荐服务，后端服务在 MySQL 数据库查询用户最近 50 次的收听记录与对应的热度信息作为参数向猜你喜欢排序服务发出请求。由于序列推荐中的收听记录参数变化比较频繁，因此在猜你喜欢排序服务中不会缓存排序结果，每次请求均根据用户收听记录重新为用户预测推荐内容。猜你喜欢排序服务会首先向召回模块请求召回内容。随后将会根据用户的收听记录请求 SeqPE 排序模型返回对应的排序结果。将排序结果返回给后端服务。由于由于序列排序需要频繁调动模型，因此后端服务每次会返回前 50 个推荐结果，并且请求对应的展示信息给前端用于展示，以为用户提供更加舒适的用户体验。




图 5-6 猜你喜欢排序服务顺序图

5.3.3.5 我的模块

在系统个人中心模块中，用户可通过简洁的操作界面随时维护个人资料和回溯音乐播放轨迹。当触发个人信息更新操作时，客户端会立即向服务端发起数据同步请求。后端系统在捕获请求后，首先对请求参数进行结构化解析，随后通过事务锁机制对数据库实施原子化更新操作，保障多端数据的一致性。当触发回溯音乐播放轨迹请求时，会对用户的访问记录，以及音乐的相关信息查询，通过历史交互界面为用户展示查询到的用户交互历史。

5.3.4 数据库设计

在数据库设计中实体的关系如图 5-7 所示，主要包含用户、作者、音乐、标签四个实体。用户与音乐之间存在多对多的收听关系，即一个用户可以收听多个音乐，音乐也可以被多人收听。作者与音乐之间存在一对多的创建关系，即一个作者可以制作多个音乐，一个音乐仅允许有一个作者。音乐与标签之间存在多对多的绑定关系，即一种标签可以绑定多个音乐，一个音乐也允许绑定多个标签。




图 5-7 数据库 ER 图

音乐表存储音乐的相关信息，包括音乐 ID、音乐实际 URL、音乐名称、音乐图片 URL、详细信息、添加时间等。

表 5-1 音乐信息表

字段名	类型	描述	备注
music_id	BIGINT	音乐唯一 id	主键
music_file_path	VARCHAR	音乐存储路径	
music_name	VARCHAR	音乐名称	
music_pic_url	VARCHAR	音乐封面存储 路径	
detail	VARCHAR	音乐的介绍文 本	
artist_id	VARCHAR	音乐家 id	外键
add_time	DATE	音乐入库时间	

艺术家表格用于存储音乐的作者信息。其主要信息艺术家 ID 用于唯一表示每一位音乐家，艺术家名称，艺术家性别、艺术家出生日期、艺术家的介绍。

表 5-2 艺术家信息表

字段名	类型	描述	备注
artist_id	BIGINT	艺术家唯一 id	主键
artist_name	VARCHAR	艺术家名称	
gender	VARCHAR	艺术家性别	
birth_date	DATE	艺术家出生日 期	

用户表存储用户注册时填写的相关个人信息，主要包括用户 ID、邮箱、性别、出生日期等信息。

表 5-3 用户信息表

字段名	类型	描述	备注
uid	BIGINT	用户唯一 id	主键
gender	VARCHAR	用户性别	
birth_date	DATE	用户出生日期	
avatar_url	VARCHAR	头像 URL	
nickname	VARCHAR	昵称	
email	VARCHAR	注册邮箱	
password	VARCHAR	用户密码	

标签表用于对音乐进行分类或标注，用于音乐的展示模块与多样性召回模块，包含标签 ID、标签名称等信息。

表 5-4 标签信息表

字段名	类型	描述	备注
tag_id	BIGINT	标签唯一 id	主键
tag_name	VARCHAR	标签名称	

音乐-标签表关系表用于表示音乐被绑定的标签的关系，由于允许同一个音乐被绑定多个不同的标签因此需要使用音乐-标签表关系表来表示多对多的关系。音乐-标签表关系表主要包括音乐 ID、标签 ID。

表 5-5 音乐-标签关系表

字段名	类型	描述	备注
music_id	BIGINT	音乐唯一 id	主键、外键
tag_id	VARCHAR	标签唯一 ID	主键、外键

音乐-用户关系表用于用于描述用户与音乐的互动关系，内容包含了用户 ID、音乐 ID、行为类别、时间戳。

表 5-6 用户-音乐关系表

字段名	类型	描述	备注
uid	BIGINT	用户唯一 id	主键、外键
musid_id	VARCHAR	音乐唯一 ID	主键、外键
Action	VARCHAR	音乐操作类型	主键
Timestamp	Timestamp	用于存储用户的行为时间	主键

5.4 本章小结

本章在明确公平感知音乐推荐系统设计目标的基础上，确保系统能够均衡满足多方核心诉求。通过分层模块化设计方法，完成了涵盖技术架构搭建、基础功能实现与关键算法优化的完整方案，特别针对各子模块的业务逻辑进行了深度细化与可行性验证。后续章节将依托本章构建的技术框架，逐步推进系统的工程化落地与性能评估工作。

第六章 公平感知的音乐推荐系统实现与测试

6.1 系统实现

6.1.1 服务端实现

本系统服务端采用 Flask 框架进行架构设计，其主要功能在于快速响应客户端请求，并实现个性化音乐推送功能。服务端通过与前端界面进行交互协作，完成音乐推荐体系中的核心数据与媒体资源管理。具体而言，采用关系型数据库 MySQL 对用户资料、音乐属性等结构化信息进行存储与维护；而针对音频流文件、专辑封面图等非结构化数据，则通过分布式对象存储系统 MinIO 实现高效存取。值得强调的是，系统特别引入 Faiss 向量数据库技术，对音乐特征向量进行索引优化，大幅提升用户兴趣匹配的检索效率。上述技术架构的有机整合，在保障系统高效运行的同时，有效提升了音乐推荐的个性化水平与推送准确度。

6.1.1.1 服务端接口

在公平感知推荐系统的实现架构中，客户端与服务端之间采用 Restful API 进行数据交互，通过 JSON 格式进行结构化数据传递，既满足了不同业务场景的需求，又确保了交互过程的高效性和有序性。系统核心接口设计详见表 6-1，值得注意的是两类推荐功能接口均需接收用户唯一标识符 uid 作为参数，服务端基于该标识符从数据存储层中提取并整合关联数据信息。

表 6-1 后端服务接口表

URL	相关描述	访问方式
/user/register	用户登录接口	POST
/user/login	用户注册接口	POST
/user/history	用户历史接口	GET
/user/upload/avatar	上传用户头像接口	POST
/user/update/info	更新用户信息	POST
/recommend/square	广场推荐接口	GET
/recommend/like	猜你喜欢推荐接口	GET

6.1.1.2 推荐功能实现

本系统推荐模块由三个核心组件构成：音乐库候选集筛选的召回服务，面向敏感信息差异用户群体的公平推荐机制，以及基于多尺度热度信息融合的序列推荐系统。其中召回服务主要负责用户兴趣与音乐库内容的初步匹配，公平推荐机

制侧重不同属性用户的权益平衡,而序列推荐模块旨在为用户提供更加准确的推荐效果。

在召回服务旨在为用户生成一个个性化的音乐库排序候选集。算法接收三个输入参数:用户的唯一标识符(uid)、请求返回的音乐数量(length)和起始位置的偏移量(offset)。首先,系统会解析客户端的请求,并查询 Redis 缓存以确定是否已经存在该用户的推荐结果。如果缓存中存在,系统将直接从 Redis 中提取候选集并返回给用户。如果缓存中不存在,系统将从 Redis 获取用户的嵌入向量 E_u ,并利用该嵌入向量在 Faiss 数据库中检索出最优的 500 个匹配结果(result)。检索到的结果将被写入 Redis 缓存中,以用户 ID 为键("{uid}.item_set"),以便后续请求时能够快速访问。该流程确保了推荐结果的即时性和一致性,同时通过缓存机制提高了系统的响应速度。最终,该算法返回一个经过排序的音乐库候选集,为用户提供多样化的音乐选择。这一过程不仅考虑了用户的历史偏好,还通过多样性算法确保了推荐内容的广泛性,避免了推荐结果的单一化,增强了用户体验。

音乐召回服务的核心功能是构建个性化音乐推荐候选集。该模块运行时需接收用户 ID(uid)、期望结果数量(length)及起始偏移量(offset)三个核心参数。当用户发起请求时,系统优先检查 Redis 缓存中是否存在对应{uid}.item_set 的缓存记录。若存在有效缓存,则直接调用缓存数据返回前端;若不存在,则执行向量检索流程——首先获取用户特征向量,通过 Faiss 引擎进行近似最近邻搜索,获得 top500 匹配项。所有新检索结果均会建立 24 小时有效期的缓存副本,既保障推荐时效又提升系统吞吐效率。

表 6-2 召回服务伪代码

音乐多样性召回伪代码

INPUT:用户 uid, 请求长度 length, 偏移长度 offset

OUTPUT: 用户音乐库排序候选集

解析客户端请求, 请求 redis 查询用户请求的内容是否已经被缓存

IF 用户的请求内容已经被缓存:

 访问 Redis 缓存数据库得到候选数据 result

ELSE:

 访问 Redis 得到缓存的用户向量 E_u

 使用 E_u 作为索引访问 Faiss 数据库提取最优的 500 个匹配结果 result

 将查询到缓存结果写入到 Redis 名为{uid}.recall_set 的 key 中

return result

广场推荐算法的核心功能是动态生成广场内容展示方案,其运行流程基于用户身份标识、请求参数长度及偏移量进行初始化操作。系统会优先检测 Redis 缓

存中是否存在可用内容，若成功匹配则即时返回缓存记录。当缓存失效时，系统将依次执行以下处理流程：通过召回服务筛选出初步候选音乐列表，同时联动 MySQL 数据库获取用户权限信息，结合 FPOSO 模型进行多维特征分析计算最优推荐序列。在此过程中同步访问数据库获取内容展示元数据，最终将处理结果封装为 JSON 格式并反馈至客户端，确保输出的广场内容展示方案兼具个性化和多样性特征。

表 6-3 广场推荐服务伪代码

广场推荐
INPUT: 用户 uid, 请求长度 length, 偏移长度 offset
OUTPUT: 广场内容展示信息
解析客户端请求, 请求 redis 查询用户请求的内容是否已经被缓存
IF 用户的请求内容已经被缓存:
访问 Redis 缓存数据库并且返回用户的交互数据;
ELSE:
访问召回服务得到用户的候选音乐集合 I
访问 MYSQL 数据库查询用户的敏感信息 p
调用加载好的模型 FPOSO, 计算出根据候选集 I 计算出最合适的 topN 的推荐结果 T
调用 MYSQL 数据库查找 T 对应的展示需要的信息得到展示信息列表 R
将查询结果包装为 JSON 格式 result
return result

个性化推荐系统中的猜你喜欢算法基于用户唯一标识（uid）、请求数量（length）及起始偏移量（offset）等参数生成下一首推荐内容。当系统接收到用户请求时，首先会查询 Redis 缓存中是否存在可用的推荐数据，若存在则立即响应缓存内容；若未命中缓存，则触发召回服务获取候选音乐集合并同步查询 MySQL 数据库，调取用户历史行为数据与内容热度信息进行综合评估。随后通过预训练的 SeqPE 模型对候选音乐集合进行智能筛选，生成精准的 topN 推荐列表，继而从 MySQL 中提取相关展示字段，最终将处理结果封装为 JSON 格式并返回前端展示。

表 6-4 猜你喜欢排序服务伪代码

猜你喜欢推荐
INPUT: 用户 uid, 请求长度 length, 偏移长度 offset
OUTPUT: 广场内容展示信息
解析客户端请求, 请求 redis 查询用户请求的内容是否已经被缓存
访问召回服务得到用户的候选音乐集合 I
访问 MYSQL 数据库查询用户的历史交互信息 h 与历史热度信息 h^a, h^i 加载好的模型 SeqPE, 计算出根据候选集 I 计算出最合适的 topN 的推荐结果 T
调用 MYSQL 数据库查找 T 对应的展示需要的信息得到展示信息列表 R
将查询结果包装为 JSON 格式 result
return result

6.1.2 客户端实现

本系统采用 Flutter 框架构建 Android 客户端作为前端实现载体。用户通过界面交互触发操作指令后, 前端应用会将操作逻辑转化为标准化请求协议向服务端发起调用。服务端返回的响应数据经过解析引擎处理, 最终通过动态渲染机制生成可视化交互界面。具体页面设计方案如下所示。

6.1.2.1 登录界面

登录界面如图 6-1(a), 登录界面 APP 的访问入口。界面顶部显示欢迎信息和应用名称。用户需输入邮箱和密码进行身份验证, 输入框旁有相应的图标提示。若用户尚未注册, 可通过“注册新账号”链接跳转至注册页面。

6.1.2.2 注册界面

注册页面如图 6-1(b), 旨在引导新用户创建账户。用户需要填写个人信息, 包括邮箱、性别(提供男、女两个选项)、出生日期(用于年龄的动态计算)、密码以及确认密码。用户填写完所有必要信息后, 点击下方的“立即注册”按钮即可完成注册流程。




图 6-1 登录与注册界面

6.1.2.3 用户个人界面

个人中心界面集中呈现用户的账户信息与功能入口。界面顶端区域设有用户头像、昵称、性别及年龄等基础信息展示模块，核心功能区包含三项主要操作：个人信息配置、收听历史追溯以及账户注销服务。各功能模块均设有直观的图形标识，支持用户点触直达目标操作。界面采用扁平化设计语言，通过合理的视觉层级划分，有效提升账户管理的便捷性和个性化设置的操作效率。底部全局导航栏整合了跨页面跳转功能，用户可便捷切换至广场等核心业务模块。

6.1.2.4 个人信息修改界面

个人信息编辑模块主要用于用户对个人资料进行更新维护。可编辑项涵盖头像设置、昵称修改及包含出生日期与性别等隐私数据调整。所有信息调整完毕后，用户需点击位于页面底部的“提交修改”按钮以确认并保存更新内容。

6.1.2.5 历史记录界面

历史记录页面专门用于展示用户过去的播放记录。下方是一个音乐列表，列出了用户曾经播放过的音乐曲目。每首曲目旁边都标注了作者的名字，为用户提供了详细的曲目信息。“播放全部”的按钮可以一键播放所有列出的曲目。



图 6-2 用户中心、信息修改与历史收听界面

6.1.2.6 广场界面

音乐应用的首页推荐页面被称为“广场”。它旨在通过展示精选的音乐作品，为用户提供发现新音乐的途径。页面设计简洁，方便用户快速浏览和选择感兴趣的音乐。底部导航栏提供了快速访问其他功能，如社交圈子和个人中心的入口。此推荐系统将运用 FPOSO 模型来增强推荐的公平性和多样性。

6.1.2.7 播放界面

音乐播放界面设计顶部区域呈现正在播放曲目的名称及演唱者信息，界面核

心位置采用圆形艺术化呈现专辑封面。底部控制栏配置了布局简洁明了的操作按键，涵盖曲目切换与播放状态控制功能。进度条实时同步音轨时长信息，便于用户精准掌握播放进度。为提升个性化推荐效果，系统创新性采用 SeqPE 模型架构，该算法通过深度挖掘用户历史听歌行为特征，为用户提供精准的下一曲目预测。

6.1.2.8 音乐详情

歌曲详情页面主要用于展示当前播放歌曲的相关信息。用户可以在这里查看歌曲名称、演唱者，以及歌曲所属的相关标签。此页面还可能包含对歌曲的详细描述，帮助用户更好地了解歌曲的背景和特点。




图 6-3 广场、音乐播放与音乐详情界面

6.2 系统功能测试

为了保证系统的实现符合原本的预期，针对系统的主要功能设计测试用例进行功能测试，用于评估各个模块的执行情况。

6.2.1 登录与注册模块测试

在测试用户注册和登录模块时，首先让新用户打开 APP 并进入登录界面，点击“注册”按钮进入注册页面。用户在注册页面填写相关信息，包括邮箱和密码。当用户首次输入密码后，再次输入不同的密码并点击“注册”按钮时，系统会提示两次密码输入不一致，并阻止注册。随后，用户重新输入两次相同的密码并点击“注册”按钮，系统成功完成注册。用户返回登录界面，输入刚注册的邮箱和密码，点击“登录”按钮后，成功进入个人界面，且界面显示正确。

表 6-5 用户注册登录测试用例

用例编号	1
测试目的	测试用户注册登录模块是否正常
前置条件	新用户进入系统
测试步骤	1. 用户进入 APP 登陆界面，点击注册页面 2. 用户填写用户相关信息 3. 用户两次填写密码不同并且点击注册 4. 用户两次正确填写密码后点击注册 5. 用户在登录界面重新输入邮箱与密码 6. 用户进入个人界面
预期结果	用户注册如果两次密码输入不同则阻止用户注册并且提示用户，输入正确后注册成功，输入正确的账号与密码后成功登录 APP 并且页面显示正确。
测试结果	符合预期，测试通过

6.2.2 用户中心模块测试

针对用户中心模块的测试流程，首先需验证已注册用户账号存在有效收听记录。用户登录应用后，依次操作如下：通过底部导航栏切换至个人中心主页，选择个人信息编辑功能进行资料更新。完成内容修改并提交后，系统立即弹出'修改成功'提示框，此时返回个人中心主页，资料卡已实时更新为最新数据。随后通过'历史收听'入口浏览过往播放记录列表，系统精准呈现用户所有历史播放条目。随机选取某条音乐记录进行播放测试时，目标曲目的元数据、播放进度及控件状态均正常加载，音频流可无异常启停。全流程操作响应及时，界面元素渲染准确，各环节功能均达验收标准。

表 6-6 用户中心试用例

用例编号	2
测试目的	测试用户中心模块是否正常
前置条件	1.用户已经注册成功 2.用户存在收听记录
测试步骤	1. 用户点击底部导航栏进入我的界面 2. 点击设置个人信息按钮，进入修改信息界面 3. 修改用户的个人信息后点击确认修改按钮 4. 返回我的界面 5. 点击历史收听按钮 6. 点击收听历史中随机一个音乐 7. 进入收听界面
预期结果	用户注册如果两次密码输入不同则阻止用户注册并且提示用户，输入正确后注册成功，输入正确的账号与密码后成功登录 APP 并且页面显示正确。
测试结果	符合预期，测试通过

6.2.3 广场推荐模块测试

在广场推荐模块的功能验证环节，首先需确认测试用户已完成注册流程且通过身份核验。当用户登录 APP 主界面后，通过底部导航栏切换至广场功能页。系统将自动加载并呈现基于用户画像生成的定制化内容，该推荐算法需综合考虑用户的历史行为偏好与安全权限范围。操作人员点击音乐推荐卡片时，应准确跳转至包含播放控制、歌词显示等核心功能的音频界面。在触发播放指令后，需验证音频流能够即时响应并保持稳定输出。进一步点击封面缩略图时，系统须准确跳转至包含创作信息、版权声明等扩展内容的多维信息页，且需确保主界面与详情页的元数据严格同步。经全链路测试验证，推荐系统的内容分发机制运行正常，音乐播放组件的交互响应时间符合设计标准，多层次界面间的数据一致性得到有效保障。在完整测试周期内，各功能节点均达到验收标准，测试结论为通过。

表 6-7 广场推荐模块测试用例

用例编号	3
测试目的	测试广场推荐模块是否正常
前置条件	1.用户已经注册成功 2.用户具有合法的敏感信息
测试步骤	1.用户点击底部导航栏进入广场界面 2.刷新展示用户的推荐内容 3.点击广场中的音乐卡片，进入音乐播放界面 4.播放对应的音乐 5.点击音乐封面图片进入音乐详情界面
预期结果	广场中能够正确显示推荐内容，点击音乐卡片后可以进入正确的音乐播放界面，点击音乐播放按钮后可以正确的播放音乐，进入详情界面后可以正确的展示音乐详细信息其中的信息内容与音乐卡片中的内容相同。
测试结果	符合预期，测试通过

6.2.4 猜你喜欢推荐模块测试

在测试“猜你喜欢”推荐模块时，首先确保用户已经成功注册。用户打开 APP 后，点击广场中的音乐卡片，进入音乐播放界面。在播放界面中，用户点击“下一首”按钮，系统应成功加载并切换到下一首音乐，并正确显示该音乐的播放界面。点击播放按钮后，音乐应正常播放。随后，用户点击音乐封面图片，进入音乐详情界面，系统应正确展示该音乐的详细信息。整个测试过程中，用户能够成功加载并播放下一首音乐，播放功能正常，且音乐详情界面的信息显示准确。所有功能均按预期工作，测试通过。

表 6-8 猜你喜欢推荐测试用例

用例编号	4
测试目的	测试猜你喜欢推荐模块是否正常
前置条件	用户已经注册成功
测试步骤	1. 点击广场中的音乐卡片，进入音乐播放界面 2. 点击播放界面中的下一首的按钮 3. 播放切换后的音乐 4. 点击音乐封面图片进入音乐详情界面
预期结果	可以成功的加载下一首音乐，点击音乐播放按钮后可以正确的播放音乐，进入详情界面后可以正确的展示音乐详细信息。
测试结果	符合预期，测试通过

6.3 性能测试

完成系统核心功能模块的验证测试后，进一步对其响应性能展开检测，综合检验其在处理请求时的稳定性和可靠性。

表 6-9 各种操作响应时间

操作	响应时间(ms)
用户注册	160
用户登录	163
用户修改信息	185
用户上传头像	356
广场推荐	278
猜你喜欢推荐	397
音乐信息请求	149
浏览用户历史	202

测试数据显示，系统在用户基本操作模块（包括注册、登录及信息维护等）反应速度相当快，所有请求处理时长均控制在 500 毫秒阈值内。值得注意的是推荐功能的性能表现：其中广场推荐与猜你喜欢模块的加载速度稍慢一些，但仍符合行业基准要求。

6.4 本章小结

本研究聚焦于公平感知型音乐推荐系统的实现与测试，采用客户端-服务器架构构建完整技术方案。服务端以 Flask 框架为基础，整合 MySQL 关系型数据

库、MinIO 对象存储服务及 Faiss 相似性搜索库，构建了高效的数据管理方案与音乐推荐引擎。客户端基于 Flutter 跨平台框架实现，确保终端用户获得流畅的交互体验。整体架构包含三大核心组件：召回服务模块实现基础候选集筛选，广场推荐模块侧重群体偏好挖掘，猜你喜欢模块专注个体行为分析，通过融合多种个性化推荐算法，在保障推荐结果公平性的前提下兼顾精准度与多样性需求

在测试阶段，系统对登录、注册、用户信息修改、广场推荐等功能进行了全面测试，结果表明各项功能均按预期工作，测试通过。性能测试显示，系统在用户基本信息操作上响应迅速，推荐功能的响应时间也在合理范围内，整体性能稳定可靠。系统成功实现了公平感知的音乐推荐功能，为用户提供个性化且多样化的音乐体验。

第七章 总结与展望

7.1 总结

本文分析了音乐软件的用户环境、音乐环境与用户的长期留存三个角度的需求,并且以此作为依据设计了公平感知的音乐推荐系统。该系统可以有效的为不同的用户群体提供合适且多样的推荐,并且挖掘热度关联为用户提供了更好的推荐体验。本文的主要内容如下:

(1) 本文提出了个性化敏感偏好的公平推荐网络,主要解决了以往公平推荐中敏感信息建模过于平均化导致的性能与公平性的缺失。通过个性化敏感信息编码层对敏感信息对用户行为的影响效果进行建模生成个性化的敏感信息嵌入,随后利用敏感信息融合层将个性化的敏感信息与全局敏感信息进行融合动态的调整敏感信息对推荐结果的影响。实验结果表明,改进模型在两个数据集上的表现优于其他基准模型。并且在消融实验中验证了其各个结构的有效性,并且通过超参数实验探索了其超参数对于结果的影响。

(2) 本文提出了 DMACR 模型,一种通过因果推理和反事实推断增强推荐多样性的新颖召回网络。DMACR 的核心创新在于引入新的因果图模型,扩展传统因果图以纳入商品标签对排名分数的影响,从而更准确地捕捉用户偏好和商品特性。在训练阶段,DMACR 通过多任务学习框架,同时最小化用户-物品匹配损失、用户热度损失、商品热度损失和标签热度损失。测试阶段利用反事实推理调整推荐分数,消除标签的直接影响,为不同类型的音乐提供了更加平等的曝光机会。实验结果表明,DMACR 显著提升了推荐列表的标签多样性,增强了推荐系统的多样性,表现出良好的鲁棒性和通用性,为营造良好的音乐环境打好了基础。

(3) 本文提出了一种多尺度热度信息融合的序列推荐模型(SeqPE),用于提高序列推荐系统的推荐性能。SeqPE 通过热度编码网络对热度信息进行非线性的聚类学习不同热度之间的关联,并通过热度融合网络学习不同的维度的热度信息之间的关系。实验表明,SeqPE 在两个真实数据集(LFM-1b 和 KuaiRec)上优于现有模型,在推荐性能上得到了显著的提升。

(4) 本文结合前面所提到的三个研究点,设计并实现了一个公平感知的音乐推荐系统,通过结合用户敏感信息和历史行为,采用多模块协同设计,实现了精准且多样化的音乐推荐服务。系统包括多样性召回模块、公平排序模块和多尺度热度信息融合序列推荐模型,分别用于筛选多样化候选集、为弱势群组用户提供更好的个性化推荐和提供更加序列推荐的准确度。同时,系统还具备用户管理、

历史记录查看和音乐播放等功能模块,以提升用户体验。在功能测试中,系统验证了用户验证与授权、推荐服务、个人信息管理和音乐播放等功能的正确性和稳定性,确保在高并发场景下仍能为用户提供流畅、高效的音乐推荐服务。

7.2 展望

在本文的研究过程中,发现了仍然存在一些局限性。这些内容可以作为接下来的研究内容,主要包含以下几个部分。

(1) 在支持多维度敏感信息研究方面,本研究中借助 FPOSO 模型,在个性化敏感偏好建模领域有效的提升了推荐系统的公平性与准确性指标。然而当前模型构建仍存在局限性,其研究视角多集中于单一敏感维度,在需要协调多元敏感群体的应用场景中表现出适应性不足。针对此问题,后续研究拟构建多任务联合学习机制,通过并行处理性别、年龄、地域等多重敏感属性的特征交互,建立多维度的参数优化体系。这种协同学习架构不仅能够精准捕捉不同群体间的特征差异,还可实现多维度敏感信息的动态平衡,推动推荐系统公平性评估体系的完善。

(2) 多任务动态权重调节机制。现有 DMACR 模型采用多任务学习框架,在用户-物品匹配度优化与多维度热度平衡方面取得进展,但任务权重参数仍采用固定配置模式。这种静态设定难以适应复杂的数据分布特征及用户行为的动态变化规律。后续研究可尝试引入强化学习机制实现权重动态优化,具体可设计综合考量推荐精度、多样性及公平性指标的奖励函数,借助 DQN、PPO 等强化学习算法实现权重参数的动态调控。这种智能化调节策略不仅能够增强模型的环境适应能力,还能依据不同数据特征和应用场景自动平衡各优化目标,从而提升推荐系统的综合性能表现。

(3) 对于热度网络的支持。在 SeqPE 模型中,虽然考虑了多尺度的热度序列以达到不同热度信息之间的关联,然而仍然缺乏更加广泛的关联在未来的工作中可以考虑引入图神经网络使其可以更加广泛的链接不同的热度信息。进而更好的提升性能。

参考文献

- [1] KOREN Y, BELL R, VOLINSKY C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.
- [2] EDWARDS H, STORKEY A. Censoring representations with an adversary[J]. arXiv preprint arXiv:1511.05897, 2015.
- [3] CHEN L, WU L, HONG R, et al. Revisiting graph based collaborative filtering: A linear residual graph convolutional network approach[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020.
- [4] WU L, YANG Y, ZHANG K, et al. Joint item recommendation and attribute inference: An adaptive graph convolutional network approach[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. 2020: 679-688.
- [5] YING R, HE R, CHEN K, et al. Graph convolutional neural networks for web-scale recommender systems[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018.
- [6] 钱忠胜,王亚惠,俞情媛,等.利用伪重叠判定机制的多层循环 GCN 跨域推荐[J/OL].软件学报,1-23[2025-06-04].<https://doi.org/10.13328/j.cnki.jos.007289>.
- [7] 王路桥,周洋涛,李青山,等.基于大语言模型的多智能体协作代码评审人推荐[J/OL].软件学报,2025,(06):2558-2575[2025-06-04].<https://doi.org/10.13328/j.cnki.jos.007326>.
- [8] EKSTRAND M D, TIAN M, AZPIAZU I M, et al. All the cool kids, how do they fit in?: Popularity and demographic biases in recommender evaluation and effectiveness[C]//Conference on Fairness, Accountability and Transparency. PMLR, 2018: 172-186.
- [9] EKSTRAND M D, TIAN M, KAZI M R I, et al. Exploring author gender in book rating and recommendation[C]//Proceedings of the 12th ACM Conference on Recommender Systems. 2018.
- [10] LAMBRECHT A, TUCKER C. Algorithmic bias? An empirical study of apparent gender-based discrimination in the display of STEM career ads[J]. Management Science, 2019, 65(7): 2966-2981.
- [11] SWEENEY L. Discrimination in online ad delivery[J]. Communications of the ACM, 2013, 56(5): 44-54.
- [12] YAO S, HUANG B. Beyond parity: Fairness objectives for collaborative filtering[J]. Advances in Neural Information Processing Systems, 2017, 30.

- [13] BEUTEL A, CHEN J, ZHAO Z, et al. Data decisions and theoretical implications when adversarially learning fair representations[J]. arXiv preprint arXiv:1707.00075, 2017.
- [14] BOSE A, HAMILTON W. Compositional fairness constraints for graph embeddings[C]//International Conference on Machine Learning. PMLR, 2019.
- [15] ZHAO C, WU L, SHAO P, et al. Fair representation learning for recommendation: A mutual information perspective[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2023.
- [16] DAI E, WANG S. Say no to the discrimination: Learning fair graph neural networks with limited sensitive attribute information[C]//Proceedings of the 14th ACM International Conference on Web Search and Data Mining. 2021.
- [17] WU L, CHEN L, SHAO P, et al. Learning fair representations for recommendation: A graph-based perspective[C]//Proceedings of the 30th World Wide Web Conference. 2021.
- [18] WU C, WU F, WANG X, et al. Fairness-aware news recommendation with decomposed adversarial learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021.
- [19] DAI S, LIN H, ZHAO Z, et al. POSO: Personalized cold start modules for large-scale recommender systems[J]. arXiv preprint arXiv:2108.04690, 2021.
- [20] ZIEGLER C N, MCNEE S M, KONSTAN J A, et al. Improving recommendation lists through topic diversification[C]//Proceedings of the 14th International Conference on World Wide Web. 2005.
- [21] CARBONELL J, GOLDSTEIN J. The use of MMR, diversity-based reranking for reordering documents and producing summaries[C]//Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. 1998.
- [22] ASHKAN A, KVETON B, BERKOVSKY S, et al. Optimal greedy diversity for recommendation[C]//Proceedings of the 24th International Joint Conference on Artificial Intelligence. 2015.
- [23] LIN Z, WANG H, MAO J, et al. Feature-aware diversified re-ranking with disentangled representations for relevant recommendation[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022.
- [24] QIN L, ZHU X. Promoting diversity in recommendation by entropy regularizer[C]//Proceedings of the 23rd International Joint Conference on Artificial Intelligence. 2013.
- [25] SHA C, WU X, NIU J. A framework for recommending relevant and diverse items[C]//Proceedings of the 25th International Joint Conference on Artificial Intelligence. 2016.

- [26] LI S, ZHOU Y, ZHANG D, et al. Learning to diversify recommendations based on matrix factorization[C]//Proceedings of the 2017 IEEE 15th International Conference on Dependable, Autonomic and Secure Computing. IEEE, 2017.
- [27] SIDANA S, LACLAU C, AMINI M R. Learning to recommend diverse items over implicit feedback on PANDOR[C]//Proceedings of the 12th ACM Conference on Recommender Systems. 2018.
- [28] CHENG P, WANG S, MA J, et al. Learning to recommend accurate and diverse items[C]//Proceedings of the 26th International Conference on World Wide Web. 2017.
- [29] HAN I, KAMBADUR P, PARK K, et al. Faster greedy MAP inference for determinantal point processes[C]//International Conference on Machine Learning. PMLR, 2017.
- [30] WARLOP R, MARY J, GARTRELL M. Tensorized determinantal point processes for recommendation[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019.
- [31] WILHELM M, RAMANATHAN A, BONOMO A, et al. Practical diversified recommendations on YouTube with determinantal point processes[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018.
- [32] PEARL J. Causality[M]. Cambridge: Cambridge University Press, 2009.
- [33] CHEN L, ZHANG H, XIAO J, et al. Counterfactual critic multi-agent training for scene graph generation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019.
- [34] TANG K, NIU Y, HUANG J, et al. Unbiased scene graph generation from biased training[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020.
- [35] PARAFITA Á, VITRIÀ J. Explaining visual models by causal attribution[C]//Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision Workshop. IEEE, 2019.
- [36] AGARWAL A, TAKATSU K, ZAITSEV I, et al. A general framework for counterfactual learning-to-rank[C]//Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. 2019.
- [37] ZHANG Y, FENG F, HE X, et al. Causal intervention for leveraging popularity bias in recommendation[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2021.
- [38] SCHNABEL T, SWAMINATHAN A, SINGH A, et al. Recommendations as treatments: Debiasing learning and evaluation[C]//International Conference on Machine Learning. PMLR, 2016.

- [39] LIANG D, CHARLIN L, BLEI D M. Causal inference for recommendation[C]//Workshop on Causation: Foundation to Application at UAI. 2016.
- [40] BONNER S, VASILE F. Causal embeddings for recommendation[C]//Proceedings of the 12th ACM Conference on Recommender Systems. 2018.
- [41] LIANG D, CHARLIN L, MCINERNEY J, et al. Modeling user exposure in recommendation[C]//Proceedings of the 25th International Conference on World Wide Web. 2016.
- [42] ZHENG Y, GAO C, LI X, et al. Disentangling user interest and conformity for recommendation with causal embedding[C]//Proceedings of the Web Conference 2021. 2021.
- [43] WEI T, FENG F, CHEN J, et al. Model-agnostic counterfactual reasoning for eliminating popularity bias in recommender system[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021.
- [44] BOONEKAMP M, DECHAMBRE A, JURANEK V, et al. FPMC: A generator for forward physics[J]. arXiv preprint arXiv:1102.2531, 2011.
- [45] TAN Y K, XU X, LIU Y. Improved recurrent neural networks for session-based recommendations[C]//Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. 2016.
- [46] TANG J, WANG K. Personalized top-n sequential recommendation via convolutional sequence embedding[C]//Proceedings of the 11th ACM International Conference on Web Search and Data Mining. 2018.
- [47] YUAN F, KARATZOGLOU A, ARAPAKIS I, et al. A simple convolutional generative network for next item recommendation[C]//Proceedings of the 12th ACM International Conference on Web Search and Data Mining. 2019.
- [48] KANG W C, MCAULEY J. Self-attentive sequential recommendation[C]//Proceedings of the 2018 IEEE International Conference on Data Mining. IEEE, 2018.
- [49] LEX E, KOWALD D, SCHEDL M. Modeling popularity and temporal drift of music genre preferences[J]. Transactions of the International Society for Music Information Retrieval, 2020, 3(1).
- [50] ANELLI V W, DI NOIA T, DI SCIASCIO E, et al. Local popularity and time in top-n recommendation[C]//Proceedings of the 41st European Conference on Information Retrieval. Springer, 2019.
- [51] JI Y, SUN A, ZHANG J, et al. A re-visit of the popularity baseline in recommender systems[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. 2020.

- [52] NAGATANI K, SATO M. Accurate and diverse recommendation based on users' tendencies toward temporal item popularity[C]//Proceedings of the RecTemp Workshop at RecSys. 2017.
- [53] BERG R V D, KIPF T N, WELLING M. Graph convolutional matrix completion[J]. arXiv preprint arXiv:1706.02263, 2017.
- [54] WANG Y, LIANG D, CHARLIN L, et al. Causal inference for recommender systems[C]//Proceedings of the 14th ACM Conference on Recommender Systems. 2020.
- [55] QIAN M, DAI F, GU X, et al. User popularity preference aware sequential recommendation[C]//Proceedings of the International Conference on Computational Science. Springer, 2023.
- [56] HARDT M, PRICE E, SREBRO N. Equality of opportunity in supervised learning[J]. Advances in Neural Information Processing Systems, 2016, 29.
- [57] PEDRESCHI D, RUGGIERI S, TURINI F. Discrimination-aware data mining[C]//Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2008.
- [58] DWORK C, HARDT M, PITASSI T, et al. Fairness through awareness[C]//Proceedings of the 3rd Innovations in Theoretical Computer Science Conference. 2012.
- [59] RAWLS J. Justice as fairness: A restatement[M]. Cambridge: Harvard University Press, 2001.
- [60] SWIETOJANSKI P, RENALS S. Learning hidden unit contributions for unsupervised speaker adaptation of neural network acoustic models[C]//Proceedings of the 2014 IEEE Spoken Language Technology Workshop. IEEE, 2014.
- [61] RENDLE S, FREUDENTHALER C, GANTNER Z, et al. BPR: Bayesian personalized ranking from implicit feedback[J]. arXiv preprint arXiv:1205.2618, 2012.
- [62] HARPER F M, KONSTAN J A. The MovieLens datasets: History and context[J]. ACM Transactions on Interactive Intelligent Systems, 2015, 5(4): 1-19.
- [63] CRAW S, HORSBURGH B, MASSIE S. Music recommendation: Audio neighbourhoods to discover music in the long tail[C]//Proceedings of the 23rd International Conference on Case-Based Reasoning. 2015.
- [64] SCHÜTZE H, MANNING C D, RAGHAVAN P. Introduction to information retrieval[M]. Cambridge: Cambridge University Press, 2008.
- [65] GUNAWARDANA A, SHANI G. A survey of accuracy evaluation metrics of recommendation tasks[J]. Journal of Machine Learning Research, 2009, 10(12).
- [66] HE X, LIAO L, ZHANG H, et al. Neural collaborative filtering[C]//Proceedings of the 26th International Conference on World Wide Web. 2017.
- [67] WU F, QIAO Y, CHEN J H, et al. MIND: A large-scale dataset for news

recommendation[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020.

[68] SCHEDL M. The LFM-1b dataset for music retrieval and recommendation[C]//Proceedings of the 2016 ACM International Conference on Multimedia Retrieval. 2016.

[69] GAO C, LI S, LEI W, et al. KuaiRec: A fully-observed dataset and insights for evaluating recommender systems[C]//Proceedings of the 31st ACM International Conference on Information & Knowledge Management. 2022.