

文献引用格式: 范凯燕, 胡彦红. 基于 LSTM 模型的音乐推荐系统研究 [J]. 电声技术, 2024, 48(9): 136–138.

FAN K Y, HU Y H. Research on music recommendation system based on LSTM model [J]. Audio Engineering, 2024, 48(9): 136–138.

中图分类号: TP183

文献标识码: A

DOI: 10.16311/j.audioe.2024.09.042

基于 LSTM 模型的音乐推荐系统研究

范凯燕, 胡彦红

(郑州科技学院, 河南 郑州 450000)

摘要: 随着音乐推荐技术的快速发展, 如何提升音乐推荐系统的准确性和用户满意度成为研究的重点。研究一种结合梅尔频率倒谱系数 (Mel-Frequency Cepstral Coefficients, MFCC)、长短期记忆 (Long Short-Term Memory, LSTM) 网络、内容推荐方法的音乐推荐系统, 并通过 MATLAB 平台进行测试。结果表明, 该推荐系统表现良好。

关键词: 音乐推荐; 梅尔频率倒谱系数 (MFCC); 长短期记忆 (LSTM); 内容推荐

Research on Music Recommendation System Based on LSTM Model

FAN Kaiyan, HU Yanhong

(Zhengzhou University of Science and Technology, Zhengzhou 450000, China)

Abstract: With the rapid development of music recommendation technology, how to improve the accuracy and user satisfaction of music recommendation system has become the focus of research. A music recommendation system combining Mel-Frequency Cepstral Coefficients (MFCC), Long Short-Term Memory (LSTM) network and content recommendation method is studied. The test was carried out by MATLAB platform. The results show that the recommendation system performs well.

Keywords: music recommendation; Mel-Frequency Cepstral Coefficients (MFCC); Long Short-Term Memory (LSTM); content recommendation

0 引言

随着互联网的普及, 音乐推荐系统作为连接用户与海量音乐资源的重要桥梁, 可以显著提升用户的听歌体验^[1]。然而, 传统音乐推荐方法难以满足日益增长的个性化推荐需求, 如基于协同过滤^[2-3]和内容过滤^[4-5]的方法。

近年来, 深度学习在推荐系统中的应用受到广泛关注和研究^[6], 尤其是长短期记忆 (Long Short Term Memory, LSTM) 模型^[7-8]。通过独特的记忆单元和门控机制, 该模型能够有效捕捉音乐数据中的时间依赖关系, 从而实现精准、个性化的音乐推荐^[9-10]。

在该背景下, 文章首先深入研究基于 LSTM 的音乐特征提取方法, 其次构建基于 LSTM 音乐特征

的音乐推荐系统, 最后设计实验评估该系统的音乐推荐效果。

1 基于 LSTM 的音乐特征提取

LSTM 单元由输入门、遗忘门、输出门组成。设输入序列为 $x=(x_1, x_2, \dots, x_t)$, 其中 x_t 表示第 t 时刻的输入向量; 隐藏状态序列为 $h=(h_1, h_2, \dots, h_t)$, 其中 h_t 表示第 t 时刻的隐藏状态向量; 细胞状态序列为 $c=(c_1, c_2, \dots, c_t)$, 其中 c_t 表示第 t 时刻的细胞状态向量。

输入门的计算公式为

$$i_t = \sigma(W_i \cdot x_t + U_i \cdot h_{t-1} + b_i) \quad (1)$$

式中: i_t 为第 t 时刻输入门的激活值, W_i 为输入向量的权重矩阵, U_i 为隐藏状态的权重矩阵, b_i 为偏置项, σ 为 Sigmoid 激活函数。

作者简介: 范凯燕 (1996—), 女, 硕士, 助教, 研究方向为软件工程。

遗忘门的计算公式为

$$f_t = \sigma(W_f \cdot x_t + U_f \cdot h_{t-1} + b_f) \quad (2)$$

式中: f_t 为第 t 时刻遗忘门的激活值, W_f 为输入向量的权重矩阵, U_f 为隐藏状态的权重矩阵, b_f 为偏置项。

细胞状态更新的计算公式为

$$\tilde{c}_t = \tanh(W_c \cdot x_t + U_c \cdot h_{t-1} + b_c) \quad (3)$$

$$c_t = f_t \cdot c_{t-1} + i_t \cdot \tilde{c}_t \quad (4)$$

式中: $\tilde{c}_t$ 为第 t 时刻候选细胞状态, W_c 为输入向量的权重矩阵, U_c 为隐藏状态的权重矩阵, b_c 为偏置项, $\tanh$ 为双曲正切激活函数。

输出门的计算公式为

$$o_t = \sigma(W_o \cdot x_t + U_o \cdot h_{t-1} + b_o) \quad (5)$$

$$h_t = o_t \cdot \tanh(c_t) \quad (6)$$

式中: o_t 为第 t 时刻输出门的激活值, W_o 为输入向量的权重矩阵, U_o 为隐藏状态的权重矩阵, b_o 为偏置项。

在提取音乐特征过程中, 输入向量 x_t 通常表示音乐信号的时域或频域特征, 如梅尔频率倒谱系数 (Mel-Frequency Cepstral Coefficients, MFCC) 等, 隐藏状态 h_t 则包含音乐信号在 t 时刻的综合特征信息。

2 基于内容的推荐优化方法

在获得 LSTM 模型的隐藏状态 h_t 后, 音乐推荐系统将基于这些深层特征向量进行内容推荐。设 N 首音乐的特征向量集合为 $\{h_1, h_2, \dots, h_N\}$, 其中 h_i 表示第 i 首音乐的特征向量, 而 $h_i = \{h_{i1}, h_{i2}, \dots, h_{iT}\}$, h_{it} 为第 i 首音乐在 t 时刻的隐藏状态向量。

音乐推荐系统需要计算用户已听音乐与候选音乐之间的相似度。设用户听过的音乐集合为 $\{u_1, u_2, \dots, u_M\}$, 其中 u_i 表示用户听过的第 i 首音乐的特征向量。可以使用余弦相似度计算用户已听音乐与候选音乐之间的相似度, 计算公式为

$$\text{sim}(h_i, h_j) = \frac{h_i \cdot h_j}{\|h_i\| \|h_j\|} \quad (7)$$

式中: $\text{sim}(h_i, h_j)$ 为第 i 首音乐与第 j 首音乐之间的相似度, $h_i \cdot h_j$ 为特征向量的点积, $\|h_i\|$ 和 $\|h_j\|$ 分别表示特征向量的模。

对于每首候选音乐 h_j , 计算其与用户已听音乐集合中的所有音乐的相似度, 并取平均值作为其最终的推荐得分。候选音乐的推荐得分计算公式为

$$\text{score}(h_j) = \frac{1}{M} \sum_{i=1}^M \text{sim}(u_i, h_j) \quad (8)$$

式中: $\text{score}(h_j)$ 为第 j 首候选音乐的推荐得分, M 为用户已听音乐的数量, u_i 为用户听过的第 i 首音乐的特征向量。

根据推荐得分对所有候选音乐进行排序, 得分越高的音乐越优先推荐给用户。另外, 为确保推荐结果的多样性, 文章引入一定的惩罚机制。候选音乐的最终推荐得分计算公式为

$$\text{final_score}(h_j) = \text{score}(h_j) - \lambda \cdot \text{novelty}(h_j) \quad (9)$$

式中: $\text{final_score}(h_j)$ 为第 j 首候选音乐的最终推荐得分; $\text{novelty}(h_j)$ 为候选音乐的新颖性指标; λ 为惩罚因子, 用于平衡推荐得分与新颖性之间的关系。

3 实验设计与结果分析

百万首歌曲数据集 (Million Song Dataset, MSD) 是一个包含 100 万首流行音乐的公开数据集。虽然该数据集中包含每首歌曲的元数据、音频特征等, 但是缺乏用户的听歌历史信息。因此, 文章结合包含用户听歌历史信息的 Last.fm 数据集进行测试, 实验方法如下。

第一, 数据预处理。从数据集中提取原始音频特征, 并利用 MATLAB 中的 Audio Toolbox 进行音频处理, 包括分帧和加窗等操作。预处理时的帧长为 1 024, 重叠率为 30%。

第二, MFCC 特征提取。从预处理后的音频信号中提取 MFCC 特征, 使用的梅尔滤波器数量为 40, 取的 MFCC 系数数量为 13。

第三, LSTM 模型训练。使用提取的 MFCC 特征作为输入训练 LSTM 模型, 以捕捉音乐信号中的时间依赖关系和深层次特征。该部分使用的核心工具箱为 Deep Learning Toolbox, 设置的隐藏单元数量为 100, 最大训练轮次为 50, 学习率为 0.01。

第四, 综合特征提取。利用训练好的 LSTM 模型对音乐数据进行特征提取, 得到每首音乐的综合特征向量。

第五,内容推荐。基于 LSTM 提取的综合特征向量,使用 pdist2 函数计算音乐之间的余弦相似度,并根据 Last.fm 数据集中的用户听歌历史评估方法的推荐效果,结果如表 1 所示。

表 1 基于 LSTM 模型的音乐推荐系统评估

指标	数值
准确率	0.87
召回率	0.82
F_1 值	0.84

由表 1 可知,基于 LSTM 模型的音乐推荐系统在准确率、召回率、 F_1 值指标上均具有出色的表现。准确率达到 0.87,意味着基于 LSTM 模型的音乐推荐系统推荐的音乐中有 87% 是用户实际感兴趣的,这反映出系统能够有效识别高质量的推荐项。召回率为 0.82,表明基于 LSTM 模型的音乐推荐系统在用户实际感兴趣的所有音乐中,能够成功推荐 82% 的音乐。这一结果表明系统具有较强的覆盖能力,能够为用户提供广泛的音乐选择并减少遗漏的重要推荐项。 F_1 值达到 0.84,显示基于 LSTM 模型的音乐推荐系统具有良好的平衡准确性和覆盖性。

4 结语

文章通过研究并验证一种音乐推荐方法,展示基于 MFCC、LSTM、内容推荐的集成技术在音乐推荐领域的应用潜力。研究表明,结合内容推荐算法后,基于 LSTM 模型的音乐推荐系统能够基于 LSTM 特征根据用户的听歌历史提供个性化的推荐。实验结果显示,基于 LSTM 模型的音乐推荐系统在准确性、覆盖率、综合表现上均达到了较高水平,证明了其在实际应用中的有效性。这为未来音乐推

荐系统的发展提供了宝贵的参考,也为进一步的优化和研究奠定了坚实的基础。

参考文献:

- [1] 谭学清,何珊.音乐个性化推荐系统研究综述[J].现代图书情报技术,2014(9):22-32.
- [2] 赵圆圆,张小雷.加权融合基于内容和协同过滤的音乐推荐算法[J].阜阳职业技术学院学报,2023,34(3):51-55.
- [3] 华泽,叶雨航.协同过滤算法及在个性化音乐推荐中的应用[J].现代计算机,2021(22):43-46.
- [4] 陈冬林,吴天昊,吴江,等.基于 word2vec 的内容过滤科技成果推荐模型研究[J].武汉理工大学学报(信息与管理工程版),2023,45(4):599-606.
- [5] 彭余辉,张小雷,孙刚.基于内容和协同过滤加权融合的音乐推荐算法[J].安庆师范大学学报(自然科学版),2021,27(2):44-48.
- [6] 黄立威,江碧涛,吕守业,等.基于深度学习的推荐系统研究综述[J].计算机学报,2018,41(7):1619-1647.
- [7] 何丽,袁斌.利用长短期记忆网络进行音乐流派的分类[J].计算机技术与发展,2019,29(11):190-194.
- [8] 余学兵,熊蕾,黄丽,等.基于长短期记忆的稀疏数据过滤推荐算法[J].计算机仿真,2023,40(2):395-398.
- [9] 胡峰松,张璇.基于梅尔频率倒谱系数与翻转梅尔频率倒谱系数的说话人识别方法[J].计算机应用,2012,32(9):2542-2544.
- [10] 柏顺,颜夕宏,张生平,等.基于梅尔频率倒谱系数与短时能量的低信噪比语音端点检测[J].南京师大学报(自然科学版),2021,44(2):117-120.

编辑:李如冰