

基于混合专家的共享账户推荐算法

岳厚平¹, 王新华^{2*}, 郭磊^{1*}, 刘培玉¹, 徐连诚¹

(1. 山东师范大学计算机与人工智能学院, 山东 济南 250358; 2. 山东师范大学图书馆, 山东 济南 250358)

摘要: 针对共享账户电视推荐场景下的行为序列混合、主导偏好时序变化问题, 提出一种基于混合专家的共享账户推荐算法 (MoE-SAR)。该方法通过混合专家网络分解行为序列, 并利用动态门控机制自适应融合专家输出, 以精准识别个体用户特征。同时, MoE-SAR 方法引入对比学习策略, 以最小化同源专家, 增强样本间距离、最大化不同专家的输出间互信息, 有效提升表征区分性与稳定性。此外, 该方法还结合 Transformer 进行时序建模, 以精准捕捉共享账户中个体用户的个性化偏好。实验结果表明, 在 HVIDEO 数据集的 E 域上, MoE-SAR 在 MRR@20 上较次优基线提升了 24.0%, 在 Recall@20 上提升了 10.8%。在 V 域上, MRR@20 提升了 8.0%, Recall@20 提升了 4.7%。

关键词: 共享账户; 混合专家; 推荐系统

中图分类号: TP391 **文献标志码:** A

引用格式: 岳厚平, 王新华, 郭磊, 等. 基于混合专家的共享账户推荐算法 [J]. 山东大学学报(理学版), 2026, 61(6): 13-24.

Shared-account recommendation with mixture-of-experts

YUE Houping¹, WANG Xinhua^{2*}, GUO Lei^{1*}, LIU Peiyu¹, XU Liancheng¹

(1. School of Computer Science and Artificial Intelligence, Shandong Normal University, Jinan 250358, Shandong, China;

2. Shandong Normal University Library, Jinan 250358, Shandong, China)

Abstract: This paper addresses the issues of behavior sequence mixing and temporal changes in dominant preferences in the shared account TV recommendation scenario by proposing a mixture-of-experts shared account recommendation (MoE-SAR) algorithm. This method decomposes behavior sequences using a mixture of experts network and adaptively fuses expert outputs through a dynamic gating mechanism to accurately identify individual user characteristics. Additionally, the MoE-SAR method introduces a contrastive learning strategy to minimize the distance between samples from the same source expert and maximize the mutual information between outputs from different experts, effectively enhancing the discriminability and stability of representations. Furthermore, this approach integrates Transformers for temporal modeling to accurately capture the personalized preferences of individual users within shared accounts. The experimental results indicate that on the E-domain of the HVIDEO dataset, MoE-SAR improves MRR@20 by 24.0% and Recall@20 by 10.8% over the second-best baseline. On the V-domain, MRR@20 improves by 8.0% and Recall@20 improves by 4.7%.

Key words: shared account; mixture-of-experts; recommendation system

0 引言

随着互联网技术的不断进步, 智能电视 (Smart TV) 已经成为家庭娱乐中不可或缺的一部分^[1]。近年来, 智能电视不仅提供了传统电视节目, 还通过内置的操作系统和应用程序支持流媒体服务、在线视频点播、游戏娱乐等多种功能, 使得用户可以在一个设备上实现多种娱乐需求。

收稿日期: 2025-08-21; 网络出版时间: 2026-02-28

基金项目: 国家自然科学基金资助项目 (62372277)

第一作者: 岳厚平 (1998—), 男, 硕士研究生, 研究方向为推荐系统. E-mail: houpingyue@163.com

* 通信作者: 王新华 (1970—), 男, 教授, 博士, 研究方向为分布式网络、推荐系统. E-mail: wangxinhua@sdu.edu.cn

郭磊 (1983—), 男, 教授, 博士, 研究方向为信息检索、社交网络和推荐系统. E-mail: leiguo.cs@gmail.com

流媒体电视服务的迅速发展和智能设备的普及,催生了个性化推荐系统的需求^[4]。推荐系统可以根据用户的历史观看记录、兴趣爱好和行为特征,自动推荐相关内容,从而提高用户的观看体验。然而,随着电视平台逐步从传统的固定播放模式向个性化推荐服务过渡,电视推荐系统面临的挑战也逐渐增多,尤其是如何在多用户环境中提供准确的个性化推荐,成为了一个亟待解决的问题^[5]。流媒体平台如 Netflix、YouTube、TikTok 等也日益成为电视观看的主流方式,吸引了大量用户订阅。

在当今的流媒体电视服务中,尤其是在家庭环境下,多个家庭成员往往共同使用同一个账户来观看电视节目,这种共享账户模式已经成为了普遍现象。共享账户不局限于家庭成员之间,朋友、同事等群体也常常选择共享一个账户,以便节省会员的服务费用。然而,在同一账户下,多个用户的观看偏好、兴趣和行为模式可能存在显著差异,如何精确地区分这些用户,并为每个用户提供个性化的推荐,成为了推荐系统面临的一个重大挑战^[6]。例如,在家庭账户中,父母可能偏好观看新闻节目,而孩子则喜欢卡通动画,老年人则喜欢观看戏曲节目。这些行为模式往往交织在同一个账户的行为日志中,导致传统推荐系统无法有效识别不同用户的个性化偏好,从而提供不准确的推荐。在没有明确的用户标识(如用户 ID)的情况下,如何有效解耦这些混合的行为,成为推荐系统的痛点问题。

现有的传统推荐方法通常隐式假设每个用户都有单一的、稳定的行为模式并且系统能够显式的根据用户表示进行个性化推荐^[4-5]。因此,在处理混合用户行为时,由于其他用户的行为产生了大量噪声,传统推荐方法可能会产生低效的推荐结果。近年来涌现出了一些方法用于解决共享账户推荐的问题。例如, π -Net 模型^[6]设计了一个并行信息共享网络,用于解决共享账户跨域序列推荐问题。该模型通过共享账户过滤单元识别不同用户的兴趣,并通过跨域传输单元将信息从一个域转移到另一个域,从而提高推荐性能。DA-GCN^[7]提出了一个基于图神经网络的模型,用于解决共享账户跨域序列推荐问题。该模型通过构建跨域序列图来表示用户和 item 之间的关系,并利用域感知图卷积网络和注意力机制学习用户和 item 的表示,从而提高推荐性能。Wen 等^[8]提出了一个名为 MISS 的多用户识别网络,该网络能够有效地捕捉跨会话 item 转换关系并区分同一账户下不同用户的行为,从而提高推荐结果的准确性。

尽管现有的共享账户推荐方法已取得一定进展,但仍存在局限性:(1) 现有方法通常通过直接假设共享账户中存在 k 个潜在用户嵌入来建模账户行为的耦合行为。然而,这种做法仅依赖于预设的潜在用户数目,无法揭示账户行为中潜在的原型模式,并且可能丢失更具代表性的用户行为特征。(2) 由于共享账户通常包含多个用户的混合行为,现有方法往往忽略了这些行为模式之间的复杂交互和噪声影响,导致生成的用户表示缺乏鲁棒性。在多个用户共同使用账户的情境下,混合交互数据更容易受到噪声的影响,从而降低推荐结果的精度。(3) 现有的工作大多采用简单的平均操作来聚合共享账户中不同潜在用户的嵌入,从而生成账户级别的表示。然而,这种方法未能考虑到不同用户在共享账户中的相对重要性,导致嵌入聚合结果可能不能真实反映主导用户的行为兴趣偏好,从而影响推荐的个性化质量。

为了应对共享账户中潜在用户行为的复杂性,本文提出混合专家共享账户推荐(MoE-SAR)模型。该模型通过以下设计解决现有方法的局限性:(1) 针对现有方法仅依赖预设潜在用户数的问题,MoE-SAR 不再直接假设固定数量的潜在用户嵌入,而是通过混合专家网络将共享账户的行为序列分解为多个专家表示,并利用动态门控机制自适应地融合各专家输出,从而揭示账户行为中的潜在原型模式,捕捉更丰富的用户特征。(2) 为解决鲁棒性不足和专家表示退化问题,本研究在混合专家网络引入对比学习策略。该策略通过约束同源专家生成的增强样本在特征空间中的嵌入向量距离最小化,并采用互信息最大化约束不同专家生成样本的嵌入向量,显著提升专家表征的区分性和均匀分布性^[9],从而增强模型对多用户耦合行为的抗噪能力。(3) 针对传统方法采用简单平均聚合潜在用户嵌入的局限性,MoE-SAR 模型利用动态门控机制对各专家输出进行加权融合,有效考虑了不同用户在共享账户中的相对重要性,从而生成更真实、具有代表性的账户级别表示。

本研究的主要贡献包括:

(1) 本研究提出 MoE-SAR 模型利用混合专家网络和动态门控机制,有效解耦共享账户中多用户混合的行为信号,提取细粒度特征。

(2) 为防止专家表示退化,模型引入对比学习策略,通过最小化同一专家生成的增强样本嵌入向量之间的距离并最大化不同专家输出间的距离,从而显著提升表示的均匀性与区分性。

(3) 结合 Transformer 编码器进行时序建模,实现专家输出的动态协同,从而精确捕捉共享账户下各用户的个性化偏好。

(4) MoE-SAR 模型在 HVIDEO 数据集上的表现明显优于现有基线方法,充分验证混合专家网络 and 对比学习策略在提升共享账户推荐效果中的关键作用。

1 相关工作

1.1 共享账户推荐系统

共享账户推荐(shared account recommendation, SAR)在多用户账户场景中备受关注。共享账户推荐系统的研究涵盖多种方法,旨在应对共享账户场景的挑战,并提高推荐的准确性。共享账户进行个性化推荐时,首先需要在混合用户行为模式中识别出个体用户,随后才能为不同的用户推荐适当的 item。例如,Bajaj 等^[1]采用基于相似度的聚类方法,旨在为在线电视账户中的不同个体用户提供个性化推荐服务。Jiang 等^[2]采用无监督框架与异构图来识别共享账户中的用户及其偏好。此外,Yang 等^[3]设计了基于无监督投影的用户识别方法,随后采用因子分解机技术来预测用户偏好,并据此生成个性化的推荐内容。Wang 等^[4]对消费日志中不同时间段内的用户偏好进行了分析,并应用了标准的用户-K 近邻(User-KNN)算法实现个性化推荐。Yang 等^[5]分析特定时间段内的 item 比例来推断用户序列,随后为已识别的用户提供个性化推荐。

最近,像 PSJNet^[6]这样的方法以端到端的方式处理共享账户序列推荐任务,它通过同时整合跨域信息,从而提升模型的整体性能。该方法基于一个假设,即账户中存在未明确标识的用户,并且整个账户是通过融合每个隐藏用户的独特特征来构建的。而 Guo 等^[7]使用最后的行为作为当前用户身份的依据。这些方法为解决共享账户推荐系统固有的挑战提供了独特的策略,有助于在共享账户场景中推进个性化推荐的发展。

1.2 基于混合专家的推荐方法

近年来,混合专家模型通过动态组合多个子网络提升模型的表达能力在推荐系统中受到广泛关注^[7-13]。现有的基于 MoE 的推荐系统工作主要是围绕多任务学习、多域推荐、多模态建模开展。

传统多任务学习模型因共享参数导致任务冲突。MMoE^[14]首次将 MoE 引入到多任务推荐,通过任务专属门控网络动态组合共享专家。类似地,SNR^[15]通过子网络的路由机制提升了参数共享的灵活性,而 Tang 等^[16]提出了 PLE 模型,该模型利用渐进式层次提取结构缓解了多任务学习中的目标冲突问题。在多域推荐任务中,M3oE^[17]提出多域多任务混合专家框架,通过解耦共享专家、领域专家和任务专家,结合两级融合机制实现跨领域知识迁移。但是,这些方法仍然面临着专家多样性不足且专家表示易受退化问题影响。尽管 Zhang 等^[18]针对多区域电视推荐场景,设计基于图神经网络的区域相似性门控机制,并结合对比学习方法抑制专家表示退化。然而,该方法并没有充分考虑多用户耦合行为问题。

不同于上述研究,本研究针对共享账户推荐场景的独特挑战,提出混合专家共享账户推荐(MoE-SAR)模型,以更精细地建模共享账户中的多用户行为。与传统 MoE 在多任务学习中的应用不同,MoE-SAR 采用混合专家结构解耦共享账户中的行为模式,并通过动态门控机制自适应融合各专家输出,从而有效应对共享账户中多用户行为的耦合问题。此外,MoE-SAR 进一步引入对比学习策略,用于缓解专家表示退化问题,提升模型的泛化能力和鲁棒性。

2 MoE-SAR 算法

2.1 问题定义

在共享账户的环境下,推荐系统面临着一项独特的挑战:如何准确区分和识别由多个潜在用户共享的账户中的行为。这一挑战的根本问题在于,同一账户中不同用户的行为往往是交织在一起的,而传统的推荐系统通常假设每个账户对应唯一的用户,从而失去了对用户个性化需求的有效建模。因此,如何在缺乏明确用户身份标识的情况下,从账户级别进行个性化推荐,成为了共享账户推荐(SAR)任务中的关键问题。

为此,本节首先定义了共享账户推荐任务的符号表示。设共享账户集合为 $U = \{U_1, U_2, \dots, U_k, \dots, U_{|U|}\}$, 其中, U_k 表示第 k 个共享账户。每个账户 U_k 是由多个潜在用户共同使用的,且这些用户的行为在账

户中是混合交织的。在 SAR 任务中,每个账户 U_k 可以与多个 item 进行交互,本节定义 item 集合为 $I = \{I_1, I_2, \dots, I_i, \dots, I_{|I|}\}$, 其 I_i 中是与账户 U_k 可能交互的第 i 个 item。

考虑到一个账户 U_k 的行为是由多个用户共同产生的,可以将账户 U_k 的历史行为序列按时间顺序组织为 $S_k = \{I_1, I_2, \dots, I_j, \dots, I_{|S_k|}\}$, 其中 I_j 表示第 j 个交互 item, 且 item 交互发生在时间顺序 j 上。

本文提出基于混合专家网络的推荐模型 MoE-SAR, 通过引入混合专家模块, 能够在不依赖显性用户身份的情况下识别共享账户中的潜在用户。本节定义在共享账户 U_k 中进行推荐的任务为预测下一个 item I_{j+1} 的概率:

$$P(I_{j+1} | S_k) \sim f(S_k), \quad (1)$$

其中, k 表示共享账户 U_k 的历史行为序列, S_k 是模型中需要学习的映射函数, 它通过对账户行为序列的建模来生成推荐结果。

2.2 MoE-SAR 概述

电视推荐系统作为智能电视的重要组成部分, 承担着根据用户偏好推荐电视节目和视频内容的任务。随着家庭成员数量的增加, 电视账户的共享模式越来越普遍。例如, 家庭中的父母和子女共享一个电视账户, 然而他们的兴趣爱好往往截然不同。父母可能更倾向于观看新闻或纪录片, 而孩子则偏好于动画片和游戏直播。在这种多用户共享同一账户的场景下, 传统的推荐系统面临着一个关键问题: 如何准确区分和识别不同用户的混合行为, 从而为每个家庭成员提供个性化的推荐服务。

传统推荐系统通常假设每个账户对应一个单一的用户, 忽略了共享账户中的多个用户身份。这种假设在家庭账户环境下显然不成立, 因为不同用户的行为在同一账户下是耦合的, 缺乏明确的身份标识。因此, 如何在没有明确用户身份的情况下, 根据共享账户的历史行为序列精确识别多个潜在用户, 并为每个用户提供个性化的推荐, 成为提升电视推荐系统准确性的亟待解决的挑战。为了解决这一挑战, 本文提出了基于混合专家网络的共享账户电视推荐 (MoE-SAR) 模型, 如图 1 所示。具体来说, MoE-SAR 模型主要包括 (1) 序列表示学习: 在 MoE-SAR 中, 本设计首先利用 Transformer 编码器对用户的历史行为序列进行建模, 捕捉时序信息。通过这种方式, 模型能够从时间维度上有效捕捉家庭成员的观看习惯与偏好演变。序列表示学习将原始的观看行为序列转化为包含时序特征的表征, 作为后续专家网络的输入。对于一个家庭共享账户, 父母和孩子可能有不同的观看频率和兴趣点, Transformer 的时序建模能力帮助模型捕捉这种动态变化。(2) 专家网络: MoE-SAR 模型引入了混合专家网络 (MoE), 每个专家网络负责对共享账户中的某一类用户行为进行建模。通过这种方式, MoE-SAR 能够有效识别多个用户, 并为每个用户提供个性化的推荐。(3) 多门混合对比专家机制: 为了克服专家表示退化问题, MoE-SAR 引入了多门混合对比专家机制。具体来说, 本研究通过对比学习策略最小化同一专家生成的增强样本的表示距离以提升相似性, 同时最大化不同专家的相同样本表示距离以提升区分能力。这一机制有效增强了专家表示的鲁棒性和平衡性, 使得模型能够在面对家庭账户成员的混合交互行为时, 始终保持良好的区分能力。(4) 预测层与损失函数: MoE-SAR 结合了交叉熵损失函数和对比损失函数, 进行联合优化。在推荐任务中, 模型利用交互历史预测下一个可能的观看内容, 而对比损失则帮助增强模型在多用户行为建模上的能力。最终, MoE-SAR 通过联合训练这两个损失函数, 在提升个性化推荐精度的同时, 成功实现了对共享账户中多个潜在用户的精准识别。

2.3 序列表示学习

在共享账户推荐任务中, 为了准确建模用户行为序列的时序信息, 本研究采用基于 Transformer 架构的编码器。该架构通过自注意力机制有效捕捉行为序列中元素间的长程依赖关系, 适合处理多用户共享账户中的复杂时序模式。MoE-SAR 模型算法是在每一层 Transformer 中通过以下 3 个主要步骤来处理输入序列的时序依赖关系: 首先, 多头自注意力机制用于计算序列中各 item 之间的动态关联权重, 使得模型能够捕捉到不同 item 间的长依赖关系。其次, 前馈网络采用 GeLU 激活函数的两层 MLP, 用以处理每个时刻的隐藏表示, 增强其非线性特征表达能力。最后, 残差连接与层归一化保证了信息在网络中的稳定流动, 有效避免了梯度消失或爆炸的问题。

设共享账户 U_k 的历史行为序列为 $S_k = \{I_1, I_2, \dots, I_T\}$, 其中 $T = |S_k|$ 为序列长度。通过可学习嵌入矩阵 $E_I \in \mathbb{R}^{|\mathcal{I}| \times d}$ 将每个 item 映射为稠密向量:

$$e_t = E_I(I_t) \in \mathbb{R}^d, \quad \forall t \in 1, 2, \dots, T, \quad (2)$$

其中, $|V|$ 表示 item 集合的大小, d 为嵌入维度。为了捕捉 item 在行为序列中的位置信息, 引入了位置嵌入矩阵 $P \in \mathbf{R}^{L \times d}$, L 为序列长度。第 t 个位置嵌入表示为

$$h_t^{(\text{pos})} = e_t + P_t \in \mathbf{R}^d, \quad (3)$$

该操作将 item 语义信息与位置信息相结合, 形成具有位置敏感性的初始表示。每个位置 t 对应的 $h_t^{(\text{pos})}$ 将作为 Transformer 编码器的输入。将位置增强后的序列表示 $H^{(\text{pos})} = [h_1^{(\text{pos})}, h_2^{(\text{pos})}, \dots, h_T^{(\text{pos})}]$ 输入至多层 Transformer 编码器进行处理得

$$H^{(\text{trn})} = \text{Transformer}(H^{(\text{pos})}) \in \mathbf{R}^{T \times d}, \quad (4)$$

其中, Transformer 编码器包含多个层级的自注意力机制和前馈网络。




图1 MoE-SAR 结构图

Fig.1 MoE-SAR architecture diagram

2.4 专家网络

为了有效解决共享账户中多个用户行为耦合的问题, 本文引入了混合专家网络机制^[24-26]。混合专家网络由多个专家网络(Experts)组成, 每个专家独立地处理输入表示, 并生成一个新的表示。专家网络通过门控机制动态选择合适的专家进行任务处理, 以此来模拟多用户环境中的行为差异。通过这种方法, 可以在共享账户推荐中更加准确地捕捉到不同用户的个性化行为模式。

假设专家网络的集合为 $\mathcal{E} = \{\mathcal{E}_1, \mathcal{E}_2, \dots, \mathcal{E}_N\}$, 其中 N 是专家数量。每个专家 $\mathcal{E}_i$ 由两层 MLP 组成, 且采

用 GeLU 作为激活函数,定义为

$$\mathcal{E}_i(h) = W_2^{(i)} \cdot \text{GeLU}(W_1^{(i)}h + b_1^{(i)}) + b_2^{(i)}, \quad (5)$$

其中, $W_1^{(i)}, W_2^{(i)} \in \mathbb{R}^{d \times d}$ 为权重矩阵, $b_1^{(i)}, b_2^{(i)} \in \mathbb{R}^d$ 为偏置项, $h \in \mathbb{R}^d$ 为输入。每个专家通过此结构独立地生成一个新的表示 h_i 。

为了动态选择专家进行加权组合,本方法设计了一个门控网络,计算每个专家的权重向量 $g_i \in \mathbb{R}^N$:

$$g_i = \text{softmax}(W_{\text{gate}} h_t^{(\text{trm})}). \quad (6)$$

其中, $W_{\text{gate}} \in \mathbb{R}^{N \times d}$ 是可学习的权重矩阵, $h_t^{(\text{trm})}$ 是通过 Transformer 编码后的隐藏状态, softmax 操作确保所有专家的权重之和为 1,即

$$\sum_{i=1}^N g_{i,i} = 1, \quad (7)$$

通过门控权重 g_i ,模型对各专家输出进行加权求和,最终得到融合后的专家表示 $h_t^{(\text{moe})}$:

$$h_t^{(\text{moe})} = \sum_{i=1}^N g_{i,i} \cdot \mathcal{E}_i(h_t^{(\text{trm})}), \quad (8)$$

其中, $h_t^{(\text{moe})} \in \mathbb{R}^d$ 融合了多个专家的贡献,通过加权组合不同专家的输出,提供了一个具有多样化特征的代表。

2.5 多门对比混合专家

为了缓解混合专家网络中专家表示退化的问题,并进一步提高在共享账户下区分不同用户行为的能力,本设计引入了对比学习策略来增强专家输出的鲁棒性。多门对比混合专家的核心思想是通过数据扰动生成专家输出的增强视图,并施加对比学习的约束,以最大化同一专家增强视图之间的对齐性,并促进不同专家之间的差异性。

因此,对于输入的隐藏状态 $h_t^{(\text{trm})}$,每个专家 $\mathcal{E}_i$ 会生成两个增强表示,分别为原始表示 $z_t^{(i,1)}$ 和通过 Dropout 操作扰动后的增强表示 $z_t^{(i,2)}$:

$$z_t^{(i,1)} = \mathcal{E}_i(h_t^{(\text{trm})}), \quad (9)$$

$$z_t^{(i,2)} = \mathcal{E}_i(\text{Dropout}(h_t^{(\text{trm})})), \quad (10)$$

其中, $\text{Dropout}(h_t^{(\text{trm})})$ 表示对输入进行 Dropout 操作,随机屏蔽部分神经元,生成扰动后的输入, $\rho = 0.1$ 为 Dropout 的概率。

为了增强专家表示的区分性,本方法引入对比损失。该损失函数旨在最小化同一专家生成的不同增强样本之间的表示差异,同时最大化不同专家表示之间的距离,从而有效缓解专家表示退化问题。首先,对每个专家生成的输出进行 L2 归一化处理,以保证不同专家的输出在同一维度上进行比较:

$$\tilde{z}_t^{(i,k)} = \frac{z_t^{(i,k)}}{\|z_t^{(i,k)}\|_2}, \quad k \in 1, 2,$$

其中, $z_t^{(i,k)}$ 是第 i 个专家的第 k 个增强表示,归一化后的表示 $\tilde{z}_t^{(i,k)}$ 具有单位范数,确保不同专家之间的相似度计算具有一致性。接下来,计算不同专家之间的相似度,对于每个样本 t ,计算每对专家 i 和 j 的相似度:

$$s_{ij} = \frac{\text{sim}(\tilde{z}_t^{(i,1)}, \tilde{z}_t^{(j,2)})}{\tau}, \quad (12)$$

其中, $\text{sim}(\cdot)$ 表示余弦相似度, τ 是温度系数。通过余弦相似度,来衡量不同专家的增强输出之间的相似度。

接下来引入对比损失函数,对于每个样本,构造一个对称相似度矩阵,其中对角线元素对应的是正样本对(即同一专家的原始输出与增强输出),非对角线元素对应的是负样本对(即不同专家的输出):

$$\mathcal{L}_{\text{cons}} = -\frac{1}{2N} \sum_{i=1}^N \left[\log \frac{e^{s_{ii}}}{\sum_{j=1}^N e^{s_{ij}}} + \log \frac{e^{s_{ii}}}{\sum_{j=1}^N e^{s_{ji}}} \right], \quad (13)$$

该损失函数由两部分组成,分别计算了 i 和 j 专家增强输出的相似度,通过交叉熵确保增强输出对齐,并最大化不同专家输出之间的差异性。对称的计算方式有助于进一步提升专家表示的多样性。

2.6 预测层和损失函数

最终的预测分数是通过加权后的专家输出和目标 item 的嵌入向量之间的点积来计算的。对于每个测

试样本,模型计算当前行为序列的表示 $h_i^{(moe)}$ 与目 item 的嵌入向量 e_{test} 的点积,得到预测分数 $\hat{y}$:

$$\hat{y} = h_i^{(moe)} \cdot e_{test}, \quad (14)$$

其中, $h_i^{(moe)}$ 是通过 MoE 组件加权融合后的最终序列表示, e_{test} 是目标 item 的嵌入向量。点积操作将行为序列表示与目标 item 的表示进行匹配,生成预测的交互得分。

推荐任务的损失 $\mathcal{L}_{rec}$ 采用交叉熵损失,用于优化模型在预测下一个 item 时的准确度。交叉熵损失计算如下:

$$\mathcal{L}_{rec} = - \sum_{i \in \mathcal{I}_{pos}} y_i \log \hat{y}_i + (1 - y_i) \log (1 - \hat{y}_i), \quad (15)$$

其中, y_i 是真实标签, $\hat{y}_i$ 是模型的预测分数。通过最小化交叉熵损失,模型能够学习如何准确地预测用户与 item 的交互概率。

最终的优化过程结合了推荐任务损失和对比损失,模型的训练目标是 minimized 总损失 $\mathcal{L}_{total}$, 即

$$\mathcal{L}_{total} = \mathcal{L}_{rec} + \lambda \mathcal{L}_{cons}, \quad (16)$$

其中, λ 是对比损失的权重系数,用于平衡推荐损失和对比损失的影响。通过联合优化, MoE-SAR 模型能够在提高推荐准确性的同时,增强专家表示的区分性,从而更好地适应共享账户中不同用户行为的建模需求。

3 实验设计

3.1 拟通过实验回答的研究问题

问题 1: MoE-SAR 模型与先进的基准模型相比表现如何?

问题 2: MoE-SAR 的关键组件是否有效,特别是专家网络、多门对比混合专家。

3.2 数据集

HVIDEO 数据集汇总了来自智能电视平台家庭账户的日志,涵盖了从 2016 年 10 月到 2017 年 6 月的内容,涉及教育、电影等多个领域。数据集包括针对不同年龄学生的教育视频和观看的电影、动画片和电视剧。由于家庭账户通常由多个家庭成员共享,该数据集收集了家庭内部的多样化行为,适用于面向共享账户序列推荐的任务。为了提高数据质量,实验排除了观看次数少于 10 次和观看时间少于 300 s 的日志。经过筛选后,最终的数据集包含 13 714 个家庭账户和 134 349 条观看序列。HVIDEO 数据集的详细信息如表 1 所示。

表 1 HVIDEO 数据集的统计信息
Table 1 Statistical information of the HVIDEO dataset

区域	Item 数量	交互数量	平均序列长度	账户数量	序列数量
E-domain	8 367	2 129 500	15.85	13 714	134 349
V-domain	11 404	1 893 784	14.09	13 714	134 349

3.3 评估指标

在本文的实验设计中,使用了 HVIDEO 数据集,它包括 E 域和 V 域两部分。本文选取每个域中所有序列的 85% 作为训练数据集,剩余部分的 15% 作为测试数据集。在评估阶段,将每个序列的最后一个 item 视为真实标签,旨在评估模型基于单个账户的历史行为序列预测下一个 item 的能力。

进一步,为了验证模型的有效性,本文展示了 Top-N 推荐结果,并采用了两个常用的评估指标: Recall@N 和 MRR@N。在实验中,本文设定 N 的值为 5 和 20。

(1) Recall@N 指标旨在衡量在 Top-N 推荐列表中模型所推荐的 item 对测试数据集中目标 item 的覆盖程度。该指标在评估时忽略 item 的具体排列顺序,因此特别适用于那些对 item 顺序要求不严格的场景。

(2) MRR@N (平均倒数排名) 指标通过计算目标 item 在推荐列表中倒数位置的平均值来评估模型性能,若目标 item 排名超出 Top-N 范围,则其排名视为零。与 Recall@N 指标不同, MRR@N 重视 item 的排列顺序,因此在 item 顺序对推荐效果至关重要的场景中, MRR@N 指标显得尤为重要。

3.4 基线方法

为了全面评估 MoE-SAR 模型的性能,本研究选取了 6 种不同类别的基线方法进行对比分析,这些基线方法包括:传统推荐方法、基于图对比学习的推荐方法、跨域推荐方法、序列推荐方法、考虑时间间隔的序列推荐方法以及共享账户序列推荐方法。

(1) 传统推荐方法

传统推荐系统主要基于用户-item 评分矩阵,通过协同过滤或内容过滤技术,利用用户历史行为或 item 特征来预测并推荐用户可能感兴趣的 item。

BPR-MF^[3]:该方法采用基于贝叶斯分析的手段,用于从隐式反馈数据中学习个性化排序。

NCF^[27]:该方法是一种基于深度神经网络的协同过滤通用框架,它通过将传统矩阵分解中的内积操作替换为多层感知机等神经网络结构,以非线性方式学习用户-item 交互函数,从而显著提升了对隐式反馈数据的建模能力。

LightGCN^[28]:该方法是轻量级 GCN 模型,通过省略非线性变换和特征转换,仅利用邻居信息聚合,高效捕捉用户与 item 的协同关系,从而提升推荐效果。

(2) 基于图对比学习的推荐方法

基于图对比学习的推荐方法是一种利用图结构来增强推荐系统学习能力的算法。这种方法的核心思想是通过对比学习来提高推荐模型对用户和 item 的表示学习能力。

LightGCL^[29]:该模型创新性地采用奇异值分解技术重构邻接矩阵,通过低秩近似实现图结构的全局协同模式提取与噪声过滤。

(3) 跨域推荐方法

跨域推荐方法通过迁移用户行为或 item 特征,利用协同过滤和嵌入共享缓解目标领域的数据稀疏性,并融合跨域知识提升推荐多样性。

NCF-MLP++^[3]:该方法是 NCF 方法的增强版,通过扩展协同过滤至不同域。

Conet^[30]:该方法通过引入跨连接单元实现源域和目标域的双向知识迁移,并利用稀疏结构自适应选择迁移的表示,从而提升推荐性能。

(4) 序列推荐方法

序列推荐方法通过分析用户历史行为序列的时序特性与上下文关联,挖掘 item 间动态依赖关系,预测用户交互偏好。

GRU4REC^[31]:该方法提出了一种基于 GRU 循环神经网络的推荐系统模型,用于解决基于会话的推荐问题。

(5) 考虑时间间隔的序列推荐方法

考虑时间间隔的序列推荐方法是一种将用户行为之间的时间差作为重要信息纳入建模的推荐算法。

Time-LSTM^[32]:该推荐方法提出改进的 LSTM 模型,通过时间门控机制结合用户行为间隔特征,捕捉兴趣动态变化,提升序列建模能力。

(6) 共享账户序列推荐方法

共享账户序列推荐方法是一种针对同一账户由多个用户共用导致混合行为序列问题的推荐算法。

π -Net^[3]:该模型可以同时为两个域生成推荐,并通过共享账户过滤单元(SFU)和跨域迁移单元(CTU)提取和共享有用信息,提高推荐性能。

PSJNet^[33]:该方法提出了并行拆分融合网络,通过并行建模识别不同用户角色和域的行为,从而实现更精准的推荐。

3.5 实验细节

MoE-SAR 模型基于 PyTorch 框架并采用 RecBole 推荐库实现^[33-34],通过 NVIDIA Quadro RTX 6000 GPU 进行加速。模型架构包 2 层 Transformer 编码器,其中每层配置 2 个注意力头。混合专家(MoE)组件包含 4 个专家网络,采用 GELU 激活函数。在正则化策略方面,本文对 Transformer 层和注意力机制均采用 0.5 的丢弃率,而 MoE 模块则使用 0.1 的专用丢弃率进行数据增强,批次大小设置为 256。对于每个基线模型,本文采用基础论文中记录的最优参数配置,并在 HVIDEO 数据集上进一步优化这些设置。

在基线模型的实验设计中,本研究遵循领域内标准并依据模型特性进行系统性参数配置。对于 LightGCL,嵌入维度设为 16,GCN 层数设为 2。LightGCN 采用 4 层结构,嵌入维度为 16。针对共享账户推荐模型, π -Net 和 PSJNet 的共享账户数量设为 4,Conet 的输入维度设为 2。在深度神经网络推荐模型中,NCF 和 NCF-MLP++训练时均采用 4 个负采样。GRU4REC 的 GRU 隐藏单元数均为 16。针对时间序列推

荐,Time-LSTM 的隐藏单元数量设为 128。此外,BPR-MF 采用用户和 item 嵌入维度均为 16 的配置,以保证实验的公平性和可比性。在原始论文建议值基础上进行跨数据集的适应性调整,实验过程中严格保持训练/测试集划分、负采样策略及评估协议的一致性^[35-37]。

3.6 对比实验结果

MoE-SAR 模型在 HVIDEO 数据集上与现有多项基线方法的对比结果如表 2($N=5$) 和表 3($N=20$) 所示。从实验数据中可以看出,MoE-SAR 在各项指标(MMR、Recall) 上均显著优于所有对比的基线模型,可以得到以下结论:

(1) 混合专家网络解耦多用户行为

实验结果表明,MoE-SAR 模型在 HVIDEO 数据集上的表现优于所有对比基线模型。这验证了混合专家网络在解决共享账户问题中的有效性。通过将共享账户中的行为序列输入到多个专家网络中,并利用门控机制动态加权融合各专家输出,MoE-SAR 能够更好地捕捉共享账户特性以及多用户的序列行为,实现多用户行为的解耦任务,完成共享账户的用户识别。

(2) 对比学习克服专家表示退化

MoE-SAR 模型显著优于基于 RNN 的推荐方法(如 GRU4REC、 π -Net 和 PSJNet),这说明引入对比学习策略在改善专家表示方面起到了关键作用。具体来说,对同一专家生成的两个增强样本的嵌入向量施加距离最小化约束,以确保它们在特征空间中具有较高的一致性。同时,对不同专家生成的同一样本嵌入向量施加距离最大化约束,从而提升它们的均衡分布性和区分能力。这样的机制有效克服了专家表示退化问题,使各专家能够捕捉到更加多样化的用户-item 交互特征。

(3) 时序建模与专家动态协同

本文提出的 MoE-SAR 方法在时序建模方面采用了 Transformer 编码器,能够捕捉用户行为序列中的全局依赖关系。同时,混合专家网络通过动态门控机制实现了各专家之间的有效协同。实验结果显示,MoE-SAR 模型超越了 GRU4REC 模型和 Time-LSTM 模型,并且与传统推荐方法(如 BPR-MF、NCF、Light-GCN、Conet、NCF-MLP++等) 之间的性能差异进一步凸显了共享账户问题和对比学习技术的重要作用。

表 2 HVIDEO 数据集的当 N 值为 5 时的对比实验结果
Table 2 Comparison experiment results of HVIDEO, when $N=5$

单位: %

模型	E-Domain		V-Domain	
	MRR	Recall	MRR	Recall
BPR-MF	2.82	2.52	4.12	5.26
NCF	5.77	11.25	22.99	27.21
LightGCN	11.55	20.70	54.00	58.45
LightGCL	<u>22.29</u>	<u>29.90</u>	33.60	44.93
NCF-MLP++	6.55	11.37	26.67	31.70
Conet	7.88	13.30	28.24	34.76
GRU4REC	13.33	22.47	61.80	66.59
Time-LSTM	11.19	20.17	59.73	64.66
π -Net	15.36	25.13	60.37	<u>67.00</u>
PSJNet	15.37	24.80	<u>61.89</u>	66.86
MoE-SAR	28.88	39.96	67.03	71.62

注: 加粗表示最优结果,下划线表示次优结果。

表 3 HVIDEO 数据集的当 N 值取 20 时的对比实验结果
Table 3 Comparison experiment results of HVIDEO, when $N=20$

单位: %

模型	E-Domain		V-Domain	
	MRR	Recall	MRR	Recall
BPR-MF	3.33	5.56	7.63	9.32
NCF	7.85	20.12	24.71	22.63
LightGCN	13.56	39.92	56.72	63.55
LightGCL	<u>24.85</u>	<u>53.38</u>	36.46	70.82

表3(续)

模型	E-Domain		V-Domain	
	MRR	Recall	MRR	Recall
NCF-MLP++	8.82	21.92	29.15	37.90
Conet	9.52	25.52	30.11	38.21
GRU4REC	15.48	44.18	62.47	73.23
Time-LSTM	13.27	41.45	60.42	71.59
π -Net	17.52	47.08	61.74	<u>74.17</u>
PSJNet	17.56	46.68	<u>62.63</u>	74.14
MoE-SAR	30.81	59.13	67.64	77.67

注: 加粗表示最优结果, 下划线表示次优结果。

3.7 消融实验

为验证共享账户电视推荐场景下用户识别与表示优化的双重机制有效性, 本文构建了两种消融变体:

(1) w/o MoE。移除混合专家模块, 从而使模型无法充分解耦共享账户中不同用户的行为信号。(2) w/o CL。去除对比学习组件, 导致专家输出缺乏有效的对比约束, 可能出现专家表示退化的情况。

如表4和表5所示, 在HVIDEO(E-domain)和HVIDEO(V-domain)数据集上的实验结果表明:

(1) 移除混合专家组件后, 模型在捕捉共享账户中多用户行为多样性方面表现明显下降。没有MoE组件, 模型难以有效解耦混合在一起的用户行为, 导致推荐精度下降。这验证了混合专家网络通过动态门控自适应分配不同专家权重, 在解耦多用户行为、提取细粒度特征方面的关键作用。

(2) 去除对比学习组件后, 模型表现也出现了下降。在缺乏对比约束的情况下, 同一专家生成的两个增强样本未能充分保持一致性, 不同专家输出之间也难以形成明显的差异, 导致专家表示退化。引入对比学习后, 通过对同一专家增强表示施加距离最小化约束, 同时对不同专家输出施加距离最大化约束, 从而有效提升了专家表示的均衡性和判别性, 进一步提高了推荐准确性。

表4 当 $N=5$ 时的消融实验结果Table 4 Ablation experiment results with $N=5$

单位: %

模型	E-Domain		V-Domain	
	MRR	Recall	MRR	Recall
w/o MOE	20.77	34.43	66.79	70.57
w/o CL	23.92	34.76	66.91	70.50
MoE-SAR	28.88	39.96	67.03	71.62

注: 加粗表示最优结果, 下划线表示次优结果。

表5 当 $N=20$ 时的消融实验结果Table 5 Ablation experiment results with $N=20$

单位: %

模型	E-Domain		V-Domain	
	MRR	Recall	MRR	Recall
w/o MOE	22.99	56.60	67.37	76.37
w/o CL	25.97	55.26	67.48	76.27
MoE-SAR	30.81	59.13	67.64	77.67

注: 加粗表示最优结果, 下划线表示次优结果。

4 结语

针对共享账户推荐场景中多用户行为混合、噪声干扰及用户识别困难等核心挑战, 本文提出了一种基于混合专家共享账户推荐模型(MoE-SAR)。首先, 通过动态门控混合专家网络将共享账户行为序列分解为多专家表示, 自适应融合不同专家输出的细粒度特征, 有效捕捉潜在用户行为的原型模式, 克服了传统方法依赖预设潜在用户数的局限性。其次, 设计跨专家对比学习策略, 通过约束同一专家增强样本的语义对齐性与不同专家间的分布差异性, 显著缓解了专家表示退化问题, 增强了模型对混合用户行为的抗噪能力。此外,

MoE-SAR 结合 Transformer 编码器对行为序列进行全局时序建模,实现共享账户中主导用户与次要用户偏好的精准分离。实验结果表明,MoE-SAR 在 HVIDEO 数据集上的推荐性能显著优于现有基线模型,验证了混合专家网络与对比学习策略的有效性。消融实验进一步揭示了混合专家网络与对比学习策略对模型的关键作用。

参考文献:

- [1] QIN J R, ZHU J C, LIU Y K, et al. Learning to distinguish multi-user coupling behaviors for TV recommendation [C] // Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining. Singapore: ACM, 2023: 204–212.
- [2] GUO L, YIN H, WANG Q Y, et al. Streaming session-based recommendation [C] // Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York: ACM, 2019: 1569–1577.
- [3] 郭磊,李秋菊,刘方爱,等. 基于自注意力网络的共享账户跨域序列推荐 [J]. 计算机研究与发展, 2021, 58(11): 2524–2537.
GUO Lei, LI Qiuju, LIU Fang'ai, et al. Shared-account cross-domain sequential recommendation with self-attention network [J]. Journal of Computer Research and Development, 2021, 58(11): 2524–2537.
- [4] 高玉凯,王新华,郭磊,等. 一种基于协同矩阵分解的用户冷启动推荐算法 [J]. 计算机研究与发展, 2017, 54(8): 1813–1823.
GAO Yukai, WANG Xinhua, GUO Lei, et al. Learning to recommend with collaborative matrix factorization for new users [J]. Journal of Computer Research and Development, 2017, 54(8): 1813–1823.
- [5] RENDLE S, FREUDENTHALER C, GANTNER Z, et al. BPR: bayesian personalized ranking from implicit feedback [EB/OL]. (2012-05-09) [2026-01-16]. <https://arxiv.org/abs/1205.2618>.
- [6] MA M Y, REN P J, LIN Y J, et al. π -net: a parallel information-sharing network for shared-account cross-domain sequential recommendations [C] // Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. Paris: ACM, 2019: 685–694.
- [7] TANG L, GUO L, CHEN T, et al. DA-GCN: A domain-aware attentive graph convolution network for shared-account cross-domain sequential recommendation [C] // Proceedings of the 30th International Joint Conference on Artificial Intelligence. Montreal: IJCAI, 2021: 2483–2489.
- [8] WEN X Y, PENG Z H, HUANG S S, et al. MISS: a multi-user identification network for shared-account session-aware recommendation [C] // Database Systems for Advanced Applications. Cham: Springer, 2021: 228–243.
- [9] ZHANG C, LIU D Y, ZUO L, et al. Multi-gate mixture-of-contrastive-experts with graph-based gating mechanism for TV recommendation [C] // Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. New York: ACM, 2023: 4938–4944.
- [10] BAJAJ P, SHEKHAR S. Experience individualization on online TV platforms through persona-based account decomposition [C] // Proceedings of the 24th ACM International Conference on Multimedia. Amsterdam: ACM, 2016: 252–256.
- [11] JIANG J Y, LI C T, CHEN Y, et al. Identifying users behind shared accounts in online streaming services [C] // Proceedings of the 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. New York: ACM, 2018: 65–74.
- [12] YANG S, SARKHEL S, MITRA S, et al. Personalized video recommendations for shared accounts [C] // 2017 IEEE International Symposium on Multimedia. Piscataway: IEEE, 2018: 256–259.
- [13] WANG Z J, YANG Y, HE L, et al. User identification within a shared account: improving IP-TV recommender performance [C] // Advances in Databases and Information Systems. Cham: Springer, 2014: 219–233.
- [14] YANG Y, HU Q M, HE L, et al. Adaptive temporal model for IPTV recommendation [C] // Web-Age Information Management. Cham: Springer, 2015: 260–271.
- [15] SUN W C, MA M Y, REN P J, et al. Parallel split-join networks for shared account cross-domain sequential recommendations [J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(4): 4106–4123.
- [16] GUO L, ZHANG J Y, TANG L, et al. Time interval-enhanced graph neural network for shared-account cross-domain sequential recommendation [J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 35(3): 4002–4016.
- [17] LI D C, LI X, WANG J, et al. Video recommendation with multi-gate mixture of experts soft actor critic [C] // Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 1553–1556.

- [18] QIN Z, CHENG Y, ZHAO Z, et al. Multitask mixture of sequential experts for user activity streams [C] // Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York: ACM, 2020: 3083-3091.
- [19] MA J, ZHAO Z, YI X, et al. Modeling task relationships in multi-task learning with multi-gate mixture-of-experts [C] // Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York: ACM, 2018: 1930-1939.
- [20] MA J Q, ZHAO Z, CHEN J L, et al. SNR: sub-network routing for flexible parameter sharing in multi-task learning [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(1): 216-223.
- [21] TANG H Y, LIU J N, ZHAO M, et al. Progressive layered extraction (PLE): a novel multi-task learning (MTL) model for personalized recommendations [C] // Proceedings of the 14th ACM Conference on Recommender Systems. New York: ACM, 2020: 269-278.
- [22] ZHANG Z, LIU S, YU J, et al. M3oE: multi-domain multi-task mixture-of-experts recommendation framework [C] // Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2024: 893-902.
- [23] ZHANG S, CHEN L, SHEN D, et al. Hierarchical time-aware mixture of experts for multi-modal sequential recommendation [C] // Proceedings of the ACM Web Conference 2025. New York: ACM, 2025: 3672-3682.
- [24] SHAZEER N, MIRHOSEINI A, MAZIARZ K, et al. Outrageously large neural networks: the sparsely-gated mixture-of-experts layer [C] // Proceedings of the International Conference on Learning Representations. Toulon: ICLR, 2017.
- [25] FEDUS W, ZOPH B, SHAZEER N. Switch transformers: scaling to trillion parameter models with simple and efficient sparsity [J]. Journal of Machine Learning Research, 2022, 23(120): 1-39.
- [26] BIAN S Q, PAN X Y, ZHAO W X, et al. Multi-modal mixture of experts representation learning for sequential recommendation [C] // Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. Birmingham: ACM, 2023: 110-119.
- [27] HE X N, LIAO L Z, ZHANG H W, et al. Neural collaborative filtering [C] // Proceedings of the 26th International Conference on World Wide Web. New York: ACM, 2017: 173-182.
- [28] HE X, DENG K, WANG X, et al. LightGCN: simplifying and powering graph convolution network for recommendation [C] // Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 639-648.
- [29] CAI X H, HUANG C, XIA L H, et al. LightGCL: simple yet effective graph contrastive learning for recommendation [C] // Proceedings of the Eleventh International Conference on Learning Representations. Kigali: ICLR, 2023: 1-15.
- [30] HU G, ZHANG Y, YANG Q. CoNet: collaborative cross networks for cross-domain recommendation [C] // Proceedings of the 27th ACM International Conference on Information and Knowledge Management. Torino: ACM, 2018: 667-676.
- [31] HIDASI B, KARATZOGLOU A, BALTRUNAS L, et al. Session-based recommendations with recurrent neural networks [EB/OL]. (2015-10-21) [2026-01-15]. <https://arxiv.org/abs/1511.06939>.
- [32] ZHU Y, LI H, LIAO Y, et al. What to do next: modeling user behaviors by time-LSTM [C] // Proceedings of the International Joint Conference on Artificial Intelligence. Melbourne: ACM, 2017: 3602-3608.
- [33] ZHAO W X, MU S, HOU Y, et al. RecBole: towards a unified, comprehensive and efficient framework for recommendation algorithms [C] // Proceedings of the 30th ACM International Conference on Information & Knowledge Management. Queensland: ACM, 2021: 4653-4664.
- [34] ZHAO W X, HOU Y, PAN X, et al. RecBole 2.0: towards a more up-to-date recommendation library [C] // Proceedings of the 31st ACM International Conference on Information & Knowledge Management. New York: ACM, 2022: 4722-4726.
- [35] WANG X H, YUE H P, GUO L, et al. User identification network with contrastive clustering for shared-account recommendation [J]. Information Processing & Management, 2025, 62(3): 104055.
- [36] GUO L, ZHANG J Y, CHEN T, et al. Reinforcement learning-enhanced shared-account cross-domain sequential recommendation [J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(7): 7397-7411.
- [37] GUO L, WANG C X, WANG X H, et al. Automated prompting for non-overlapping cross-domain sequential recommendation [J]. IEEE Transactions on Knowledge and Data Engineering, 2025, 37(9): 4990-5003.

(编辑: 胡春燕)