

分类号：
UDC：

密级：
学号：416100210258

南昌大学专业学位硕士研究生
学位论文

基于混合策略的音乐推荐系统设计与实现

Design and Implementation of Music Recommendation System
Based on Hybrid Strategy

饶旺

培养单位（院、系）：数学与计算机学院计算机科学与技术系

指导教师姓名、职称：周明建 教授

指导教师姓名、职称：张宇诚 高级工程师

专业学位种类：电子信息

专业领域名称：计算机技术

论文答辩日期：2024 年 6 月 1 日

答辩委员会主席：_____

评阅人：_____

2024 年 6 月 1 日

摘要

音乐推荐系统在帮助用户发现感兴趣音乐方面扮演着日益重要的角色。然而，由于用户偏好的多样性和音乐内容的复杂性，如何准确、高效地进行个性化音乐推荐仍然面临诸多挑战。本文深入探讨了国内外音乐推荐系统的研究现状，针对现有系统中存在的数据稀疏、冷启动等问题，提出了一种融合协同过滤和基于内容的混合音乐推荐方法。本文的主要研究内容如下：

1. 为了构建一个全面的音乐推荐数据集，本文通过爬取网易云音乐平台的数据，获取了丰富的歌曲信息和用户行为数据。在此基础上，设计了一种结合残差网络（ResNet）和门控循环单元（GRU）的深度学习模型 ResGRU，用于从音乐频谱图中提取时空特征。该模型充分利用了 ResNet 在图像特征提取方面的优势和 GRU 在时序建模方面的长处，实现了对音乐内容的精准表征和分类。为了进一步丰富推荐系统的个性化能力，本文引入了“歌曲基因”的概念，通过分析用户的历史播放记录，刻画其在语种、情感、风格等维度上的偏好特征。
2. 在推荐算法的设计上，本文提出了一种融合协同过滤和基于歌曲基因的混合推荐策略。该策略综合考虑了用户的协同信息和音乐的内容特征，能够动态调整不同策略的权重，以适应不同用户的偏好和行为模式。为了解决无法直接获取用户显式评分的问题，本文还提出了一种利用歌曲播放次数等隐式反馈数据构建用户-歌曲评分矩阵的方法，为协同过滤推荐提供了数据基础。
3. 为了验证所提出模型和算法的有效性，本文在自主构建的大规模音乐数据集上进行了系统的实验评估。实验结果表明，ResGRU 模型在歌曲分类任务上取得了优于其他主流模型的性能，证实了其在特征提取和歌曲表征方面的优势。此外，本文提出的混合推荐策略在离线推荐场景下展现出了显著的性能提升，验证了融合不同推荐策略的可行性和有效性。
4. 本文详细阐述了音乐推荐系统的设计与实现过程。系统采用了前后端分离的架构，并合理设计了数据库表结构和系统功能模块。同时，本文还针对推荐引擎的构建提出了一套完整的离线计算方案。最终，基于软件工程规范，实现了一个功能完备的音乐推荐系统。

关键词：音乐推荐；深度学习；混合推荐；协同过滤；歌曲基因

ABSTRACT

Music recommendation systems play an increasingly important role in helping users discover music of interest. However, due to the diversity of user preferences and the complexity of music content, there are still many challenges in making accurate and efficient personalized music recommendations. This paper deeply explores the research status of domestic and international music recommendation systems. In view of the problems of data sparsity and cold start existing in current systems, a hybrid music recommendation method combining collaborative filtering and content-based approaches is proposed. The main research contents of this paper are as follows:

1. In order to construct a comprehensive music recommendation dataset, this paper crawled data from the Netease Cloud Music platform to obtain rich song information and user behavior data. On this basis, a deep learning model ResGRU combining residual network (ResNet) and gated recurrent unit (GRU) is designed to extract spatial and temporal features from music spectrogram. This model takes full advantage of ResNet's strengths in image feature extraction and GRU's strengths in sequence modeling, achieving precise representation and classification of music content. To further enhance the personalization capability of the recommendation system, the concept of "song gene" is introduced, which characterizes users' preferences in dimensions such as language, emotion, and style by analyzing their historical playback records.

2. In terms of recommendation algorithm design, this paper proposes a hybrid recommendation strategy combining collaborative filtering and song gene-based approaches. This strategy comprehensively considers user collaborative information and music content features, and can dynamically adjust the weights of different strategies to adapt to different users' preferences and behavior patterns. To address the problem of lacking direct access to users' explicit ratings, this paper also proposes a method to construct a user-song rating matrix using implicit feedback data such as song playback counts, providing a data foundation for collaborative filtering

recommendation.

3. To validate the effectiveness of the proposed model and algorithms, this paper conducted systematic experiments on a self-constructed large-scale music dataset. The experimental results show that the ResGRU model achieves superior performance in song classification tasks compared to other mainstream models, demonstrating its advantages in feature extraction and song representation. Furthermore, the proposed hybrid recommendation strategy exhibits significant performance improvement in offline recommendation scenarios, validating the feasibility and effectiveness of integrating different recommendation strategies.

4. This article elaborates in detail the design and implementation process of a music recommendation system. The system adopts a front-end and back-end separation architecture, and has reasonably designed the database table structure and system functional modules. Moreover, this paper proposes a complete offline calculation solution for the construction of the recommendation engine. Ultimately, based on software engineering specifications, a fully functional music recommendation system has been realized.

Keywords: music recommendation; deep learning; hybrid recommendation; collaborative filtering; song genes

目 录

第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 推荐系统研究现状.....	2
1.2.2 音乐推荐系统研究现状.....	4
1.3 论文主要内容.....	5
1.4 论文组织安排.....	6
第 2 章 相关理论及知识介绍	8
2.1 基于内容的推荐算法.....	8
2.2 基于近邻的推荐算法.....	9
2.2.1 基于用户的协同过滤算法.....	10
2.2.2 基于物品的协同过滤算法.....	11
2.3 基于模型的推荐算法.....	13
2.4 混合推荐算法.....	14
2.5 相似度计算.....	15
2.5.1 余弦相似度.....	15
2.5.2 皮尔逊相关系数.....	16
2.5.3 杰卡德相似系数.....	17
2.6 本章小结.....	18
第 3 章 音乐推荐系统模型	19
3.1 引言.....	19
3.2 数据构建及特征提取.....	20
3.2.1 数据集构建.....	21
3.2.2 用户-歌曲评分矩阵构建	22
3.2.3 音频特征提取.....	23
3.3 融合残差网络与循环神经网络模型	26
3.3.1 残差神经网络.....	27
3.3.2 门控循环单元.....	28
3.3.3 ResGRU 模型	29
3.4 基于用户协同和歌曲基因的混合推荐模型	31
3.4.1 基于用户协同推荐模型.....	31
3.4.2 基于歌曲基因的推荐模型.....	33
3.4.3 混合推荐模型.....	35
3.5 实验结果与分析.....	37

3.5.1 实验设置.....	37
3.5.2 实验数据集.....	38
3.5.3 实验评价指标.....	38
3.5.4 分类模型结果与分析.....	40
3.5.5 推荐模型结果与分析.....	41
3.6 本章小结.....	44
第4章 音乐推荐系统设计与实现	45
4.1 系统分析.....	45
4.1.1 可行性分析.....	45
4.1.2 系统需求分析.....	46
4.2 系统设计.....	50
4.2.1 系统架构设计.....	50
4.2.2 数据库表设计.....	52
4.2.3 系统功能设计.....	55
4.2.4 推荐功能设计.....	56
4.3 音乐推荐系统实现.....	56
4.3.1 基础功能模块.....	57
4.3.2 每日推荐模块.....	59
4.3.3 歌曲推荐模块.....	60
4.3.4 历史记录模块.....	61
4.3.5 发布乐评模块.....	62
4.3.6 后台管理模块.....	62
4.4 本章小结.....	63
第5章 总结与展望	64
5.1 工作总结.....	64
5.2 展望.....	65
参考文献.....	66

第 1 章 绪论

1.1 研究背景和意义

随着互联网技术在 21 世纪的快速发展，数据量呈现出爆炸性增长，成为了一种不可逆转的发展趋势。《中国互联网络发展状况统计报告》第 53 次发布显示，截至 2023 年 12 月，中国网民数量已达到 10.92 亿，相比 2022 年 12 月增加了 1109 万人，互联网普及率提升至 76.4%^[1]。在此背景下，数字音乐市场同时也表现出巨大的增长潜力。《2022 年中国数字音乐产业报告》作为中国数字音乐领域的首份行业研究，揭示了中国数字音乐市场总规模达到了 1554.9 亿元，年增率达 16.8%，这一数据力证了数字音乐市场的蓬勃生机与增长潜力。

随着数字音乐服务的兴起和互联网技术的迅猛发展，音乐推荐系统^[2]已成为帮助用户从庞大的音乐库中发现喜欢音乐的重要工具。这些系统能够根据用户的偏好、历史行为和上下文信息推荐音乐，极大地丰富了用户的音乐体验。然而，由于用户偏好的多样性和音乐内容的复杂性，如何准确、高效地进行音乐推荐仍然是一个挑战。传统的音乐推荐系统主要依赖于协同过滤和基于内容的推荐两大策略。协同过滤通过分析用户的历史行为来发现用户间的相似性，而基于内容的推荐则依赖于音乐的元数据或声学特征等。尽管这两种方法各有优势，但它们也存在明显的局限性。例如，协同过滤方法面临着冷启动问题和稀疏性问题，而基于内容的推荐则可能忽略了用户行为和偏好的动态变化。针对以上问题，基于混合策略的音乐推荐系统设计与实现应运而生。混合推荐系统通过结合协同过滤、基于内容的推荐以及其他方法（如基于知识的推荐、情感分析等），旨在克服单一推荐策略的限制，提高推荐的准确性和用户满意度。此外，随着深度学习技术的发展，利用神经网络模型来提取音乐特征和学习用户偏好，为混合推荐系统提供了新的思路和方法。从研究的意义来看，设计并实现一个基于混合策略的音乐推荐系统不仅能够提升用户体验，促进音乐消费，还有助于音乐平台更好地了解用户需求，优化内容推荐策略。此外，该研究领域的探索对于推荐系统理论的发展和实践应用具有重要意义，能够为未来音乐推荐技术的创新提供理论支持和实证参考。

综上所述，基于混合策略的音乐推荐系统的设计与实现，不仅是音乐信息

检索领域的研究热点，也是满足现代数字音乐服务需求的关键技术之一。通过深入研究并解决其中的关键问题，可以为用户提供更加个性化、多样化和精准的音乐推荐服务，同时为音乐推荐系统的发展开辟新的路径。

1.2 国内外研究现状

近年来，推荐系统已成为人工智能领域的一个重要分支，无论是在学术界还是工业界，都获得了广泛的关注和深入的研究。作为解决信息过载^[3]难题的关键技术，推荐系统通过精细分析用户的历史行为和偏好，向用户推荐可能引起其兴趣的信息或服务。特别是在音乐领域，随着音乐数据的急剧膨胀，用户在寻找自己喜欢的曲目时面临着越来越大的挑战。在众多对抗信息过载的策略中，音乐推荐系统尤为突出，被视为一种高效的解决方案，因此成为了研究的热点。本节将对推荐系统和音乐推荐系统的国内外研究现状进行综述，重点介绍各类推荐算法的原理、优缺点以及最新进展，并指出目前研究中存在的问题和不足。

1.2.1 推荐系统研究现状

自推荐系统理念诞生以来，距今已逾二十多年，该系统的发展标志着人工智能研究领域的一个关键进展，并已被众多企业纳入其产品服务中。例如，Amazon 依据用户的历史行为分析，向用户推送个性化商品，此举使得其营业收入提升了约 20%^[4]。Netflix 通过调研发现，约 60%的用户认同推荐系统挑选的电影类别与个人偏好相吻合^[5]。Apple 公司通过运用推荐算法在其 iTunes 平台上为用户匹配其可能偏爱的音乐，借此策略提升了企业盈利。同样，Last.fm、豆瓣和字节跳动旗下的今日头条等平台已经证明了推荐系统的显著成效。此外，推荐系统领域的最新研究成果通常会在国际计算机学会每年举办的推荐系统会议（RecSys）上得到展示。在这一学术会议上，Zhang 及其他研究者^[6]深入探讨并分析了当前的推荐模型，归纳出这些先进研究方法的长处与存在的不足。他们还指出了该领域面临的未解决问题，并突出了推荐系统在商业领域的关键作用。目前，推荐系统广泛运用的算法涵盖了基于内容的推荐算法^[7]、协同过滤算法^[8]以及综合运用这两种方法的混合推荐算法^[9]。

基于内容的推荐算法主要依据对项目特征的分析 and 项目间相似性的计算，以推荐与用户喜好相匹配的内容。即便在用户评分信息不足的情况下，这种算法仍能够带来个性化的推荐服务，从而有效地解决了新项目难以获得关注和长尾物品缺乏曝光的问题。但这方法可能导致推荐内容的多样性不足，因为它倾向于推荐与用户已显示兴趣相似的项目，限制了推荐结果的广泛性。Geng 等研究者^[10]开发了一种利用社交网络中的图像内容进行推荐的新型深度学习模型。此外，单京晶将 k-means 聚类算法融入传统的基于内容的推荐系统中，从而设计出了一种创新的推荐策略^[11]。

在推荐系统领域，协同过滤算法扮演着至关重要的角色。该算法可以分为三种主要类型：基于用户的协同过滤、基于物品的协同过滤，以及基于模型的协同过滤方法。Sarvar 等人^[12]提出了一种基于物品的协同过滤方法，并在实践中证实其性能优于基于用户的协同过滤。此外，Hofmann 等人^[13]提出了一种潜在语义分析的协同过滤模型，该模型致力于揭示用户的潜在偏好。Gediminas 及其团队^[14]则对推荐系统进行了进一步的分类，包括基于用户的协同过滤、基于内容的推荐，以及这两种方法的结合使用，并探讨了它们各自的研究方向。

在 Hadoop 这一云计算平台的支持下，Zhao 等研究者^[15]成功实现了基于用户的协同过滤算法，有效应对了算法扩展性的难题。与此同时，Breese 等研究者^[16]通过协同过滤技术，利用用户的历史偏好数据预测新用户可能感兴趣的物品，提高了推荐的准确性。此外，Symeonidis 等人^[17]对推荐系统中的矩阵分解技术进行了深入研究，并分析了这些技术对提升推荐效果的具体贡献。这些研究成果为推荐系统的发展提供了重要的理论基础和实践指导。Wang 等人^[18]开发了一种混合相似性模型，该模型基于 Kullback-Leibler 散度，能够在数据稀疏的情况下区分用户的评分差异，提高了预测准确性。Nilashi 等研究者^[19]研究了一种融合协同过滤的推荐算法，通过奇异值分解技术进行降维处理，以发现更匹配的项目和用户群体，有效减轻了数据稀疏性对推荐系统的影响。此外，Liu 等人^[20]提出了一种创新的推荐算法，该算法结合了社交网络数据，通过构建信任特征矩阵，将用户偏好信息融入传统矩阵分解方法中，从而降低了数据稀疏性对推荐效果的不利影响。这些研究为推荐系统的发展提供了新的思路和方法。

当前，不存在一款万能的推荐算法，能够覆盖所有推荐场景。这是因为每一种算法都具备其独特的优点与限制。混合推荐算法通过结合多种推荐技术的优点，旨在提供更加准确和满意的推荐结果。Cano 及其同事^[21]详细讨论了混合

推荐系统的最新进展,探讨了不同混合推荐技术的基本原理、限制以及未来发展趋势。Lu 等人^[22]设计了一种创新的混合推荐模型,该模型专注于社交网络社区中关联规则的挖掘,并运用社区分布特征进行数据分析。这种混合推荐方法在国内外推荐系统中得到了广泛应用,它通过整合多种信息资源,为用户提供更加精准和个性化的推荐服务。国内的推荐平台普遍采取这种综合的混合推荐方式,通过融合多样的信息资源,向用户提供更加个性化的推荐服务。

1.2.2 音乐推荐系统研究现状

随着音乐平台的数据增长和曲库扩展,用户的音乐需求变得更加广泛,单靠搜索功能难以满足这种多样化的需求。因此,推荐系统在音乐平台中扮演着至关重要的角色。在全球范围内,如 Pandora 和 Last.fm 这样的音乐平台因其先进的推荐算法而受到用户的广泛欢迎,因为其为用户提供了个性化的音乐服务。Pandora 采用的是一种基于内容的推荐方法,通过专人标注歌曲属性并打标签,之后通过这些标签计算不同音乐作品之间的相似性,以此来向用户推荐相应的歌曲^[23]。另一方面,Last.fm 通过分析用户过往的音乐行为,识别用户对各类音乐的偏好,根据这些信息为用户定制个性化的歌单^[24]。这两种方法各有侧重,但都旨在提升用户的音乐体验。

相比之下,中国音乐推荐系统的发展较晚,个性化推荐能力有待提升,国内有网易云音乐、QQ 音乐、豆瓣等平台通过分析用户对音乐的社交互动行为,如评论、分享等,来向用户推荐感兴趣的音乐^[25]。此外,用户对音乐的喜好与其所处环境有密切联系,例如天气变化和不同时间段会影响用户的音乐选择^[26],所以当前的音乐推荐系统必须综合考虑多种因素,并持续进行优化迭代,以便更精确地满足用户的个性化需求,给用户更多个性化推荐^[27]。协同过滤推荐算法作为推荐系统中的核心技术,同样也是目前各大音乐平台的主流推荐技术之一。然而,传统的推荐技术固有其自身的不足,比如数据稀疏以及冷启动问题,即当系统遭遇新进用户或项目的时候,很可能会面临着数据量过少无法计算用户或项目间相似度的挑战。因此,系统难以向新用户提供恰当的项目推荐,影响了推荐准确性的提升。基于内容的推荐系统面临的主要挑战包括特征提取的困难和高计算复杂度。为了克服这些限制,混合推荐系统采用了融合多种推荐技术的策略,有效地解决了冷启动^[28]和数据稀疏性问题^[29],从而补足了单一推

荐方法的不足。为了应对数据稀疏性的挑战，Kai 等人^[30]开发了一个创新的模型，该模型将深度学习技术与协同过滤算法相结合。这个模型利用了经过优化的自编码器和卷积神经网络来识别音乐文件中的隐含特征。通过整合深度学习与协同过滤的方法，模型能够全面地分析用户喜好和音乐属性。通过加强对协同过滤机制的监督，模型有效地解决了评分矩阵稀疏的问题，并提高了预测准确性。对于冷启动问题，Zhong 等人开发了一种效率高且简洁的卷积神经网络模型（MCRN），专门用于分析音乐的音频特性。该模型采用傅里叶变换技术对音频信号进行处理，将其转换成频谱图。随后，多通道卷积递归神经网络（MCRN）能够精确地从这些频谱图中抽取音乐的关键特征。通过比较研究，已经证实 MCRN 在音乐的分类和推荐系统中，相比其他模型展现了更高的准确性^[31]。在音乐推荐领域，循环神经网络作为深度神经网络的一种变体，同样扮演着关键角色。例如，通过采用矩阵分解方法，Zhao 等人^[32]有效地捕获了用户和歌曲的长期特征，并运用自然语言处理技术来抽取音乐的上下文信息。通过在真实数据集上训练长短时记忆网络，他们取得了显著的实验成果。同年，针对音乐分类中的准确性不高和周期长的问题，Zheng 等人^[33]提出了一种改进的循环神经网络模型。该模型引入了注意力机制，目的是提高分类的准确性。实验结果显示，这一方法有效地提高了音乐分类的准确度。

尽管混合推荐系统通过融合多种技术策略在一定程度上缓解了冷启动和数据稀疏性问题，但对于新用户或新歌曲的精准推荐能力仍有待提高。并且基于内容的推荐系统面临着特征提取困难和计算复杂度高等问题，限制了其应用的效率和准确性。此外，虽然深度学习技术的引入为音乐推荐提供了新的解决方案，通过挖掘用户偏好与音乐特性间的深层关联，提高了推荐的准确性，但这些方法往往还存在需要大量的数据支持，对于数据量相对较小的场景不够适用等问题。

1.3 论文主要内容

在音乐推荐领域中，提供精准、个性化的推荐服务，解决用户遇到的问题，并提高他们的满意度，对推荐系统的成功至关重要。本文围绕音乐推荐系统的设计与优化，展开了深入研究与实践，主要工作如下：

- （1）针对现有音乐推荐系统中的数据稀疏问题以及用户显性评分数据的

不足，本文从网易云音乐开放服务平台爬取了大量的歌曲信息与用户播放记录，构建了一个全面的数据集。为构建用户-歌曲评分矩阵，本文提出了一种基于用户播放行为的隐性反馈机制，从而为深入分析用户偏好和歌曲特性提供了丰富的数据基础。

(2) 针对传统音乐分类模型在空间特征提取和时间序列分析方面的局限性，本文提出了一个创新的歌曲分类模型——ResGRU。该模型结合了残差网络的空间特征提取能力和门控循环单元的时间序列处理优势，相较于传统 CNN 和 RNN 模型，ResGRU 实现了更高效的参数利用和更精准的时间序列特征提取。通过与现有的歌曲分类模型（如 HCRNN、FCN6、DielemanCNN 等）进行对比实验和结果分析，证实了 ResGRU 模型在歌曲分类准确性上的显著提升。

(3) 面对推荐系统中的数据稀疏与冷启动问题，本文设计了一种新型混合推荐模型，该模型有效融合了协同过滤和歌曲基因推荐策略，并通过动态调整这两种策略的加权混合方法，针对不同用户播放记录的丰富程度进行适应性调整。该混合推荐模型的设计不仅提高了推荐准确性，也增强了系统对新用户和新歌曲的适应能力，经过实验验证展现出良好的性能。

(4) 基于混合推荐策略的需要，本文设计了一个音乐推荐系统。系统后端采用基于 Python 的 Django 框架构建，前端则选用基于 JavaScript 的 Vue 框架，实现了前后端分离的开发设计。通过对爬取的网易云音乐数据的细致分析与处理，本系统成功实现了包括数据展示、用户行为分析、个性化音乐推荐等核心功能模块，为用户提供了一个直观、高效、个性化的音乐发现体验。

1.4 论文组织安排

第一章，绪论。本章内容从音乐推荐系统的研究背景和其重要性入手，对音乐信息服务的进展以及推荐技术在国内外的的发展情况进行了系统的整理，从而铺垫了本研究的核心议题和整体论文架构的展开。

第二章，相关理论及知识介绍。本章节首先阐述了几种主要的推荐算法，涵盖了基于内容、协同过滤以及混合推荐算法，并解析了这些算法的核心思想与基础原理。接下来，本节探讨了数种普遍采用的相似性计量方式，涵盖了余弦相似性、皮尔逊相关性系数和杰卡德相似性系数等。并比较了它们各自的长处和短板。

第三章，音乐推荐系统模型。本章节分析并设计了采用混合策略的音乐推荐系统中的加权推荐算法，提出了一种结合了残差神经网络与门控循环单元的歌曲分类模型，命名为 ResGRU，以及一个融合了协同过滤和歌曲基因的混合推荐模型。为了解决用户歌曲评分数据缺失这一问题，本章提出了一种新的算法，该算法利用用户的播放记录来隐式地构建音乐评分矩阵。随后，通过与当前流行音乐分类模型的实验比较，并对推荐算法的结果进行评估，证实了该方法的有效性。

第四章，音乐推荐系统的设计与实现。本章深入探讨了采用混合策略的音乐推荐系统的需求分析和可行性研究，并详尽阐述了系统架构的设计思路以及推荐引擎的开发过程。基于上述分析和初步设计，成功设计开发了系统功能较为丰富、推荐效果较为精准的音乐推荐系统。

第五章，总结与展望。本章总结了本文的主要研究内容，并针对所设计开发的基于混合策略的音乐推荐系统存在的局限性提出了未来的研究方向。

第2章 相关理论及知识介绍

2.1 基于内容的推荐算法

基于内容的推荐算法是最早被应用的推荐技术之一，时至今日仍在广泛使用，并取得了良好的效果。当前，今日头条的推荐系统在很大程度上采用了这种算法。与依赖其他用户活动模式的推荐系统不同，基于内容的推荐算法主要依据用户的个人行为数据来提供个性化推荐。这类系统在构建推荐模型时，主要依赖于目标对象的相关信息 and 用户的个人信息。目标对象的信息可能包括元数据描述、标签、用户评论以及人工标注等，而用户信息则涉及诸如年龄、性别、偏好、地域和收入等人口统计学数据。用户与目标对象之间存在多种交互动作，包括但不限于评论、收藏、点赞、观看、浏览、点击、加入购物车以及购买等。通过分析这些数据，推荐系统能够为用户提供精准的内容推荐服务。




图 2.1 基于内容进行电影推荐

如上图 2.1 基于内容进行电影推荐所示，基于内容进行电影推荐示例中，可以观察到用户 A 和 C 对爱情和浪漫题材电影的偏好，而用户 B 则倾向于恐怖与惊悚类型的影片。在此基础上，系统便会向用户 A 推荐那些符合其偏好（爱

情与浪漫)且尚未观看的电影C, 以提供个性化的观影体验。

基于内容的推荐算法深入挖掘并利用用户历史行为数据, 来精确构建用户的兴趣偏好模型, 并据此推荐与其兴趣偏好高度一致的项目。实现这一个性化推荐过程, 主要经历以下几个关键步骤: 首先进行内容表征, 即通过提取每项内容的关键特征, 如标签、描述等信息, 来准确描述该项内容的核心属性; 接着是特征学习, 这一步骤通过分析用户以往偏爱的内容特征, 学习并建立用户的偏好模型, 能够从用户的历史行为中识别出关键的兴趣点; 最后, 基于所学习的用户偏好和所有候选项目的特征, 采用余弦相似度等算法, 计算并筛选出与用户兴趣模型相似度最高的 TOP-N 项目列表进行推荐。通过这样的流程, 不仅能够为用户提供与其个人兴趣紧密相关的内容, 还能发现并推荐新的、可能未被用户发现的有趣内容, 从而丰富用户的体验并增加用户满意度。但是基于内容的推荐算法存在以下两个较明显缺点: 第一, 该算法在推荐时主要依靠用户以往对项目的喜好, 因此它生成的推荐内容通常与用户之前喜爱的项目相似, 这限制了算法挖掘用户潜在兴趣的能力。由于这种依赖历史喜好的做法, 算法很难为用户发现新的或未被探索的兴趣领域, 进而可能导致推荐内容的多样性不足。第二, 使用该推荐算法无法为新用户产生推荐, 也就是前面第一章所提的冷启动问题。对于没有历史喜好记录的新用户, 缺乏其个性化特征的数据, 导致难以为其生成推荐内容。在这种情况下, 可能就需要采取人工打标签的方式来补充用户特征信息, 从而实现对新用户的有效推荐。

2.2 基于近邻的推荐算法

基于近邻的推荐算法, 尤其是协同过滤算法, 属于推荐系统中的一种经典方法, 该技术在学术界和产业界均获得了广泛的采纳和运用。通常所讨论的协同过滤的经典场景可借由我们在挑选电影时的经验理解: 当我们难以抉择哪些电影值得观看时, 往往会向身边品味相似的朋友求推荐。这种基于相似口味或风格的推荐正是协同过滤的精髓所在。而基于近邻的推荐算法主要指的就是这种协同过滤技术。在基于近邻的推荐算法里, 协同过滤技术细分为基于用户的推荐 (User-CF) 和基于物品的推荐 (Item-CF), 它们均以找到相似度高的用户或物品为基础, 进行个性化推荐。

2.2.1 基于用户的协同过滤算法

基于用户的协同过滤算法依据用户过往的行为数据，揭示用户的物品偏好，并通过这些偏好进行打分。接着，算法比较用户对同一物品的评价，以此来确定用户间的相似度。简而言之，如果一个用户与另一用户的兴趣相近，那么基于这种方法系统就会向他推荐与之相似度高的用户喜爱的物品。




图 2.2 基于用户的协同推荐

如上图 2.2 所示，基于用户的协同推荐的实例中可以看出：用户 A 对电影 A 和 C 表示出了喜爱，同样，用户 C 也对电影 A 与电影 C 表示出了喜爱，而用户 C 额外还喜欢电影 D。由于用户 A 未曾表明对电影 D 的偏好，可以据此将电影 D 推荐给用户 A。基于用户的协同过滤主要包括以下几个步骤：

步骤一：收集用户偏好。首先，系统需要收集用户对于不同项目的偏好信息。这些信息可以是显式的，比如评分和评论；也可以是隐式的，如浏览历史、购买历史等用户历史行为数据从而来构建用户-项目评分表。假设用户对某一项目的评分高低即表示用户对项目的喜好程度。

步骤二：计算用户之间的相似度。为此，将采用一种度量相似性的方法，例如余弦相似性或皮尔逊相关系数等（这些具体的相似性度量方法将在后续小节中详细阐述说明）来计算每对用户之间的相似度。这一步的目标是找到与目标用户（即需要生成推荐的用户）相似的用户群体。

步骤三：找到邻居用户。基于上一步计算出的相似度，系统会为每个用户找到一定数量的最相似的用户，这些用户被称为“邻居”。选择邻居的数量是

一个重要的参数，邻居的数量会影响推荐的质量和多样性，太少可能会导致推荐不准确，太多则可能降低推荐的相关性，它可以根据实际情况调整。

步骤四：生成推荐。最后，系统会根据邻居用户的偏好信息来预测目标用户对尚未互动过的项目的偏好程度。一种常见的方法是对邻居用户的评分进行加权平均，其中权重是用户之间的相似度。

基于用户的协同过滤能够提供高度个性化的推荐，因为它直接基于用户的历史偏好来找到相似用户群体并生成推荐，且能够随着用户偏好的变化，推荐内容可以实时更新，反映用户的最新兴趣偏好。但缺点也很明显，一是随着用户和物品数量的增加，计算用户间相似度的成本变得非常高，影响算法的扩展性。二是存在数据稀疏性问题，在用户-物品交互矩阵中，大多数用户只与少数物品有交互，导致矩阵非常稀疏，计算相似度时可能不准确。三是存在新用户的冷启动问题，由于缺乏历史行为数据，难以将新用户与现有的相似用户群体进行有效匹配，从而影响推荐的准确性。

2.2.2 基于物品的协同过滤算法

基于物品的协同过滤推荐关注于物品间的相似性，依据用户对各个物品的评分来判定这些物品之间的关联度。其核心思想是向用户推荐与他先前偏好物品相类似的其他物品。这种推荐逻辑与用户的直接偏好并无直接联系，而是基于物品之间的相似性进行推荐。此过程中，主要挑战在于如何有效衡量物品之间的相似度，以实现精准推荐。




图 2.3 基于物品的协同过滤

如图 2.3 所示是基于物品的协同过滤推荐流程的一个实例，其中用户 C 表现出对电影 A 的偏好。考虑到电影 C 与电影 A 具有较高的相似性，系统则向用户 C 推荐了他未曾表达过喜好的电影 C。这种方法基于物品间的相似度，为用户发现并推荐潜在的兴趣点。基于物品的协同过滤主要包括以下几个步骤：

步骤一：收集用户偏好数据。这一步与上文基于用户的方法相同，需要收集用户对不同物品的偏好信息，包括显式反馈（如评分、喜欢/不喜欢）和隐式反馈（如浏览时间、点击率等）。

步骤二：计算物品之间的相似度。系统会计算所有物品对之间的相似度，通常使用余弦相似度、皮尔逊相关系数、杰卡德相似系数等方法。这一步的目的是识别出那些拥有相似用户偏好模式的物品。

步骤三：基于物品相似度和用户历史偏好生成推荐。对于一个给定的用户，算法会查看该用户过去评价过的物品，并找到这些物品的相似物品。然后根据物品的相似度和用户对这些已评价物品的偏好来预测用户对未评价物品的偏好。

步骤四：生成最终推荐列表。根据预测的偏好度，为用户生成一个排名列表，通常选择预测偏好度最高的 N 个物品推荐给用户。

基于物品的协同过滤具有可扩展性、稳定性、解释性强等优点。如果物品的数量少于用户数量，计算物品之间的相似度相对容易处理，该方法更适合大规模数据环境；物品的特性不像用户偏好那样频繁变化，物品相似度矩阵更新的频率低于用户相似度矩阵，减少了计算量；使用此方法的推荐理由通常也很直观（如“因为你之前购买过某产品，而进行类似产品推荐”），提高了用户接受推荐的可能性。但是此算法会难以解决系统新加入物品的冷启动问题，对于新加入系统的物品，由于缺乏足够的用户交互数据，难以计算其与其他物品的相似度，从而会影响推荐质量。再者就是会导致推荐过于过度专一化，因为运用该算法进行推荐时系统会倾向于推荐与用户已知偏好非常相似的物品，进而会导致推荐单一，多样性不足。

综合上述分析，基于协同过滤推荐系统的优势在于其不需要对物品或用户进行复杂建模，同时能够利用群体智慧发现用户的潜在兴趣。不过，这类算法主要依赖历史数据，因此在处理新出现的物品或用户时会遇到所谓的“冷启动”问题。此外，推荐质量受到用户历史偏好数据的量和质的影响。通常，这些偏好数据以稀疏矩阵的形式存在，而稀疏性在计算过程中会引发一系列问题。例如，个别用户的异常偏好可能对推荐结果的准确性造成较大干扰。

2.3 基于模型的推荐算法

基于模型的基础推荐算法运用机器学习技术，利用用户的历史偏好作为训练数据，建立模型以预测用户未来可能的喜好。当用户再次访问系统时，依据此模型提供个性化推荐。构建模型的过程涉及到从用户的行为数据中抽取关键特征，并同时为用户和物品赋予相应的“标签”；这和基于人口统计学的用户标签、基于内容方法的物品标签的本质是一样的，都是特征的提取和匹配，有显性特征时（如用户标签、物品分类标签）推荐系统可以直接通过属性匹配来进行推荐。在缺乏这些直接属性的情况下，系统需要依赖用户的历史偏好数据来挖掘潜在的特征，这时隐语义模型（Latent Factor Model）便被用来实现这一功能。

隐语义模型是近年来推荐系统领域较为热门的话题，它主要是通过隐含特征将用户与物品联系起来，把用户与物品转换为隐语义，从数据出发，进行个性化推荐，将用户和物品通过中介隐含因子联系起来，隐含因子可通过机器学习得到^[34]。隐语义模型可以通过数学视角进行理解。如图 2.4 所示，在隐语义模型的计算框架中，偏好矩阵 R 被用来表示用户对物品的喜好，其中 R_{ij} 元素反映了用户 i 对物品 j 的偏好强度。矩阵 P 捕捉了用户对各类物品的偏好情况，而 P_{ij} 元素具体表示用户 i 对物品类别 j 的偏好程度。另一方面，矩阵 Q 描述了物品与各个类别之间的关系， Q_{ij} 元素指示了物品 j 在类别 i 中的权重大小。该模型的目标是通过物品类别这一桥梁，将用户与物品的关联性表示为 P 矩阵和 Q 矩阵的乘积，从而分解偏好矩阵 R 。这一过程本质上是基于用户对物品的现有偏好（矩阵 R ）来推导出 P 和 Q 两个矩阵。




图 2.4 隐语义模型计算框架

隐语义模型利用 $R_{UI} = P_U Q_I = \sum_{k=1}^K P_{u,k} P_{k,i}$ 来计算用户 U 对物品 I 的兴趣度 R_{UI} 。该模型会把物品分为 K 个类别, 其中, $p(u, k)$ 表示用户 u 对第 k 个分类的偏好强度 ($1 < k \leq K$), 相应地, $q(k, i)$ 表示物品 i 在第 k 个分类中的权重 ($1 < k \leq K$)。

通过这种方式, 隐语义模型能够基于用户和物品的潜在特征进行有效的推荐。通过最优化损失函数, 旨在求解矩阵 P 和 Q 中的参数, 以最小化用户 u 对物品 i 的真实喜好程度与预测喜好程度之间的均方误差。损失函数公式如 2.1 所示:

$$\sum_{(U,I) \in K} (R_{UI} - \hat{R}_{UI})^2 = \sum_{(U,I) \in K} (R_{UI} - \sum_{k=1}^K P_{u,k} Q_{k,i})^2 + \lambda \|P_U\|^2 + \lambda \|Q_I\|^2 \quad (2.1)$$

式中的 $\lambda \|P_U\|^2 + \lambda \|Q_I\|^2$, 此项防止模型过度拟合数据, 其中 λ 的选取需通过实验确定, 以适应不同的应用场景。常用的优化算法为随机梯度下降, 它通过迭代更新参数以达到误差最小化的目的。

协同过滤和隐语义模型相比较而言, 协同过滤是基于统计, 隐语义是基于模型的。空间复杂度相比, 隐语义模型较小, 而隐语义模型实时推荐依旧难以实现, 目前采用离线计算较多且隐语义模型解释性不强。

2.4 混合推荐算法

混合推荐系统通过结合两个或多个推荐方法, 旨在解决单一算法面临的局限, 从而显著提升推荐质量。这种方法根据不同算法的融合方式, 主要可以划分为以下几种基本模式。通过这样的整合, 它能有效地弥补各单独算法的不足。

(1) 特征组合混合。在特征组合混合推荐中, 系统整合了多种算法的特征数据作为初始输入, 并选定一个算法作为核心, 以产生最终的推荐。例如, 结合协同过滤和基于内容的推荐: 协同过滤首先为每个样本分配特征, 接着, 这些特征连同与内容相关的数据一起, 被用于构建和优化基于内容的推荐模型。

(2) 加权混合。在加权混合方法中, 综合多种推荐算法对每个候选项的评分, 并通过加权机制为每个项目计算得到一个综合得分。接下来, 根据这些加权得分的大小进行排序, 以确定针对特定用户 u 对目标项目 i 的最终推荐顺序。这种方法依靠对不同算法结果的加权组合, 优化推荐效果。如式 2.2 所示:

$$rec_{weighted}(u, i) = \sum_{k=1}^n \beta_k \times rec_k(u, i) \quad (2.2)$$

这里要保证不同推荐算法输出的得分要在同一个范围内，否则加权计算将毫无意义。

(3) 分支混合。在分支混合策略中，系统根据特定的规则选择适当的推荐算法来处理特定情况。这意味着，当满足某一条件时，系统会采用特定的推荐算法生成结果。用公式表示即：若条件满足，则对于某个用户 u 和项目 i ，推荐结果 $rec_{switching}(u, i) = rec_k(u, i)$ ，其中 $k = 1, \dots, n$ 。分支条件可能与用户当前的状态或上下文环境有关。

(4) 级联混合。在级联混合模式下，一个算法生成的推荐列表被传递给下一个算法，后者对这份列表进行调整，如改变排列顺序或移除某些项，但不会添加新的推荐对象。这种方式意味着每个算法的输出直接影响到下一个算法的输入，确保了推荐流程的连续性和高度专注于筛选与排序。可用下面公式 2.3 简单表示：

$$rec_{cascade}(u) = rec_n(u), n \geq 2, k \geq 2, rec_k(u) \subseteq rec_{k-1}(u) \quad (2.3)$$

其中 n 是级联的算法个数， $rec_k(u)$ 是第 k 个推荐算法的推荐结果。

2.5 相似度计算

推荐系统中的相似度计算是核心组成部分之一，它帮助系统评估和比较用户和物品之间的相似性，以下将介绍几种常用的相似度计算方法。

2.5.1 余弦相似度

余弦相似度通过比较两个向量的方向相似度来评估它们之间的相似性，忽略它们的长度差异。这种度量强调方向一致性，而非向量大小。值越接近于1就表示夹角越接近于0，也就表示两个特征向量越相似，反之则表示两个特征向量差异性越大，余弦相似度的公式表示如式 2.4 所示：

$$sim(u, v) = \cos \theta = \frac{X \cdot Y}{||X|| ||Y||} = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2 \cdot \sum_{i=1}^n y_i^2}} \quad (2.4)$$

其中 X, Y 分别是两个向量，其中 x_i 表示用户 x 对项目 i 的评分， y_i 即表示用户 y 对项目 i 的评分。比如，在一个音乐平台当中，平台上有成千上万首歌曲，每首歌曲都可以根据其特征（如节奏、音调、声乐类型等）被表示为一个向量。同样，用户的喜好也可以通过他们过去听过的歌曲和对这些歌曲的评分转化为一个向量。考虑一个简化的情况，使用三维向量来表示每首歌曲和用户的喜好，分别对应于歌曲的节奏、音调、声乐类型的偏好程度。

例如有两首歌曲，歌曲《红日》对应的特征向量表示为 $A = [0.9, 0.3, 0.2]$ ，歌曲《情歌》对应的特征向量表示为 $B = [0.8, 0.5, 0.2]$ ，而用户小王的喜好向量为 $U = [0.9, 0.4, 0.1]$ 。

首先，可以根据上述公式来计算用户喜好与每首歌曲之间的余弦相似度，我们可以得出用户小王与歌曲《红日》、《情歌》的相似度分别如下所示：

$$\begin{aligned} \text{sim}(U, A) &= \frac{0.9 * 0.9 + 0.3 * 0.4 + 0.2 * 0.1}{\sqrt{0.9^2 + 0.3^2 + 0.2^2} \sqrt{0.9^2 + 0.4^2 + 0.1^2}} \approx 0.99 \\ \text{sim}(U, B) &= \frac{0.9 * 0.8 + 0.5 * 0.4 + 0.2 * 0.1}{\sqrt{0.8^2 + 0.5^2 + 0.2^2} \sqrt{0.9^2 + 0.4^2 + 0.1^2}} \approx 0.98 \end{aligned}$$

根据计算可得歌曲《红日》与用户小王喜好之间的余弦相似度约 0.99，而歌曲《情歌》与小王喜好之间相似程度约为 0.98。尽管两首歌曲都与用户的喜好十分接近，但歌曲《红日》与用户小王的喜好相似度略高，因此我们可以认为歌曲《红日》与用户小王的喜好更加吻合，应优先推荐给用户。

2.5.2 皮尔逊相关系数

皮尔逊积矩相关系数，简称皮尔逊相关系数（Pearson correlation coefficient），是一个统计指标，用来衡量两个变量之间的线性关联程度。这种方法通过分析变量间的直线关系强度，提供了相关性的量化评估。其值范围从-1 到 1，其中 1 表示完全正相关，0 表示无线性关系，-1 表示完全负相关。计算公式如式 2.5 所示：

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (2.5)$$

这里， x_i 和 y_i 分别是两个变量的观测值， $\bar{x}$ 和 $\bar{y}$ 分别是它们的平均值。在音乐推荐系统中，这种相关性计算可以帮助系统了解不同用户之间的相似度。系统可以根据这种相似度来推荐用户可能感兴趣的新歌曲。如果发现两个用户的喜好

高度相关，系统可以推荐其中一个用户喜欢的歌曲给另一个用户，这样增加用户发现新喜好歌曲的机会。例如，音乐平台有两位用户小红与小明，他们都对5首共同听过的歌曲进行了评分。其中小红对五首歌曲的评分分别为：[5, 4, 4, 3, 5]，小明对五首歌的评分依次为：[3, 2, 4, 4, 5]。首先需要计算小红与小明对五首歌曲评分的平均值依次为 $\bar{x}$ 、 $\bar{y}$ ：用户小红的歌曲评分均值计算结果如下所示：

$$\bar{x} = \frac{5 + 4 + 4 + 3 + 5}{5} = \frac{21}{5} = 4.2$$

用户小明的歌曲评分均值计算结果如下所示：

$$\bar{y} = \frac{3 + 2 + 4 + 4 + 5}{5} = \frac{18}{5} = 3.6$$

然后,将上述所求得的值代入使用皮尔逊相关系数的计算公式来进行用户小红和用户小明之间的相似度计算结果如下所示：

$$r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}} = 0.073$$

此计算结果表明用户小红和用户小明在音乐喜好上的相关性不强。

2.5.3 杰卡德相似系数

杰卡德系数（Jaccard similarity coefficient）是一种用于评估两个集合之间相似性的度量指标，用于比较有限样本集合之间的相似性和差异性。它的值介于0和1之间，其中0表示两个集合没有任何相同元素，1表示两个集合完全相同。杰卡德相似系数的计算公式如式 2.6 所示，是两个集合交集的大小除以它们并集的大小：

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (2.6)$$

其中， A 和 B 是两个集合， $A \cap B$ 表示集合 A 和 B 的交集， $A \cup B$ 表示集合 A 和 B 的并集。在音乐推荐系统中，如果我们要找到与某个用户音乐品味最相似的用户群体，可以计算该用户与系统中其他用户的杰卡德相似系数，然后选择相似度最高的用户进行歌曲推荐，从而实现更加个性化的音乐推荐服务。例如，用户小李喜欢的歌曲集合为： $A = \{\text{歌曲1}, \text{歌曲2}, \text{歌曲3}, \text{歌曲4}\}$ ，用户小余喜欢的歌曲集合为： $B = \{\text{歌曲2}, \text{歌曲3}, \text{歌曲5}, \text{歌曲6}\}$ 。首先，可以计算得出

小李与小余喜欢的歌曲交集为：

$$A \cap B = \{\text{歌曲 2}, \text{歌曲 3}\} = 2$$

小李与小余喜欢的歌曲并集为：

$$A \cup B = \{\text{歌曲 1}, \text{歌曲 2}, \text{歌曲 3}, \text{歌曲 4}, \text{歌曲 5}, \text{歌曲 6}\} = 6$$

然后，使用杰卡德相似系数公式计算他们的相似度计算结果为：

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{2}{6} = 0.33$$

根据以上结果说明，用户小李和用户小余的音乐品味相似度为 0.33，表明他们有一定程度的相似性，但也有不少差异。

2.6 本章小结

本节内容主要概述了推荐系统算法的技术背景和理论基础。首先，对基于内容的推荐算法、基于近邻的协同过滤算法以及基于模型的推荐算法等传统方法进行了深入探讨，其次，阐述了主要算法原理并且给出了相对应的计算公式，分析了不同推荐算法技术的区别和优缺点；最后介绍了混合推荐算法的相关理论。

第3章 音乐推荐系统模型

本章首先介绍了构建本文所使用的数据集的方法，包括数据的爬取、清洗和预处理等步骤，并详细阐述了如何利用用户的隐式反馈数据构建用户-歌曲评分矩阵以及如何提取歌曲音频的特征。在此基础上，本章重点介绍了本文提出的两个核心模型：融合残差网络与循环神经网络的歌曲分类模型 ResGRU，以及结合协同过滤和基于歌曲内容的混合推荐模型。最后，通过一系列的实验，验证了所提出模型的有效性，并与其他主流模型进行了比较和分析。

3.1 引言

随着数字音乐平台的蓬勃发展，音乐推荐系统在帮助用户发现感兴趣音乐方面发挥着日益重要的作用。音乐推荐的核心在于理解用户偏好，并根据这些偏好向用户推荐新的音乐作品。目前，协同过滤是音乐推荐中广泛采用的技术之一。该方法基于用户或音乐之间的相似性，向用户推荐那些与其喜好相似用户欣赏的音乐，或是与用户过去喜欢的音乐风格相近的作品。然而，由于大多数用户很少对音乐进行显式评分，导致用户-音乐评分矩阵的高度稀疏性，这对协同过滤的效果构成了挑战。

除评分数据稀疏外，音乐标签的缺失也是一个亟待解决的问题。尽管一些音乐平台为其音乐提供了相应的标签，但仍有许多音乐，特别是新发行的音乐，存在标签缺失的情况。音乐标签对于理解音乐的风格、情感等特征具有重要意义，其完整性直接影响到推荐系统的性能。

在探索音乐推荐系统的研究中，深度学习技术已成为解决特征学习难题的重要工具。Chang 等人提出了一种基于卷积神经网络（CNN）的个性化音乐推荐系统（PMRS），利用音乐的音频信号节拍对不同流派的音乐进行分类，并通过结合协同过滤推荐算法来推荐音乐给用户。Senac 等人通过将 CNN 应用于选定的八个音乐特征，有效提高了音乐流派分类的准确性。Kim 等人在一维 CNN 架构中添加多级特征聚合模块，显著提高了模型的精度。这些工作表明，卷积神经网络在捕捉音乐频谱特征方面具有优势。但单纯使用卷积神经网络难以对

音乐在时间维度上的特征进行建模。鉴于循环神经网络在处理时序数据方面的优势，一些学者将其引入音乐推荐领域。Jannach 等人^[35]设计了一种端到端的神经网络模型，通过卷积神经网络提取音乐的音频特征，再利用循环神经网络对时间特征进行建模，最终生成音乐推荐列表。尽管该模型在一定程度上弥补了以往方法的不足，但其忽略了用户行为数据蕴含的协同信息。综上，现有研究虽然在音乐特征表示学习和时序建模等方面取得了进展，但仍面临着如何同时利用音频内容特征和用户行为协同信息的挑战。此外，已有的音乐数据集在规模、领域覆盖度等方面还有待加强。

针对上述问题，本章提出了一种融合协同过滤和基于内容的混合音乐推荐方法。首先，通过爬取网易云音乐平台的数据，构建了一个大规模音乐推荐数据集，其中包含丰富的用户交互记录和音乐属性标签。在此基础上，设计了一种结合残差网络(ResNet)和门控循环单元(GRU)的深度学习模型 ResGRU，用于从音乐频谱图中提取时空特征。该模型充分利用了 ResNet 在图像特征提取方面的优势和 GRU 在时序建模方面的长处。此外，本章还引入了歌曲“基因”的概念，通过分析用户的历史播放记录，刻画用户在语种、情感、风格等维度上的偏好。最后，本章提出了一种融合协同过滤和基于歌曲基因的混合推荐策略，可以兼顾用户的协同信息和音乐的内容特征，提高推荐的准确性和多样性。

3.2 数据构建及特征提取

当前，可公开获取的音乐数据集主要包括 Million Song Dataset、Last.fm 以及 MSD's Last.fm 等。Million Song Dataset 是由 Columbia University 与 The Echo Nest 联合创建的，它作为一个庞大的音乐数据库，包含了超过一百万个歌曲条目的信息。这些数据不仅覆盖了歌曲的元数据信息，如艺术家、专辑和发行年份，也包括了歌词和歌手详情。然而，尽管其规模庞大，这个数据集主要聚焦于 20 世纪的作品，对近年来的音乐作品涵盖不全，并且它缺少对音乐特征的详细描述，如旋律、节奏和情感，这对于在其上进行音乐特征分析和推荐任务时构成了限制。更重要的是，Million Song Dataset 及其他数据集并未提供歌曲标签标注，或是歌曲标签存在误差和缺失，且不包含音频文件，这不符合本文提出利用歌曲基因来提升推荐效果的研究目标。同时又考虑到目前公开可用的音乐数据集主要聚焦于英文歌曲，而对于具有独特旋律和歌词特色的华语歌曲信

息却相对缺乏。特别是从音频分析的角度来看,华语流行音乐经常融入了特有的民族乐器和独特的演唱技巧,这使得它们与外文歌曲存在明显差异^[36]。鉴于现有公开数据集所面临的限制,包括对近代音乐作品的不充分覆盖、对音乐特征描述的缺乏,以及歌曲标签的不完整或错误,本文采取了自主收集数据的策略。通过网易云音乐公开接口爬取所需的音频内容及用户行为历史,经过精细的数据预处理,自行构建了一个既包含歌曲音频文件又包含用户历史行为的音乐数据集,为本文研究提供了符合需求的数据集。

3.2.1 数据集构建

本章针对网易云音乐开放平台提供的公开数据,包括但不限于歌曲详情、艺人资料、用户数据等,分别进行了相应爬虫代码编写,爬取数据并经整理后构建出数据集。其中,经整理后的歌曲数据详情如下表 3.1 所示:

表 3.1 音乐数据集

数据项	数量(条)	备注
歌曲 (song)	25952	歌曲的基本信息
歌曲标签 (song tag)	80365	歌曲可对应多个标签
用户 (user)	800	用户的基本信息
用户标签(user tag)	2840	用户可对应多个标签
歌手 (singer)	11700	歌手的基本信息
歌手标签 (singer tag)	35788	歌手可对应多个标签
歌单 (playlist)	960	歌单的基本信息
歌单标签 (playlist tag)	2850	歌单所对应的标签
听歌历史 (user history)	100000	用户的单曲听歌次数

数据集采纳了包括语种、风格、场景、情绪及主题在内的五大音乐分类维度。每一维度下,详细的分类标准如下表 3.2 所示,旨在全面细致地捕捉音乐的多元特性。

表 3.2 音乐详细分类

分类维度	详情分类
风格	流行、摇滚、民谣、电子、舞曲、说唱、轻音乐、爵士、拉丁、古典、
语种	华语、日语、韩语、粤语、欧美、法语

情感	怀旧、清新、浪漫、伤感、治愈、放松、孤独、安静、开心、痛苦
主题	影视原声、校园、游戏、经典、榜单、儿童、游戏、综艺等
场景	夜晚、学习、运动、下午茶、驾车、酒吧等

需要加以注意的是，上述音乐详细分类中主题与场景两大分类维度下的详情分类大多是基于用户人为划分而来的，而并不是基于歌曲自身的特征基因来进行划分的。故本文在进行实际分类操作时将该部分下的细分类舍弃不予考虑。

3.2.2 用户-歌曲评分矩阵构建

音乐推荐系统通常收集用户的隐式行为数据，如浏览历史、播放记录和收藏行为，这与电影推荐系统依赖用户显式行为数据（例如评分）的做法形成对比。虽然隐式反馈所蕴含的信息可能没有显式评分那样直接和清晰，但是其庞大的数据规模仍然能够揭示用户的真实偏好。此外，考虑到许多用户在平台上往往不会参与评分活动，利用隐式反馈数据分析用户喜好则成为了必然选择。这种方法不仅弥补了显式数据的不足，而且能够通过细致的用户行为分析，捕捉到更加丰富和深入的用户偏好信息。因此，在缺乏直接评价的情境下，隐式数据的广泛采集与分析显得尤为关键。它通过记录和评估用户的行为轨迹，为音乐推荐系统提供了一种更为细腻且全面的用户喜好洞察。这种方法不仅优雅地绕过了用户参与度低下的问题，还以其庞大的样本量和丰富的行为维度，确保了推荐结果的个性化和精准性。简而言之，通过精心分析隐式反馈数据，能够深入挖掘用户偏好的细微差异，进而提供更加贴合用户需求的音乐推荐服务，使其在数字音乐平台上的体验更加丰富和满意。大多数用户不会直接表达对音乐的喜爱程度，但他们的行为—播放次数、听歌时长、歌曲收藏等，却提供了丰富的间接证据来揭示他们的真实偏好。因此，通过对这些细节丰富的行为数据进行挖掘和分析，就能够建立起一套更为微妙和精准的推荐机制，以适应用户多变的音乐口味和听歌场景。本文参考文献^[37]所提出的方法，将用户歌曲播放次数这一隐式数据转化为对音乐的隐性评价进行打分度量，结合先进的推荐算法，不仅能够增强用户体验，还能在音乐推荐的海洋中为用户引航，帮助他们发现和探索更多可能未曾触及但潜在喜爱的歌曲。为此，本文将用户的歌曲播放次数这一隐式数据作为核心数据来源，通过分析歌曲的播放频次，推算出用户对各曲目的偏好评分。具体而言，本文将根据用户的历史听歌记录，统计记录中的每首歌曲的播放频次，进而依据本文提出的算法，将这些播放频次转

化为具体的评分，从而编织出一张全面反映用户音乐偏好的评分矩阵。具体的算法描述如下：

（1）非线性转换

依次获取用户对各歌曲的播放次数，首先我们应用对数公式（如下 3.1 所示）来对各歌曲的播放次数进行转换，以此来减少用户对歌曲播放次数的大值与小值之间的差距。 x 为原始的用户歌曲播放次数， y 为经转换后的用户歌曲播放次数值：

$$y = \log(1 + x) \quad (3.1)$$

（2）标准化处理

接下来，对每个用户歌曲经对数转换后的播放次数进行标准化的处理，使用户对歌曲的评分分数分布在 1 到 10 之间。标准化处理可通过以下公式 3.2 进行最大-最小标准化实现：

$$z = 1 + \left(9 \times \frac{y - \min(Y)}{\max(Y) - \min(Y)} \right) \quad (3.2)$$

其中， Y 是用户歌曲播放记录中各歌曲播放次数分别经上述对数转换后的播放次数集合， $\min(Y)$ 代表的是集合当中的最小值， $\max(Y)$ 代表的是集合当中的最大值， z 即代表着用户对已听歌曲的最终评分。

通过上述两步处理，本文有效地将用户对歌曲的原始播放次数转化为更加合理的评分范围内，本文设定用户对歌曲评分的最大值为 10，减少了长尾音乐分布对评分的影响。经过以上两步方法处理使得即使是播放次数较少的歌曲也能获得公平的评价，同时保留了对用户喜好的敏感度。对所有用户的历史听歌记录均经由上述两步处理计算，便可得到最终的用户-歌曲评分矩阵。

3.2.3 音频特征提取

为进行歌曲流派的分类，利用音频信号已经成为众多研究者探索的领域。然而，这些音频通常以 wav 或 mp3 等格式存储，这些格式仅包含波形数据，无法被深度学习模型直接用于训练。因此，必须首先将音频信号转换为二维的频谱图，这样才能够利用深度学习模型进行有效的特征提取。实际上，音频特征为区分不同歌曲提供了最有效且最具有辨识度的信息。因此，对于本研究而言，提取歌曲的音频特征成为了一个至关重要的步骤。音频特征可以分为时域特征与频域特征两大类。为了全面地提取和表达音频特征，本文提出了一种特征

表示方法，该方法能够综合反映音频的时域与频域信息。

歌曲的原始音频通常以 mp3、wav 等格式存储，这些格式内的内容是基于一维时域信号。为了揭示音频信号在频域的特征，傅里叶变换成为了一种常用的方法。然而，该方法并不能充分揭示音频频率随时间变化的动态特性。为了克服这个问题，许多研究提出了时频域分析方法，如短时傅里叶变换和拉普拉斯变换等。这些方法能够把音频信号转换成图像，使得卷积神经网络可以更有效地抽取音频特征。特别是短时傅里叶变换，作为一种流行的技术，它通过时频分析将音频信号转换为声谱图，这样可以展示出在不同时间点的频率和能量分布。例如歌手林俊杰演唱的歌曲《江南》在时域上的波形图显示如下图3.1所示，其中横坐标表示的是时间，纵坐标表示的是振幅。




图 3.1 歌曲音频在时域上的波形图

如图 3.2 所展示的是歌曲《江南》通过短时傅里叶变换处理后，我们得到了其音频信号的时频谱图。图中的横轴维持不变，表示时间，而纵轴则转变为频率。图像中的颜色强度表示了不同时间点的声音强度：颜色越偏向红色，表明相应时刻的声音响度越大。通过这种方式，图中同时融合了时域和频域的信息，展现了频率随时间的动态变化情况。




图 3.2 歌曲音频信号时变频谱图

时频谱图相比于波形图，展现了更丰富的频域信息。然而，这类信息呈现的是声音的全频范围。尽管人耳可以感知从 20 赫兹到 20000 赫兹的声音频率，但是人类对高频声音的敏感度随频率升高而递减，即对频率变化的感知能力随频率增加而降低。这意味着，在较高频率处，人耳对声音变化的察觉程度减小。例如一个音频示例，在其两个不同时间点上，频率从 1000 赫兹增至 2000 赫兹，尽管频率翻倍，人类对音高的感知却未呈现相应的线性倍增。这表明人耳对音调变化的感知与频率的实际增长之间存在非线性的关系。面对上述问题，众多研究者引入了梅尔频率尺度（MEL），通过一个映射公式将普通的赫兹频率 f 转化为梅尔频率($\text{mel}(f)$)。这一转换关系在公式 3.3 中得到了体现：

$$\text{mel}(f) = 2595 \times \log_{10} \left(1 + \frac{f}{700} \right) \quad (3.3)$$

通过上述梅尔映射公式，得到的梅尔频率与人类听觉的感知呈线性关系。也就是说，当梅尔频率翻倍时，人耳所感知的音调也会相应地增加一倍。考虑到人类对不同频率的声音敏感度不同，这种映射类似于一个滤波器，它能够选择性地对特定频率的声音进行感知。在此基础上，部分研究者采用梅尔滤波器组，通过一系列的滤波器将音频信号的时频谱映射为梅尔频谱图。例如，歌曲《江南》所展示的梅尔频谱图见于下图 3.3 所示。图中，时间轴保持不变，作为横轴；而纵轴现则表示为梅尔频率。




图 3.3 歌曲音频梅尔频谱图

歌曲的自动分类过程紧密依托于人类的感知和认知能力，而梅尔频谱通过模拟人耳的听觉特征来构建频谱图。利用梅尔频谱提供的频域特征表示，可以有效地反映人耳对频率变化的感知差异。采用歌曲音频处理后生成的梅尔频谱图作为神经网络输入，有助于网络更深层次地捕捉音频信号中的频域特征，并从中提取出更加有效的特征表示。这种方法通过更精确地捕获歌曲内含的情感与认知层面的信息，进而在歌曲分类任务上实现更高的性能表现。虽然神经网络在图像识别任务中取得了显著成效，然而，直接使用由歌曲音频生成的梅尔频谱作为输入并不适用。这是因为歌曲的持续时间通常介于 1 至 5 分钟之间，导致直接从音频中得到的梅尔频谱图在时间维度上具有极高的分辨率，通常超过 17000 个数据点（具有 17000x1025 的维度）。这种高维度的输入会大幅降低神经网络训练的效率，故而需要采取降维措施。首先，将前文从网易云平台下载的 MP3 格式歌曲文件借助基于 python 语言编写的 librosa 库，将所有音频数据转换为统一的 wav 格式，并设定采样率为 44100Hz。随后，对连续的音频信号进行分帧和窗口化处理。在每个窗口内，通过短时傅里叶变换来获得相应的频谱特征。然后，将这些频谱送入 Mel 滤波器中，以产生 Mel 频谱。最终，Mel 频谱被转换成图像格式并保存下来。因为 ResNet50 通常接受 224x224 像素的输入图像，故先对整首歌曲的梅尔频谱图进行时间轴上的分割，将其分解成多个 224x224 大小的子序列图。以一首时长为 3 分钟的歌曲为例，通过这种方法，可以从原始梅尔频谱图中得到 12 张 224x224 的梅尔频谱子序列图。这种处理不仅增加了单首歌曲的样本数量，从而丰富了训练集，还降低了模型训练的复杂度。

3.3 融合残差网络与循环神经网络模型

随着深度学习技术的不断发展，卷积神经网络（Convolutional Neural Network, CNN）和循环神经网络（Recurrent Neural Network, RNN）已经成为处理不同类型数据的主流模型。其中，CNN 擅长提取空间特征，在图像分类、目标检测等任务中取得了巨大成功；而 RNN 则擅长处理时序数据，在自然语言处理、语音识别等领域表现出色。然而，在许多实际应用中，数据往往具有时空特征，即既包含空间信息，又包含时间依赖关系。为了有效处理这类数据，需要设计能够同时提取和利用时空特征的模型。

本节将探讨如何融合残差网络（Residual Network, ResNet）与门控循环单

元（Gated Recurrent Neural Network, GRU），构建一种新颖的复合模型 ResGRU。ResNet 是一种深层 CNN，通过引入残差连接，有效地解决了深度网络中的梯度消失问题，使得训练更深的网络成为可能。GRU 是一种改进的 RNN，通过引入门控机制，能够更好地捕获长距离依赖关系，同时缓解了梯度消失和梯度爆炸问题。ResGRU 模型结合了 ResNet 在特征提取方面的优势和 GRU 在处理时序数据方面的优势，旨在实现对时空特征的有效建模。

3.3.1 残差神经网络

残差神经网络（ResNet）是由 He 等人^[38]于 2016 年提出的一种革命性的深度学习模型。与传统的卷积神经网络（CNN）不同，ResNet 引入了残差连接（Residual Connection）的概念，通过在网络中添加恒等映射（Identity Mapping）来解决深度网络训练中的退化问题，使得网络能够学习残差函数，从而实现更深层次的网络结构。

ResNet 的核心思想是在网络中引入残差块（Residual Block），如图 3.4 所示。每个残差块由两个或多个卷积层组成，并在块的输入和输出之间添加一个恒等映射（Identity Mapping）。这个恒等映射使得网络能够直接将输入信息传递到输出，从而避免了因网络深度增加而导致的信息丢失问题。具体而言，残差块可以表示为：

$$y = F(x, \{W_i\}) + x \quad (3.4)$$

其中， x 和 y 分别表示残差块的输入和输出， $F(x, \{W_i\})$ 表示残差块中的卷积层， W_i 表示卷积层的权重。通过恒等映射，残差块的输出可以直接与输入相加，使得网络能够更容易地学习恒等函数，从而缓解了深度网络训练中的退化问题。




图 3.4 ResNet 残差结构


ResNet 的另一个重要特点是使用了批量归一化^[39] (Batch Normalization, BN)。BN 通过对每一层的输入进行归一化处理,使得网络的训练更加稳定,同时也加速了网络的收敛速度。在残差块中, BN 通常被放置在卷积层之后, 激活函数之前。ResNet 的网络结构通常由多个残差块堆叠而成, 不同的 ResNet 模型具有不同的网络深度和残差块数量。例如 ResNet-50 包含 50 个卷积层, 其中包括 16 个残差块; ResNet-101 包含 101 个卷积层, 其中包括 33 个残差块。这些不同深度的 ResNet 模型能够在不同的任务上取得优异的性能。

3.3.2 门控循环单元

循环神经网络是一种适用于处理序列数据的神经网络模型。与前馈神经网络不同, RNN 能够处理变长序列输入, 并在序列的每一个时间步共享参数。然而, 传统的 RNN 在处理长序列数据时容易出现梯度消失或梯度爆炸的问题, 限制了其在实际应用中的表现。

为了解决这一问题, 众多研究人员提出了很多基于改进的 RNN 模型, 如长短期记忆网络^[40]和门控循环单元^[41]等。其中, GRU 作为 LSTM 的一种变体, 在保持较高性能的同时, 具有更加简洁的结构和更少的参数量, 因此在许多序列建模任务中得到了广泛应用。

GRU 的核心思想是引入了门控机制来控制信息的流动, 如图 3.5 所示。在每个时间步, GRU 通过更新门 (Update Gate) 和重置门 (Reset Gate) 来决定如何更新隐藏状态, 从而自适应地捕捉序列中的长期和短期依赖关系。



具体而言，GRU 在时间步 t 的计算过程可以表示为：

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t]), \quad (3.5)$$

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t]), \quad (3.6)$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t]), \quad (3.7)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t, \quad (3.8)$$

其中， r_t 和 z_t 分别表示重置门和更新门， $\tilde{h}_t$ 表示候选隐藏状态， h_t 表示当前时间步的隐藏状态， σ 和 $\tanh$ 分别表示 Sigmoid 激活函数和双曲正切激活函数， $*$ 表示元素级别的乘积， W_r 、 W_z 和 W 表示可学习的权重矩阵。

重置门 r_t 的作用是调节前一时间步的隐藏状态 h_{t-1} 对当前候选隐藏状态 $\tilde{h}_t$ 的作用力度。当重置门的值接近 0 时，GRU 单元会倾向于忽略前一时间步的隐藏状态，实现对内部状态的重置；当重置门接近 1 时，前一时间步的隐藏状态将被保留并用于计算当前候选隐藏状态。更新门 z_t 用于控制前一时间步的隐藏状态 h_{t-1} 和当前候选隐藏状态 $\tilde{h}_t$ 对当前隐藏状态 h_t 的影响。当更新门接近 0 时，GRU 会保留前一时间步的隐藏状态；当更新门接近 1 时，GRU 会使用当前候选隐藏状态来更新当前隐藏状态。

通过重置门和更新门的协同作用，GRU 能够自适应地捕捉序列中的长期和短期依赖关系，在一定程度上缓解了梯度消失和梯度爆炸的问题。与 LSTM 相比，GRU 省去了细胞状态（Cell State）和输出门（Output Gate），使得模型结构更加简洁，参数量更少，在训练和推理时具有更高的效率。

在实际应用中，GRU 已经在多个领域取得了显著的成果。在自然语言处理任务中，如机器翻译^[42]、情感分析^[43]和语言模型^[44]等，GRU 通常作为编码器或解码器的基本组件，用于捕捉文本序列中的语义信息。在语音识别任务中，GRU 也被广泛用于声学建模^[45]和语言建模^[46]，取得了与 LSTM 相媲美的性能。此外，GRU 还在时间序列预测^[47]、推荐系统^[48]等领域展现出了优异的表现。

3.3.3 ResGRU 模型

本文结合了 ResNet 和 GRU 的优点，提出了一种融合 ResNet 与 GRU 的复合模型，称为 ResGRU 模型。该模型旨在充分利用 ResNet 在特征提取方面的优势，同时利用 GRU 在处理时序数据方面的优势，从而实现对时空特征的有效提取和利用。ResGRU 模型的整体结构如图 3.6 所示。该模型主要由三个部分组成：

空间特征提取部分、时序特征提取部分以及输出部分。




图 3.6 ResGRU 模型结构图

空间特征提取部分采用 ResNet 结构。输入数据首先经过一个 Dropout 层，以防止过拟合。然后，数据依次通过两个残差模块进行特征提取。每个残差模块由两个卷积单元构成，卷积单元的结构与标准残差块相同，包含两个卷积层和一个连接层。通过残差模块，可以提取输入数据的高层空间特征，同时避免了深度网络中的梯度消失问题。

时序特征提取部分采用 GRU 结构。GRU 是一种改进的循环神经网络，相比于标准的 RNN，它引入了更新门和重置门，能够更好地捕获长距离依赖关系，同时缓解了梯度消失和梯度爆炸问题。ResNet 提取的空间特征首先经过一个 Reshape 层，将特征图转化为适配 GRU 输入的形状。然后，特征序列被传入一个 GRU 层，GRU 层能够建模特征序列在时间维度上的依赖关系，提取时序特征。

输出部分采用一个全连接层，将 GRU 提取的时序特征映射到输出空间。最后，通过 Softmax 函数得到最终的预测结果。

ResGRU 模型的前向传播过程可以用以下公式表示：

$$X_{\text{dropout}} = \text{Dropout}(X), \quad (3.9)$$

$$X_{\text{res1}} = \text{ResBlock1}(X_{\text{dropout}}), \quad (3.10)$$

$$X_{\text{res2}} = \text{ResBlock2}(X_{\text{res1}}), \quad (3.11)$$

$$X_{\text{reshape}} = \text{Reshape}(X_{\text{res2}}), \quad (3.12)$$

$$H_{\text{gru}} = \text{GRU}(X_{\text{reshape}}), \quad (3.13)$$

$$Y_{\text{pred}} = \text{Softmax}(\text{Dense}(H_{\text{gru}})), \quad (3.14)$$

其中, X 表示输入数据, X_{dropout} 表示经过 Dropout 层处理后的数据, X_{res1} 和 X_{res2} 表示两个残差模块的输出, X_{reshape} 表示经过 Reshape 层处理后的特征序列, H_{gru} 表示 GRU 层的输出, Y_{pred} 表示最终的预测结果。

ResGRU 模型充分利用了 ResNet 和 GRU 的优点, 能够同时提取输入数据的空间特征和时序特征。利用残差连接技术, 模型得以构建更加深入的网络结构, 从而增强其对特征的提取能力。同时, GRU 层能够有效建模时序依赖关系, 捕获序列数据中的长距离依赖。实验结果表明, ResGRU 模型在多个时空序列任务上取得了优异的性能, 验证了模型的有效性。

3.4 基于用户协同和歌曲基因的混合推荐模型

在实际运用中, 各种推荐模型适配于各自的应用场景。为了优化推荐性能, 通常采用融合多种模型的策略, 这样可以整合各个模型的优势。通过将多种不同模型有机结合在一起, 可以更好地适应各种推荐场景的需求, 从而提升推荐系统的整体性能和准确度。

3.4.1 基于用户协同推荐模型

(1) 用户-歌曲评分矩阵

在基于用户的协同过滤推荐模型中, 用户的偏好通常以向量形式来描述, 汇集所有用户的偏好向量形成用户-歌曲评分矩阵, 作为协同过滤算法的基础。模型旨在计算用户间的相似度, 识别并聚集邻近用户, 进而在这个近邻集合中为用户推荐音乐。特别是在缺乏用户对歌曲直接进行评分的音乐推荐系统里, 用户对歌曲的偏好则可以通过其对歌曲重复播放的频次来加以体现。在本文的第 3.2.2 小节中, 已经描述了一种将用户对某歌曲的播放次数转化为用户对该歌

曲的隐性评分的方法。根据这种方法,假设存在一组音乐 S ,当一组音乐作品受到邻近用户的青睐,而目标用户尚未体验过这些作品时,我们可以通过对这些邻近用户对音乐集 S 的隐性评分取平均值,从而预测目标用户对这些音乐可能的评分,形成预测评分集合 R 。接着,将 R 中预测评分最高的前 N 首歌曲推荐给目标用户^[49]。

(2) 优化用户相似度计算

在现实的音乐推荐系统应用中,由于用户与歌曲的数量过于庞大,很多用户之间往往缺乏共同收听过的歌曲记录,导致无共同评分的歌曲数据,这种情况在进行用户之间的相似度计算时会导致分子常为0,从而用户间相似度为0的结果^[50]。这种情况下,计算这些用户之间的相似度就显得既无意义也浪费时间。为提高效率,只对有共同歌曲收听记录(即有共同歌曲评分记录)的用户对进行相似度计算。本文通过构建歌曲到用户的倒排表,即可快速找出哪些用户对同一首歌曲有评分,从而优化了传统协同过滤算法的计算过程。根据以上提出的优化策略,本文首先创建一个从歌曲指向到评分过该歌曲的用户的倒排索引,这样就能轻松识别出对歌曲有评分记录的用户群体。接下来,利用这个索引信息,构建一个歌曲与用户之间的倒排表,如下图3.7所示。



图 3.7 歌曲-用户倒排表

继而,依托于构建好的倒排表,经进一步使用余弦相似来计算有共同歌曲评分记录用户对的用户相似度值,不断更新最后汇总得出用户间的相似矩阵 U ,如下图3.8所示,以此作为优化后的协同过滤模型的基础。


	用户A	用户B	用户C	用户D
用户A	0	R_{ab}	R_{ac}	R_{ad}
用户B	R_{ba}	0	R_{bc}	R_{bd}
用户C	R_{ca}	R_{cb}	0	R_{cd}
用户D	R_{da}	R_{db}	R_{dc}	0

图 3.8 用户相似度矩阵

观察可得，用户相似度矩阵是一个对称矩阵，例如矩阵中斜对称数值 $R_{ab} = R_{ba}$ ，其值即代表用户A,B间的相似度。用户自身之间的相似度值设为 0。

3.4.2 基于歌曲基因的推荐模型

根据歌曲的一些基本特征，本章引入了歌曲基因的概念。此外，还将歌曲基因融入到推荐算法中，并将歌曲基因与协同过滤算法相结合，形成基于歌曲基因的混合音乐推荐方法。基因一词最初源于生物学，描述携带遗传信息并决定生物特征的分子。而歌曲则由旋律、节奏和音色等元素构成。区分不同歌曲的主要因素在于它们的旋律和节奏。将这一概念类比到音乐领域，歌曲基因即指那些决定歌曲听觉特征的基本信息。对于一段歌曲来说，它包含了很多特征，比如旋律和歌词等^[51]。然而，对于歌曲之间的差异，最重要的区别在于旋律和节奏。歌曲基因，其实是指描述歌曲信息的基本元素。在目前的音乐推荐系统中，听众很难根据歌曲的文字内容找到自己喜欢的目标歌曲。要解决这个问题，就需要通过歌曲基因来完成推荐过程。一般来说，如果用户对某一类型的歌曲感兴趣，那一定是因为该类型的歌曲有某种独特之处，吸引了用户。比如，如果用户对钢琴曲感兴趣，那一定是因为钢琴悠扬的音色对用户有一定的吸引力。对于一段歌曲来说，有很多直观的歌曲特征，比如歌词、旋律，是我们感受到的。这些相似的特征都是内在的，很难改变，我们把这些特征称为内在基因。但是，一首歌曲并不仅仅包含它的内在特征，除了其他特征，比如歌曲语言、风格等，我们把这些音乐特征称为外部基因。通过对歌曲的各种属性进行分析总结，可以得到如下图 3.9 所示的歌曲基因构成图^[52]。



在歌曲的基因中，一部分具有客观性质，如乐器使用和旋律构成，这些因素不受个人偏好的影响，具有普遍性。而另一部分属性则带有主观性，包括歌曲所传达的情感和其自身风格，这些因素可能因听众的个人经历和情感状态而有所不同。歌曲标签作为一种重要的外部基因，它概括了作品的风格、所蕴含的情感以及使用的语言等方面，为理解和对歌曲进行分类提供了便利。

在本研究中，通过考察歌曲的三个关键外部基因——语种、风格以及情感，来评估用户对这些维度的偏好。这三个属性直接对应于我们数据集中歌曲的三个分类体系。通过应用前文提出的 ResGRU 模型，能够学习并明确每个分类标准下的具体类别。

（1）语种偏好

从用户历史播放记录分析可知，不同用户对不同音乐语种的偏好表现出显著差异：部分用户倾向于听英文歌曲，而其他人可能更喜欢粤语或仅限于华语曲目。基于这种差异，本研究提出了一种衡量用户歌曲语种偏好的方法，详细描述见公式 3.15。

$$SLP(U_i, L_j) = \frac{songL(U_i, L_j)}{songCount(U_i)} \quad (3.15)$$

上述式子中， $SLP(U_i, L_j)$ 代表用户 U_i 对 L_j 语种歌曲的偏好程度， $songL(U_i, L_j)$ 描述了在用户 U_i 的歌曲播放历史记录中，那些归属于 L_j 语种的曲目， $songCount(U_i)$ 则指的是用户播放的歌曲总量。

（2）情感偏好

考虑到不同用户都有独特的聆听风格，他们对歌曲情感的偏好也各不相同。

一些用户可能喜欢积极向上的歌曲，而另一些人可能喜欢悲伤的歌曲。因此，对于不同的歌曲情感，有必要计算用户对各种情感的偏好。计算公式如 3.16 所示：

$$SEP(U_i, L_j) = \frac{songE(U_i, L_j)}{songCount(U_i)} \quad (3.16)$$

上述式子中， $SEP(U_i, L_j)$ 代表用户 U_i 对 L_j 情感歌曲的偏好程度， $songE(U_i, L_j)$ 描述了在用户 U_i 的歌曲播放历史记录中，那些归属于 L_j 情感的曲目， $songCount(U_i)$ 则指的是用户播放的歌曲总量。

(3) 风格偏好

不同的用户可能喜欢不同类型的歌曲。例如，一些用户可能喜欢古典音乐，而另一些用户则更喜欢流行歌曲。因此，有必要计算用户对每种类型歌曲风格的偏好。计算公式如下 3.17 所示：

$$SSP(U_i, L_j) = \frac{songS(U_i, L_j)}{songCount(U_i)} \quad (3.17)$$

上述式子中， $SSP(U_i, L_j)$ 代表用户 U_i 对 L_j 风格歌曲的偏好程度， $songS(U_i, L_j)$ 描述了在用户 U_i 的歌曲播放历史记录中，那些归属于 L_j 风格的曲目， $songCount(U_i)$ 则指的是用户播放的歌曲总量。

将上述三个歌曲基因的偏好程度进行综合，就可以得到用户的综合歌曲基因偏好。其整合模式公式如下 3.18 所示：

$$Score(U_i, j) = a * SLP(U_i, L_j) + b * SEP(U_i, L_j) + c * SSP(U_i, L_j) \quad (3.18)$$

在上式中，用户 U_i 对歌曲 j 的基因偏好得分用 $Score(U_i, j)$ 表示，其中系数 $a+b+c$ 值和为 1。

3.4.3 混合推荐模型

基于用户协同的推荐模型能够发现并推荐出用户可能感兴趣但之前未曾收听过的歌曲，主要依赖于用户在推荐系统内留下的行为数据，而无需对歌曲的内容进行深入的分析，但对于拥有大量用户以及歌曲的系统时，用户仅收听过极少数歌曲，易导致推荐算法难以找到相似的用户与歌曲。基于本文提出的歌曲基因的推荐模型能够向新用户推荐歌曲，且推荐的歌曲与用户之前喜欢的项目在内容上相似，透明度高，可解释性也更加强^[53]，但其忽略了用户之间的相互影响，推荐的多样性可能较低，用户总是被推荐与之前相似的歌曲。本文提

出将上述两个模型进行混合使用，能够有效地互补各自的劣势，发挥它们各自的优势。在用户的歌曲播放记录较为充分时，适当提高基于协同过滤策略的权重；相反，当用户的歌曲播放记录较少，仅在系统留有少量交互数据时，应增强基于歌曲基因分析的模型所占的权重。将上述两个模型进行加权混合，歌曲推荐流程图如下图 3.10 所示：




图 3.10 加权混合推荐歌曲流程图

基于用户协同与基于歌曲基因的推荐模型相结合的混合推荐算法对用户未听歌曲的推荐度值（即用户对未听歌曲的预测评分）公式如下 3.19 所示：

$$S(U_i, j) = \alpha * \text{Score}(U_i, j) + (1 - \alpha) * \frac{\sum_{k=1}^n \text{sim}(i, k) \times \text{Score}(k, j)}{n} \quad (3.19)$$

其中， $S(U_i, j)$ 表示用户*i*对未听歌曲*j*的最终评分，同时也反映了用户*i*对歌曲*j*的最终偏好， $\text{Score}(U_i, j)$ 表示用户*i*对于歌曲*j*的歌曲基因偏好， $\text{sim}(i, k)$ 表示用户*i*与近邻用户*k*之间的相似度，而 $\text{Score}(k, j)$ 表示用户*i*的近邻用户*k*对歌曲*j*的偏好评分， n 为近邻用户的个数。本系统推荐详细流程如下图 3.11 所示。




图 3.11 系统推荐详细流程图

3.5 实验结果与分析

本节将详细介绍实验的设置、使用的数据集、评估指标以及实验结果与分析。并通过全面的实验评估，展示所提出的 ResGRU 模型在歌曲分类任务上的有效性和优越性以及混合推荐模型的实验表现。

3.5.1 实验设置

本文为了全面评估 ResGRU 模型的性能，搭建了一个强大的实验环境。硬件方面使用了 AMD R7-5800H CPU 和 NVIDIA GeForce RTX 4060Ti GPU，并配备了 16GB 的内存。软件方面，实验在 Windows10 操作系统上进行，使用 Python 3.8 作为编程语言，并基于 Pytorch 1.9 深度学习框架和 NVIDIA CUDA

11.2 进行模型的实现和训练。详细的实验软硬件环境配置如下表 3.3 所示：

表 3.3 实验软件与硬件环境介绍

实验环境	配置详情
CPU	AMD R7-5800H
GPU	NVIDIA GeForce RTX 4060Ti
内存	16GB
操作系统	Windows10
编程语言	Python 3.8
深度学习框架	Pytorch 1.9
CUDA	NVIDIA CUDA 11.2

在模型训练过程中，本文对超参数进行了调优，以获得最佳的性能。对于每个分类模型，实验设定迭代次数为 900 轮。学习率是模型训练的重要参数，实验采用了 Adam 优化器，并设置初始学习率为 0.0001。Adam 优化器能够自适应地调整学习率，加速模型的收敛。

3.5.2 实验数据集

本文使用了自主爬取和构建的音乐数据集。该数据集包含 25952 条歌曲记录，其中成功下载到音频文件的歌曲数量为 16905 条。为了适配 ResGRU 模型的输入，本文对原始音频数据进行了预处理。首先，将所有音频文件转换为梅尔频谱图表示。考虑到不同音频的时长差异，以 3 分钟长度的歌曲为例，其梅尔频谱图在时间轴上的维度达到 16368。为了统一输入尺寸并减少计算复杂度，本文对梅尔频谱图进行降维处理，最终得到尺寸为 224x224 的标准化梅尔频谱序列图，每个音频对应 12 张序列图，并具有 3 个颜色通道。

为了全面评估模型在不同分类标准下的性能，按照歌曲的语种、情感和风格三个维度对数据集进行了标注。在模型训练阶段分别针对这三个分类标准进行训练和评估。

3.5.3 实验评价指标

为了客观评估模型的性能,我们采用了五个常用的评价指标：精确率（Precision）、召回率（Recall）、F1 分数（F1 Score）、均方根误差（Root Mean Square Error, RMSE）和平均绝对误差（Mean Absolute Error, MAE）：

(1)精确率(Precision)

精确率表示的是在所有推荐给用户的项中,用户实际感兴趣(或者说是相关的)项所占的比例。假设一个音乐推荐平台为用户推荐了 20 首歌曲,这 20 首歌曲中,有 8 首是用户实际喜欢并会去点击收听的歌曲。这就意味着,该音乐平台的精确率为 40%。精确率计算公式如下式 3.20 所示:

$$Precision = \frac{\sum_{u \in U} |R(u) \cap L(u)|}{\sum_{u \in U} |R(u)|} \quad (3.20)$$

其中 U 是用户集合, L 是测试集合, $R(u)$ 是系统对用户 u 推荐的物品集合, $L(u)$ 是用户 u 所评价过的物品集。如果推荐系统能够持续提供高质量的推荐,用户就更倾向于使用该系统,从而提高用户粘性和平台的活跃度。然而,也值得注意的是,仅仅追求高精确率可能会牺牲覆盖率和多样性。例如,系统可能倾向于只推荐那些“保险”的、大众化的歌曲来确保精确率,从而忽略了新歌推荐或个性化推荐。因此,平衡精确率与其他指标(如召回率、多样性等)是推荐系统设计的重要考量。

(2)召回率(Recall)

召回率是衡量推荐系统找回用户实际感兴趣项的能力。在音乐推荐场景中,召回率可以帮助我们理解推荐算法能够从全部用户喜欢的音乐中找回多少比例。假设用户 A 实际喜欢 10 首歌曲,我们的推荐系统给用户 A 推荐了 5 首歌曲。在这 5 首推荐的歌曲中,有 3 首是用户 A 实际喜欢的。这意味着,该音乐推荐平台能够找回用户 A 实际喜欢的音乐列表中 30%的歌曲。召回率的计算公式如下式 3.21 所示:

$$Recall = \frac{\sum_{u \in U} |R(u) \cap L(u)|}{\sum_{u \in U} |L(u)|} \quad (3.21)$$

(3)F1 分数(F1 Score)

F1 分数是一个综合考虑精确率(Precision)和召回率(Recall)的指标,用于评估推荐系统(或任何分类模型)的整体性能。由于精确率和召回率往往是相互制约的指标,F1 分数通过对它们进行调和平均来平衡二者的影响,提供了一个单一的度量标准,以评估模型的准确性和完整性。F1 的计算公式如下式 3.22 所示:

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3.22)$$

(4)均方根误差(RMSE)

均方根误差是衡量模型预测值与实际值偏差的常用指标,广泛应用于回归

分析和推荐系统中。RMSE 通过对预测误差的平方求平均后再开方，提供了一个衡量预测准确度的量度。它表示的是预测值与实际观测值之间差异的标准差。均方根误差的计算公式如式 3.23 所示：

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.23)$$

其中， n 代表评分的总数，而 $\hat{y}_i$ 表示预测的评分， y_i 则对应实际的评分。RMSE 的数值越接近于零，意味着模型预测的评分与实际评分之间的偏差越小，从而表明预测的准确度越高。

(5) 平均绝对误差(MAE)

平均绝对误差 (MAE) 是一种衡量预测误差的指标，它计算的是预测值与实际观测值之间差异的绝对值的平均。与均方根误差 (RMSE) 相比，MAE 对异常值的影响较小，因为它不像 RMSE 那样对误差进行平方，因此不会过分放大的误差。MAE 提供了一个直观的误差度量，表示模型预测值与实际值之间的平均偏差。MAE 的计算公式如式 3.24 所示：

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.24)$$

其中， n 是评分的总数， $\hat{y}_i$ 是预测评分， y_i 是实际评分。同理，较小的 MAE 值意味着模型预测结果与实际观测结果之间的偏差更小，从而表明预测精度较高。

通过综合考虑这五个指标，可以全面评估模型的性能。

3.5.4 分类模型结果与分析

本节将详细评估 ResGRU 模型在歌曲分类任务上的性能，并与其他先进的歌曲分类方法进行比较。实现选取了三个具有代表性的基准模型：HCRNN、DielemanCNN^[54]和 FCN6^[55]，它们分别采用了不同的网络结构和特征表示方法。为了全面评估模型的性能，实验采用了两个常用的评价指标：准确率 (Accuracy)、AUC 值。其中，准确率衡量了模型在测试集上的分类正确率，AUC 值反映了分类器的好坏。这两个评价指标的数值均界定在 0 至 1 的区间内，数值越高则意味着模型的性能表现越出色。

本节首先在情感分类任务上对比了 ResGRU 模型与其他三个模型的性能，

实验结果如下表 3.4 所示。具体而言, ResGRU 模型的准确率达到 0.87, 明显高于 HCRNN 的 0.792、FCN6 的 0.587 和 DielemanCNN 的 0.493。这表明 ResGRU 模型在情感分类任务上具有更强的判别能力, 能够更准确地识别歌曲所表达的情感类别。同时, ResGRU 模型的 AUC 值也分别达到了 0.894, 显著优于其他三个模型。这进一步验证了 ResGRU 模型在情感分类任务上的优越性。

表 3.4 不同模型实验对比

	FCN6	DielemanCNN	HCRNN	ResGRU
Accuracy	0.587	0.493	0.792	0.87
AUC	0.812	0.6719	0.875	0.894

由于引入了循环神经网络, ResGRU 模型在准确率 (Accuracy)、AUC 值均超过了其他三个模型。这表明 ResGRU 模型能够有效地从梅尔频谱图中提取出与情感相关的特征, 并通过循环神经网络建模时序依赖关系, 从而实现对歌曲情感的准确分类。

3.5.5 推荐模型结果与分析

在本节进行基于协同过滤、歌曲基因、混合推荐模型、SVD++以及 K-Means 模型的比较实验分析。模型评估采用了 MAE (平均绝对误差) 与 RMSE (均方根误差) 作为评价指标。采用 MAE (平均绝对误差) 作为衡量推荐准确性的指标, 而 RMSE (均方根误差) 则被用来衡量推荐结果的分散性。

本文自行搜集并构建了一个含有 800 个用户及超过 25,000 首歌曲的数据集。对于任意给定用户 U_i , 将数据集内的歌曲数据细分为三个子集合: S_a 、 S_b 和 S_c 。这里, 集合 S_c 包括了用户 U_i 尚未收听过的歌曲; 而集合 S_a 与集合 S_b , 均由用户 U_i 已经听过的歌曲构成, 两集合之间不存在交集。集合 S_a 作为训练数据集使用, 而集合 S_b 则作为测试数据集, 集合内歌曲的数量的比例定为 7 比 3。本文设计了三种推荐模型: 基于用户协同推荐、基于歌曲基因推荐以及混合推荐模型, 以预测用户 U_i 对测试集合 S_b 中歌曲的喜好评分。通过从预测结果中随机选取 10 首至 100 首音乐, 并计算这些预测评分的 MAE (平均绝对误差) 和 RMSE (均方根误差) 值, 以评估各推荐模型的性能。根据以上模型计算得出的 MAE、RMSE 值实验结果分别如下图 3.12、图 3.13 所示:




图 3.12 推荐模型 MAE 实验结果对比图




图 3.13 推荐模型 RMSE 实验结果对比图

以上实验数据表明，在评估推荐系统性能时，本文所构建的混合模型在 MAE 和 RMSE 指标上均低于另外两个对比模型，显示出更佳的预测精准度。随着歌曲预测评分数量的增加，这两个指标的数值持续降低。然而，上述结果仅限于本文提出的三种推荐模型的相互比较。为全面验证提出的混合模型的优越性，现将其与 SVD++ 模型^[56]和 K-Means 模型进行了进一步的对比实验，具体实验结果如下图 3.14、图 3.15 所示。




图 3.14 不同推荐模型 MAE 实验结果对比




图 3.15 不同推荐模型 RMSE 实验结果对比

实验结果表明，相较于 SVD++ 和 K-Means 这两种经典模型，本文提出的混合模型在 MAE 和 RMSE 两个评估指标上表现出较低的数值，从而显现出其较高的推荐精确性。

混合推荐模型的精确度（Precision）会随着参数 α 的不同设置而发生变动，如图 3.16 所展示。在对自行收集的歌曲数据集完成预处理之后，发现用户收听歌曲的中位数数量达到 60 首。基于这一发现，实验选取用户收听过的歌曲数量分别为 50、60、70 首的情况下不同 α 值进行实验评估。实验结果表明，模型的准确率随着收听歌曲数量的增多而有所提升。具体来看，在用户收听 50 首歌曲中，当 α 值设置为 0.3 时，模型达到最高准确率；而在 60 首歌曲中，该最高点出现在 α 值为 0.4；对于 70 首歌曲，最优 α 值为 0.5。该现象支持了混合推荐模型的优越性：在用户具有较丰富的听歌记录时，增强协同过滤模型的作用；而在用户听歌历史较少的情况下，提升歌曲基因模型的重要性，以达到更精确的推

荐效果。




图 3.16 混合推荐模型准确率变化图

3.6 本章小结

本节详细讨论了构建音乐数据集的策略，并针对缺乏用户对歌曲的直接评分信息的难题，提出了一种创新的方法，即通过用户的播放次数来形成歌曲的评分矩阵。本章还引入了一种结合残差神经网络（ResNet）与门控循环单元（GRU）的深度学习模型 ResGRU 来针对歌曲基因进行分类标注进而为后续混合推荐模型构建作铺垫。在推荐模型设计方面，提出结合了基于用户协同过滤和歌曲基因偏好的混合模型来对用户尚未收听过的歌曲进行预测评分，从而进行 TOP-N 歌曲推荐。最后经实验证明，本文提出的混合推荐模型在推荐准确性上超越了单一模型、SVD++模型以及 K-Means 模型。

第 4 章 音乐推荐系统设计与实现

本章将详细阐述基于混合策略的音乐推荐系统的设计与实现过程。首先，通过深度学习方法提取音频特征，然后结合协同过滤算法捕捉用户偏好，设计混合推荐策略。在系统实现方面，采用前后端分离架构，选择流行框架和工具，并合理设计数据库。本章将从可行性分析、需求分析、架构设计、功能设计、推荐算法等方面，对音乐推荐系统进行全面剖析。

4.1 系统分析

本系统计划采用基于 Python 的 Django 框架作为音乐推荐系统后端的搭建框架，前端则使用基于 JavaScript 的 Vue 框架进行基于前后端分离形式的开发设计。深度学习模型和混合推荐算法的开发采用 Python 编程语言，并在 Pytorch 框架上完成了模型训练的全过程。此外，基于歌曲基因的分类标签和歌曲间相似度的计算结果将被存储至 MySQL 数据库中，以实现数据的持久化。系统软硬件开发环境、开发工具及对应具体信息如下表 4.1 所示：

表 4.1 系统开发软硬件需求表

开发环境	详细信息
后端开发工具	PyCharm2020 专业版
前端开发工具	VisualStudio Code
操作系统	Windows10
开发语言	Python/HTML/CSS/JavaScript
数据库	MySQL 8.0.16/Redis
显卡	NVIDIA GeForce RTX 4060Ti
内存	16GB
数据库管理工具	Navicat Premium

4.1.1 可行性分析

1. 技术可行性

本文音乐推荐系统依托于 Python 编程语言，并在 Pytorch 深度学习框架的支持下，进行深度学习模型的开发与训练，旨在实现基于歌曲基因的自动分类。

这一分类过程涉及歌曲与其相关标签的匹配，并将这些信息持久化至 MySQL 数据库中。为了建立一个全面的数据集，我们采用 Python 编写了数据抓取脚本，通过网易云音乐的开放 API 接口，获取了包含歌曲资料、歌手资料、用户历史听歌记录、歌单内容及音频文件和播放历史等多维度的歌曲数据集。

在前端展示方面，系统利用 Vue 进行界面开发，确保了用户界面的响应性和动态表现力。同时，后台管理系统由 Django 框架构建，为数据管理提供了强大而灵活的工具。前后端数据的交互通过运行在 NodeJS 上的服务完成，保证了数据传输的高效和安全。

以上所使用的技术栈均为开源且无需成本支出，且由于这些技术都得到了广泛的社区支持，它们不仅满足了开发音乐推荐系统所需的规模要求，而且大大降低了开发的复杂性。综合来看，该系统的技术架构是可行的，并且能够有效支持推荐系统的需求。

2. 操作可行性

在本文的系统中，操作环节分为两大部分：模型训练和数据展示。训练阶段，模型是在 Pytorch 框架的基础上建立的，并通过配备了 RTX4060Ti 显卡的计算环境利用 CUDA 进行加速。通过持续优化参数并反复进行迭代训练，以精确获得最优化的模型参数。至于展示部分，用户可通过浏览器输入系统网址进入系统，通过注册、登录互动并使用系统的各项功能。整个系统的运行和操作都可以在装有 Windows10 操作系统的计算机上无障碍地进行，显示出操作的实用性。

4.1.2 系统需求分析

在本小节中，将采取软件工程的策略，对本文提出的基于混合策略的音乐推荐系统进行详细的需求调研和分析。

1. 系统功能需求分析

本文开发的音乐推荐系统旨在通过分析用户的歌曲播放历史，结合歌曲标签信息来为其智能推荐歌曲。系统设有两种用户角色：普通用户和管理员。普通用户在登录后，系统将为其呈现个性化的音乐推荐，而管理员则有权管理歌曲数据以及一般用户的数据。此系统的设计目的是提供一个用户界面友好、推荐准确的在线音乐推荐平台，包括但不限于用户的注册登录、个性化音乐推荐、

歌曲的搜索、播放、下载、热度排行榜及用户发表自己的乐评、个人收听记录管理等模块。此外，管理员专属模块允许在后端管理系统对用户数据进行维护，包括查看和调整用户的音乐偏好设置以及上传发布新歌。本系统的核心在于其推荐机制，同时也支持歌曲播放、用户点评等互动功能，确保了用户体验的丰富性和系统交互的流畅性。总体而言，系统的功能结构分为用户互动、管理员管理及基础服务支撑三大模块。整个系统功能需求用例如下图 4.1 所示：




图 4.1 系统功能需求用例图

（1）用户注册、登录模块。

该模块是整个音乐推荐系统的核心模块之一，凡是通过浏览器输入网址进入到音乐推荐系统前台的用户都必须先进行注册、登录操作之后方可使用前台所展现的各个模块功能，否则以未进行登录的游客身份只能浏览首页。用户可以通过注册账号从而来登录系统的前台。新用户第一次注册使用时，应根据注册页面的要求提示，输入自己的相关信息完成系统的注册。注册成功后系统将自动跳转到登录页面，此时用户输入之前注册的账

号、密码即可顺利进入到系统前台进行使用。

（2）歌曲搜索模块。

用户进入前台系统,在已登录的状态下可以通过在首页顶部的搜索框中输入想要查找的歌曲的歌名关键词信息来快速检索出对应歌曲,从而点击进行收听、下载等。进行搜索时可以进行精确查找,也支持模糊搜索。未进行登录的游客不可使用系统搜索功能,点击搜索后系统会自动跳转到用户登录页面。

（3）热门歌曲模块。

已登录的用户以及游客可以在网站首页靠右侧查看当前系统中的热门歌曲,系统默认按照歌曲的总播放量进行排序。已登录用户可点击排行榜当中的感兴趣歌曲来查看歌曲详情、收听、发表评论等,未进行登录的游客不可点击查看。

（4）每日推荐模块。

该功能针对已登录用户开放,系统后台每天会通过获取、分析用户的听歌行为,结合每个用户的个人听歌偏好来为用户进行个性化的音乐推荐,该部分为离线推荐设计,将采用本文提出的混合推荐模型来为用户提供推荐服务。每日为用户推荐六首歌曲在系统前台居中位置推送展示给用户,用户可通过点击歌曲封面或者歌曲名快速跳转进入对应歌曲详情页面。

（5）歌曲推荐模块。

当已登录用户通过在系统前台点击进入歌曲列表,用户将可以查看当前系统中的所有歌曲。该模块有歌曲的全部分类标签。当用户点击任何一种分类标签时,系统将展现当前标签下的所有歌曲,按歌曲热度从高到低进行排序,并且当用户再次点击其中的任意一首歌曲,均可跳转到当前歌曲的详情列表,查阅当前歌曲的详细信息(演唱歌手、所属专辑、发布时间等),可进行歌曲的收听、下载以及发表自己的专属歌曲评论。同时,系统会向用户进行当前歌曲的相似歌曲推荐,推送与当前歌曲相似度最高的五首歌曲。

（6）歌单推荐模块。

当已登录用户通过在系统前台点击进入歌单列表,用户将可以查看当前系统中的所有歌单。该模块有歌单的全部分类标签。当用户点击任何一种分类标签时,系统将展现当前标签下的所有歌单,按歌单热度从高到底

进行排序，并且当用户再次点击其中的任意一个歌单，均可跳转到当前歌单的详情列表，查阅当前歌单的详细信息，查看当前歌单下所包含的所有歌曲。同时，系统会向用户进行当前歌单的相似歌单推荐，推送与当前歌单相似度最高的五个歌单。

（7）歌手推荐模块。

当已登录用户通过在系统前台点击进入歌手列表，用户将可以查看当前系统中的所有歌手。该模块有歌手的全部分类标签。当用户点击任何一种分类标签时，系统将展现当前标签下的所有歌手，按歌手热度从高到低进行排序，并且当用户再次点击其中的任何一名歌手，均可跳转到当前歌手的详情列表，查阅当前歌手的详细信息，查看当前歌手的所有歌曲作品。同时，系统会向用户进行当前歌手的相似歌手推荐，推送与当前歌手相似度最高的五名歌手。

（8）用户推荐模块。

当已登录用户通过系统前台点击进入用户列表，用户将可以查看当前系统中的所有用户。当用户选择点击任意一个系统中的音乐发烧友，将可以在该音乐发烧友的详情页面查看该音乐发烧友的所展示的个人信息以及其所创建的歌单条目。同时，系统会向用户推送基于当前音乐发烧友的相似度最高的其他用户

（9）后台管理模块。

系统管理员能够通过输入正确的用户名和密码来访问后台管理系统。在后台，管理员能够管理并维护系统的基础数据，包括用户信息、歌曲信息和交互数据等。此外，管理员还可以处理推荐数据、上传新歌曲等管理任务。

2. 系统非功能需求分析

音乐推荐系统的成功不仅取决于其能够为用户推荐合适的音乐这一核心功能，还取决于许多非功能性方面的考量，这些考量将直接影响系统的整体质量和用户体验。接下来的部分将对音乐推荐系统的非功能性需求进行探讨，涵盖稳定性、可扩展性、可靠性、精确性及用户友好性等主要评价标准。

（1）稳定性

系统需要能够持续稳定地为用户提供服务，即使面临突发性问题也不例外。系统设计时需考虑各种潜在的风险因素，并制定相应的应对措施和备份方案，

以确保在出现问题时，系统仍能维持基本功能的运行。

（2）可扩展性

随着用户基数的扩大和业务需求的演进，最初设计的系统可能无法充分适应未来的发展需求。因此，在系统设计之初就应考虑到可扩展性，为将来可能的功能拓展和性能提升预留空间和接口。

（3）可靠性

系统的可靠性要求在于能够在长时间运行中维持性能稳定，减少系统故障或宕机的发生。实现高可靠性的措施包括但不限于设置合理的性能指标、建立有效的故障处理机制、以及进行稳定性测试等。

（4）准确性

音乐推荐系统的核心价值在于能够准确地识别用户的音乐偏好，并推荐相匹配的音乐。因此，系统的设计和算法选择必须致力于提高推荐准确性，以增强用户黏性和满意度。

（5）易用性

系统应提供简洁直观的用户界面，使用户能够轻松地发现和使用系统设计的功能。包括用户界面设计、清晰的操作指南、以及实时的反馈和提示机制，这些都是提高用户体验和易用性的关键因素。

通过上述分析，我们可以看到，音乐推荐系统的设计和实现不仅需要满足用户的直接功能需求，还需要考虑到这些非功能性需求，以确保系统的长期稳定运行和提升用户的满意度。

4.2 系统设计

4.2.1 系统架构设计

本系统采用基于 Python 的 Django 框架作为后端的搭建框架，前端则使用基于 JavaScript 的 Vue 框架进行基于前后端分离模式进行构建设计。依据业务特点，为了减少系统的耦合度，提高系统的扩展能力，将整个系统架构设计为以下几个层次。系统架构示意图如下图 4.2 所示。




图 4.2 系统架构图

该音乐推荐系统的总体架构分为表现层、业务层、数据服务层、数据存储层。

(1) 表现层

表现层包含了用户通过浏览器访问系统前台时可见的页面，以及管理员登录后台管理界面时可观察到的管理页面。本音乐推荐系统的前端页面及其组件是通过 Vue 框架进行设计和实现的。得益于 Vue 框架的数据双向绑定特性、轻量级优势和简洁易用性，前端页面和相关组件的设计与开发得以迅速完成。

(2) 业务层

业务层主要负责处理音乐系统前台的歌曲搜索、用户注册及登录、热门歌曲、每日推荐、歌曲推荐、歌手推荐、相似用户推荐等功能模块的业务逻辑。该层主要在服务器端运行。它响应来自音乐推荐系统前端的业务请求，连接到已配置的数据库服务器，执行必要的计算处理，并将结果传回前端以供展示。对于每日推荐以及相似歌曲、相似歌手、相似歌单、相似用户的推荐，需要每日额外经过使用前文提出的算法进行定时离线计算处理完成。该层采用 Python 语言进行开发，基于 Django 框架进行业务的搭建。

(3) 数据服务层

数据服务层负责处理用户交互数据进行离线计算来对各推荐模块的数据进行构建以供业务层进行调用使用。

(4) 数据层

数据层的核心职能是将用户资料、音乐作品信息以及历史交互行为等数据持久地存储至数据库中。此外，该层还负责构建相应的接口供业务逻辑层调用。采用 Django 内置的 ORM 框架来管理 MySQL 数据库。

4.2.2 数据库表设计

本音乐推荐系统内主要采用 MySQL 数据库以及 Redis 数据库结合的方式进行数据表的存储。其中，将常规的数据库表数据持久化地存储在 MySQL 数据库中，而 Redis 数据库主要用来将系统内的热点数据以及用户在登录过程中使用的 JWT 登录令牌进行缓存，以提升整个系统的数据加载性能，以便增强用户的体验感。系统内共有 16 张表，分别为用户信息表（user_info）、用户相似度表（users_sim）、用户推荐用户表（user_users_recommend）、歌曲信息表（song_info）、歌曲标签表（song_tag）、歌曲相似度表（songs_sim）、歌曲点评表（song_comment）、歌曲动态表（song_dynamic）、用户推荐歌曲表（user_songs_recommend）、歌手信息表（singer_info）、歌手相似度表（singers_sim）、用户推荐歌手表（user_singers_recommend）、歌单信息表（songslist_info）、歌单相似度表（songs_list_tag）、用户推荐歌单表（user_songslist_recommend）、用户历史听歌记录表（user_history_record）。下面将对系统内主要的表结构进行介绍。

(1) 用户信息表。该表用来存储用户的基本信息，具体字段属性如下表 4.2 所示。

表 4.2 用户信息表

表字段	字段类型	字段含义	备注
u_id	int	用户编号	主键，不可重复
u_name	varchar	用户名	不可重复
u_password	varchar	密码	
u_gender	varchar	用户性别	
u_tags	varchar	用户音乐标签	可多个，逗号隔开

(2) 用户相似度表。该表用来存储系统内的各个用户的相似度值，以供

后续基于用户相似度的用户推荐模块使用，具体的字段属性如下表 4.3 所示。

表 4.3 用户相似度表

表字段	字段类型	字段含义	备注
id	int	记录编号	主键，不可重复
user_id	int	用户编号	
sim_user_id	varchar	相似用户编号	
sim	double	相似值	

(3) 歌曲信息表。该表主要用来存储歌曲的基本信息，如歌名、歌曲演唱者、时长、所属专辑、发行时间、歌词、歌曲封面和歌曲音频文件，其中歌曲封面、歌词和歌曲音频文件是以文件路径的形式记录在数据库中的。具体的字段属性如下表 4.4 所示。

表 4.4 歌曲信息表

表字段	字段类型	字段含义	备注
song_id	int	歌曲编号	主键，不可重复
song_name	varchar	歌曲名称	
s_singer	varchar	歌曲的演唱者	
s_time	varchar	歌曲的时长	
s_album	varchar	歌曲所属专辑	
s_release	date	歌曲发行时间	
s_img	varchar	歌曲封面路径	
s_lyrics	varchar	歌曲歌词路径	
s_file	varchar	歌曲音频链接	

(4) 歌曲标签表。该表主要用来存储歌曲标签的基本信息，包含语种，风格等，具体字段属性如下表 4.5 所示。

表 4.5 歌曲标签表

表字段	字段类型	字段含义	备注
id	int	记录编号	主键，不可重复
song_id	int	歌曲编号	外键，关联歌曲信息
song_tags	varchar	歌曲所属标签	可多个，逗号隔开

(5) 歌曲点评表。该表主要用于歌曲点评页面，在该表中，因为一首歌可以有多条点评信息，所以歌曲信息表与歌曲点评表之间存在一对多的数据关系。具体的字段属性如下表 4.6 所示。

表 4.6 歌曲点评表

表字段	字段类型	字段含义	备注
c_id	int	点评编号	主键，不可重复

c_text	varchar	歌曲点评内容
c_user	varchar	关联用户名
c_date	date	点评时间
c_song_id	int	点评歌曲编号

(6) 歌曲动态表。该音乐推荐系统内部需求涉及歌曲的动态信息, 因此延伸出了歌曲动态表, 主要用于记录歌曲的播放次数、搜索次数和下载次数, 并且与歌曲信息表实现一对一的数据关系, 也就是说一首歌曲只有一条动态信息。具体的字段属性如下表 4.7 所示。

表 4.7 歌曲动态表

表字段	字段类型	字段含义	备注
id	int	记录编号	主键, 不可重复
s_plays	int	歌曲播放次数	
s_search	int	歌曲搜索次数	
s_download	int	歌曲下载次数	
song_id	int	歌曲编号	外键, 关联歌曲信息

(7) 歌手信息表。该表主要是来存储歌手的相关信息, 包括歌手编号、名字、音乐作品数、歌手头像链接。具体的字段属性如下表 4.8 所示。

表 4.8 歌手信息表

表字段	字段类型	字段含义	备注
singer_id	int	歌手编号	主键, 不可重复
singer_name	varchar	歌手名	
s_song_num	int	歌手作品数	
singer_tags	varchar	歌手所属标签	可多个, 逗号隔开
singer_img	varchar	歌手头像链接	

(8) 歌单信息表。该表主要用来存储歌单的相关信息, 如歌单编号、歌单名字、歌单所属标签、歌曲编号等, 具体的字段属性如下表 4.9 所示。

表 4.9 歌单信息表

表字段	字段类型	字段含义	备注
sl_id	int	歌单编号	主键, 不可重复
sl_name	varchar	歌单名字	不可为空
song_id	int	歌曲编号	外键, 关联歌曲信息
sl_song_num	int	包含作品数	
sl_tags	varchar	歌单所属标签	可多个, 逗号隔开
sl_user	varchar	创建歌单用户	
sl_date	date	歌单创建时间	
sl_description	varchar	歌单描述	可为空
sl_covering	varchar	歌单封面链接	
sl_playcount	int	歌单播放次数	

(9) 用户推荐歌曲表。该表主要用来记录为用户进行歌曲的推荐信息,具体的字段属性如下表 4.10 所示。

表 4.10 用户推荐歌曲表

表字段	字段类型	字段含义	备注
r_id	int	推荐编号	主键, 不可重复
u_id	int	用户编号	
song_id	int	歌曲编号	
recommendation	double	歌曲推荐度	

(10) 用户历史听歌记录表。该表主要用来存放用户在系统内的历史听歌信息,具体的字段属性如下表 4.11 所示。

表 4.11 用户历史听歌记录表

表字段	字段类型	字段含义	备注
p_id	int	记录编号	主键, 不可重复
u_id	int	用户编号	
song_id	int	歌曲编号	
p_date	date	收听时间	

4.2.3 系统功能设计

根据上文 4.1 小节的系统分析可知,系统前台主要是为用户提供歌曲的搜索、播放、下载、发表乐评以及为用户进行各类推荐,后台为管理员提供各类数据的管理操作以及上传发布新的歌曲,可以得到本音乐推荐系统的前后台功能结构模块图如下图 4.3 所示。




图 4.3 音乐推荐系统前后台功能模块图

4.2.4 推荐功能设计

本音乐推荐系统的离线推荐引擎设计如下图 4.4 所示。通过前期完成对数据集的构建以及根据获取到用户的历史听歌记录来构建用户-歌曲评分矩阵，根据歌曲编号找到对应的音频文件，经过预处理的音频文件被转换成一系列的梅尔频谱图。这些转换后的梅尔频谱图随后被送入训练完成的模型中，以提取关键特征，并实现基于歌曲基因的分类。接着，生成的歌曲-标签矩阵与用户-歌曲评分矩阵一同输入到混合推荐模型中，进行加权计算，最终得出 TopN 的歌曲推荐结果，输出相应的歌曲推荐数据并持久化地写入到 MySQL 数据库的用户推荐歌曲表中，完成一次离线推荐数据构建。




图 4.4 离线推荐引擎

4.3 音乐推荐系统实现

经过以上两节的系统分析以及系统设计，对系统的整体实现有了基本的蓝

图。本节将主要对音乐推荐系统的实现结果以及主要功能模块效果进行选择展示介绍。

4.3.1 基础功能模块

(1) 登录、注册模块

该模块是整个音乐推荐系统的核心模块之一，凡是通过浏览器输入网址进入到音乐推荐系统前台的用户都必须先进行注册、登录操作之后方可使用前台所展现的各个模块功能，否则以未进行登录的游客身份只能浏览首页。用户可以通过免费注册账号来登录系统的前台。新用户注册使用时，应根据注册页面（如下图 4.5 所示）的要求提示，输入自己的用户名、性别、密码来完成系统的注册。注册成功后系统将自动跳转到登录页面（如下图 4.6 所示），此时用户属于第一次登录，应该输入之前注册的账号、密码以及按照页面提示要求选择自己喜欢的歌曲类型，至少选择两个类型标签，以便系统对该用户进行基于标签的个性化音乐推荐，有效解决新用户进入该音乐推荐系统的冷启动问题。


The image shows a web page for user registration. At the top, it says "我的音乐" (My Music) and "Hi, 我的音乐欢迎您!" (Hi, My Music welcomes you!). The main heading is "用户注册" (User Registration). Below this, there are four input fields: "用户名" (Username), a gender dropdown menu with "男" (Male) and "女" (Female) options, "密码, 4-16位数字/字母/符号(空格除外)" (Password, 4-16 digits/letters/symbols (space excluded)), and "重复密码" (Repeat Password). There is a checkbox labeled "已阅读并同意用户注册协议" (I have read and agree to the user registration agreement). Below the checkbox is a green button labeled "免费注册" (Free Registration). At the bottom, there is a link that says "已有我的音乐帐号, 立即登录" (Already have my music account, log in immediately).

图 4.5 用户注册页面



图 4.6 用户登录页面

(2) 歌曲查找模块

用户进入前台系统，在已登录的状态下可以通过在首页顶部的搜索框中输入想要查找的歌曲的歌名关键词信息来快速检索出对应歌曲。比如在搜索框输入“演”字，系统便会查询歌曲名字包含该关键字的所有歌曲，目前该系统内只有“演员”这一首歌曲名包含“演”字，所以只显示一条记录。详情如下图 4.7 所示。进行搜索时可以进行精确查找，也支持模糊搜索，同时搜索框下方将根据所有用户搜索歌曲次数总和来展示最近系统内的几首热搜歌曲。



歌曲	歌手	时长
演员	薛之谦	04:11

图 4.7 歌曲搜索页面

(3) 热门歌曲模块

已登录的用户以及游客可以在网站首页靠右侧查看当前系统中的热门歌曲，系统默认按照歌曲的总播放量进行排序，仅展示播放量前十的歌曲（如下图 4.8 所示），用户可通过点击对应歌曲快速进入歌曲详情页面收听、下载歌曲。



图 4.8 热门歌曲

4.3.2 每日推荐模块

该功能针对已登录用户开放，用户第一次登录系统时，系统会根据新用户首次登录系统时所选的歌曲类型标签来进行基于标签的个性化歌曲推荐。而后当用户在本系统内留有历史听歌记录，系统后台每天会定时通过获取、分析用户的听歌行为，结合每个用户的个人听歌偏好来为用户进行基于混合模型的歌曲推荐，考虑到后续计算数据规模会比较大，所以每一天只使用模型进行一次计算，每日为用户推荐六首歌曲在系统前台居中位置（如下图 4.9 所示）推送展示给用户，用户可通过点击去收听快速跳转进入对应歌曲详情页面。



图 4.9 首页每日推荐

4.3.3 歌曲推荐模块

已登录用户通过在系统首页点击导航栏上歌曲按钮进入歌曲列表，用户可以查看当前系统中的所有歌曲。该模块有歌曲的全部分类标签。当用户点击任何一种分类标签时，系统将展现当前标签下的所有歌曲，按歌曲热度（播放量加下载量总和）从高到低进行排序（如图 4.10 所示），并且当用户再次点击其中的任意一首歌曲，均可跳转到当前歌曲的详情页面（如图4.11所示），查阅当前歌曲的详细信息(演唱歌手、所属专辑、发布时间等)，可进行歌曲的收听、下载以及发表自己的专属歌曲评论。同时，系统会向用户进行当前歌曲的相似歌曲推荐，推送与当前歌曲相似度最高的五首歌曲（如图 4.12 所示）。




图 4.10 歌曲热度排行榜



图 4.11 歌曲详情页面




图 4.12 相似歌曲推荐

4.3.4 历史记录模块

在该模块中，将展现当前用户在本音乐推荐系统的历史听歌记录，包含歌曲名、歌手、具体的歌曲收听时间，具体如下图 4.13 所示。



图 4.13 用户历史听歌记录

4.3.5 发布乐评模块

用户在收听对应的歌曲后，可以在该歌曲下发表自己的个人评论及对歌曲的见解，查看其他用户对当前歌曲的评论。具体展示如下图 4.14 所示。



图 4.14 歌曲评论页面

4.3.6 后台管理模块

本音乐推荐系统的后台管理系统（如下图 4.15 所示）是在使用基于 Django 框架内置的 Admin 后台系统进行二次开发完成的。后台管理员在经过登录认证通过后，可以对系统前台网站进行信息的管理与维护，简单来说，它是在为管理人员提供便捷的网站数据库和文件操作途径，确保网页内容能够迅速更新和调整。



图 4.15 音乐推荐系统后台管理页面

4.4 本章小结

本节详尽阐述了采用混合策略的音乐推荐系统的设计与实现方法。首先对系统进行了细致的分析工作，这包括可行性研究和需求调研，以确立系统的目标和功能规格。其中系统被细分为多个关键模块，包括歌曲搜索、热门歌曲排行、每日推荐、以及后端数据维护等。系统的结构设计、功能布局、推荐机制以及数据库的架构都得到了系统性的描述。在推荐机制的设计中，核心思路是构建一个用户-歌曲评分的矩阵，该矩阵由用户的歌曲播放记录隐式反馈数据经提出的算法转换生成。通过提取歌曲的音频文件，根据其唯一的标识符（ID），转化每首曲目为多张梅尔频谱序列图，进而训练 ResGRU 模型来实现歌曲的自动分类。利用基于用户的协同以及基于用户自身歌曲基因的偏好来对用户未收听过的歌曲进行加权混合预测评分，将预测分从高到低排序，取出 TOP-N 歌曲完成最终的歌曲推荐。除此之外，本章还介绍了系统的开发环境、并展示了主要功能的实现效果。以上内容的展示不仅透彻地解释了系统的工作原理，而且为后续的研究和开发奠定了坚实的基础。

第5章 总结与展望

5.1 工作总结

本文围绕基于混合策略的音乐推荐系统设计与实现系统地开展研究工作。首先，通过深入剖析国内外音乐推荐系统的研究现状，本文明确了目前研究面临的问题及其局限性，为本文的研究提供了切入点和思路。在此基础上，本文提出了一种创新的音乐推荐模型，该模型巧妙地融合了基于内容的推荐和协同过滤推荐两种经典方法的优势，能够有效缓解数据稀疏性和冷启动等问题，显著提升推荐的准确性和多样性。

为了实现高效、精准的音乐特征提取和分类，本文设计了一种结合残差网络（ResNet）和门控循环单元（GRU）的深度神经网络模型 ResGRU。该模型利用 ResNet 在图像特征提取方面的优势和 GRU 在时序建模方面的长处，能够同时捕捉音乐的时域和频域特征，实现对音乐内容的全面理解和表征。在此基础上，本文还引入了“歌曲基因”的概念，通过分析用户的历史播放记录，刻画其在语种、情感、风格等维度上的偏好特征，为个性化推荐提供了更加细粒度的用户画像。

在推荐算法的设计上，本文提出了一种融合协同过滤和基于歌曲基因的混合推荐策略。该策略综合考虑了用户的协同信息和音乐的内容特征，能够动态调整不同策略的权重，适应不同用户的偏好和行为模式。同时，面对无法直接获取用户显式评分的问题，本文还提出了一种利用歌曲播放次数等隐式反馈数据构建用户-歌曲评分矩阵的方法，为协同过滤推荐提供了数据基础。

为了验证所提出模型和算法的有效性，本文在自主构建的大规模音乐数据集上进行了系统的实验评估。实验结果表明，ResGRU 模型在歌曲分类任务上取得了优于其他主流模型的性能，证实了其在特征提取和歌曲表征方面的优势。此外，本文提出的混合推荐策略在离线和在线推荐场景下均展现出了显著的性能提升，验证了融合不同推荐策略的可行性和有效性。

最后，本文详细阐述了音乐推荐系统的设计与实现过程。系统采用了前后端分离的架构，并合理设计了数据库表结构和系统功能模块。同时，本文还针

对推荐引擎的构建提出了一套完整的离线计算方案，确保了推荐数据的实时性和准确性。整个系统的开发严格遵循软件工程规范，经过了全面的测试和优化，最终实现了一个功能完备、性能优异的音乐推荐系统。

5.2 展望

尽管本文在音乐推荐系统的设计与实现方面取得了一定的研究成果，但仍有许多问题和挑战有待进一步探索 and 解决。展望未来，以下几个方面值得深入研究：

（1）多模态音乐信息的融合。本文主要利用了音乐的音频信号和元数据信息进行特征提取和推荐，而在实际场景中，音乐往往与歌词、MV、专辑封面等多种模态信息相伴而生。如何有效地融合这些异构数据，构建更加全面和准确的音乐表征，是未来研究的一个重要方向。多模态学习和跨模态检索技术的引入，有望进一步提升音乐推荐的性能和用户体验。

（2）用户反馈和交互行为的深度挖掘。用户与音乐平台的交互行为蕴含着丰富的偏好信息和反馈信号，如歌曲的播放、收藏、评论、分享等。如何更好地利用这些隐式反馈数据，构建动态演化的用户偏好模型，是一个具有挑战性的课题。此外，用户的社交网络关系和社交行为也蕴含了宝贵的协同信息，值得进一步挖掘和利用。

（3）音乐推荐的可解释性和透明度。虽然深度学习模型在推荐性能上取得了突破，但其“黑盒”特性也引发了可解释性和透明度方面的担忧。用户往往希望了解推荐结果背后的原因，以建立对系统的信任。因此，如何设计可解释的推荐模型，为用户提供直观、易懂的推荐解释，是一个亟待解决的问题。可解释性的提升不仅有助于增强用户体验，也为算法的优化和调试提供了依据。

总之，音乐推荐系统仍有广阔的研究空间和应用前景。随着深度学习、大数据分析、人机交互等技术的不断发展，个性化音乐推荐服务必将迎来新的突破和变革。未来的研究需要立足于用户需求和行业痛点，不断探索创新的推荐模型和算法，优化系统架构和用户体验，同时兼顾推荐的公平性、可解释性和伦理规范。相信通过学术界和产业界的共同努力，智能、个性化的音乐推荐系统必将为用户带来更加美好的音乐探索和聆听体验。

参考文献

- [1] 中国互联网络信息中心. 第 53 次《中国互联网络发展状况统计报告》[EB/OL]. <https://www.cnnic.net.cn/n4/2024/0322/c88-10964.html>.2024-3-22
- [2] Cheng Z, Shen J, Zhu L, et al. Exploiting Music Play Sequence for Music Recommendation[C]//IJCAI. 2017, 17: 3654-3660.
- [3] 陈彬, 张荣梅. 智能推荐系统研究综述[J]. 河北省科学院学报, 2018, 35(3): 82-92.
- [4] Linden G, Smith B, York J. Amazon. com recommendations: Item-to-item collaborative filtering[J]. IEEE Internet computing, 2003, 7(1): 76-80.
- [5] Davidson J, Liebald B, Liu J, et al. The YouTube video recommendation system[C]//Proceedings of the fourth ACM conference on Recommender systems. 2010: 293-296.
- [6] Zhang S, Yao L, Sun A, et al. Deep learning based recommender system: A survey and new perspectives[J]. ACM computing surveys (CSUR), 2019, 52(1): 1-38.
- [7] Javed U, Shaukat K, Hameed I A, et al. A review of content-based and context-based recommendation systems[J]. International Journal of Emerging Technologies in Learning (iJET), 2021, 16(3): 274-306.
- [8] Cui Z, Xu X, Fei X U E, et al. Personalized recommendation system based on collaborative filtering for IoT scenarios[J]. IEEE Transactions on Services Computing, 2020, 13(4): 685-695.
- [9] Sharma S, Rana V, Malhotra M. Automatic recommendation system based on hybrid filtering algorithm[J]. Education and Information Technologies, 2022, 27(2): 1523-1538.
- [10] Geng X, Zhang H, Bian J, et al. Learning image and user features for recommendation in social networks[C]//Proceedings of the IEEE international conference on computer vision. 2015: 4274-4282.
- [11] 单京晶. 基于内容的个性化推荐系统研究[D]. 长春: 东北师范大学, 2015.
- [12] Sarwar B, Karypis G, Konstan J, et al. Item-based collaborative filtering recommendation algorithms[C]//Proceedings of the 10th international conference on World Wide Web. 2001: 285-295.
- [13] Hofmann T. Latent semantic models for collaborative filtering[J]. ACM Transactions on Information Systems (TOIS), 2004, 22(1): 89-115.
- [14] Adomavicius G, Tuzhilin A. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions[J]. IEEE transactions on knowledge and data engineering, 2005, 17(6): 734-749.
- [15] Zhao Z D, Shang M S. User-based collaborative-filtering recommendation algorithms on hadoop[C]//2010 third international conference on knowledge discovery and data mining.

- IEEE, 2010: 478-481.
- [16] Breese J S, Heckerman D, Kadie C. Empirical analysis of predictive algorithms for collaborative filtering[J]. arXiv preprint arXiv:1301.7363, 2013.
- [17] Symeonidis P. Matrix and tensor decomposition in recommender systems[C]//Proceedings of the 10th ACM conference on recommender systems. 2016: 429-430.
- [18] Wang Y, Deng J, Gao J, et al. A hybrid user similarity model for collaborative filtering[J]. Information Sciences, 2017, 418: 102-118.
- [19] Nilashi M, Ibrahim O, Bagherifard K. A recommender system based on collaborative filtering using ontology and dimensionality reduction techniques[J]. Expert Systems with Applications, 2018, 92: 507-520.
- [20] Liu Y, Yang H, Sun G, et al. Collaborative Filtering Recommendation Algorithm Based on Multi-relationship Social Network[J]. Ingénierie des Systèmes d'Information, 2020, 25(3).
- [21] Çano E, Morisio M. Hybrid recommender systems: A systematic literature review[J]. Intelligent data analysis, 2017, 21(6): 1487-1524.
- [22] Lu X, Huang H H, Wu H Y, et al. A hybrid recommendation model for community attributes of social networks based on association rule mining[C]//2018 3rd International Conference on Mechanical, Control and Computer Engineering (ICMCCE). IEEE, 2018: 420-424.
- [23] Joyce J. Pandora and the Music Genome Project, song structure analysis tools facilitate new music discovery[J]. Scientific Computing, 2006, 23(14): 40-41.
- [24] Acquisti A, Gross R. Imagined communities: Awareness, information sharing, and privacy on the Facebook[C]//International workshop on privacy enhancing technologies. Berlin, Heidelberg: Springer Berlin Heidelberg, 2006: 36-58.
- [25] 万姝懿, 闫大卫. 我国网络音乐市场发展现状研究[J]. 艺术教育, 2014 (4): 72-73.
- [26] 丁明波. 基于深度学习的个性化音乐推荐方法研究[D]. 中国石油大学(华东), 2017.
- [27] 毋亚男, 刘德然, 许小可. 基于双向情感分析的实时性音乐推荐系统设计[J]. 大连民族大学学报, 2017, 19(1): 76-79.
- [28] Lam X N, Vu T, Le T D, et al. Addressing cold-start problem in recommendation systems[C]//Proceedings of the 2nd international conference on Ubiquitous information management and communication. 2008: 208-211.
- [29] Feng C, Liang J, Song P, et al. A fusion collaborative filtering method for sparse data in recommender systems[J]. Information Sciences, 2020, 521: 365-379.
- [30] Kai H. Automatic recommendation algorithm for video background music based on deep learning[J]. Complexity, 2021, 2021: 1-11.
- [31] Mao Y, Zhong G, Wang H, et al. MCRN: a new content-based music classification and recommendation network[C]//Neural Information Processing: 27th International Conference, ICONIP 2020, Bangkok, Thailand, November 18–22, 2020, Proceedings, Part IV 27. Springer International Publishing, 2020: 771-779.
- [32] Yang H, Zhao Y, Xia J, et al. Music playlist recommendation with long short-term memory[C]//Database Systems for Advanced Applications: 24th International Conference,

- DASFAA 2019, Chiang Mai, Thailand, April 22–25, 2019, Proceedings, Part II 24. Springer International Publishing, 2019: 416-432.
- [33] Jia N, Zheng C J. Model of Music Theme Recommendation Based on Attention LSTM [J]. Computer Science, 2019, 46(S2): 230-235.
- [34] 陈博文. 基于隐语义模型的混合推荐模型研究[D]. 兰州: 兰州大学, 2019.
- [35] Jannach D, Ludewig M. When recurrent neural networks meet the neighborhood for session-based recommendation[C]//Proceedings of the eleventh ACM conference on recommender systems. 2017: 306-310.
- [36] 何蓉. 基于卷积神经网络的音乐推荐系统[D]. 南京邮电大学, 2019
- [37] Wang Q, Sun M, Xu C. An improved user-model-based collaborative filtering algorithm[J]. Journal of Information and Computational Science, 2011, 8(10): 1837-1846.
- [38] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [39] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. pmlr, 2015: 448-456.
- [40] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [41] Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014.
- [42] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [43] Tang D, Qin B, Liu T. Document modeling with gated recurrent neural network for sentiment classification[C]//Proceedings of the 2015 conference on empirical methods in natural language processing. 2015: 1422-1432.
- [44] Jozefowicz R, Vinyals O, Schuster M, et al. Exploring the limits of language modeling[J]. arXiv preprint arXiv:1602.02410, 2016.
- [45] Chung J, Gulcehre C, Cho K H, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv preprint arXiv:1412.3555, 2014.
- [46] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention[C]//International conference on machine learning. PMLR, 2015: 2048-2057.
- [47] Che Z, Purushotham S, Cho K, et al. Recurrent neural networks for multivariate time series with missing values[J]. Scientific reports, 2018, 8(1): 6085.
- [48] Hidasi B, Karatzoglou A, Baltrunas L, et al. Session-based recommendations with recurrent neural networks[J]. arXiv preprint arXiv:1511.06939, 2015.
- [49] 宋雪峰. 基于深度学习的个性化音乐推荐系统设计与实现[D]. 黑龙江大学, 2021.
- [50] 林丽珊. 基于协同过滤算法的社区音乐推荐系统的设计与实现[D]. 湖南大学, 2016.
- [51] Liu H, Kou H, Chi X, et al. Combining time, keywords and authors information to construct papers correlation graph (S)[C]//SEKE. 2019, 19: 11-19.
- [52] Zhang R, Tu S, Sun Z. A hybrid music recommendation method based on music genes and

- collaborative filtering[C]//2022 IEEE Intl Conf on Dependable, Autonomic and Secure Computing, Intl Conf on Pervasive Intelligence and Computing, Intl Conf on Cloud and Big Data Computing, Intl Conf on Cyber Science and Technology Congress (DASC/PiCom/CBDDCom/CyberSciTech). IEEE, 2022: 1-6.
- [53] Afchar D, Melchiorre A, Schedl M, et al. Explainability in music recommender systems[J]. AI Magazine, 2022, 43(2): 190-208.
- [54] Dieleman S, Schrauwen B. End-to-end learning for music audio[C]//2014 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2014: 6964-6968.
- [55] Wang Z, Li J, Chen X, et al. Musical instrument playing technique detection based on fcn: Using chinese bowed-stringed instrument as an example[J]. arXiv preprint arXiv:1910.09021, 2019.
- [56] Jiang S, Li J, Zhou W. An Application of SVD++ Method in Collaborative Filtering[C]//2020 17th International Computer Conference on Wavelet Active Media Technology and Information Processing (ICCWAMTIP). IEEE, 2020: 192-197.