

分类号: TP391

密 级: 公开

UDC:

单位代码: 10142

沈阳工业大学 硕士学位论文

基于知识图谱的个性化音乐推荐系统的设计与实现



学 号: 202121010

作 者: 杨明远

专业学位类别: 电子信息

领 域: 软件工程

论 文 类 型: 工程（应用）软件开发

2024 年 08 月 28 日

沈阳工业大学硕士学位论文

基于知识图谱的个性化音乐推荐系统的设计与实现

Design and Implementation of Personalized Music Recommendation
System Based on Knowledge Graph

作 者： 杨明远 单位： 软件学院

指 导 教 师： 姜岩 教授 单位： 沈阳工业大学
中国科学院

协助指导教师： 王宇 副研究员 单位： 沈阳自动化研究所

单位：

论文答辩日期： 2024 年 08 月 28 日

学位授予单位： 沈 阳 工 业 大 学

摘要

随着数字音乐服务的广泛普及和音乐产业的发展，音乐推荐系统已成为提高用户体验和增加平台用户粘性的重要手段之一。然而，传统的基于用户历史行为的推荐算法已无法满足用户个性化和多样化的需求。因此，为更好地满足用户需求，借助音乐领域的知识图谱获取充足的语义信息，可以为用户提供更准确、全面的推荐服务。基于此，本文的研究核心是基于知识图谱的推荐算法，主要探讨如何高效利用知识图谱辅助音乐推荐，提升音乐推荐性能，具体研究如下。

针对现有算法利用协同信息和结构化信息不充分的问题，本文提出了一种融合协同信息的知识图谱推荐算法。该算法考虑了物品的协同信息而且使用共同邻居排序采样，更准确地获得物品的高阶表示。首先，结合协同过滤的思想，通过构建协同集合的方式引入协同信息，可以更好地挖掘用户兴趣。其次，在邻域信息聚合时采用了共同邻居排序的采样方式，在保证效率的同时提高了采样的质量。实验结果表明，该方法有效地提升了推荐的准确度。

针对邻域信息聚合过程中，对实体间重要关系学习不够灵活的问题，本文提出了一种基于图注意力的知识图谱推荐算法。将用户-物品交互图融入到知识图谱当中，构建协同知识图谱。首先提取协同信息，然后在邻域信息聚合时，引入图注意力机制，使得每个邻居节点的权重可以根据其与目标节点的关系动态调整，捕捉到节点之间更加复杂的关系。实验结果表明，该方法进一步提升了推荐的准确度。

本文设计并且实现了基于知识图谱的个性化音乐推荐系统。首先使用爬虫技术获取了国内音乐相关数据，构建了中文音乐知识图谱，然后对系统进行了需求分析与系统设计，最后使用本文提出的模型实现了音乐推荐系统。

关键词：音乐推荐，知识图谱，协同信息，图注意力

Abstract

With the widespread popularity of digital music services and the development of the music industry, music recommendation systems have become one of the important means to improve user experience and increase platform user stickiness. However, traditional recommendation algorithms based on user behavior history can no longer meet the personalized and diversified needs of users. Therefore, to better meet user needs, it is necessary to obtain sufficient semantic information through the knowledge graph in the music domain, which can provide users with more accurate and comprehensive recommendation services. Based on this, the research focus of this thesis is the recommendation algorithm based on knowledge graph, mainly exploring how to efficiently use knowledge graph to assist music recommendation and improve the performance of music recommendation. The specific research is as follows.

To address the issue of insufficient utilization of collaborative and structured information in existing algorithms, this thesis proposes a knowledge graph recommendation algorithm that integrates collaborative information. The algorithm considers the collaborative information of items and uses common neighbor sorting sampling to more accurately obtain high-order representations of items. Firstly, by incorporating the idea of collaborative filtering and constructing collaborative sets, collaborative information can be introduced, which helps to better explore user interests. Secondly, the sampling method of common neighbor sorting is used when aggregating neighborhood information, which improves the quality of sampling while ensuring efficiency. Experiments on three datasets demonstrate that this method effectively improves the accuracy of recommendations.

To address the issue of inflexible learning of important relationships between entities during neighborhood information aggregation, this thesis proposes a knowledge graph recommendation algorithm based on graph attention. The user-item interaction graph is integrated into the knowledge graph to construct a collaborative knowledge graph. Firstly, collaborative information is extracted. Then, when aggregating neighborhood information, a graph attention mechanism is introduced, so that the weight of each neighboring node can be dynamically adjusted according to its relationship with the target node, capturing more complex relationships between nodes. Experimental results demonstrate that this method further improves the accuracy of recommendations.

This thesis designs and implements a personalized music recommendation system based on knowledge graph. Firstly, crawler technology is used to obtain domestic music-related data, and a Chinese music knowledge graph are constructed. Then, the system is analyzed for requirements and designed. Finally, the music recommendation system is implemented using the model proposed in this thesis.

Key Words: Music Recommendation, Knowledge graph, Collaborative information, Graph attention

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 推荐系统研究现状.....	2
1.2.2 音乐推荐系统研究现状.....	3
1.3 论文研究内容.....	4
1.4 论文结构安排.....	5
第 2 章 相关理论与技术	6
2.1 传统推荐系统.....	6
2.1.1 基于内容的推荐算法.....	6
2.1.2 基于协同过滤的推荐算法.....	7
2.1.3 混合推荐算法.....	8
2.2 知识图谱.....	9
2.3 图神经网络.....	10
2.4 基于知识图谱的推荐算法	12
2.4.1 基于嵌入的方法.....	13
2.4.2 基于路径的方法.....	15
2.4.3 混合的方法.....	15
2.5 本章小结.....	16
第 3 章 融合协同信息的知识图谱推荐算法	17
3.1 模型描述.....	17
3.1.1 协同信息的获取.....	18
3.1.2 优化采样的知识传播.....	19
3.1.3 协同信息的聚合.....	22
3.1.4 推荐预测.....	22
3.2 实验与结果分析.....	23
3.2.1 数据集描述.....	23
3.2.2 评价指标.....	24
3.2.3 基线方法.....	25
3.2.4 实验设置.....	25
3.2.5 实验结果.....	25
3.3 本章小结.....	29
第 4 章 基于图注意力的知识图谱推荐算法	30
4.1 模型描述.....	30

4.1.1 协同知识图谱的构建.....	31
4.1.2 基于图注意力的知识传播.....	32
4.1.3 推荐预测.....	34
4.2 实验与结果分析.....	35
4.2.1 实验设置.....	36
4.2.2 实验结果.....	36
4.3 本章小结.....	38
第 5 章 个性化音乐推荐系统的设计与实现	39
5.1 需求分析.....	39
5.1.1 管理员需求分析.....	39
5.1.2 用户需求分析.....	40
5.1.3 非功能需求分析.....	40
5.2 系统设计.....	41
5.2.1 系统架构设计.....	41
5.2.2 数据库设计.....	43
5.3 数据获取.....	45
5.4 系统实现.....	47
5.5 本章小结.....	52
第 6 章 结论与展望	53
6.1 结论.....	53
6.2 展望.....	53
参考文献.....	54

第 1 章 绪论

1.1 研究背景及意义

随着音乐产业的不断发展，音乐流媒体服务已经成为用户获取音乐的主要方式。iTunes、腾讯、网易等音乐流媒体服务商通过提供方便的音乐播放功能和个性化的推荐服务，为用户带来了更好的音乐体验。然而，随着音乐数量的增长，用户面临更多的选择，用户在这些海量选择中可能会感到困惑和无法决策的迷茫状态，这是信息时代带来的“信息过载”负面影响^[1]。

为了应对“信息过载”问题，人们提出了推荐系统。推荐系统采取主动策略，根据用户的兴趣偏好主动推荐可能符合需求的内容。在当前互联网快速发展的环境下，推荐系统被广泛应用^[2-5]，受到越来越多的关注。在音乐行业中，对于音乐爱好者而言，音乐推荐系统可以通过了解用户心理偏好和听歌习惯等方面来提供个性化的音乐服务，提高用户的音乐体验和满意度。此外音乐推荐系统不仅可以满足用户的需求，还可以提高音乐产品的市场价值，为音乐行业带来更多的商业机会。了解用户心理偏好的变化和趋势，对于音乐产品的开发和推广有着重要的意义。未来，音乐推荐系统将在更广泛的领域得到应用，并在音乐产业中发挥越来越重要的作用。

对于音乐推荐系统而言，推荐算法是其核心。在音乐推荐场景中，推荐算法利用用户的历史行为信息和音乐的属性信息，获得用户与音乐之间的潜在联系，从而将用户可能感兴趣的音乐推荐给他^[6]。传统的基于内容和基于协同过滤的推荐算法已被广泛应用，并且具有良好的推荐效果。然而，随着大数据时代的发展，传统的推荐算法面临着冷启动问题和数据稀疏的问题^[7]。冷启动问题指的是，当向原有推荐系统中加入新用户或者新物品时，由于对于新用户或新物品的交互信息缺少，难以对用户进行推荐；数据稀疏问题指的是用户行为数据过于稀疏，难以准确地描述用户的兴趣^[8]。

为了解决这些问题，引入辅助信息是一种有效的方法。近年来，将辅助信息和推荐系统相结合，逐渐成为了研究热点。常见的辅助信息包括物品的属性、评论内容、用户的社交网络等^[9]。知识图谱作为一种异构网络，同样可以引入到推荐系统当中，和推荐系统相结合，并且有效地缓解了传统推荐系统存在的一些问题^[10-11]。将知识图谱引入到推荐系统中，目的是利用知识图谱中的实体和关系信息，丰富推荐系统中的物品表示^[12]。

因此,使用知识图谱辅助音乐推荐相较于传统推荐算法,具有一定优势^[13]。首先,知识图谱的各个节点之间由关系路径链接,在一定程度上,可以为音乐推荐系统提供可解释性。其次,知识图谱是音乐属性的拓展信息,可以有效地缓解冷启动问题。最后,知识图谱中包含着丰富的语义信息,将知识图谱作为音乐推荐系统的辅助信息,可以提高对音乐高阶信息的使用,更加准确地挖掘用户的兴趣,从而提高推荐的准确性。综上所述,本文将研究如何使用知识图谱辅助音乐推荐,探索提升推荐性能的方法。

1.2 国内外研究现状

1.2.1 推荐系统研究现状

推荐系统的历史可以追溯到 20 世纪 90 年代。随着互联网的发展,推荐算法已经成为人工智能领域的一个重要分支,同时也得到了广泛的应用,如电子商务、社交网络、音乐和视频等领域^[14]。在算法层面,协同过滤、基于内容的推荐等传统方法不断优化,深度学习、强化学习等新兴技术的融入进一步提升了推荐效果。同时,对用户行为数据的深入挖掘与分析,以及如何提高推荐的个性化和精准度成为关键研究点。

传统推荐算法主要涵盖基于内容的推荐算法、基于协同过滤的推荐算法以及混合的推荐算法。其中,协同过滤算法一直是推荐系统中的经典算法,近年来,研究人员通过引入更多的用户特征和行为信息,提高了算法的准确性。例如,考虑用户的浏览时长、收藏行为等,对用户相似度的计算进行了优化,使得推荐结果更贴合用户的真实兴趣。其中,应用最为广泛的算法当属矩阵分解协同过滤算法^[15]。该算法通过矩阵分解的手段,实现对用户-物品交互矩阵的降维,进而预测用户-物品交互矩阵中未知位置的评分。奇异值分解(Singular Value Decomposition, SVD)作为一种经典的矩阵分解降维方法,其核心思路是将用户-物品交互矩阵分解为三个矩阵,以用于预测用户对未知物品的评分。基于内容的推荐算法也在不断改进通过更深入的自然语言处理技术,能够更精准地提取文本特征,从而为用户推荐更相关的内容。此外,混合推荐算法成为研究热点,将协同过滤与基于内容的推荐相结合,充分发挥两者的优势。例如,先通过基于内容的推荐为新用户提供初步推荐,再利用协同过滤算法根据用户的反馈进行精准推荐。

伴随人工智能的蓬勃发展,众多研究者将深度学习应用于推荐系统之中。2016 年,谷歌公司推出了 Wide&Deep 推荐模型^[16],它将基础的线性回归模型与深度学习网络横向拼接,使推荐具备了良好的泛化能力。2019 年, Wang 等提出了神经图协同过滤推荐

模型^[17], 该模型将用户和物品之间的关系构建为一个图形结构, 并运用图神经网络对用户和物品进行嵌入表示, 最终通过内积得分函数来预测用户对物品的评分或喜好。

1.2.2 音乐推荐系统研究现状

随着音乐数字化时代的到来, 众多的异质音乐显然已经越过了用户对音乐的基本需求和对音乐的承载基线。那么如何帮助用户能够精确, 迅速的在海量的音乐中找到他们喜欢的音乐, 成为了推荐系统研究的一大热点。

在国内, 如网易云音乐等知名音乐平台, 广泛应用了协同过滤算法。网易云音乐通过分析用户的听歌历史、收藏、评论等行为数据, 计算用户之间的相似度。对于相似度较高的用户, 将其喜好的音乐推荐给其他相似用户。这种算法在一定程度上提高了推荐的准确性, 但也存在一些问题, 比如新用户由于缺乏历史数据, 可能会得到不太准确的推荐。国内的研究人员也在积极探索利用社交数据来提升音乐推荐效果。例如, QQ 音乐通过分析用户在社交平台上的好友关系、分享行为以及群组互动等数据, 挖掘用户的潜在音乐喜好。当用户的好友喜欢某类音乐并进行分享时, 系统会将相关音乐推荐给该用户。此外, 一些研究还关注用户在音乐社交平台上的讨论话题、音乐推荐群组中的交流信息等, 以此更全面地了解用户的音乐兴趣, 从而提供更贴合用户需求的推荐。

在国外, 深度学习展示了其在音乐推荐中的优势。以 Spotify 为例, 它采用了深度神经网络来分析用户的历史行为和音乐特征。通过对海量数据的学习, 模型能够捕捉到复杂的用户偏好模式, 从而提供高度个性化的推荐。例如, 模型可以根据用户对不同类型音乐的播放时长、跳过频率等细节, 精准预测用户对新音乐的喜好程度。

除了以上较大的音乐平台, 在音乐推荐领域, 一些研究者也贡献颇多。比如, Ke 等^[18]探讨了用户音乐播放历史数据和人口统计特征, 构建了一个嵌入式用户模型来表示用户的音乐偏好, 模型可通过分别计算音轨的音频嵌入和不同的用户嵌入之间的相似度来确定推荐的最佳用户组。Lvana 等^[19]从用户喜欢收听的歌手的音乐情感角度建立音乐推荐系统, 通过对用户选取的歌手进行情感分析, 计算多个歌手的综合情感, 然后推荐给用户符合综合情感的音乐推荐列表, 该系统设计了对选取歌手、情感分析结果、推荐列表的可编辑功能, 用户可以方便通过修改信息来获得满意的推荐结果。李丹阳等^[20]提出基于多源信息融合的音乐推荐方法, 通过两段式模型融合多源信息构建音乐特征体系, 解决冷启动问题并提高推荐效果。杨明极等^[21]提出的混合注意力机制的独立循环神经网络音乐推荐算法 (AIRNN), 借助散射变换对音频数据进行预处理, 并引入注意力机制, 显著提高了音乐推荐的准确率。李琳等^[22]所提出的基于多层

注意力表示的音乐推荐模型（HARM），能够有效区分用户对歌曲多域特征的差异偏好以及不同历史行为对用户偏好的影响。王海龙等^[23]创建的基于音乐信息检索（MIR）及 K-Means 标签聚类的音乐个性化推荐算法，通过构建 MIR 系统多模网络并采用 K-Means 标签聚类，提升了音乐推荐的质量和效率。

以上方法在一定程度上提高了音乐推荐的准确性和效果，但仍存在一些问题，如算法复杂，训练模型时间较长、难以处理复杂的音乐关系等。为了缓解这些问题，辅助信息的引入成为了一个有效的手段。而知识图谱具有强大的知识表示和推理能力，可以更好地处理音乐领域的复杂关系和语义信息，为音乐推荐提供更加准确、全面和个性化的推荐服务。

1.3 论文研究内容

知识图谱作为一种结构化的知识表示方式，可以建模不同实体之间的关系，为推荐系统提供更加丰富的信息。将知识图谱中学习到的特征表示自然地融入音乐推荐中，可以更好地捕捉用户的兴趣和行为模式，从而提高音乐推荐的精准度。本文的主要研究内容如下。

（1）对于关于音乐推荐系统的发展历程进行了梳理，对于推荐系统技术，知识图谱技术和二者结合的基于知识图谱的推荐进行了详细的介绍和分析。

（2）针对现有算法对协同信息和结构化信息利用不充分的问题。本文提出了融合协同信息的知识图谱推荐算法，引入了协同信息，而且在邻域聚合过程中采用共同邻居排序采样，提高推荐结果的准确性和实用性。引入协同信息，可以更好地挖掘用户兴趣和实体间的相关性。在图卷积步骤中采用共同邻居排序的采样方式，在保证效率的同时提高了采样的质量。

（3）针对在知识传播邻域聚合过程中实体间重要关系学习不够灵活的问题，本文提出了基于图注意力的知识图谱推荐算法。将用户-物品交互图融合到知识图谱当中，得到协同知识图谱，采用轻量级图卷积操作提取协同信息。并且在知识传播过程中引入图注意力机制，以根据节点之间的关系动态地分配邻居节点的权重。通过这种方式，进一步提高了推荐的准确度。

（4）对音乐推荐系统进行需求分析和系统设计使用爬虫技术获取国内音乐相关数据，构建中文音乐知识图谱。基于以上推荐模型，使用主流前后端开发框架对系统进行了实现。

1.4 论文结构安排

本文针对音乐相关数据，实现了基于知识图谱的个性化音乐推荐系统，文整体结构共分为五章，其内容和结构安排如下：

第1章首先介绍了本课题研究的背景及意义，然后介绍了推荐系统和音乐推荐系统的研究现状、最后介绍了课题主要研究的内容和本文的结构安排。

第2章介绍了音乐推荐系统涉及的相关技术，为本文研究实现基于知识图谱的音乐推荐系统提供理论基础。

第3章介绍了融合协同信息的知识图谱推荐算法。该模型通过引入协同信息和共同邻居排序采样，以提高推荐结果的准确性和实用性。结合协同过滤的思想，引入协同信息，可以更好地挖掘用户兴趣和实体间的相关性。在图卷积时采用了共同邻居排序的采样方式，在保证效率的同时提高了采样的质量。实验证明，该方法可以有效提升推荐的准确度。

第4章介绍了基于图注意力的知识图谱推荐算法。在第3章模型的基础上，将用户-物品交互图融入知识图谱中，使用轻量级图卷积操作提取协同信息，并且使用图注意力机制动态分配邻居节点的权值。实验证明，该方法可以有效提升推荐的准确度。

第5章首先对音乐推荐系统进行了需求分析和系统设计，为系统实现给予指导。然后使用爬虫技术获取国内音乐相关数据，构建了中文音乐知识图谱。最后使用主流前后端开发框架对系统进行了实现。

第6章对本文的工作进行总结，说明当前工作仍存在的缺陷，并对未来工作展望。

第2章 相关理论与技术

本章主要对基于知识图谱的推荐系统相关技术予以介绍。首先，阐述了推荐系统技术、知识图谱以及图神经网络技术。随后，对基于知识图谱的推荐算法进行了介绍。

2.1 传统推荐系统

随着人类社会的发展，信息越来越多，若不加处理，人们和企业从海量的信息中选择适合自己的内容，这个问题就叫做信息过载。信息过载不仅会浪费人们的时间和精力，还会降低人们的工作效率和生活质量。为了解决信息过载的问题，推荐系统应运而生。推荐系统是一种基于用户历史行为或物品属性信息进行建模分析的系统，旨在预测用户可能喜欢的物品并进行推荐。推荐系统的核心是算法模型，通过对用户历史行为和物品属性信息的分析，可以建立用户和物品之间的关系模型，从而预测用户对物品的喜好程度。推荐系统的应用非常广泛，例如电商平台、社交媒体、新闻网站等。在电商平台上，推荐系统可以根据用户的历史购买记录和浏览行为，为用户推荐符合其兴趣和需求的商品，提高用户的购物体验 and 购买率。在社交媒体上，推荐系统可以根据用户的兴趣和社交关系，为用户推荐感兴趣的内容和好友，增加用户的社交互动和粘性。在新闻网站上，推荐系统可以根据用户的浏览历史和兴趣偏好，为用户推荐相关的新闻和文章，提高用户的阅读体验和满意度。本节将围绕推荐系统技术的核心即推荐算法展开介绍，传统推荐算法主要分为三类，基于内容的推荐算法，基于协同过滤的推荐算法和混合推荐算法。

2.1.1 基于内容的推荐算法

基于内容的推荐算法是一种常见的推荐系统算法，它主要基于物品的属性或特征，来计算物品之间的相似度，然后根据用户的历史行为和偏好，为用户推荐与其喜好相似的物品^[24]。其核心思想是通过度量方式计算不同物品之间的相似度，从而推荐给用户相似的物品。其中，物品之间的相似度一般采用余弦相似度或欧几里得距离等方式计算。基于内容的推荐算法的优点是可以推荐用户可能感兴趣的新物品，而不需要考虑其他用户的行为。基于内容的推荐算法具有计算简单、推荐准确等优点，因此得到了广泛的应用。但是它也有一些缺点，例如容易受到物品属性的限制，难以发现用户的潜在兴趣等，可能会出现推荐过于相似的物品，导致推荐列表缺乏多样性。在音乐推荐场景下，基于内容的推荐算法如图 2.1 所示，一个用户喜欢听周杰伦的《晴天》，那么该

用户也可能喜欢周杰伦的《七里香》，就把《七里香》推荐给该用户。




图 2.1 基于内容的推荐算法示意图

Fig. 2.1 Schematic diagram of content-based recommendation algorithm

2.1.2 基于协同过滤的推荐算法

协同过滤算法是一种常用的推荐算法，使用广泛，它基于用户的历史行为数据或者用户的偏好信息，来预测用户对未知物品的喜好程度。协同过滤算法的基本思想是，通过分析用户和物品之间交互信息的相似性，来给用户推荐其可能喜欢的物品。相似的用户会有相似的偏好，反过来，相似的物品会被相似的人喜欢。基于协同过滤的推荐算法又可以细分为不同的类型，接下来介绍这几种方法。

(1) 基于用户的协同过滤

基于用户的协同过滤通过计算用户之间交互行为的相似度，给一个用户推荐与之交互行为相似的其他用户喜欢的物品。例如用户的浏览、收藏等行为，这些行为可以被看作是用户对商品的偏好和兴趣的体现。通过对这些行为数据进行分析 and 挖掘，可以发现用户之间的相似性和差异性，从而实现个性化推荐。

在一个推荐系统中的两个用户分别表示为向量 u_1 和向量 u_2 ，那么用户 u_1 和用户 u_2 之间的余弦相似度可以表示为式 (2.1)。其中， u_1 和 u_2 是两个用户的向量表示， $\|u\|$ 表示向量 u 的模长。

$$\cos(u_1, u_2) = \frac{u_1 \cdot u_2}{\|u_1\| \cdot \|u_2\|} \quad (2.1)$$

例如图 2.2，用户 2 喜欢物品 1，物品 2，物品 3，用户 1 喜欢物品 1 和物品 2，用户 1 和用户 2 在交互行为上具有相似性，即都喜欢物品 1 和物品 2，那么就可以把物品 3 推荐给用户 1。




图 2.2 基于用户的协同过滤算法示意图

Fig. 2.2 Schematic diagram of user based collaborative filtering algorithm

（2）基于物品的协同过滤

基于物品的协同过滤通过计算物品之间被交互行为的相似度，将物品推荐给与相似物品有交互的用户。如图 2.3 所示。物品 1 和物品 3 都被用户 2 和用户 3 存在交互，在交互行为上相似，那么可以把物品 3 推荐给与物品 1 存在交互的用户 1。




图 2.3 基于物品的协同过滤算法示意图

Fig. 2.3 Schematic diagram of items based collaborative filtering algorithm

2.1.3 混合推荐算法

混合推荐算法是一种综合考虑基于内容的推荐算法和协同过滤算法的特点的推荐

算法^[25]。

根据不同的混合推荐算法类型，可以将其分为加权式、变换式和合并式^[26]。加权式混合推荐算法使用不同的推荐算法进行推荐，对它们的推荐结果进行加权组合，得到最终的推荐结果。其中，权重的分配可以由算法的推荐性能决定，性能高，效果好的算法可拥有较大的权重。变换式推荐算法根据不同的场景直接采用不同的，适应场景的推荐算法。是由多种推荐算法生成推荐，将推荐结果合并，从而得到一个全面的推荐列表。

混合推荐算法由于使用了多种推荐算法的结果，推荐的结果会更为全面。这些混合推荐算法可以在不同的场景下使用，以提高推荐的准确性和全面性。同时，这些算法也可以根据具体情况进行组合使用，以达到更好的效果。相比于单一的推荐算法，混合推荐算法可以避免数据稀疏和冷启动等问题，提高推荐的新颖程度和用户满意度。在实际应用中，混合推荐算法是一种更加有效的推荐算法，已经被广泛应用，取得了较好的效果，避免了只使用单一推荐算法的劣势。

2.2 知识图谱

知识图谱是一种用于描述实体、概念和它们之间关系的图形化知识表示方式。它是一种基于语义的数据结构，可以用于存储和管理大量的结构化和半结构化数据。知识图谱可以帮助人们更好地理解 and 利用数据，从而实现更智能化的数据分析和应用。

知识图谱的常用数据模型为有向边标记图。有向边标记图是一种常见的数据模型，其结构由节点和有向且带有标记的边组成。这种模型的优势在于能够清晰地表达实体之间的关系，具有很强的直观性。这使得关系的方向和类型一目了然，便于理解和分析。综上，知识图谱由三元组构成，它可以表示为 $\{(h, r, t) | h, t \in E, r \in R\}$ ， h 表示头实体， r 表示实体之间的关系， t 表示尾实体。 E 表示实体集合， R 表示实体间关系的集合。比如，三元组（陈奕迅，演唱，《十年》）表示是歌手陈奕迅演唱了音乐《十年》。

在知识图谱中，实体是指具有独立存在和特定含义的事物，相互关系则是指实体之间的联系和互动。知识图谱的异构网络结构使得它能够更加准确地表达实体之间的关系，从而提高了知识的表征能力。当前，研究领域涌现出众多公共知识图谱和商业知识图谱，这些知识图谱已成功应用于问答、文本处理等人工智能技术领域，对于推动人工智能技术的发展提供了有力支持。目前，常见的大型知识图谱包括 Freebase^[27]、Wikidata^[28]、YAGO^[29]和 Dbpedia^[30]等。其中，Freebase 是由 Google 创建的一个包含数百万个实体和属性的知识图谱，涵盖了许多不同的领域。Wikidata 是由维基媒体基金会创建的一种开放、协作的知识图谱，其主要目的是为维基百科和其他维基媒体项目提

供支持。YAGO 和 Dbpedia 等知识图谱也具有广泛的应用价值。这些大型知识图谱为人工智能领域的研究提供了丰富的数据资源。

针对不同行业的认知水平差异,知识图谱通常被划分为限定领域的行业知识图谱和无限制领域的一般知识图谱^[31]。行业知识图谱主要应用于特定行业,提供专门的知识指导,准确度高,应用广泛。例如,智能问答系统、商品推荐系统等都可以利用行业知识图谱来提高准确度和效率。一般知识图谱则主要应用于聊天机器人等应用程序,它不仅包含了通用知识,还包含了各种领域的知识,但准确度相对较低。

知识图谱领域重要的一部分是知识图谱嵌入,在嵌入方法中,平移距离的翻译模型是一种常见的方法,包括 TransE^[32]、TransH^[33]、TransR^[34]和 TransD^[35]等。平移距离的翻译模型在表示知识图谱中的实体之间的关系时,利用了平移的几何意义。具体的几何意义是,通过将头实体向量平移一定的距离,使其移动到尾实体向量的位置。这个距离就是表示关系的向量。基于这种平移的几何变换原则,可以将实体向量表示与知识图谱的图结构同构起来,从而更好地表示实体之间的关系。在知识图谱中,可以通过将每个三元组的头实体、尾实体和关系分别嵌入到向量 h 、 t 和 r 中,以满足 $h+r \approx t$ 的条件。为了评估三元组的真实性,可以使用一个评估函数,该函数定义在 L1 范数或 L2 范数约束下,通过计算 $h+r$ 和 t 之间的距离来确定。目标是最小化有关系的实体之间的距离,同时最大化不相关的实体之间的距离。其数学表达式如式 (2.2) 所示。

$$d(h+r,t)=\|h+r-t\|_{L1/L2} \quad (2.2)$$

其中, $d(h+r,t)$ 表示 $h+r$ 和 t 之间的距离。TransE 模型的优点是简单易懂,计算速度快,训练效果好。但是它无法准确处理多义词和异构性等问题。TransH 使用一个超平面来表示每个关系,并且将头实体和尾实体映射到关系超平面上,然后在超平面上计算它们的互动关系。TransR 在不同的空间中建模实体和关系,对于每一个关系,设置一个投影矩阵,将实体从实体空间投影到关系空间。TransR 可以更好地处理不同关系之间的差异性,并且保持实体之间的一般关联性。但是它需要更多的参数和更长的训练时间。

2.3 图神经网络

图神经网络 (Graph Neural Network, GNN) 是一种深度学习模型,用于处理图数据结构。与传统的神经网络模型不同,图神经网络能够捕捉节点的局部和全局信息,从而提高对图结构的理解和处理能力^[36],这种能力使得图神经网络在人工智能领域得到了广泛的应用^[37]。图神经网络基础模型主要由传播模块和聚合模块构成。

传播模块是实现节点间交互和特征融合的关键环节，节点间的信息传递与状态更新方式对模型的性能和效果起着至关重要的作用。其中，聚合器在图神经网络中担当着关键角色，负责整合邻居节点的信息。常见的聚合方式有均值聚合、求和聚合和最大池化聚合等。均值聚合是通过计算邻居节点特征的平均值来更新中心节点的特征，这种方式适用于特征分布较为均匀的情形。求和聚合则是将邻居节点的特征简单相加，在强调邻居节点特征总量的场景中较为适用。最大池化聚合选取邻居节点特征中的最大值，能够突出最重要的特征信息。更新器利用聚合得到的信息来更新节点的状态。其工作原理通常基于某种特定的函数或规则，比如线性变换、非线性激活函数等。以线性变换为例，先将聚合的信息与权重矩阵相乘，再加上偏置项，然后经过非线性激活函数（如 ReLU 函数），从而得到更新后的节点状态。这样的更新过程使得节点能够持续融合邻居的信息，进而更好地捕捉图结构中的特征和模式。

输出模块在图神经网络中负责将节点和边的向量表示转化为最终的预测或输出。在监督学习场景下，特定节点的监督信号通常以标签的形式呈现。例如，在节点分类任务中，每个节点可能被标注为不同的类别。损失函数的定义一般基于预测值与真实标签之间的差异。常见的损失函数有交叉熵损失函数和均方误差损失函数。交叉熵损失函数常应用于分类问题，用于衡量预测概率分布与真实分布之间的差异；均方误差损失函数则适用于回归问题，它计算预测值与真实值之间的平均平方差异。常见的输出形式包括节点分类、边预测和图分类等。节点分类输出每个节点所属的类别；边预测判断节点之间是否存在连接以及连接的属性（如连接的强度、类型等）；图分类则是对整个图进行分类。不同的输出形式适用于不同的应用场景。例如，在社交网络分析中，节点分类常用于判断用户的兴趣类别；在交通网络中，边预测可用于预测道路的拥堵情况以及道路之间的连接属性；在生物信息学中，图分类可用于区分不同的蛋白质结构。




图 2.4 欧式空间的数据结构

Fig. 2.4 The data structure of Euclidean space




图 2.5 非欧氏空间的数据结构

Fig. 2.5 The data structure of non-Euclidean space

图神经网络被设计用于特征学习和预测任务，这些任务通常需要考虑节点之间的关系。它有效地处理非欧几里德空间中的图结构数据，欧式空间和非欧式空间中的数据如图 2.4，图 2.5 所示。相较于欧氏空间，非欧氏空间并不规则。

早期的图神经网络存在着一些限制，难以适应异构和动态变化的图结构。比如，由于传统的卷积滤波器对非欧式结构数据的限制，使其并不能很好地应用于图结构数据中。为了克服这个此问题，研究人员发展出了图卷积神经网络（Graph Convolutional neural Network, GCN）。它通过将图形数据表示为图形邻接矩阵，利用邻接矩阵来提取节点之间的关系，并通过卷积操作来提取节点特征^[38]。图卷积神经网络可以分为基于谱域的图卷积神经网络和基于空域的图卷积神经网络。基于谱域的图卷积神经网络使用图的拉普拉斯矩阵的特征向量作为基函数，通过对特征向量进行卷积操作得到新的特征向量。而基于空域的图卷积神经网络则是将每个节点的邻居节点特征和节点自身特征作为输入，使用一个神经网络进行卷积操作，并将卷积后的特征作为新的节点特征。

除此之外，注意力机制逐渐成为研究热点。图注意力网络（Graph Attention Network, GAT）应运而生。图注意力网络通过计算节点之间的相似度，将相似度作为权重对节点进行加权，从而实现对节点的聚合^[39]。图注意力网络已经被广泛应用于任务如图像分类、节点分类、链接预测等，取得了很好的效果^[40]。

2.4 基于知识图谱的推荐算法

使用知识图谱辅助推荐相较于传统推荐算法，具有一定优势^[41]。首先，知识图谱的各个节点之间由关系路径链接，在一定程度上，可以推荐系统提供可解释性。其次，知识图谱是物品属性的拓展信息，可以有效地缓解冷启动问题。此外，知识图谱由实体之间的各种关系组成，可以帮助推荐系统挖掘实体之间的关系，提高推荐系统的准确

率和性能。最后，知识图谱中包含着丰富的语义信息，将知识图谱作为推荐系统的辅助信息，可以提高对物品高阶信息的使用，更加准确地挖掘用户的兴趣，从而提高推荐的准确性。图 2.6 展示的是一个基于知识图谱的推荐示例，在该示例中，向用户推荐了音乐《千里之外》，这是因为它和用户喜欢的音乐《桃花扇》和《晴天》有相同的属性特征，即国风和周杰伦演唱。




图 2.6 基于知识图谱的推荐示例

Fig. 2.6 Example of recommendation based on knowledge graph with academic rigor

根据推荐系统如何结合知识图谱信息的方式，可以分为基于嵌入的方法、基于路径的方法和基于混合的方法，下文将分别介绍这三种方法。

2.4.1 基于嵌入的方法

基于嵌入的方法往往是直接利用知识图谱的信息来增强物品或者用户的表示^[42]。基于嵌入的方法主要包含两个重要模块，知识图谱嵌入模块和推荐模块。对于知识图谱嵌入技术，常见的知识图谱嵌入方法有 TransE、TransH、TransR 和 TransD 等翻译距离模型。翻译距离模型是将尾向量视作由首向量经过关系向量的翻译距离所得到的结果。

根据知识图谱嵌入模块和推荐模块的学习顺序，又可以分为以下几类，分别是依次学习、联合学习和交替学习，如图 2.7 所示。

依次学习是指将知识图谱嵌入和推荐模型的学习过程分别进行，先学习知识图谱嵌入模型，再将学习得到的知识图谱嵌入放推荐模型中进行学习。这种方法的优点是可以分别对知识图谱嵌入和推荐模型进行优化，缺点是可能会出现信息流失和误差传递的问题。

联合学习是指将知识图谱嵌入和推荐模型的学习过程合并为一个联合学习过程，

同时优化两个模型。这种方法的优点是可以充分利用知识图谱和推荐模型之间的相互关系，缺点是优化过程可能会比较复杂。




图 2.7 知识图谱与推荐的联合方式

Fig. 2.7 The joint approach of knowledge graph and recommendation

交替学习是指将知识图谱嵌入和推荐模型的学习过程交替进行，先优化一个模型，再优化另一个模型，交替进行。这种方法的优点是可以充分利用知识图谱和推荐模型之间的相互关系，同时避免了信息流失和误差传递的问题，缺点是可能会出现局部最优解的问题。

CKE 模型^[43]主要利用知识图谱、文本和图片等辅助信息得到物品的向量表示，最后得到推荐结果。其中，TransR 模型是一种基于关系嵌入的方法，它可以将物品表示为在关系空间中的向量。通过使用 TransR 模型，CKE 模型可以将物品的知识图谱信息融入到物品表示中。然后和推荐模块做联合学习训练，最后进行推荐。该模型结合了知识图谱，文本信息和视觉信息等作为推荐的辅助信息，提升推荐的准确度。

DKN 模型^[44]是一种基于内容的点击率预测模型，主要针对于新闻领域使用的推荐模型，新闻推荐不同于其他领域推荐，新闻的推荐往往存在时效性问题。DKN 用知识感知卷积神经网络（Knowledge-aware Convolutional Neural Network, KCNN）学习句子文体的嵌入，由于用户不同的历史兴趣对当前候选新闻的影响不同，最后加入注意力机制根据用户历史浏览记录添加权重得到用户偏好。但是由于 DKN 模型是依次进行学习，知识图谱嵌入模块和推荐模块之间独立，无法实现端到端的训练。

MKR 方法^[45]，该模型采用多任务学习法，包括推荐部分和知识图谱嵌入部分，推荐部分学习用户和物品的潜在向量，知识图谱嵌入部分学习相关实体的表示，通过一

个交叉压缩单元连接,通过这种方式,可以共享不同任务之间的信息,从而提高模型的泛化能力和效率。

基于嵌入的方法在理解用户和物品特征方面展现了优越性,其有助于挖掘用户偏好。然而,知识图谱作为一种重要的知识表示方式,其节点众多,关系复杂,呈现出高度的结构性和层次性。基于嵌入的方法常常忽略了知识图谱中的高阶结构信息,导致对知识图谱的利用不够充分。

2.4.2 基于路径的方法

基于路径的推荐算法是一种挖掘基于图谱用户、物品之间多种连接关系^[46],利用知识图谱中的路径信息来进行推荐的方法。在知识图谱中,实体之间的关系连接可由路径表示,两个实体之间可能存在多条路径,可以根据这些路径帮助发现用户和物品之间的潜在关联。利用知识图谱中的实体、关系和属性信息,可以构建元路径或元图。对于每个发现的元路径,可以计算路径权重来衡量它对于用户和物品之间关联的重要性。

HeteRec 模型^[47],又称为 PER,是一种基于路径的推荐模型,通过构建多种元路径来描述用户和物品之间的关系,然后使用路径相似性来计算它们之间的相似度得分。这个得分可以被用来构造用户偏好矩阵,从而进行推荐。最后,使用矩阵分解来生成个性化的推荐列表。

RKGE 模型^[48]使用循环神经网络对用户和物品之间的语义路径进行建模,并学习语义路径的嵌入向量。这些嵌入向量可以被用来表示用户和物品之间的关系,从而进行推荐预测。

然而,基于路径的方法的主要挑战在于路径选择的优化问题。在实践中,定义有效的元路径需要领域专业知识,手动设计元路径是非常困难的,所以,基于路径的方法难以在实际中应用。

2.4.3 混合的方法

基于混合的方法将上述两种方法结合起来,既考虑实体之间的嵌入关系,也考虑实体之间的高阶关系^[49]。它既使用基于嵌入的方法来得到实体的嵌入表示,也根据路径发现实体之间的高阶关系,它可以克服单一方法的局限性,从而获得更准确的推荐结果。

RippleNet 模型^[50]以用户交互过的物品作为种子,由内向外,以类似水波纹一样外,一圈圈扩散传播,中心和周围实体之间的关联性不断减少,然后得到能够表示用户偏好的波纹集合。将用户交互过的种子得到的多个波纹集合叠加起来,便形成了用户对

于物品的偏好分布。

KGCN 模型^[51]是一种将图卷积网络和知识图谱结合的推荐模型。该模型从知识图谱中采样实体的邻居集作为邻域，聚合邻域信息得到实体的表示。通过聚合邻域信息，可以学习 KG 的结构信息和语义信息以及用户的个性化和潜在兴趣。

KGAT 模型^[52]利用图注意力网络进行消息传递，从而聚合出物品向量与用户向量，最终得到推荐结果。

CKAN 模型^[53]采用异构传播策略对协作信号和知识关联进行显式编码，并采用知识感知的注意力机制对邻域重要性进行区分。

混合方法将基于嵌入的技术与基于路径的方法相结合，通过融合路径传播的概念来增强用户及物品特征的表示。这种方法能提供更为精准的预测结果，相较于其他两种方法展现出了其独特的优势，但需要大量的计算资源，且参数优化过程较为复杂。

2.5 本章小结

本章主要聚焦于推荐系统的关键技术，深入探讨了知识图谱的相关技术以及二者结合的基于知识图谱的推荐算法。首先对推荐系统进行了形式化的描述，以便为读者提供一个清晰且系统的理解框架。随后详细介绍了传统推荐算法的三种主要类型，分别是基于内容的推荐、协同过滤推荐以及混合推荐。在介绍传统推荐算法的基础上，本章进一步介绍了图神经网络和知识图谱的概念及其相关技术。知识图谱作为一种强大的知识表示工具，能够有效地揭示实体之间的复杂关系，为推荐系统提供更为丰富和深入的语义信息。最后，本章重点探讨了基于知识图谱的推荐算法，将这类算法分为三个主要类别，并分别进行了详细的阐述。

第3章 融合协同信息的知识图谱推荐算法

使用知识图谱辅助推荐在一定程度上提高了推荐系统的性能，但仍有许多挑战需要克服，比如如何有效地利用协同信息和结构化信息，如何更准确地获得用户和物品的高阶表示。针对以上问题，本章提出了融合协同信息的知识图谱推荐算法。首先，结合协同过滤的思想，通过引入协同信息，可以更好地挖掘用户兴趣和实体间的相关性。其次，在图卷积分聚合邻域信息时优化采样方式，采用了共同邻居排序的采样方式，在保证效率的同时提高了采样的质量。

3.1 模型描述

针对现有算法利用协同信息和结构化信息不充分的问题，本文提出了一种融合协同信息的知识图谱推荐算法。该模型融合了共同邻居排序采样和协同信息来提高推荐结果的准确性和实用性。具体来说，首先，该模型基于知识图谱来构建实体之间的关系网络，并将这些关系应用到推荐过程中。其次，该模型引入协同信息，协同信息是指物品与用户之间的交互相似性信息，它可以帮助模型更好地推荐符合用户兴趣的内容。通过挖掘物品的协同信息，来推荐与用户历史行为相似的物品，通过挖掘物品的协同信息来更好地推荐符合用户兴趣的内容。另外，在知识传播过程的邻居节点采样步骤时采用了共同邻居排序的方式，既选择与这种方法在采样时既保证了采样效率也提高了采样的质量。

推荐场景可以描述如下。假设在推荐场景中，有一组 M 个用户的集合 $U = \{u_1, u_2, \dots, u_M\}$ 和一组 N 个物品的集合 $V = \{v_1, v_2, \dots, v_N\}$ 。根据用户的隐式反馈，如点击、浏览、购买行为，可以得到一个用户-物品的交互矩阵 $Y \in \mathbb{R}^{M \times N}$ ，当 $y_{uv} = 1$ 时表示用户 u 和物品 v 产生了交互，否则 $y_{uv} = 0$ 。此外，知识图谱作为物品的辅助信息定义为 $G = \{(h, r, t) | h, t \in E, r \in R\}$ ，其中三元组 (h, r, t) 表示头实体 h 与尾实体 t 通过关系 r 相连 E 和 R 分别表示实体和关系的集合。在音乐推荐场景中，有用户-物品的交互对（用户 A-《青花瓷》），表示用户 A 对《青花瓷》产生过交互行为。对于推荐任务，给定用户-物品交互矩阵 Y 和知识图谱 G ，需要通过学习得到一个预测函数 $\hat{y}_{uv} = F(u, v | \theta, Y, G)$ ，其中， $\hat{y}_{uv}$ 代表预测的概率， θ 表示函数的模型参数。该函数的主要任务是预测用户 u 对未交互过的物品 v 是否存在潜在的兴趣。

综上，该模型通过应用知识图谱来构建实体关系网络，并融合共同邻居排序采样和协同信息。该模型会考虑多个因素，例如用户历史行为、实体间的关系、实体的属性

等,从而提供更加个性化、全面的推荐服务。为了方便描述,将本章算法表示为 KGRCI (Knowledge Graph Recommendation Algorithm Integrating Collaborative Information)。模型结构如图 3.1 所示。




图 3.1 KGRCI 模型结构图

Fig. 3.1 KGRCI Model architecture diagram

3.1.1 协同信息的获取

协同过滤是一种常见的推荐系统算法,其核心思想是利用用户之间的相似性来预测用户对物品的评分或喜好。在协同过滤中,用户之间的相似性通常是通过计算它们之间的相似度来实现的。根据协同过滤的思想,与同一物品有过交互的用户通常会有相似的兴趣爱好,因此可以利用这些用户的信息来更加详细地描述该物品。与同一物品有过交互的用户通常会有相似的兴趣爱好,因此可以利用这些用户的信息来更加详细地描述该物品,即用与物品交互过的用户的其他历史记录来表示该物品。

本章中物品的协同信息使用其协同集合来表示。将同一个用户交互的物品称为协同集合,物品的协同集合是与其被交互用户交互过的其他物品集合,如图 3.2 所示。

物品 v 的协同集合 $C(v)$ 可以定义为式 (3.1),其中 v_u 表示同一个用户交互的物品, $y_{uv_u}=1$ 表示用户 u 与这个物品 v_u 有过交互。

$$C(v) = \{v_u \mid u \in \{u \mid y_{uv} = 1\} \cap y_{uv_u} = 1\} \quad (3.1)$$

考虑到运算复杂度和数据中的噪声影响,需要设定一个超参数 n ,来约束一个物品的协同集合的大小。如果协同集合的大小超过 n ,那么可以随机选择,也可以选择余弦相似度最大的前 n 个物品作为协同集合,本文选择随机选择的方式来决定协同集合。




图 3.2 物品的协同集合

Fig. 3.2 Collaborative set of an item

3.1.2 优化采样的知识传播

知识传播是一项重要的工作,其主要任务是对物品及其邻居节点进行聚合。为了实现这一目标,本文将知识图谱中节点的邻域信息建模为接收域,通过聚合接收域信息,得到节点的增强表示。通过这种方式,能够提供节点更准确和全面的表示,从而更好地理解和应用知识图谱。图 3.3 展示了两层接收域,蓝色圆点表示知识图谱给定的实体,绿色圆点表示接受域的实体。

另外,本文对采样步骤进行了优化,提高了采样的质量。 $N(v)$ 表示直接连接到 v 的实体集合,在知识图谱中, $N(v)$ 的大小可能在所有实体上都有很大的不同,每个实体的邻居节点个数不同且数量多,所以需要限制其大小,进行采样操作。传统的随机采样方法不能充分考虑到知识图谱中待采样实体和其他实体的关系连接紧密程度。实体之间的共同邻居数量越多,说明它们之间的联系越紧密,所以本文对待采样节点的邻居进行共同邻居排序采样。通过这种方法,可以更加准确地捕捉实体之间的关系,提高知识图谱的表示能力和推理能力。




图 3.3 两层接收域示意图

Fig. 3.3 A two-layer receptive field schematic diagram

共同邻居排序采样方法可以描述如下，对于一个主节点 e ，需要选择其邻居节点作为其接收域。在选择邻居节点时，首先根据传统随机采样方法设定一个阈值 K ，如果某个节点 e 的邻居数量大于或等于阈值 K ，则计算出主节点 e 与每个邻居节点之间的共同邻居数量 C ，将邻居节点按照它们与主节点 e 的共同邻居数量排序，选择其中与主节点 e 共同邻居数量最多的前 K 个节点作为采样目标。邻居节点的数量不足阈值 K ，则剩余的位置采用传统的随机重复采样方法获得，如图 3.4 所示。




图 3.4 共同邻居排序采样

Fig. 3.4 Common neighbor ranking sampling

该方法可以更好地利用协同信息来挖掘用户兴趣和物品之间的关联性，并以此作为推荐系统的基础。与传统的随机采样方法相比，此方法考虑了不同节点之间的关联性，更加准确地选择了符合用户兴趣的内容，并且可以提高采样的质量，增强了推荐模型的性能。因此，通过共同邻居排序采样之后的实体 v 的接收域表示如式 (3.2) 所示。

$$S(v) = \{t | t \in N(v)\}, |S(v)| = K \quad (3.2)$$

接下来，计算用户关系得分，在知识图谱中，一个实体是和其他实体相连的，它们之间的关系也是不同的。通过用户关系评分可以获得目标用户的个性化偏好，目标用户对某条路径对应的物品越感兴趣，它的得分就越高，反之越低。例如，一个用户喜欢《青花瓷》很可能是因为周杰伦演唱这首歌，而其他用户可能也喜欢这首音乐，但是喜欢的原因确是因为这首歌风格是国风，可见知识图谱中实体间关系对于用户兴趣的重要性。

从当前给定用户 u 和物品 v ，使用函数 g 计算用户 u 与关系 r 之间的得分，本文函数 g 函数使用的是点积运算，如式 (3.3) 所示。

$$\pi_r^u = g(u, r) \quad (3.3)$$

其中， $u \in \mathbb{R}^d$ 和 $r \in \mathbb{R}^d$ 分别为用户 u 和关系 r ， d 为向量的维度。 π_r^u 代表关系 r 对用户 u 在推荐中的重要性。为了聚合接收域的信息，需要计算为归一化用户关系得分，如式 (3.4) 所示。

$$\tilde{\pi}_{r,v,e}^u = \frac{\exp(\pi_{r,v,e}^u)}{\sum_{e \in S(v)} \exp(\pi_{r,v,e}^u)} \quad (3.4)$$

根据归一化用户关系得分，就可以得到一个实体的接收域信息，具体计算采用线性组合接收域中节点的方式，如式 (3.5) 所示，其中 e 是实体的表示。

$$v_{S(v)}^u = \sum_{e \in S(v)} \tilde{\pi}_{r,v,e}^u e \quad (3.5)$$

然后将实体表示及其接收域信息 $v_{S(v)}^u$ 聚合到单个向量中，将实体 v 与其邻居节点进行聚合的函数如式 (3.6) 所示。其中， $\mathbf{W}$ 和 b 分别表示权重和偏置量， σ 为非线性函数，本文使用的是 Sigmoid 函数。

$$v_{agg} = \sigma(\mathbf{W} \cdot (v + v_{S(v)}^u) + b) \quad (3.6)$$

如图 3.5 展示的是知识传播的过程。 H 表示接收域的最大层数，后缀 $[h]$ 表示当前传播次数。 $e''[h]$ 为第 h 次传播得到的向量表示，通过聚合邻居节点的信息之后得到第 $h+1$ 阶表示 $e''[h+1]$ ，即蓝色节点。




图 3.5 邻居节点聚合示意图

Fig. 3.5 Diagram of neighbor node aggregation

3.1.3 协同信息的聚合

经过上述几层，可以得到物品的协同集合，也获得了经过知识传播之后的用户和物品向量，接下来需要将经过知识传播增强后的协同集合 $C'(v)$ 中对应的实体与物品本身进行聚合操作。本章在此步骤采用的方法采用加权平均值的方式，对于一个物品 v ，设置超参数 α 为物品 v 自身的权重 w_v ，超参数 n 为协同集合中向量的个数，那么协同集合中的所有向量权重 w_{col} 均设置如式 (3.7) 所示。

$$w_{col} = \frac{1-\alpha}{n} \quad (3.7)$$

聚合计算过程具体如式 (3.8) 所示。

$$v_{sum} = w_v v_{agg} + \sum_{i=0}^{|C'(v)|} w_{col} C'(v)_i \quad (3.8)$$

经过上述操作，可以得到结合了协同信息的物品的最终的向量表示 v_{sum} 。

3.1.4 推荐预测

最后，预测函数的计算方式是将用户聚合后的表示向量与物品聚合后的表示向量作内积，具体如式 (3.9) 所示。

$$\hat{y}_{uv} = u^T v_{sum} \quad (3.9)$$

模型的完整损失函数定义如式 (3.10) 所示。

$$\mathcal{L} = \sum_{u \in U} \left(\sum_{v: y_{uv}=1} \mathcal{J}(y_{uv}, \hat{y}_{uv}) - \sum_{i=1}^T \mathbb{E}_{v_i \sim P(v_i)} \mathcal{J}(y_{uv_i}, \hat{y}_{uv_i}) \right) + \lambda \|\mathcal{F}\|_2^2 \quad (3.10)$$

其中 $\mathcal{J}$ 表示交叉熵函数，是一种用于分类任务的损失函数，用于衡量预测的概率分布与真实标签之间的差异。 y_{uv} 是实际上的交互情况， $\hat{y}_{uv}$ 是模型预测的交互情况。 $\mathcal{J}(y_{uv}, \hat{y}_{uv})$ 表示它们的真实评分 y_{uv} 和模型预测评分 $\hat{y}_{uv}$ 之间的误差。 $v: y_{uv} = 1$ 表示所有与该用户发生过交互的物品集合，表示求集合中元素个数的操作。 $P(v_i)$ 表示从物品集合中采样物品 v_i 的概率分布， $\mathbb{E}$ 表示期望，选取的负例根据一个概率分布进行选择，该概率分布记作 P ，并且假设 P 采用均匀分布。对于每个用户 u ，从物品集合中随机采样和正样本的相同的 T^u 个物品，计算它们的预测评分和真实评分之间的误差 $\mathcal{J}(y_{uv_i}, \hat{y}_{uv_i})$ 。最后一项是 L2 正则项，用于缓解模型过拟合的问题。

在优化方面，Adam 用于优化所有模型，其中批处理大小固定为 1024。采用了 Xavier 初始化器初始化模型参数。

3.2 实验与结果分析

为了验证本章模型的有效性，将进行实验。实验硬件环境包括 Intel Core i5-13500H 2.60GHz 处理器、16GB 内存和 NVIDIA RTX4050 显卡。软件环境包括 Windows10 操作系统、Python3.10 编程语言、PyTorch2.0.0 深度学习框架和 CUDA12.0 并行计算平台。

3.2.1 数据集描述

为了更好地评估推荐模型的性能，采用了 Last.FM^[54]数据集。Last.FM 数据集包含了 1872 名用户在 Last.FM 上的音乐播放记录以及艺术家和歌曲的信息。用于音乐推荐的场景。该数据集可以用于评估推荐模型在音乐推荐场景下的性能。数据集的基本信息如表 3.1 所示。

表 3.1 数据集的基本信息
Tab. 3.1 Basic information of the dataset

数据集属性	数量
用户	1872
物品	3846
交互	42346
实体	9366
关系	60
知识图谱三元组	15518

在进行实验之前，需要对数据集进行预处理。通过对数据集进行预处理，可以将原始数据转换为适合推荐模型的格式，并减少数据的稀疏性。这有助于提高推荐模型的

性能，并提高推荐结果的准确性和实用性。具体来说，对于 Last.FM 数据集，将用户对物品的交互转换为二元标记，如果用户对物品存在交互，则标记为 1，否则为 0。

3.2.2 评价指标

在点击率预测场景下，使用训练好的模型对测试集中每个用户-物品对的交互情况进行预测，评价指标为模型的 AUC 值（Area Under Curve）。

AUC 则是 ROC 曲线（Receiver Operating Characteristic）下的面积，用于衡量模型的性能。而 ROC 曲线是以真正率（True Positive Rate, TPR）为纵轴，假正率（False Positive Rate, FPR）为横轴绘制的，两者的计算方式如式（3.11）和式（3.12）所示。

$$TPR = \frac{TP}{TP + FN} \quad (3.11)$$

$$FPR = \frac{FP}{TN + FP} \quad (3.12)$$

其中 TP 和 FN 分别代表正样本中被算法预测为正样本或负样本的样本数；TN 和 FP 分别代表负样本中被算法预测为负样本或正样本的样本数。

在点击率预测中，AUC 是一种常用的性能指标。点击率预测是指根据用户的历史行为和当前的上下文信息，预测用户是否会点击某个广告或某个推荐内容。AUC 可以衡量模型对正样本和负样本的分类能力，即模型能否将真实的点击样本排在未点击样本之前。因此，AUC 可以用来评估点击率预测模型的性能。在推荐系统中，可以将用户对物品的感兴趣程度作为分类标签，将模型预测的用户对物品感兴趣程度作为分类得分，然后根据分类得分计算 ROC 曲线和 AUC 值。AUC 值的取值范围在 0.5 到 1 之间，值越大表示模型的性能越好。当 AUC 值为 0.5 时，表示模型的预测效果等同于随机猜测；当 AUC 值为 1 时，表示模型的预测效果完美无缺。

在 Top-K 推荐场景下，本文选择精确率 Precision@K 指标对推荐集分别进行评估，指标计算如式（3.13）所示。

$$Precision@K = \frac{TP@K}{TP@K + FP@K} \quad (3.13)$$

其中 TP@K 代表向用户推荐的前 K 个物品中，正样本中被算法预测为正样本的样本数；FP@K 代表向用户推荐的前 K 个物品中，负样本中被算法预测为正样本的样本数。通过计算 Precision@K 指标，可以评估模型在 Top-K 推荐场景下的推荐效果。如果 Precision@K 越高，说明模型的推荐结果越准确，推荐效果越好。

3.2.3 基线方法

LibFM: 该模型将用户和物品的特征向量分解为低维因子空间, 并使用这些因子的内积来预测用户对物品的评分或偏好。

RippleNet: 该模型是一个基于知识图谱的推荐模型, 使用类似涟漪扩散的方式, 提出水波集的概念, 将水波集聚合得到用户表示。最后根据用户表示和物品表示得到最后的推荐结果。

KGCN: 该模型利用了图神经网络的思想, 从知识图谱中每个实体的邻居集中采样作为邻域, 然后结合邻域信息得到实体的表示, 最后结合推荐思想进行训练得到推荐结果。

MKR: 该模型采用多任务学习法, 包括推荐部分和知识图谱嵌入部分, 通过一个交叉压缩单元连接, 通过这种方式, 可以共享不同任务之间的信息, 从而提高模型的泛化能力和效率。

CKAN: 该模型采用异构传播策略对协作信号和知识关联进行显式编码, 并采用知识感知的注意力机制对邻域重要性进行区分。

3.2.4 实验设置

在该模型中, 训练集、验证集和测试集的比例均为 6: 2: 2。超参数的设定如表 3.2 所示。其中 d 表示嵌入维度, K 表示采样的邻居节点个数, H 表示传播的层数, lr 表示学习率, λ 表示 L2 正则系数, n 表示协同集合的大小, 即协同邻居的数量, w_v 表示主节点 v 的权重。

表 3.2 超参数设置
Tab. 3.2 Hyperparameter tuning

超参数	参数值
d	16
K	4
H	1
lr	5×10^{-3}
λ	1×10^{-4}
n	4
w_v	0.8

3.2.5 实验结果

在点击率预测场景下, 为了确保模型的有效性, 需要对模型进行测试, 并使用评价指标来衡量其性能。在本文中, 使用 AUC 值作为评价指标, 对模型进行评估。在测试

集中，对每个用户-物品对的交互情况进行预测，并计算出模型的 AUC 值。图 3.6 展示了模型在训练过程中 AUC 值的变化情况。




图 3.6 训练过程中 AUC 的变化

Fig. 3.6 The changes in AUC during the training process

这些观察结果可以提供有关模型训练的有用信息。首先可以看到，模型的性能随着训练的进行而逐渐提高，这表明本文模型具有很好的学习能力，并且能够不断地从数据中学习到更好的表示。其次可以看到，在训练过程中波动较大，这可能是由于 Last.FM 数据集数据较为稀疏。具体地与其他推荐模型的对比实验结果如表 3.3 所示。

表 3.3 不同模型在点击率预测场景下的 AUC 值

Tab. 3.3 AUC of different models in click-through rate prediction scenario

模型	AUC 值
LibFM	0.7781
RippleNet	0.7891
KGCN	0.7960
MKR	0.7947
CKAN	0.8354
KGRCI	0.8410

通过与其他推荐模型的对比实验可以发现，结合知识图谱辅助推荐的效果明显优于不使用知识图谱的情况。这表明，知识图谱能够为推荐模型提供有用的信息，帮助提升模型的推荐性能。另外，点击率预测场景下，本文提出模型在 Last.FM 数据集上，AUC 值为 0.8410，均优于其他模型，在推荐性能上，总体上相较于其他模型有一定程度的提升，表明该模型在预测用户对物品感兴趣程度时具有较强的准确性和区分能力。

具体地,这种提升可能与模型引入了协同信息和共同邻居排序采样方式有关。一方面,其他推荐模型,通常只考虑物品本身的特征,而忽略了它们之间的协同交互信息。而在引入协同信息后,模型可以更好地捕捉用户和物品之间的关系,从而提高推荐的准确性和多样性。另一方面,共同邻居排序采样方式在图卷积过程中提高了采样的质量,从而有效提升了推荐性能。




图 3.7 协同集合大小对 AUC 的影响

Fig. 3.7 The impact of collaborative set size on AUC

对于本章提出的推荐模型,为了探究有无协同集合辅助以及协同集合大小对模型性能的影响,进行了实验研究,研究了协同集合大小对 AUC 值的影响。图 3.7 展示的是聚合协同信息时,物品自身权重 w_v 设置为 0.8 时,协同集合大小 n 对 AUC 值的影响。

从显示的结果中,可以直观地观察到,通过采用协同集合引入协同信息,可以有效地提升 AUC 指标。因为在训练的过程中,引入协同信息,充分挖掘用户和物品之间可能存在的潜在的偏好关系,可以有效提升推荐性能。但是,也可以在实验结果中看到,随着协同集合的大小增加,AUC 值也增加。然而,当协同集合大小超过一定阈值时,AUC 值不再增加,反而开始下降。这样的现象可以解释为随着协同集合的增加,其中的噪声也增加,导致预测结果受到较多噪声的影响而下降。

这一结论说明了在构建协同集合时需要注意噪声的影响。尽管增加协同集合的大小可以提高 AUC 指标,但是过大的协同集合可能会引入更多噪声,从而削弱模型的性能。因此,在选择协同集合大小时需要达到一个平衡,同时考虑到噪声的影响。通过合理的调整协同集合大小,可以最大限度地提高模型的性能。

在 Top-K 推荐场景下，本文对提出的推荐模型进行实验评估，采取精确率 Precision@K 作为评价指标，实验结果如图 3.8 所示。




图 3.8 Last.FM 数据集上的精确率

Fig. 3.8 Precision on the Last.FM dataset

在实验结果图中，可以得出多方面的信息。可以看到未使用知识图谱辅助推荐的 LibFM 表现不如其他使用了知识图谱辅助推荐的方法。这说明知识图谱中包含丰富信息，可以提高推荐性能。若只利用用户-物品交互数据作为训练集为用户进行推荐，最终得到的推荐结果很难让用户满意，而知识图谱作为一种具有丰富语义的辅助信息，可以很好的辅助推荐系统在数据稀疏的情况下提高推荐系统的性能，为用户提供更多满意的物品。

当 K 为 2 时，CKAN 的表现最佳，但随着 K 值的增加，其精确率表现不如其他基线方法。这表明 CKAN 更适合推荐列表较短的场景。然后，在 MKR 方法下，当 K 取各个值时，精确率表现都处于较高水平。这可能是因为，虽然 Last.FM 数据集具有稀疏性，但 MKR 模型利用交叉压缩单元，联合学习推荐模块与知识图谱模块，可以有效地缓解数据稀疏问题。最后，在 Top-K 推荐场景下，相对于其他基线方法，KGRCI 表现良好，无论 K 取何值。这表明 KGRCI 成功地利用了用户历史交互记录中的协同信息和知识图谱中的结构化信息，提高了推荐性能。

3.3 本章小结

本章提出了一种创新的基于知识图谱的推荐模型，旨在通过引入协同信息和采用共同邻居排序采样策略，进一步提高推荐结果的准确性。该模型在充分挖掘用户兴趣和实体间相关性的基础上，注重提升采样质量，从而为用户提供更加精准和个性化的推荐服务。具体而言，本章模型通过引入协同信息，充分利用了用户行为和偏好之间的关联，有效地提高了推荐的准确性。同时，为了克服传统采样方法可能存在的样本质量不高的问题，采用了共同邻居排序采样策略。这一策略通过优先选取与用户共同邻居数量较多的实体进行采样，保证了样本的代表性和相关性，从而进一步提升了推荐结果的实用性。实验结果表明，无论是在点击率预测场景下，还是在 Top-K 推荐场景下，该模型展现出了优异的性能。

第 4 章 基于图注意力的知识图谱推荐算法

在第 3 章中提出了一种融合协同信息知识图谱推荐算法，该模型引入了物品的协同信息，并且优化了邻域聚合时的采样方式，充分利用用户行为和偏好之间的关联，有效地提高了推荐的准确性。然而，针对聚合邻域信息时，存在着对实体间重要关系学习不够灵活的问题。在对该模型进行研究后，发现结合图注意力机制，动态分配邻域节点的权重，可以有效地聚合邻域信息，获得更准确的用户和物品的向量表示。同时，将用户-物品交互图引入到物品知识图谱中，也可以更好地获取协同信息，这种方法可以更好地捕捉用户和物品之间的关联，从而提高推荐的准确性。

4.1 模型描述

本章模型如图 4.1 所示。首先根据知识图谱和用户-物品交互图，得到协同知识图谱，然后进行逐层的知识传播，分别得到用户和物品的高阶表示，最终得到预测的推荐结果。另外，为了方便对实验结果进行描述，将本章算法命名为 GAKGR（Graph Attention-based Knowledge Graph for Recommendation）。




图 4.1 GAKGR 模型结构图

Fig. 4.1 GAKGR Model architecture diagram

假设在推荐场景中，有一组 M 个用户的集合 $U = \{u_1, u_2, \dots, u_M\}$ 和一组 N 个物品的集合 $V = \{v_1, v_2, \dots, v_N\}$ 。根据用户的隐式反馈，如点击、浏览、购买行为，可以得到一

个用户-物品的交互矩阵 $Y \in \mathbb{R}^{M \times N}$ ，当 $y_{uv}=1$ 时表示用户 u 喜欢物品 v ，反之， $y_{uv}=0$ 表示用户 u 不喜欢物品 v 。

此外，知识图谱作为物品的辅助信息定义为 $G = \{(h, r, t) | h, t \in E, r \in R\}$ ，其中三元组 (h, r, t) 表示头实体 h 与尾实体 t 通过关系 r 相连， E 和 R 分别表示实体和关系的集合。对于推荐任务，给定用户-物品交互矩阵 Y 和知识图谱 G ，主要任务是预测用户 u 对物品 v 是否有潜在的兴趣。最终目标是要学习得到一个预测函数 $\hat{y}_{uv} = F(u, v | \Theta, Y, G)$ ，其中 $\hat{y}_{uv}$ 代表用户 u 对于物品 v 的预测评分， Θ 表示函数的模型参数。

4.1.1 协同知识图谱的构建

协同知识图谱就是将用户-物品交互图与物品的知识图谱相结合。它将两个图合并成一个统一的关系图，从而实现更加准确和有效的推荐。在协同知识图谱中，用户、物品和其他实体节点之间使用关系进行连接，这样做的好处是有利于充分利用高阶连通性。除了直接连接的用户和物品之间的关系外，还应该考虑到更远的关系，例如通过共同的兴趣点或者相似的属性来连接用户和物品。

协同知识图谱的优点在于它能够将用户的行为数据与知识图谱中的实体信息相结合，从而提高推荐的准确性。在协同知识图谱中，用户参与到了知识图谱的构建当中，用户与实体之间产生了高阶的连接，这样的协同知识图谱有助于挖掘用户、物品与实体之间的高阶信息。通过协同知识图谱，可以更好地理解用户的兴趣和需求，从而提供更加个性化的推荐服务。

协同知识图谱如图 4.2 所示，图中蓝色节点表示的是用户，橙色节点表示的是物品，灰色节点表示的是知识图谱中的其他实体。可以看到在协同知识图谱中，用户参与到了知识图谱的构建当中，用户与实体之间产生了高阶的连接，这样的协同知识图谱有助于挖掘用户、物品与实体之间的高阶信息。




图 4.2 协同知识图谱示意图

Fig. 4.2 Collaborative knowledge graph illustration

4.1.2 基于图注意力的知识传播

首先, 为了更有效地提取用户历史交互记录中的协同信息, 并确保模型计算复杂度不过高, 本文选用了轻量级图卷积方法, 以获取对用户和物品节点的强化表示获得对用户和物品节点的加强表示 u' 和 v' , 分别如式 (4.1) 和式 (4.2) 所示, 其中 $N(u)$ 和 $N(v)$ 分别表示用户 u 和物品 v 的邻居。

$$u' = \sum_{v \in N(u)} \frac{1}{\sqrt{|N(u)| |N(v)|}} v^{(l-1)} \quad (4.1)$$

$$v' = \sum_{u \in N(v)} \frac{1}{\sqrt{|N(u)| |N(v)|}} u^{(l-1)} \quad (4.2)$$

通过上述计算步骤能获得用户历史记录中的协同信息, 接下来对于知识图谱中的高阶信息进行学习。对于头节点 h , 它与其邻居节点之间存在 (h, r, t) 这样的知识三元组连接关系, 这里的头节点 h 包括用户节点, 物品节点与知识图谱中其他实体节点。知识传播的主要工作是对 h 及其邻居节点进行聚合, 以丰富实体节点信息。为了实现这一目标, 将节点的邻域信息建模为接收域, 本章采用了图注意力网络的思想, 在传播过程中学习每个邻居的注意力权值, 确定每个邻居节点对头节点的影响程度。然后, 将邻居节点的特征信息与对应的注意力权值相乘, 得到加权邻居特征表示。最后, 将加权邻居特征表示进行聚合, 得到头节点 h 的新表示。

通过这种方式, 可以揭示高阶连接的重要性, 从而更好地丰富头节点的信息。同时, 保留了第三章的邻域节点的采样方法, 具体方法此处不再赘述。可以有效地提高采样的质量, 增强推荐模型的性能。经过采样后的邻域表示为 $N(h)$, 其中包含了头节点 h 及其邻居节点的特征信息。通过对 $N(h)$ 进行聚合, 可以得到头节点 h 的新表示, 从而实现知识传播。

对于一个头节点 h , 首先计算邻域节点的注意力权值, 在此处使用到 $\tanh$ 函数作为激活函数。具体计算如式 (4.3) 所示。其中 $\mathbf{W}_r$ 是关系学习矩阵。

$$\pi(h, r, t) = (\mathbf{W}_r t)^T \tanh(\mathbf{W}_r h + r) \quad (4.3)$$

在计算完邻域节点的注意力权值后, 需要对这些权值进行归一化处理, 以确保它们的总和为 1。这样可以使得每个邻居节点对头节点的影响程度更加准确和合理。具体来说, 可以采用 softmax 函数对注意力权值进行归一化处理, 如式 (4.4) 所示。

$$\pi(h, r, t) = \frac{\exp(\pi(h, r, t))}{\sum_{(h, r, t) \in N(h)} \exp(\pi(h, r, t))} \quad (4.4)$$

根据归一化处理后的邻域节点注意力权值后,可以得到头实体的接收域信息 $S(h)$,接收域信息通过对邻居节点的特征表示进行加权求和,如式(4.5)所示。

$$S(h) = \sum_{(h,r,t) \in N(h)} \pi(h,r,t)t \quad (4.5)$$

在得到接收域信息 $S(h)$ 后,需要将它们聚合到单个向量中,以便进行后续的推荐任务。具体来说,可以采用一个线性变换来将头节点表示 h 和接收域信息 $S(h)$ 进行聚合,这里选择的激活函数为 LeakyReLU 函数。具体计算如式(4.6)所示,其中 $\mathbf{W}$ 是可训练的权重矩阵。

$$f = \text{LeakyReLU}(\mathbf{W}(h + S(h))) \quad (4.6)$$

综上所述,假设一个头节点有三个尾节点,邻域聚合过程如图4.3所示。




图 4.3 邻域聚合

Fig. 4.3 Neighborhood Aggregation

为探索高阶连接信息,文中堆叠多个传播层,第 l 跳(即第 l 次传播)的实体表示递归的来自第 $l-1$ 跳的实体表示,具体计算如式(4.7)所示。其中, $h^{(l-1)}$ 表示第 $l-1$ 跳的实体表示, $S(h)^{(l-1)}$ 表示第 $l-1$ 跳的头实体的接收域信息。通过堆叠多个传播层,可以逐步探索高阶连接信息,从而更好地丰富头实体的特征表示。

$$h^{(l)} = f(h^{(l-1)}, S(h)^{(l-1)}) \quad (4.7)$$

经过上述步骤,可以得到知识传播之后的增强的协同知识图谱,在协同知识图谱中,有着用户 u 与物品 v 的增强向量表示。也就是说第 l 次传播可以得到用户表示 $u^{(l)}$ 和物品表示 $v^{(l)}$,通过对用户和物品的所有增强向量表示进行拼接,可以得到最终的用

户表示 u 和物品表示 v ，其中包含了用户和物品的丰富特征信息。具体计算分别如式 (4.8) 和式 (4.9) 所示。

$$u = u^{(0)} \parallel \dots \parallel u^{(l)} \quad (4.8)$$

$$v = v^{(0)} \parallel \dots \parallel v^{(l)} \quad (4.9)$$

4.1.3 推荐预测

在得到最终的用户表示 u 和物品表示 v 之后，可以通过计算它们的内积来预测用户对物品的评分。预测函数的计算方式是将用户聚合后的表示向量与物品聚合后的表示向量作内积，具体如式 (4.10) 所示。 $\hat{y}_{uv}$ 表示模型预测的用户 u 对物品 v 的兴趣偏好。

$$\hat{y}_{uv} = u^T v \quad (4.10)$$

模型的损失函数由两部分组成，一部分是知识图谱嵌入损失，另一部分是推荐损失。

在知识图谱嵌入损失函数方面，采用 TransR 算法，TransR 算法相较于 TransE 算法，可以考虑到关系和向量存在于不同的空间，通过映射矩阵将实体映射到关系的空间上，如图所示。




图 4.4 TransR 示意图

Fig. 4.4 TransR diagram

知识图谱嵌入学习函数如式 (4.11) 和式 (4.12) 所示。其中 W_r 是关系映射学习矩阵。

$$h_r = h\mathbf{W}_r, \quad t_r = t\mathbf{W}_r \quad (4.11)$$

$$g(h, r, t) = \|h_r + r - t_r\|_2^2 \quad (4.12)$$

所以知识图谱嵌入损失如式(4.13)所示。

$$\mathcal{L}_{\text{KG}} = \sum_{(h, r, t, t') \in T} -\ln \sigma(g(h, r, t') - g(h, r, t)) \quad (4.13)$$

其中, σ 是 sigmoid 函数, $T = \{(h, r, t, t') | (h, r, t) \in G, (h, r, t') \notin G\}$ 是通过随机替换有效三元组中的一个实体构造的三元组。通过最小化知识图谱嵌入损失, 可以优化模型在知识图谱上的表现, 从而提高模型的泛化能力。

另一方面, 推荐损失如式(4.14)所示, 其中 $\mathcal{J}$ 表示使用交叉熵计算的损失值。对于一个给定的用户 u , 假设该用户与一些物品具有交互行为, 那么 T^u 表示对于该用户进行负采样时, 选取的负例个数, 其中 $\{v: y_{uv} = 1\}$ 表示所有与该用户发生过交互的物品集合, 表示求集合中元素个数的操作。在负采样中, 选取的负例根据一个概率分布进行选择, 该概率分布记作 P , 并且假设 P 采用均匀分布。

$$\mathcal{L}_{\text{REC}} = \sum_{u \in U} \left(\sum_{v: y_{uv}=1} \mathcal{J}(y_{uv}, \hat{y}_{uv}) - \sum_{i=1}^{T^u} \mathbb{E}_{v_i \sim P(v_i)} \mathcal{J}(y_{uv_i}, \hat{y}_{uv_i}) \right) + \lambda \|\mathcal{F}\|_2^2 \quad (4.14)$$

综上, 最终的损失函数表示如式(4.15)所示, 由知识图谱嵌入损失 $\mathcal{L}_{\text{KG}}$ 和推荐预测损失两部分 $\mathcal{L}_{\text{REC}}$ 组成, 其中最后一项是 L2 正则项, 用于缓解模型训练中过拟合的问题。

$$\mathcal{L} = \mathcal{L}_{\text{REC}} + \mathcal{L}_{\text{KG}} + \lambda \|\mathcal{F}\|_2^2 \quad (4.15)$$

最后, 本文在提到的所有模型训练中均使用 Adam 优化器, 包括本文提出的模型, 其中批处理大小固定为 1024。Adam 优化器结合了动量法和自适应学习率的优点, 可以在训练过程中自适应地调整学习率, 从而加速模型的收敛速度。

为了初始化模型参数, 采用了 Xavier 初始化器。Xavier 初始化器是一种常用的参数初始化方法, 可以使得模型的参数在训练过程中保持在合理的范围内, 从而提高模型的收敛速度和泛化能力。

4.2 实验与结果分析

为了验证本章模型的有效性, 将进行实验。实验硬件环境包括 Intel Core i5-13500H 2.60GHz 处理器、16GB 内存和 NVIDIA RTX4050 显卡。软件环境包括 Windows10 操作系统、Python3.10 编程语言、PyTorch2.0.0 深度学习框架和 CUDA12.0 并行计算平台。

本章实验所使用到的数据集、对数据集的预处理、基线方法均与第三章一致，此处不再过多赘述。

4.2.1 实验设置

对于 Last.FM 数据集，训练集、验证集和测试集的比例为 6: 2: 2。超参数的设定如表 4.1 所示，其中 d 为向量嵌入的特征维度， K 表示采样的邻居节点个数， H 为邻域聚合中接收域的层数， lr 为学习率， λ 为 L2 正则系数。

表 4.1 超参数设置
Tab. 4.1 Hyperparameter tuning

超参数	参数值
d	16
K	4
H	1
lr	5×10^{-3}
λ	1×10^{-4}

4.2.2 实验结果

为了检验模型的有效性，在点击率预测场景下。本文使用训练好的模型对测试集中每个用户-物品对的交互情况进行预测，评价指标为模型的 AUC 值。实验结果如表 4.2 所示。

表 4.2 不同模型在点击率预测场景下的 AUC 值
Tab. 4.2 AUC of different models in click-through rate prediction scenario

方法	AUC
LibFM	0.7781
RippleNet	0.7891
KGCN	0.7960
MKR	0.7947
CKAN	0.8354
KGCRI	0.8410
GAKGR	0.8452

可以看出本章提出的模型相比其他模型在 AUC 评估指标上具有一定的优势，相较于其他模型有不同程度的提升。该模型的 AUC 值为 0.8452，具有不错的性能，高于其他基线模型，这表明在数据较为稀疏的推荐场景下，本章模型依然能够有效地挖掘用户交互记录和知识图谱中的高阶信息，提供较好的推荐结果。

与之前的模型相比,本章模型在点击率预测场景中拥有更高的 AUC 值,这充分表明该模型具备更出色的推荐性能。其优势主要体现在以下方面。

首先,通过运用图注意力机制,能够动态地为邻域节点分配权重。这样做的好处在于可以更加精准地捕捉到各个邻域节点的重要程度,从而高效地聚合邻域信息,进而获取更为准确的用户和物品的向量表示。其次,将用户-物品交互图引入到物品知识图谱中,能够更好地获取协同信息。这种方式使得模型可以充分利用用户与物品之间的交互关系,挖掘出潜在的关联模式,从而为推荐提供更有力的依据,大大提高推荐的准确性和个性化程度。

为了研究本文模型在不同稀疏水平训练集下的表现情况,本节将训练集比例依次递减,具体地,将训练集比例从 60%调整到 40%,其中依次减少 10%的交互数据,取 5 次结果的平均值作为每个稀疏水平下的最终结果,如表 4.3 所示。

表 4.3 在不同比例的训练集下模型的 AUC 值
Tab. 4.3 AUC values of the model under different proportions of training sets

模型	训练集比例		
	60%	50%	40%
LibFM	0.7781	0.7564	0.6754
RippleNet	0.7891	0.7621	0.6823
KGCN	0.7960	0.7754	0.6916
MKR	0.7947	0.7715	0.7054
CKAN	0.8354	0.8045	0.7363
KGCRI	0.8410	0.8115	0.7543
GAKGR	0.8452	0.8228	0.7624

在此处,并未进一步降低训练集的比例。这是由于 Last.FM 数据集本身存在数据稀疏性问题,若训练集过少,训练效果将不尽人意。对表中的实验结果进行分析,可得出如下结论。一方面,在不同的训练集稀疏水平下,本文的推荐模型均表现出最优性能,这充分表明本章所提出的推荐算法性能优于对比推荐算法。另一方面,随着训练数据比例依次降低,各个模型的性能均有所下滑。然而,使用知识图谱的推荐算法降幅较小,这意味着在数据稀疏的情况下,基于知识图谱的推荐算法所展现出的性能要优于未使用知识图谱的推荐算法,进一步验证了将知识图谱引入推荐系统能够有效缓解推荐系统的数据稀疏性问题。

在 Top-K 推荐场景下,本文采取精确率 Precision@K 作为评价指标,实验结果如图 4.5 所示。




图 4.5 Last.FM 数据集上的精确率

Fig. 4.5 Precision on the Last.FM dataset

依据实验结果能够清晰地看出，在 Top-K 场景中，与其他基线模型相比，本章模型同样有着出色的表现。相较于第 3 章模型，本章模型有一定程度的提升，这可能有两个方面的原因，一方面，协同知识图谱能够将用户的行为数据与知识图谱中的实体信息相结合，从而提高推荐的准确性；另一方面，使用图注意力可以更加精准地捕捉到各个邻域节点的重要程度，从而高效地聚合邻域信息，也会带了精确率指标的提高。从图中能够观察到，随着 K 值的增大，CKAN 模型所表现出的推荐效果呈现出下降趋势。然而，本文所提出的算法在 K 值增大的情况下，依然能够保持良好的推荐性能。这充分表明，在推荐列表较长时，本章模型在推荐方面具有较为显著的优势。

4.3 本章小结

本章提出了基于图注意力的知识图谱推荐算法，旨在解决第 3 章邻域聚合中，对实体间重要关系学习不够灵活的问题。该模型将用户融入到知识图谱中，得到协同知识图谱。先使用轻量级图卷积方法提取协同信息，然后在知识传播过程中使用图注意力机制，动态地学习邻域节点的注意力权重。在实验中，将本章模型与第 3 章模型、其他基准模型加以对比。实验结果表明，本章模型在推荐效果上有提升，其性能优于其他基线模型。总体上，本章模型表现出良好的推荐性能。

第5章 个性化音乐推荐系统的设计与实现

本章将介绍采用基于知识图谱的个性化音乐推荐系统的设计与实现流程。首先,通过分析系统的需求,基于知识图谱的音乐推荐系统进行了总体设计、功能设计以及数据库设计。接着详细介绍了主要功能模块的具体设计和实现。其中,推荐模块使用了本文提出的推荐算法来训练数据,结合用户历史交互记录中的协同信息和知识图谱中的结构化信息,预测用户感兴趣的音乐。最后实现完整的、可交互的音乐推荐系统。结果表明,采用本文提出的推荐算法构建的音乐推荐系统在性能上表现出色,该系统不仅能够全面考虑用户的偏好,还能够充分利用知识图谱中的高阶信息。

5.1 需求分析

系统主要分为管理端和客户端,管理端主要由系统管理员使用,客户端则主要由用户使用。所以,需求分析从管理员的需求和用户的需求两个方面展开。

5.1.1 管理员需求分析

管理员模块的功能包括:登录、音乐管理,用户管理,角色管理。

(1) 登录。管理员需要在登录页面输入账号和密码,以验证身份。如果输入的账号和密码正确,管理员就可以进入管理后台进行后台管理操作。登录是管理员进入管理后台的必要步骤,只有经过身份验证的管理员才能进行后台管理操作。管理员的登录和后台管理操作是系统管理的重要环节,需要严格控制和管理。

(2) 音乐管理。音乐包括查询、增加、修改和删除音乐信息。在音乐管理中,管理员可以通过查询音乐名称、歌手、关键字等相关信息,以便更好地了解音乐的情况。管理员还可以通过搜索功能查找最新发布的音乐,以及与该音乐相关的信息。管理员可以添加新的音乐数据,对已有的音乐数据进行修改,也可以删除过时或不再受用户青睐的音乐数据,以保持系统的数据完整性和准确性。

(3) 用户管理。主要管理系统中已注册的用户,包括以下功能。查看用户信息,查看用户的账户信息、查询用户收听过的音乐等;修改用户信息,更改现有的用户数据信息;删除用户信息,管理员可注销破坏系统顺序的用户账号,禁止其使用系统。

(4) 角色管理。角色管理是超级管理员的专属功能,包括添加管理员和修改管理员权限等功能。在角色管理中,超级管理员可以对普通管理员进行管理,以提升系统管理效率。管理员的系统权限是根据其职责和工作需要来分配的,超级管理员可以根据

实际情况添加新的管理员，并为其分配相应的操作权限。在修改管理员权限方面，超级管理员可以根据管理员的工作需要和职责，对其操作权限进行修改，以区分不同管理员的职责和权限。通过角色管理，超级管理员可以更好地管理管理员，提高系统管理效率和数据质量。

5.1.2 用户需求分析

用户模块的功能包括：注册、登录、个人中心、浏览首页、分类浏览、音乐搜索和音乐推荐。

(1) 注册。注册功能是指用户在系统中输入必要信息并完成确认后，成为系统的用户的过程。在注册过程中，用户需要提供邮箱、密码等必要信息，并进行确认，以便系统能够识别用户身份。一旦注册成功，用户就可以通过登录页面进入系统，成为系统用户，享受系统提供的各种服务和功能。

(2) 登录。在输入正确的账号和密码后，进入音乐推荐系统的主页，才能进行搜索和收听音乐等操作。在登录过程中，用户需要输入已注册的账号和对应的密码，系统会对输入的信息进行验证，验证通过后，系统会将用户重定向到音乐推荐系统的主页。

(3) 热门歌曲。在系统主页上，系统会向用户展示当前的热门音乐，用户可以根据自己的兴趣和喜好选择自己喜欢的音乐进行收听。

(4) 最近新歌。在系统主页上，系统会向用户展示当前最新出品的新歌，让用户能够及时了解最新的音乐动态，发现更多优秀的音乐作品。

(5) 分类浏览。在音乐浏览页面，提供分类选项，以便更方便地浏览音乐。系统可以将音乐按照歌手、年代和类型等进行分类。用户可以根据自己的喜好和需求，快速地找到其想要的音乐。

(6) 音乐搜索。用户可以在搜索框中输入关键词，系统会根据关键词搜索音乐库中的歌曲，并将搜索结果展示给用户。用户可以通过搜索功能快速找到自己想要的音乐。

(7) 音乐推荐。系统会根据用户的历史收听记录和喜好，向用户推荐相关的音乐。用户可以在个人中心页面查看推荐的音乐，并进行收听。

(8) 我的收藏。用户可以将自己喜欢的音乐添加到收藏夹中，方便以后收听。用户可以在个人中心页面查看自己的收藏列表，并进行管理。

5.1.3 非功能需求分析

(1) 可扩展性。系统应具备良好的可扩展性，能够处理大规模的请求。

(2) 稳定性。系统应具备高可用性和稳定性，能够处理异常情况和并发访问。

(3) 安全性。系统应具备良好的安全性,保护用户的个人信息和数据安全。

(4) 用户友好性。系统应具备良好的用户界面和交互设计,提供良好的用户体验。

5.2 系统设计

该应用通过 B/S 架构的设计,实现了前后端的分离和解耦。前端使用 Vue3 渐进式框架,通过组件化的方式实现界面的模块化和可复用性。后端使用 SpringBoot 框架,通过自动化配置和约定大于配置的方式,简化了开发流程和部署过程。除此之外,该应用还使用了 Redis 作为缓存数据库,通过将热门数据和频繁访问的数据存储在 Redis 中,提高了系统的访问速度和响应性能。可以把整个系统分为分成三层,即持久层、业务层和控制层。

在持久层,使用 MySQL 数据库进行数据存储和管理。通过 SpringBoot 框架提供的对象关系映射功能,将数据库表映射为 Java 对象,实现数据的持久化和访问。同时,采用面向对象的设计思想,将数据操作封装成独立的持久层组件,提供对数据库的增删改查等操作。

在业务层,通过面向接口的设计方式,定义业务逻辑的接口和实现类。通过接口的抽象定义,实现业务逻辑的解耦和可扩展性。业务层负责处理业务逻辑,包括数据的处理、计算、验证等。同时,通过面向对象的设计思想,将业务逻辑封装成独立的业务层组件,提供对外的服务接口。

在控制层,采用 SpringMVC 框架实现请求的分发和处理。控制层是整个系统的核心部分,它负责接收和处理用户请求,并将请求转发到相应的业务逻辑处理方法。通过控制器的定义和配置,将前端的请求映射到相应的业务逻辑处理方法。同时,为了实现控制层的可复用和可扩展性,采用了面向接口的设计方式。在控制层中,定义了一些接口,用于描述不同的业务逻辑处理方法。这些接口可以被不同的实现类所实现,从而实现不同的业务逻辑处理。通过这种方式,可以将控制层与业务层解耦,使得控制层的可复用性和可扩展性得到了提高。

5.2.1 系统架构设计

根据上文的需求分析,在本文中,管理员模块和用户模块是该系统的两个主要功能模块。管理员模块的功能包括:登录、音乐管理,用户管理,角色管理;用户模块的功能包括:注册、登录、热门歌曲、最近新歌、分类浏览、音乐搜索和音乐推荐。系统功能模块图如图 5.1 所示。




图 5.1 系统功能模块图
Fig. 5.1 System functional module diagram

系统的整体架构是由四个不同的层组成，如图 5.2 所示。这四个层分别是基础设施层、数据存储层、业务层和应用层。




图 5.2 系统架构图
Fig. 5.2 System architecture diagram

基础设施层是系统的最底层，主要负责提供系统运行所必需的基础设施，如硬件、网络和操作系统等。基础设施层的主要任务是保证系统的安全性、稳定性和可靠性。

数据存储层位于基础设施层之上，主要负责存储和管理系统所需的各种数据。这些数据包括用户信息、音乐数据、系统配置信息等。于此同时，为了考虑性能问题，系统采用 Redis 非关系型数据库对访问频繁的数据进行缓存，该层也负责数据缓存、事务控制、缓存过期控制和数据同步。

业务层是系统的核心层，它负责实现系统的各种业务逻辑。业务层是系统的最关键部分，它的设计应该尽量简单、可扩展和可维护，以确保系统的稳定性和可靠性。

应用层是系统的最上层，它提供给用户的是一个友好、易用的界面。应用层包括用户端和管理员端。

5.2.2 数据库设计

音乐推荐系统的正常运行需要底层数据库的可靠部署。信息的存储、更新、处理、统计等操作必须在数据库管理系统的支持下进行。系统使用 MySQL 数据库存储音乐信息，确保后续数据的更新和扩展。本节将重点完成系统数据库的总体设计。

通过系统的需求分析和功能模块的设计，音乐推荐系统针对主要的功能一共设计了 7 张数据库表，分别是用户表、角色表、音乐表、歌手表、专辑表、类别表、用户历史收听记录表、用户收藏表。

用户表用于存储系统管理员、普通用户的用户信息，包括账号、密码、手机号码和电子邮箱等信息，该表主键为用户 ID，用于唯一标识用户信息，用户角色表中的角色 ID 字段作为外键映射出本表，用户表的详细设计如表 5.1 所示。

表 5.1 用户表
Tab. 5.1 User table

序号	数据库字段	类型	字段长度	字段含义	备注
1	id	varchar	20	用户ID	主键
2	username	varchar	40	用户账号	非空
3	password	varchar	40	密码	非空
4	gender	varchar	10	性别	非空
5	telephone	varchar	40	手机号码	非空
6	email	varchar	40	电子邮箱	非空
7	roleId	int	-	角色ID	外键

角色表用于存储用户角色信息，区分用户的权限，主键为角色 ID，用户表中的用户角色字段作为外键映射出本表。角色表的详细设计如表 5.2 所示。

音乐表用于存储音乐的详细信息，包括音乐 ID，音乐名称，歌手 ID，专辑 ID，类别，发行时间。音乐表的详细设计如表 5.3 所示。

表 5.2 角色表

Tab. 5.2 Role table

序号	数据库字段	类型	字段长度	字段含义	备注
1	id	varchar	20	角色ID	主键
2	name	varchar	40	角色名称	非空
3	remark	varchar	500	角色说明	可以为空

表 5.3 音乐表

Tab. 5.3 Music table

序号	数据库字段	类型	字段长度	字段含义	备注
1	id	varchar	20	音乐ID	主键
2	name	varchar	40	音乐名称	非空
3	singer_id	varchar	20	歌手ID	可以为空
4	album_id	varchar	20	专辑ID	可以为空
5	category	varchar	20	音乐类别	可以为空
6	release_time	varchar	20	发行时间	可以为空
7	duration	int	-	音乐时长	非空

歌手表用于存储歌手的信息，包括歌手 ID，歌手名字。歌手表的详细设计如表 5.4 所示。

表 5.4 歌手表

Tab. 5.4 Singer table

序号	数据库字段	类型	字段长度	字段含义	备注
1	id	varchar	20	歌手ID	主键
2	name	varchar	40	歌手名字	非空

专辑表用于存储专辑的信息，包括专辑 ID，专辑名字，歌手 ID。专辑表的详细设计如表 5.5 所示。

表 5.5 专辑表

Tab. 5.5 Album table

序号	数据库字段	类型	字段长度	字段含义	备注
1	id	varchar	20	专辑ID	主键
2	name	varchar	40	专辑名字	非空
3	singer_id	varchar	20	歌手ID	非空

类别表用于存储专辑的详细信息，包括类别 ID，类别名称。类别表的详细设计如表 5.6 所示。

表 5.6 类别表

Tab. 5.6 Category table

序号	数据库字段	类型	字段长度	字段含义	备注
1	id	varchar	20	类别ID	主键
2	name	varchar	40	类别名称	非空

用户历史收听记录表用于存储用户的历史收听记录，该表主键为用户 ID，用于记录唯一标识，用户历史收听记录表的详细设计如表 5.7 所示。

表 5.7 用户历史收听记录表

Tab. 5.7 User listening history table

序号	数据库字段	类型	字段长度	字段含义	备注
1	id	varchar	20	记录ID	主键
2	user_id	varchar	20	用户ID	非空
3	music_id	varchar	20	音乐ID	非空
4	time	date	-	收听时间	非空

用户收藏表用于存储用户的收藏，该表主键为用户 ID，用于记录唯一标识，用户收藏表的详细设计如表 5.8 所示。

表 5.8 用户收藏表

Tab. 5.8 User favorites table

序号	数据库字段	类型	字段长度	字段含义	备注
1	id	varchar	20	记录ID	主键
2	user_id	varchar	20	用户ID	非空
3	music_id	varchar	20	音乐ID	非空
4	time	date	-	收听时间	非空

5.3 数据获取

音乐知识图谱的构建是基于知识图谱的音乐推荐系统的开发基础，同时需要获取用户历史收听记录来测试系统功能性。为了实现这一目标，利用 Python 编程语言和 requests 库收集所需的音乐数据，然后需要对收集到的音乐数据进行处理和清洗，具体来说，需要去除重复数据、缺失数据和错误数据，并对数据进行格式化和标准化处理，以确保数据的准确性和完整性。最后并将其导入 MySQL 中，建立音乐知识图谱和用户历史交互记录表。

首先是音乐相关数据的获取,这里展示获取到的音乐信息数据。共有 3655 首歌曲,具体信息如图所示。每一行从左到右每一列分别代表的是音乐,类别标题,语种,歌手名,专辑。具体数据展示如图 5.3 所示。

歌曲	类别	语种	歌手	专辑
愛にできることはまだあ	二次元-动漫歌曲	日语	RADWIMPS	天気の子
我是一只鱼	另类/独立-独立流行	国语	落日飞车	我是一只鱼
一万次悲伤	摇滚-流行摇滚	国语	逃跑计划	世界
Payphone	流行-欧美流行	英语	Maroon 5, Wiz	Payphone
Stuck with U	节奏布鲁斯	英语	Ariana Grande	Stuck with U
Every Breath You Take	摇滚	英语	The Police	Every Breath You Take: The Classics
Send It (feat. Rich Homie	嘻哈说唱-流行说唱	英语	Austin Mahoney	Send It (feat. Rich Homie Quan)
I Feel It Coming	电子	英语	The Weeknd, Da	Starboy
Yellow	摇滚-另类摇滚	英语	Coldplay	Yellow
你要如何,我们就如何	摇滚-独立摇滚	国语	康姆士COMZ"	你要如何,我们就如何
世界が終わるまでは...	二次元-动漫歌曲	日语	WANDS	THE BEST OF TV ANIMATION SLAM DUNK~Single Collection~
Shape of You	流行-欧美流行	英语	Ed Sheeran	Shape of You
西湖	摇滚-独立摇滚	国语	痛仰乐队	不要停止我的音乐
Photograph	流行-欧美流行	英语	Ed Sheeran	x (Deluxe Edition)
No One Else Like You	摇滚-流行摇滚	英语	Adam Levine	Begin Again (Music From and Inspired By the Original
Intentions (Acoustic)	流行-欧美流行	英语	Justin Bieber	Intentions (Acoustic)
걱정말아요 그대	摇滚-韩国摇滚	韩语	野菊花	들국화
Psycho, Pt. 2	流行-欧美流行	英语	Russ	Psycho, Pt. 2
Under Pressure (2011	摇滚-另类摇滚	英语	Queen, David	Hot Space (2011 Remaster)
我们俩	流行-华语流行	国语	郭顶	微微
Dont Wanna Know	流行-欧美流行	英语	Maroon 5, Keith	Red Pill Blues (Deluxe)

图 5.3 音乐数据展示图

Fig. 5.3 Music data display diagram

愛にできることはまだあるかい	歌手	RADWIMPS
愛にできることはまだあるかい	风格	1315
愛にできることはまだあるかい	专辑	天気の子
愛にできることはまだあるかい	语种	日语
我是一只鱼	歌手	落日飞车
我是一只鱼	风格	1035
我是一只鱼	专辑	我是一只鱼
我是一只鱼	语种	国语
一万次悲伤	歌手	逃跑计划
一万次悲伤	风格	1098
一万次悲伤	专辑	世界
一万次悲伤	语种	国语
Payphone	歌手	Maroon5
Payphone	歌手	WizKhalifa
Payphone	风格	1032
Payphone	专辑	Payphone
Payphone	语种	英语
Stuck with U	歌手	ArianaGrande
Stuck with U	歌手	JustinBieber
Stuck with U	风格	1028
Stuck with U	专辑	Stuck with U
Stuck with U	语种	英语

图 5.4 知识图谱数据展示图

Fig. 5.4 Knowledge graph data display diagram

在得到了音乐相关的数据后,对数据进行处理得到 (h,r,t) 形式的三元组,三元组的具体个数为 30564,其中包含 9273 个实体,8 种关系。图 5.4 展示了知识图谱中部分三元组的具体数据。这些数据不仅包含了丰富的音乐信息,还揭示了音乐元素之间的内在联系和层次结构。这些三元组之间的关系和属性信息构成了音乐知识图谱的核心内容,为音乐推荐系统提供更加准确推荐服务。

本文在得到三元组的基础上,对音乐相关数据进行处理,得到知识图谱的可视化展示,如图 5.5 所示。从图中可以直观地看到,音乐知识图谱当中包含丰富的信息,不仅有歌曲的属性信息,也包含着与其他实体之间的联系与关系。



图 5.5 知识图谱可视化展示图

Fig. 5.5 Knowledge graph visualization diagram

5.4 系统实现

管理端的核心功能是用户管理和音乐管理,界面展示分别如图 5.6 和图 5.7 所示。

请输入关键字

搜索

添加用户

用户名	角色	年龄	性别	操作
日暮别河	管理员	18	男	编辑删除
徐崎荣	普通用户	20	女	编辑删除
白雪公主的后妈OvO	普通用户	22	男	编辑删除
肖肖95	普通用户	25	男	编辑删除
一死玉山前	管理员	30	女	编辑删除
酒空人已醉	普通用户	28	男	编辑删除
广州最后一位绅士	普通用户	24	女	编辑删除
无一处是归途_BKVD	普通用户	26	男	编辑删除
你不要心动哦	管理员	32	男	编辑删除
紫色鲑鱼	普通用户	29	女	编辑删除

图 5.6 用户管理界面展示图

Fig. 5.6 User management interface display image

音乐管理

添加

删除

☐	歌曲名称	歌手	专辑	时长	操作
☐	晴天	周杰伦	叶惠美	4:22	编辑删除
☐	成全	林宥嘉	说谎的女人	4:15	编辑删除
☐	说散就散	JC	说散就散	4:20	编辑删除
☐	稻香	周杰伦	魔杰座	3:35	编辑删除
☐	七里香	周杰伦	七里香	4:59	编辑删除
☐	小幸运	田馥甄	前度	4:13	编辑删除
☐	告别的时代	张国荣	告别的时代	4:23	编辑删除
☐	匆匆那年	王菲	匆匆那年	5:01	编辑删除
☐	红日	李克勤	红日	4:43	编辑删除
☐	爱情转移	陈奕迅	黑白灰	4:23	编辑删除

图 5.7 音乐管理界面展示图

Fig. 5.7 Music management interface display image

用户端系统主页是用户接触到的系统前端，其展示的内容对于用户的体验至关重要。在该页面中，包含了热门音乐和最近新歌两个功能模块。其中，热门音乐的展示是一项重要的功能。用户可以通过该功能选择自己喜欢的音乐进行收听。除了热门音乐，

还在系统主页中展示了最近新歌。这个功能模块展示了最近发布的新歌曲，让用户可以及时了解到最新的音乐动态。首页界面展示如图 5.8 所示。




图 5.8 首页界面展示图

Fig. 5.8 Homepage display image




图 5.9 分类浏览界面展示图

Fig. 5.9 Category browsing interface display image

为了提高用户的浏览效率和体验，音乐浏览页面提供分类选项。系统根据类型等对音乐进行分类，提供了多种分类选项，用户可以根据自己的需求选择相应的分类选项，更方便地浏览和搜索自己感兴趣的音乐。分类浏览如图 5.9 所示。

音乐推荐功能是一项重要的功能，通过分析用户的历史收听记录和喜好，系统可以向用户推荐相关的音乐，从而提高用户的满意度和使用效率。用户可以方便地查看

推荐的音乐，并进行收听。这项功能可以为用户提供更加个性化的音乐体验，同时也可以增加用户黏性。

为了实现音乐推荐功能，系统使用 xxl-job 后台任务对用户历史交互记录 and 知识图谱数据进行训练。音乐推荐流程图如图 5.10 所示，用户点击推荐按钮，如果该用户存在历史交互记录，则使用本文提出的推荐模型进行后台训练，在训练完成后保存本次推荐结果，xxl-job 通知 SpringBoot 训练完成，SpringBoot 获得推荐结果，返回给前端进行数据展示；如果用户不存在历史交互记录，则获得热门歌曲列表，作为推荐结果返回给前端，并且通知用户对系统进行新交互。




图 5.10 音乐推荐流程图

Fig. 5.10 Category browsing interface display diagram

为了检验推荐系统的有效性,对实际的推荐功能进行测试,某用户的部分历史收听记录如表 5.9 所示,可以看到该用户可能喜欢周杰伦和陈奕迅的音乐。

表 5.9 某用户部分历史收听记录

Tab. 5.9 Partial historical listening record of a certain user

序号	歌曲	歌手	专辑	类型
1	你的背包	陈奕迅	Special Thanks To...	流行-华语流行
3	十年	陈奕迅	黑白灰	流行-华语流行
4	一路向北	周杰伦	J III MP3 Player	流行-华语流行
5	花海	周杰伦	魔杰座	流行-华语流行
6	好久不见	陈奕迅	认了吧	流行-华语流行
7	魔鬼中的天使	田馥甄	My Love	流行-华语流行

系统的音乐推荐界面展示如图 5.11 所示。可以从中清楚地看到为该用户推荐了周杰伦和陈奕迅的歌曲,同时也向该用户推荐了其他华语流行音乐。由此可见,该系统可以有效挖掘用户的兴趣与偏好,为用户提供准确的推荐,提升用户体验满意度。

首页 音乐推荐 ×			
生成推荐			
歌曲名称	歌手	专辑	操作
告白气球	周杰伦	周杰伦的床边故事	🔊 播放 ☆ 收藏
晴天	周杰伦	叶惠美	🔊 播放 ☆ 收藏
夜曲	周杰伦	十一月的萧邦	🔊 播放 ☆ 收藏
稻香	周杰伦	魔杰座	🔊 播放 ☆ 收藏
青花瓷	周杰伦	我很忙	🔊 播放 ☆ 收藏
听妈妈的话	周杰伦	依然范特西	🔊 播放 ☆ 收藏
七里香	周杰伦	七里香	🔊 播放 ☆ 收藏
爱情转移	陈奕迅	认了吧	🔊 播放 ☆ 收藏
K歌之王	陈奕迅	K歌之王	🔊 播放 ☆ 收藏
好久不见	陈奕迅	认了吧	🔊 播放 ☆ 收藏
浮夸	陈奕迅	认了吧	🔊 播放 ☆ 收藏
爱情怎么了	贺一航	爱情怎么了	🔊 播放 ☆ 收藏
说散就散	JC	说散就散	🔊 播放 ☆ 收藏

图 5.11 音乐推荐界面展示图

Fig. 5.11 Music recommendation interface display image

5.5 本章小结

本章主要介绍了基于知识图谱的推荐系统的需求分析、系统设计、数据获取和系统实现。在需求分析方面，分别分析了管理员需求、用户需求和非功能需求。在系统设计方面，分别讨论了系统架构设计和数据库设计。同时，本章还介绍了如何获取音乐数据并构建知识图谱，以及系统实现的每个功能的页面展示。

第6章 结论与展望

6.1 结论

本研究旨在创建一种基于知识图谱的个性化音乐推荐系统，以提供更加个性化的音乐推荐服务，解决音乐领域信息过载的问题。为了实现这一目标，本文主要工作涵盖了以下几个方面。

针对现有推荐算法利用协同信息和结构化信息不充分的问题，本文提出了一种融合协同信息的知识图谱推荐算法。融合了物品的协同信息和共同邻居排序采样，更准确地获得物品的高阶表示。实验结果表明该方法有效地提升了推荐的准确度。

针对在知识传播邻域聚合过程中，实体间重要关系学习不够灵活的问题，本文提出了一种基于图注意力的知识图谱推荐算法。该模型将用户-物品交互图融合到知识图谱当中，得到协同知识图谱，使用轻量级图卷积得到提取协同信息。并且在知识传播过程中引入图注意力机制，以根据节点之间的关系动态地分配邻居节点的权重。通过这种方式，可以更加灵活地学习实体间重要关系，从而进一步提高了推荐的准确度。

本文设计并实现了基于知识图谱的个性化音乐推荐系统。首先对系统进行了需求分析和系统设计，为系统实现给予指导。然后使用爬虫技术获取国内音乐相关数据，构建了中文音乐知识图谱。最后基于本文提出的推荐模型，使用主流前后端开发框架对系统进行了实现，系统运行稳定且达到了预期的设计目的。

6.2 展望

由于受研究时间和实验资源等多方面因素的影响，基于知识图谱的个性化音乐推荐系统在未来还有很大的发展空间，可以从以下方面进行探索和改进。

（1）本文提出的推荐模型将知识图谱作为辅助信息来增强推荐，但是采用的辅助信息依然比较单一，在将来的工作中，考虑加入其他信息，比如歌曲的音频特征，实现多模态音乐推荐，综合各类信息来帮助提升推荐算法的效果。

（2）在现实生活中，用户的交互和偏好是不断变化的，基于静态偏好建模的推荐系统不能及时捕捉用户不断变化的兴趣。为了使模型更加动态，需要使用一些适当的技术和算法，以便能够捕捉到用户行为和偏好的变化，并且在时间上不断更新模型。

参考文献

- [1] Guo Q, Zhuang F, Qin C, et al. A survey on knowledge graph-based recommender systems[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 34(8): 3549-3568.
- [2] Sacenti J A P, Fileto R, Willrich R. Knowledge graph summarization impacts on movie recommendations[J]. Journal of Intelligent Information Systems, 2022, 58(1): 43-66.
- [3] Elbir A, Aydin N. Music genre classification and music recommendation by using deep learning[J]. Electronics Letters, 2020, 56(12): 627-629.
- [4] Qi T, Wu F, Wu C, et al. Personalized news recommendation with knowledge-aware interactive matching[C]// Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: ACM, 2021: 61-70.
- [5] Feng Y, Hu B, Lv F, et al. Atbrg: Adaptive target-behavior relational graph network for effective recommendation[C]// Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: ACM, 2020: 2231-2240.
- [6] 赵俊逸, 庄福振, 敖翔, 等. 协同过滤推荐系统综述[J]. 信息安全学报, 2021, 6(05): 17-34.
- [7] Wei J, He J, Chen K, et al. Collaborative filtering and deep learning based recommendation system for cold start items[J]. Expert Systems with Applications, 2017, 69: 29-39.
- [8] 于蒙, 何文涛, 周绪川, 等. 推荐系统综述[J]. 计算机应用, 2022, 42(06): 1898-1913.
- [9] Seo Y D, Kim Y G, Lee E, et al. Personalized recommender system based on friendship strength in social network services[J]. Expert Systems with Applications, 2017, 69: 135-148.
- [10] 张明星, 张骁雄, 刘姗姗, 等. 利用知识图谱的推荐系统研究综述[J]. 计算机工程与应用, 2023, 59(04): 30-42.
- [11] Shao B, Li X, Bian G. A survey of research hotspots and frontier trends of recommendation systems from the perspective of knowledge graph[J]. Expert Systems with Applications, 2021, 165: 113764.
- [12] Sang L, Xu M, Qian S, et al. Knowledge graph enhanced neural collaborative recommendation[J]. Expert systems with applications, 2021, 164: 113992.
- [13] 田萱, 陈杭雪. 推荐任务中知识图谱嵌入应用研究综述[J]. 计算机科学与探索, 2022, 16(08): 1681-1705.

- [14] 黄勃, 严非凡, 张昊, 等. 推荐系统研究进展与应用[J]. 武汉大学学报(理学版), 2021, 67(06): 503-516.
- [15] Wang C D, Deng Z H, Lai J H, et al. Serendipitous recommendation in e-commerce using innovator-based collaborative filtering[J]. IEEE Transactions on Cybernetics, 2018, 49(7): 2678-2692.
- [16] Cheng H T, Koc L, Harmsen J, et al. Wide & deep learning for recommender systems[C]// Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. New York, NY, USA: ACM, 2016: 7-10.
- [17] Wang X, He X, Wang M, et al. Neural graph collaborative filtering[C]// Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval. New York, NY, USA: ACM, 2019: 165-174.
- [18] Chen K, Liang B, Ma X, et al. Learning audio embeddings with user listening data for content-based music recommendation[C]// Proceedings of IEEE International Conference on Acoustics, Speech and Signal Processing. Toronto, ON, Canada: IEEE, 2021: 3015-3019.
- [19] Andjelkovic I, Parra D, O'Donovan J. Moodplay: interactive music recommendation based on artists' mood similarity[J]. International Journal of Human-Computer Studies, 2019, 121: 142-159.
- [20] 李丹阳, 甘明鑫. 基于多源信息融合的音乐推荐方法[J]. 数据分析与知识发现, 2021, 5(02): 94-105.
- [21] 杨明极, 刘畅, 宋泽. 注意力机制与改进 RNN 的混合音乐推荐算法研究[J]. 小型微型计算机系统, 2020, 41(10): 2235-2240.
- [22] 李琳, 唐守廉. 基于多层注意力表示的音乐推荐模型[J]. 电子学报, 2020, 48(09): 1672-1679.
- [23] 王海龙, 柳林, 林民, 等. 基于信息检索及 k 均值聚类的音乐个性化推荐算法[J]. 吉林大学学报(工学版), 2021, 51(05): 1845-1850.
- [24] Lops P, Jannach D, Musto C, et al. Trends in content-based recommendation: Preface to the special issue on Recommender systems based on rich item descriptions[J]. User Modeling and User-Adapted Interaction, 2019, 29: 239-249.
- [25] Kouki P, Schaffer J, Pujara J, et al. Generating and understanding personalized explanations in hybrid recommender systems[J]. ACM Transactions on Interactive Intelligent Systems (TiiS), 2020, 10(4): 1-40.
- [26] 吴施虎. 基于知识图谱的推荐算法研究[D]. 成都: 电子科技大学, 2022.
- [27] Bollacker K, Evans C, Paritosh P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]// Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data. New York, NY, USA: ACM, 2008: 1247-1250.

- [28] Vrandečić D, Krötzsch M. Wikidata: a free collaborative knowledgebase[J]. Communications of the ACM, 2014, 57(10): 78-85.
- [29] Suchanek F M, Kasneci G, Weikum G. Yago: A large ontology from wikipedia and wordnet[J]. Journal of Web Semantics, 2008, 6(3): 203-217.
- [30] Bizer C, Lehmann J, Kobilarov G, et al. Dbpedia-a crystallization point for the web of data[J]. Journal of Web Semantics, 2009, 7(3): 154-165.
- [31] 杨振辰, 汤悦. 知识图谱在推荐系统中的应用研究[J]. 上海电力大学学报, 2022,38(02): 163-170.
- [32] Bordes A, Usunier N, Garcia-Duran A, et al. Translating embeddings for modeling multi-relational data[J]. Advances in Neural Information Processing Systems, 2013, 26: 1-9.
- [33] Wang Z, Zhang J, Feng J, et al. Knowledge graph embedding by translating on hyperplanes[C]// Proceedings of the AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2014, 28(1): 1112–1119.
- [34] Lin Y, Liu Z, Sun M, et al. Learning entity and relation embeddings for knowledge graph completion[C]// Proceedings of the AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2015, 29(1): 2181–2187.
- [35] Ji G, He S, Xu L, et al. Knowledge graph embedding via dynamic mapping matrix[C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing. Stroudsburg: ACL, 2015: 687-696.
- [36] Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(1): 4-24.
- [37] Li X, Sun L, Ling M, et al. A survey of graph neural network based recommendation in social networks[J]. Neurocomputing, 2023, 549: 126441.
- [38] Bhatti U A, Tang H, Wu G, et al. Deep learning with graph convolutional networks: An overview and latest applications in computational intelligence[J]. International Journal of Intelligent Systems, 2023, 2023: 1-28.
- [39] Tao Z, Wei Y, Wang X, et al. Mgat: Multimodal graph attention network for recommendation[J]. Information Processing & Management, 2020, 57(5): 102277.
- [40] Zhou W, Xia Z, Dou P, et al. Double attention based on graph attention network for image multi-label classification[J]. ACM Transactions on Multimedia Computing, Communications and Applications, 2023, 19(1): 1-23.

- [41] Wang H, Zhang F, Wang J, et al. Exploring high-order user preference on the knowledge graph for recommender systems[J]. ACM Transactions on Information Systems (TOIS), 2019, 37(3): 1-26.
- [42] 罗承天, 叶霞. 基于知识图谱的推荐算法研究综述[J]. 计算机工程与应用, 2023, 59(01): 49-60.
- [43] Zhang F, Yuan N J, Lian D, et al. Collaborative knowledge base embedding for recommender systems[C]// Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, NY, USA: ACM, 2016: 353-362.
- [44] Wang H, Zhang F, Xie X, et al. DKN: Deep knowledge-aware network for news recommendation[C]// Proceedings of the 2018 World Wide Web Conference. New York, NY, USA: ACM, 2018: 1835-1844.
- [45] Wang H, Zhang F, Zhao M, et al. Multi-task feature learning for knowledge graph enhanced recommendation[C]// Proceedings of the 2019 The World Wide Web Conference. New York, NY, USA: ACM, 2019: 2000-2010.
- [46] 秦川, 祝恒书, 庄福振, 等. 基于知识图谱的推荐系统研究综述[J]. 中国科学:信息科学, 2020, 50(7): 937-956.
- [47] Yu X, Ren X, Sun Y, et al. Personalized entity recommendation: A heterogeneous information network approach[C]// Proceedings of the 7th ACM International Conference on Web Search and Data Mining. New York, NY, USA: ACM, 2014: 283-292.
- [48] Sun Z, Yang J, Zhang J, et al. Recurrent knowledge graph embedding for effective recommendation[C]// Proceedings of the 12th ACM Conference on Recommender Systems. New York, NY, USA: ACM, 2018: 297-305.
- [49] 赵晔辉, 柳林, 王海龙, 等. 知识图谱推荐系统研究综述[J]. 计算机科学与探索, 2023, 17(04): 771-791.
- [50] Wang H, Zhang F, Wang J, et al. Ripplenet: Propagating user preferences on the knowledge graph for recommender systems[C]// Proceedings of the 27th ACM International Conference on Information and Knowledge Management. New York, NY, USA: ACM, 2018: 417-426.
- [51] Wang H, Zhao M, Xie X, et al. Knowledge graph convolutional networks for recommender systems[C]// Proceedings of The World Wide Web Conference. New York, NY, USA: ACM, 2019: 3307-3313.
- [52] Wang X, He X, Cao Y, et al. Kgat: Knowledge graph attention network for recommendation[C]// Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York, NY, USA: ACM, 2019: 950-958.

- [53] Wang Z, Lin G, Tan H, et al. CKAN: Collaborative knowledge-aware attentive network for recommender systems[C]// Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: ACM, 2020: 219-228.
- [54] Cantador I, Brusilovsky P, Kuflik T. Second workshop on information heterogeneity and fusion in recommender systems (HetRec2011)[C]// Proceedings of the fifth ACM Conference on Recommender Systems. New York, NY, USA: ACM, 2011: 387-388.