

融合主题建模与时间加权的音乐推荐方法研究

RESEARCH ON MUSIC RECOMMENDATION METHODS BASED ON TOPIC MODELING AND TIME-AWARE WEIGHTING

学 院 名 称： 人工智能学院

专业学位类别： 计算机技术

研究生姓名： 邵泽明

指 导 教 师： 陈瀚宁教授

2025 年 6 月

分类号：TP391

密级：公开

学校代码：10057

研究生学号：22836923

融合主题建模与时间加权的音乐推荐方法研究

Research on Music Recommendation Methods Based on Topic Modeling and Time-aware Weighting

专业学位类别（领域）：计算机技术

校内指导教师：陈瀚宁 教授

企业指导教师：赵阳阳 高级工程师

研究生姓名：邵泽明

申请学位级别：全日制电子信息硕士

论文提交日期：2025 年 6 月

论文课题来源：横向项目

学位授予单位：天津科技大学

摘要

在大数据快速发展的背景下,推荐系统成为人们高效获取信息的重要工具。然而,现有推荐系统在数据稀疏性、用户偏好建模不足以及动态兴趣捕捉不足等方面仍面临挑战。为此,本文提出了一种融合主题建模与时间加权机制的音乐推荐方法,以提升推荐的时效性和准确性。

(1) 为缓解数据稀疏性和用户偏好建模不足等问题,本文针对歌词文本特征提出基于注意力机制改进的 LDA 模型(A-LDA)与 TF-IDF 的双通道主题特征提取方法,歌词文本通过 TF-IDF 提取文档关键词特征,同时通过 A-LDA 模型提取潜在主题特征,形成双通道文本主题特征。该方法增强了模型对歌词语义信息的捕捉能力,有效改善了冷启动与长尾音乐场景下的推荐效果。

(2) 针对用户兴趣的动态变化,本文对双通道提取的歌词文本主题特征——TF-IDF 关键词权重与 A-LDA 语义主题向量——进行时间加权,获得时间感知的加权主题兴趣表示,从而更准确反映用户兴趣随时间的演变趋势。

(3) 在推荐模型构建方面,本文设计了基于 DeepFM 的多特征融合模型 DeepFM-T-A-LDA-T。模型中 FM 部分有效捕捉特征间的交互关系,DNN 部分进一步建模高阶非线性组合。同时,通过负样本生成策略和类别权重调整,提升模型在长尾数据下的鲁棒性。

最后,本文基于 LastFM-1k 和 30Music 数据集进行实验验证,结果表明所提出的模型在准确率、召回率等评价指标上显著优于传统 DeepFM 与其他基线方法,特别在处理用户兴趣动态变化与数据稀疏场景下表现更优。研究为个性化音乐推荐提供了新的解决思路,也为用户偏好建模与多模态特征融合提供了实践参考。

关键词: 音乐推荐; 文本主题建模; 时间加权机制; DeepFM 模型; A-LDA

ABSTRACT

With the rapid development of big data, recommendation systems have become essential tools for efficiently accessing information. However, existing recommendation systems still face challenges such as data sparsity, insufficient user preference modeling, and inadequate dynamic interest capture. To address these issues, this paper proposes a music recommendation method that integrates topic modeling with a time-weighting mechanism to enhance the timeliness and accuracy of recommendations.

(1) To alleviate data sparsity and improve user preference modeling, a dual-channel topic feature extraction method is proposed for lyrics text, combining an attention-enhanced LDA model (A-LDA) with TF-IDF. The lyrics are processed by TF-IDF to extract document keyword features, while latent topic features are obtained via the A-LDA model, forming dual-channel textual topic features. This approach enhances the model's ability to capture lyrical semantic information and effectively improves recommendation performance in cold-start and long-tail music scenarios.

(2) To capture the dynamic evolution of user interests, the dual-channel lyric textual topic features—TF-IDF keyword weights and A-LDA semantic topic vectors—are subjected to a time-weighting process, producing time-aware weighted topic interest representations that more accurately reflect the temporal evolution of user preferences.

(3) Regarding model construction, a multi-feature fusion model based on DeepFM, named DeepFM-T-A-LDA-T, is designed. The FM component effectively captures interactions among features, while the DNN component further models higher-order nonlinear combinations. Additionally, by optimizing negative sample generation strategies and adjusting class weights, the model's robustness to long-tail data is improved.

Finally, experiments conducted on the LastFM-1k and 30Music datasets demonstrate that the proposed model significantly outperforms traditional DeepFM and other baseline methods in accuracy, recall, and other evaluation metrics, particularly excelling in handling dynamic user interests and data sparsity. This study provides a novel approach for personalized music recommendation and offers practical insights for user preference modeling and multimodal feature fusion.

Key words: Music Recommendation, Textual Topic Modeling, Temporal Weighting Mechanism, DeepFM Model, A-LDA

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.3 研究面临的主要问题.....	3
1.4 研究内容与章节安排.....	5
1.4.1 研究内容.....	5
1.4.2 论文结构安排.....	5
2 相关理论与技术	7
2.1 推荐算法的分类.....	7
2.2 推荐系统评价指标.....	9
2.3 深度学习推荐模型.....	11
2.4 注意力机制.....	18
2.5 文本特征处理方法.....	19
2.6 本章小结.....	21
3 融合文本主题建模与时间加权的音乐推荐模型	23
3.1 训练样本构建与时间特征提取	23
3.2 歌词文本预处理.....	24
3.3 基于双通道文本特征融合的 DeepFM 推荐模型	25
3.3.1 TF-IDF 特征提取	25
3.3.2 LDA 主题模型原理	26
3.3.3 注意力机制原理.....	28
3.3.4 改进的增强主题模型.....	29
3.3.5 A-LDA 特征提取	30
3.3.6 双通道文本特征提取方法.....	31
3.4 基于时间加权与文本特征的融合模型构建	32
3.4.1 时间加权机制设计	32
3.4.2 文本主题特征的时间加权方法.....	33
3.4.3 融合模型训练与优化策略.....	34
3.5 本章小结.....	36
4 实验设计与结果分析	37
4.1 实验环境与数据集说明.....	37
4.2 实验设计基础.....	42
4.2.1 实验评价指标.....	42
4.2.2 实验流程.....	43

4.2.3 数据划分策略.....	44
4.3 实验设计与实现.....	44
4.3.1 对比实验：NCF、NeuMF、SASRec 和 Cose Rec 的推荐性能	44
4.3.2 改进实验：DeepFM 模型及其变体的实现	46
4.4 实验结果分析.....	47
4.4.1 Lastfm-1k 数据集上各模型性能对比分析	47
4.4.2 30Music 数据集上各模型性能对比分析	50
4.4.3 文本特征与时间加权对推荐效果的贡献	51
4.4.4 最优参数分析.....	52
4.5 本章小结.....	55
5 总结与展望.....	57
5.1 全文总结.....	57
5.2 主要创新点.....	58
5.3 论文不足之处.....	58
5.4 展望.....	58
6 参考文献.....	60

1 绪 论

1.1 研究背景与意义

随着互联网技术的快速发展,音乐流媒体平台已经成为人们获取音乐的主要方式之一^[1]。近年来,全球音乐流媒体平台用户规模迅速增长。据 IFPI《全球音乐报告》显示,到 2023 年,全球音乐流媒体用户数已增至约 6.5 亿,较前一年增加了 8%^[2]。在国内市场上,网易云音乐、QQ 音乐等平台用户数量已经突破了 5 亿大关,智能设备的普及让越来越多的人选择通过手机或其他移动设备来享受音乐^[3]。这一趋势表明,音乐流媒体已经成为现代生活不可或缺的一部分,极大地改变了人们接触音乐的方式。

用户数量的激增同时促使着平台不断进行更新迭代,如何以更优质的服务来保留用户的关注度成为一个重要问题。想要从海量的音乐中精准推测用户的喜好,考验着平台的算法准确率,如果没能抓住用户的喜好,就会导致用户群体的流失^[4]。平台想要提高用户的依赖性,就要打造符合用户个人偏好的音乐推荐功能,在大音乐时代背景下,用户往往更倾向于能够明显符合自己偏好的音乐平台^[5]。而抓住用户喜好的关键,当前来说最好的方式是通过推荐算法的方式。国外 Spotify 音乐平台以用户的播放记录和社交网络等信息为用户提供个性化的音乐推荐^[6];网易云音乐也通过分析用户的行为日志来优化了推荐功能,重点推出“每日推荐”功能,提高了用户的留存率^[7]。提高音乐推荐的准确率从而成为音乐平台受欢迎程度的一个重要因素。

音乐推荐中常常采用用户的行为历史数据来进行建模分析,比如播放历史,点赞收藏记录等^[8]。这些行为记录了用户的主观行为,代表了用户的行为偏好^[9]。音乐平台可以利用这些用户数据打造一个个性化的用户画像,给用户打造各式各样的标签,再通过标签来推荐相应的音乐^[10]。推荐同样具有时效性,用户的行为往往会伴随着时间维度^[11]。在一段时间内,用户的兴趣爱好可能发生多次变化,抓住时间信息,能够让音乐平台更加的具有动态推荐性,通过多种方法,音乐平台可以捕捉用户时间维度上的兴趣变化,从而提高推荐准确率和时效性^[12]。用户的播放历史行为代表了用户的短期偏好数据,收藏点赞等主观行为更能代表用户的强烈兴趣。利用这些用户数据,可以帮助音乐平台快速的理解用户需求,挖掘潜伏的用户兴趣,提高推荐算法的能力。

在音乐推荐领域中,使用文本信息是一个有效捕获用户偏好的方法^[13]。歌曲的歌词信息、歌手信息、标签信息等包含了丰富的语义,通过借助这些信息,可以构建一个更为完整的用户画像,有效弥补了单纯的用户行为数据所造成的数据局限性,更全面的理解用户偏好。通过对歌词或者评论进行情感分类,可以有效的提取其中富含的情感信息,为构建兴趣模型而作出贡献。而歌词作为歌曲的关键组成部分,更是包含了歌曲的大部分信息,有利于进行歌曲的情感研究和主题研究^[14],借助自然语言处理技术对其进行语义分析,系统可以提取诸如“爱情”、“励志”、“怀旧”等关键词。采用 LDA 等主题建模方法^[15],还可以将歌曲归类到不同的情感和主题下,帮助根据

用户的主题偏好做出更为精准的推荐。评论和标签不仅是用户主观感受的直接体现,还弥补了行为数据在捕捉用户即时兴趣方面的不足。例如,用户在评论中提到“治愈系音乐”或“适合跑步的节奏”,这些反馈为推荐系统提供了宝贵的上下文信息。大多数研究在处理文本特征时,往往独立于行为数据进行分析,未能充分利用二者之间的互补优势^[16]。要建立有效的跨模态交互机制,高效融合用户行为数据与文本特征,是当前推荐系统研究的一个关键挑战。

1.2 国内外研究现状

上世纪 90 年代初期,推荐系统领域的研究工作开始萌芽。协同过滤方法(Collaborative Filtering, CF)^[17]构成了早期推荐算法的主要技术路径。1994 年,Resnick 等人首次将协同过滤技术应用于 GroupLens 新闻推荐系统。这种方法基于用户或物品之间的相似性,通过历史交互数据提供推荐服务。1998 年间,Breese 及其合作者对传统协同过滤方法实施了重要改良。基于用户的协同过滤(UserCF)与基于物品的协同过滤(ItemCF)两种变体由此诞生。前者通过找到兴趣相似的用户来进行推荐,后者则根据物品间的相似性来为用户提供建议^[18]。

协同过滤是一个经典的推荐算法,有了很多应用的实际案例,但是其仍然存在一些显著的缺点。其中一个问题就是冷启动问题,当有新用户进入平台后,平台往往缺乏相应的历史数据,从而无法有效地为此用户进行推荐。第二个问题是数据稀疏性问题,用户的收听往往只存在于一小部分歌曲当中,如何从庞大的音乐库中找到相应的用户-物品评分是一个极大的挑战。为了改善上面这些问题,部分研究人员提出了矩阵分解(Matrix Factorization, MF)技术^[19],通过计算用户与物品之间的潜藏因子来提高了模型在数据稀疏环境下的适应能力,同时缓解了冷启动这一个问题。2006 年 Netflix 举办了推荐系统竞赛,加快了矩阵分解技术的进一步扩展^[20],FunkSVD^[21]与 SVD++^[22]等代表性算法相继提出。这些算法通过将交互矩阵映射到低维潜在空间,有效降低了数据的稀疏性,从而提升了推荐质量^[23]。但是这些模型主要依赖于用户的历史评分数据,没有有效融合用户或物品的内容信息,当新用户或新物品出现时,仍存在一定的局限性^[24]。

深度学习技术近年来不断取得突破性进展,为推荐系统领域注入了新的活力。2016 年 Google 提出的 Wide&Deep 模型颇具开创性,该模型将浅层特征提取与深层神经网络进行有机结合,在点击率预估任务中表现突出^[25]。次年,DeepFM 在因子分解机的基础上引入神经网络,显著提升了高维稀疏数据的处理能力^[26-27]。Transformer 结构的推荐模型,如 SASRec^[28]和 BERT4Rec^[29],增强了对用户兴趣动态变化的建模能力。虽然深度学习模型在特征表达和非线性建模方面表现出色,但它们对计算资源的需求较高,如何平衡推荐效果与计算效率依然是一个研究重点。

在音乐推荐领域,研究逐步从传统的协同过滤转向内容建模和行为建模相结合的方向。根据特征来源的不同,当前的研究主要可分为以下三类:

（1）基于文本特征的推荐方法

歌词及评论等文本信息揭示音乐的语义与风格，增强推荐的语义理解能力。早期如 Pandora 通过人工标注音乐属性实现内容推荐，但成本较高、可扩展性差。随着自然语言处理技术的发展，研究者开始使用主题模型（如 LDA）和 TF-IDF 等方式提取文本特征。例如，Van den Oord 等人提出使用卷积神经网络提取音频与文本特征进行内容推荐^[30]。近年来，预训练语言模型（如 BERT、GPT）在自然语言处理领域的突破，为歌词文本的语义理解带来了新的可能。通过深层上下文建模，这些模型能够捕获歌词中的情感、隐喻及复杂语义，从而提升基于文本的音乐推荐效果。但预训练模型体量庞大，计算资源消耗大，同时如何将歌词的语义信息与用户行为数据有效融合，仍是当前研究的难点。此外，歌词文本存在多义词和歧义问题，影响模型的语义准确性，亟需设计适配音乐场景的轻量化预训练模型和跨模态融合策略。

（2）基于行为序列的推荐方法

用户的交互行为（如播放、点赞、收藏等）是推荐系统建模的重要依据。代表性模型如 GRU4Rec^[31]和 SASRec 基于序列模型（RNN、Transformer 等）建模用户的兴趣演化趋势，在音乐推荐中取得了良好效果。这类方法能够较好地捕捉用户的短期和长期偏好，适用于会话式推荐和实时推荐等应用场景。但其普遍依赖用户行为日志，缺乏明确的偏好标注。此外，大多数序列模型使用固定时间窗口，难以动态适应用户偏好变化，对冷启动和兴趣转移的建模仍不够充分。

（3）基于多模态融合的推荐方法

近年来，多模态融合方法逐渐成为主流研究方向，尤其在音乐推荐领域，结合音频、歌词、封面图像与用户行为数据可以提升推荐的全面性。例如，Spotify 提出的 Session-based Recommendation with Transformers（SBR-T）模型^[32]融合了用户短期和长期行为，提高了推荐精度^[33]。此外，通过融合歌词语义和行为序列，模型可以更好地理解用户的音乐偏好。然而，目前多模态融合仍面临诸多挑战^[34]。一方面，模态之间的信息存在分布差异，不同模态的特征融合方式复杂^[35]；另一方面，部分模态（如文本）未被充分重视，常被简化为辅助输入，未能发挥其深层语义信息的作用^[36-37]。同时，多模态方法普遍依赖于复杂的模型结构和大量训练资源，且在隐式反馈环境中如何精确建模用户偏好仍是难点。

此外，时间信息在用户行为建模中亦不可忽视。用户偏好具有明显的时效性，但目前许多模型仍使用静态的时间窗口^[38]，对用户兴趣的即时变化缺乏敏感性，这限制了推荐结果的实时性与准确性。未来研究应更加注重时间动态建模，并结合多模态信息以实现更加精细化、个性化的推荐策略^[39]。

1.3 研究面临的主要问题

目前音乐推荐存在一些问题，主要表现在数据不足导致数据稀疏，用户信息利用不充分导致用户偏好建模不足，时间信息利用不够充分等方面。

（1）数据稀疏性

音乐平台目前普遍存在的问题就是数据存在稀疏性^[40]。在用户使用过程中，往往只会对少部分歌曲进行收听，从而导致用户的交互行为分布不平衡，少量歌曲包含了大部分的用户交互行为，而大部分歌曲没有产生任何交互，这会导致在构建用户—歌曲评分矩阵时，出现数据过于稀疏的问题。

数据稀疏性会带来很多的影响。音乐平台在使用协同过滤进行推荐时，由于协同过滤使用用户—歌曲评分矩阵进行相似度计算，此时过于稀疏的数据评分会造成计算不够准确^[41]。而在使用矩阵分解技术时，由于模型可以很好的捕捉数据之间的关系，如果数据过于稀疏，就会导致出现过拟合问题，模型无法有效的泛化。对于新歌曲或新用户出现时，矩阵分解模型就会出现冷启动问题。稀疏的数据无法有效的捕捉用户的偏好信息，因此，如何在数据稀疏的环境背景下有效提高推荐系统的性能，成为了一个主要的研究方向^[42]。

（2）用户偏好建模不足

在推荐算法中，评价算法模型的优劣的一个重要方法就是观察用户偏好建模的好坏，好的模型更能完美的捕捉用户的偏好信息^[43]。当前用户的建模策略存在一些不足之处，大多数平台仅仅依赖于用户的显示评分数据，忽视用户的隐式评分，而要获得用户的主观评分是较为困难的，这极大的影响了推荐系统的性能。用户在音乐平台留下的多数是音乐交互记录，点赞收藏等行为，而很多会给听过的音乐进行评分，这就要求音乐推荐要基于当前这些有效数据来进行^[44]。而音乐偏好也同时具有时效性，用户某段时间的音乐交互记录和另一段时间的交互记录可能并不存在关联性，这就要求模型及时的去更新用户的兴趣变化^[45]，同时关注历史行为以及近期行为才能更多的去捕捉用户偏好。而当前许多模型仍以静态性偏好建模为主，以矩阵分解技术为例，矩阵分解利用用户与物品的潜藏因子来构建用户兴趣，但是这些因子通常是静态的，这就导致模型无法捕捉到用户的动态变化。在引入序列模型后，这一问题得以改善，但仍然存在不足之处。用户行为建模还存在着许多不确定性，例如噪声问题，社交因素导致的干扰等等，这些问题提高了建模的复杂性和不确定性。

（3）动态兴趣捕捉不足

时间信息在推荐系统中扮演着至关重要的角色，用户的兴趣和行为在随着时间推移而不断发生变化。如果忽视时间维度的变化，推荐模型往往会缺乏动态性，难以准确反映用户当前的真实偏好^[46]。目前已有研究开始关注用户行为的时间顺序，但对行为间的实际时间间隔及兴趣随时间衰减的过程建模仍不充分^[47]，这在一定程度上影响了模型对用户近期偏好的刻画能力，降低了推荐的准确性与实时性。

此外，用户行为常常具有周期性或阶段性特征，在不同时间段可能呈现出重复或相似的兴趣模式。当前多数方法尚难以有效捕捉这种周期性变化，时间建模机制普遍较为简化，常采用线性或指数衰减函数来对历史行为进行加权^[48-49]。尽管这些方法在一定程度上缓解了历史信息对近期兴趣建模的干扰，但仍难以深入挖掘用户行为背后

的复杂动态模式，限制了推荐系统的时效性和个性化能力。如何更精细、动态地利用时间信息建模用户兴趣演化过程，仍是当前推荐系统研究中的重要挑战之一。

1.4 研究内容与章节安排

1.4.1 研究内容

针对以上所提到的问题，本文提供了一种新的改进模型 DeepFM-T-A-LDA-T 模型，该模型结合了用户的历史行为数据和音乐文本数据，从而有效提高音乐推荐的准确性。为了缓解数据稀疏性问题，本研究引入了歌词文本数据来进行建模，通过深入挖掘文本的语义信息来弥补行为数据的不足，同时引入时间机制，对用户的主题兴趣加权，有效的捕捉了用户时间维度上的兴趣变化，完成了动态的用户偏好建模。通过多模态融合机制，将文本数据与行为数据有效结合起来，增强了模型的推荐能力。

在实验环境中，本文采用了 Last.fm-1k 和 30Music 数据集，数据集包含了用户的行为数据以及时间信息，能够帮助模型完成此次实验。最后通过设计了多组对比实验，并采用多种评价指标来对模型效果进行评估。实验结果表明，改进后的 DeepFM-T-A-LDA-T 模型在准确率、召回率等多项指标中均取得了不错的效果。

1.4.2 论文结构安排

本文共分为五个章节，总体结构安排如下：

第一章绪论，主要介绍了研究的国内外背景，介绍了当前推荐算法以及音乐推荐领域的研究现状，并指出了当前存在的一些问题。

第二章相关理论与技术，引入了推荐算法的基本概念和多种评价指标方式，同时介绍了更加主流的深度推荐模型 DeepFM、NCF、SASRec、CosRec 以及它们的相关原理。接着介绍了注意力机制的相关概念，最后阐述了本文在研究中所使用的一些关键技术，TF-IDF 算法，LDA 主题模型以及多模态融合理论。

第三章结合文本主题建模与时间加权的音乐推荐方法，重点介绍所提出的融合文本主题建模与时间加权策略的音乐推荐方法。此章节首先介绍了用户的行为特征分析，针对数据集中的数据进行一些分析和处理，然后介绍了文本的预处理方式。下面分为了两个部分，第一部分介绍了文本信息的处理，通过 TF-IDF 和 A-LDA 结合的方式形成双通道文本主题特征提取。A-LDA 是利用注意力机制增强主题模型对文档主题分布的挖掘能力，可以有效提取文本潜藏的深层语义信息。第二部分介绍了动态兴趣的时间加权策略，设计并实现了基于时间衰减函数引导的主题兴趣特征加权建模方法，并对获取的主题文本信息进行时间加权，从而获得最终的改进模型 DeepFM-T-A-LDA-T，最后设计了一些模型的优化策略。

第四章实验设计与结果分析，本章节主要完成了实验的设计与分析，先是对实验环境和所使用的数据集进行一个简单的介绍，然后介绍本次的实验基础，评价指标的选取和实验流程环节。下面分为了两个主要部分，第一部分完成了对比实验设计和改进实验设计，详细说明了实验所采用的各种参数指标；第二部分则是对实验数据进行

一个说明和分析，指出模型的提升，最后对实验的参数进行一些调优说明。

第五章总结与展望，本章节总结了本文的研究成果，并对一些不足之处进行了说明，同时阐述了未来的研究展望。

总体文章框架结构图如图 1 所示。




图 1 论文的结构框架

Fig. 1 The Structural Framework of the Paper

2 相关理论与技术

2.1 推荐算法的分类

当前阶段下，互联网技术的持续演进使得推荐算法化身为应对大数据环境所引致信息超载现象的关键性手段^[50]。不断增长且动态变化的用户数据群，构成了算法系统所需直面的核心难题—如何实现海量数据中用户偏好的精准提取^[51]。本节将介绍推荐系统的分类及其评价指标，为后续协同过滤算法及深度学习模型的讨论奠定基础，并为本研究的理论框架提供支持。

推荐系统根据算法的原理和数据的来源，主要被分为三个类别：基于内容的推荐、协同过滤推荐以及混合推荐^[52]。

基于内容的推荐方法依赖于物品的属性信息^[53]，在推荐过程中分析出各项物品的属性与用户行为偏好的相似度，从而进行物品推荐。这种方法先通过构建物品的特征矩阵，接着再分析用户的历史偏好，构建出一个用户偏好模型。例如，如果一个用户经常播放带有标签为“摇滚”的音乐，那么系统就会将该用户画像定义为摇滚型用户，每当发布新的歌曲时，系统会自动分析新的歌曲的特征，如果与用户的个人画像标签相符，就会推荐给相应的用户^[54]。这种推荐方法对于新的物品推荐来说十分友好，无需用户具体相应的历史数据即可完成新物品的推荐^[55]。但是此方法可能忽视了用户的个人行为数据，缺乏与用户之间的交互，可能会导致推荐的个性化程度不高。内容推荐算法的工作流程图如图 2-1 所示。

内容推荐算法流程图




图 2-1 内容推荐算法流程图

Fig. 2-1 Content Recommendation Algorithm Flowchart

协同过滤推荐利用用户的历史行为数据，通过用户或物品间的相似性实现推荐^[56]。系统计算用户之间或者物品之间的相似度。例如，两个用户在过去都给相同的电影打

过高分，系统认为这两个用户具有较高相似度。当其中一个用户观看了一部新电影并给出高分，系统向另一个相似的用户推荐这部电影^[57]。协同过滤无需依赖物品的内容信息即可运行，能够捕捉用户之间复杂的兴趣模式^[58]。但是在冷启动和数据稀疏场景下，协同过滤表现受限。新用户或新歌曲加入平台时，由于缺乏足够历史数据，难以提供有效推荐^[59]。此外，由于在计算的时候需要大量相似度得分，在处理大规模数据时，协同过滤可能遇到性能瓶颈。协同过滤推荐算法的工作流程图如图 2-2 所示。

协同过滤推荐系统工作流程图




图 2-2 协同推荐系统工作流程图

Fig. 2-2 Collaborative Recommendation System Workflow Diagram

推荐系统研究领域，混合式推荐方法正获得研究者们越来越多的关注^[60]。内容过滤技术的优势性与协同过滤算法被该方法结合，物品内容特征及用户行为数据的双重利用得以实现。实例显示，相比单一推荐模式，性能提升显著。不仅充分挖掘了物品属性特征，用户历史行为间相似性也得到了有效运用^[61]。以音乐推荐为例，歌词文本特征分析技术与历史点播记录相结合的方式被证实具有独特价值。用户偏好信息既可从播放行为序列中提取，又能通过歌词语义解析获得更精细的刻画。当前学术界普遍认为，此类融合策略代表着技术演进的主要方向。值得注意的是，神经网络技术在推荐领域的应用正呈加速态势^[62]。复杂特征交互关系的自动学习功能使其具备显著优势性。实例表明，个性化推荐能力因此获得实质性增强。本研究采用的 DeepFM 框架即属典型代表，混合推荐范式与深度学习机制被该模型创新性地整合。精准捕捉用户行为模式的同时，偏好背后的深层语义信息亦能被有效解读。图 2-3 直观展示了混合推荐系统的运行机制流程。实验数据证实了经优化后模型架构带来的服务质量全面提升这一事实。

混合推荐系统工作流程图




图 2-3 混合推荐系统工作流程图

Fig. 2-3 Hybrid Recommendation System Workflow Diagram

2.2 推荐系统评价指标

推荐系统的性能评估是衡量模型效果的关键步骤。常用的评价指标包括 AUC、NDCG@k、Precision@k、Recall@k、F1@k 和 MRR@k^[63]。衡量推荐系统性能的多个维度通过这些指标得以实现，涉及排序效能、推荐精确度以及用户感受层面。下文将对各指标的具体含义、运算方法及其价值展开详细阐述。

（1）ROC 曲线下的面积（AUC）

AUC 是 ROC 曲线（Receiver Operating Characteristic Curve）下的面积，用于衡量二分类模型的排序能力。在推荐场景中应用时，该指标能够区分用户偏好项目与非偏好项目的能力被重点考察。横轴设置为伪阳性率（FPR），纵轴则采用真阳性率（TPR），如公式 2-1 所示呈现其计算过程：FP 与 TN 之和作为分母时 FP 作分子构成 FPR，TP 与 FN 之和作为分母时 TP 作分子构成 TPR，其计算公式如式 2-1 所示：

$$FPR = FP / (FP + TN), TPR = TP / (TP + FN) \dots\dots\dots \text{式 (2-1)}$$

样本分类过程涉及的伪阳性、真阴性、真阳性以及假阴性数量，分别采用 FP、TN、TP 和 FN 予以标识。处于 0 与 1 之间的数值范围，构成 AUC 指标的可取值域。当且仅当 AUC 值达到 0.5 时，模型的排序效能与随机猜测相当；完美分类情形下该指标取值为 1，低于 0.5 的数值则反映模型性能劣于随机水平。尤为值得注意的是，AUC 指标具有评估全局排序能力的特性，即便样本类别呈现不均衡分布状态仍能保持稳定。

（2）归一化折扣累积增益（NDCG@K）

NDCG@k 是一种衡量推荐列表排序质量的指标，广泛应用于信息检索和推荐系统。基于 DCG（折扣累积增益）与 IDC（理想折扣累积增益）的计算结果，该指标

得以构建。其计算公式如式 2-2 所示：

$$DCG@k = \sum_{i=1}^k \frac{rel_i}{\log_2(i+1)} \dots\dots\dots \text{式 (2-2)}$$

其中，参数 i 的取值区间为 1 至 k 。代表第 i 个推荐项相关程度的是 rel_i 变量，常规情况下正样本取值为 1，负样本则为 0。作为折扣因子发挥作用的是 $\log_2(i+1)$ 项，该项使得序列前端位置具有更高权重值。IDCG@ k 表征最优排序状态下的 DCG@ k 值，此时所有正样本均排列于序列最前端。其计算公式如式 2-3 所示：

$$NDCG@k = DCG@k / IDCG@k \dots\dots\dots \text{式 (2-3)}$$

由此可见，通过上述计算过程实现的，是推荐列表排序质量的标准化评估。该指标之数值域处于闭区间[0,1]内，当 NDCG@ k 取值为 1 时，可证明推荐序列达到理想状态；若其值为 0，则表明推荐列表内不存在有效样本或排序完全失准。不仅涉及推荐结果相关性之评估，NDCG@ k 指标还对排序质量进行考量，该特性对于有限推荐列表场景下的用户体验评估具有显著价值，用户视线通常集中于列表前部区域。

(3) 精确度@ k (Precision@ k)

Precision@ k 衡量 Top- k 推荐列表中正样本的比例，是推荐系统准确性的一个重要指标。其计算公式如式 2-4 所示：

$$Precision@k = \text{True Positives in Top-}k / k \dots\dots\dots \text{式 (2-4)}$$

其中，True Positives in Top- k 表示 Top- k 推荐列表中正样本的数量， k 是推荐列表的长度。Precision@ k 的值范围为[0,1]，值越高表示推荐列表的准确性越高。Precision@ k 对推荐列表里正样本准确比例给予衡量，这样的方式十分直观，易于让人理解，还可迅速评估推荐系统的精准程度，在系统以最大化用户满意度为目标时，Precision@ k 可明确呈现推荐相关性的高低，帮助优化推荐效果。

(4) 召回率@ k (Recall@ k)

Recall@ k 衡量 Top- k 推荐列表中正样本的覆盖率，是推荐系统召回能力的指标。其计算公式如式 2-5 所示：

$$Recall@k = \text{True Positives in Top-}k / \text{Total Positives} \dots\dots\dots \text{式 (2-5)}$$

其中 True Positives in Top- k 表示 Top- k 推荐列表中正样本的数量，Total Positives 表示所有正样本的总数。Recall@ k 的值范围为[0,1]，其数值大小与推荐列表对正样本的覆盖程度呈现正相关关系。系统特性中的全面性可借助 Recall@ k 来实现量化评估，关键维度里的覆盖能力同样可依靠此指标得以体现，实例显示，借助该指标可有效检测关键内容的遗漏状况，也可保障用户兴趣点在推荐列表中的展示充分程度，可见该指标可有效衡量多样化推荐方面的系统表现。

(5) F1 值@ k (F1@ k)

F1@ k 是 Precision@ k 和 Recall@ k 的调和平均值，用于平衡推荐系统的准确性和覆盖率。其计算公式如式 2-6 所示：

$$F1@k = 2 * (\text{Precision}@k * \text{Recall}@k) / (\text{Precision}@k + \text{Recall}@k) \dots\dots \text{式 (2-6)}$$

$F1@k$ 的值范围为 $[0,1]$ ，其数值高低直接反映了模型在准确性与覆盖率之间的平衡程度达成情况。准确性与召回率这两个关键维度的平衡问题作为调和平均值的特殊形式存在，可借助 $F1@k$ 来解决，如此一来便可避免单一指标依赖所导致的潜在偏差问题。实例说明，在面临正负样本分布不均的特殊场景时，该指标能更稳定地契合系统性能的全面评估需求。

(6) 平均倒数排名 ($MRR@k$)

$MRR@k$ 是一种衡量推荐列表中第一个正样本位置的指标，反映 Top-1 推荐的准确性。其计算公式如式 2-7 所示：

$$MRR@k = \frac{1}{N} \sum_{i=1}^N \frac{1}{rank_i} \dots\dots\dots \text{式 (2-7)}$$

其中 $rank_i$ 是 Top-k 推荐列表中第一个正样本的位置， N 是用户总数。若 Top-k 列表中无正样本，则 $1/rank_i=0$ 。 $MRR@k$ 的值范围为 $[0,1]$ ，其数值大小与正样本平均排序呈现显著相关性。由此可见，较高数值意味着更优的正样本前置表现。

关注重点集中于推荐列表首位的 $MRR@k$ 指标，对于评价用户核心关注项的排序效果具有特殊意义。用户点击行为往往优先发生于推荐列表初始位置。实例证明，该指标能够有效衡量推荐系统对用户首要偏好的满足程度性。推荐精准度与用户体验由此获得双重提升。

2.3 深度学习推荐模型

随着深度学习领域不断向前发展，传统推荐算法正逐步朝着神经网络架构转变，深度学习方法可自动发掘特征间的非线性关联，整合了显式特征还融合了隐式特征，让推荐系统的效能得到了提升。本节重点阐述 DeepFM、NCF、SASRec 和 CoseRec 这四种典型模型实例，为后续模型构建工作奠定理论基础。

(1) DeepFM 模型架构

DeepFM 模型由因子分解机与深度神经网络相结合而形成的，其创新性体现在同时捕获低阶和高阶特征交互作用的能力方面^[64]。构成该模型的两大组件分别为 FM 模块与 DNN 模块。经过嵌入层转换得到的低维特征向量，将分别输入这两个并行运作的处理单元之中。

FM 模块的工作原理是通过内积来计算特征间的二阶交互^[65]，例如用户 ID 与音乐 ID 的组合权重，计算复杂度为 ($O(nk)$ ， n 为特征数， k 为嵌入维度)。

DNN 模块由多层次的全连接网络组成，它利用非线性激活函数来提取高阶的特征交互，来增强模型对复杂关系的建模能力^[66]。

两部分输出通过加和操作融合，最终经 sigmoid 函数预测用户偏好概率^[67]。DeepFM 采用交叉熵损失训练，常结合 L2 正则化和 Adam 优化器防止过拟合。DeepFM 模型结构图如图 2-4 所示。




图 2-4 DeepFM 模型结构图

Fig. 2-4 DeepFM Model Architecture Diagram

1. 输入与嵌入层

假设输入特征为 $x=[x_1, x_2, \dots, x_n]$ ，其中 n 是特征数量。每个离散特征（用户 ID、音乐 ID）会被编码成稀疏向量，经过嵌入层映射为低维密集向量，其计算公式如式 2-8 所示：

$$v_i = E_i x_i, v_i \in R^k \dots\dots\dots \text{式 (2-8)}$$

其中 k 是嵌入维度， E_i 是对应特征的嵌入矩阵。

2. FM 模块

FM 模块计算所有特征的二阶交互特征的贡献，其计算公式如式 2-9 所示：

$$y_{FM} = \sum_{i=1}^n w_i x_i + \sum_{i=1}^n \sum_{j=i+1}^n (v_i, v_j) x_i x_j \dots\dots\dots \text{式 (2-9)}$$

其中第一项是线性部分， w_i 为一阶权重，第二项是二阶交互， $\langle v_i, v_j \rangle = v_i^T v_j$ 表示嵌入向量的内积，捕捉特征间的相互影响。该计算复杂度为 $O(nk)$ ，比显式枚举所有二阶组合 $O(n^2)$ 高效。

3. DNN 模块

DNN 模块对嵌入向量进行拼接，其计算公式如式 2-10 所示：

$$a^{(0)} = [v_1, v_2, \dots, v_n] \in R^{nk} \dots\dots\dots \text{式 (2-10)}$$

经过多层全连接网络，其计算公式如式 2-11 所示：

$$a^{(l+1)} = \sigma(W^{(l)}a^{(l)} + b^{(l)}), l = 0, \dots, L-1 \dots \dots \dots \text{式 (2-11)}$$

其中 $W^{(l)}$, $b^{(l)}$ 是第 l 层的权重和偏置, σ 是非线性激活函数 (如 ReLU)。该模块学习更复杂的高阶交互信息。

4. 输出层与预测层

模型最终输出为两部分的加和, 再通过 sigmoid 函数映射成概率, 其计算公式如式 2-12 所示:

$$\hat{y} = \sigma(y_{FM} + w_{DNN}^T a^{(L)} + b) \dots \dots \dots \text{式 (2-12)}$$

其中 w_{DNN} 是 DNN 输出层权重, b 是偏置项, σ 是 sigmoid 函数, 用于预测用户对某音乐的偏好概率。

DeepFM 模型结合了因子分解机 (FM) 和深度神经网络 (DNN) 的优势, 能够同时捕获特征之间的低阶和高阶交互关系, 适应高维稀疏数据的建模需求。在音乐推荐任务中, 用户和音乐的多模态特征较为复杂且稀疏, DeepFM 在特征表达方面表现出较强的泛化能力和训练稳定性。此外, DeepFM 结构相对简洁, 计算效率较高, 便于快速迭代和部署。相比于近年来提出的图神经网络 (GNNs) 和基于 Transformer 的序列模型, 这些前沿模型虽然在捕捉复杂用户行为序列和图结构信息方面具有优势, 但通常训练成本更高、模型复杂度更大, 且需要更多数据支持。在本研究的数据规模和计算资源限制条件下, DeepFM 作为基线模型能较好地平衡模型性能与复杂度, 便于在融合文本主题和时间加权策略的基础上实现高效的多模态特征融合与推荐性能提升。由此, 本研究采用 DeepFM 作为基础模型。

5. 损失函数与优化

模型采用二元交叉熵作为损失函数, 其计算公式如式 2-13 所示:

$$Loss = -\frac{1}{N} \sum_{i=1}^N (y_i \log \hat{y}_i + (1 - y_i) \log (1 - \hat{y}_i)) + \lambda ||\theta||_2^2 \dots \dots \dots \text{式 (2-13)}$$

其中 N 是样本数, y_i 是真实标签, $\hat{y}_i$ 是预测概率, λ 是 L2 正则化系数, θ 是所有模型参数。训练时通常采用 Adam 优化器进行参数更新, 有效防止过拟合并加速收敛。

(2) NCF 模型

神经协同过滤 (NCF) 通过将矩阵分解技术和神经网络结合的方式, 来克服传统的 MF 算法的局限性^[68]。NCF 算法包含有广义矩阵分解 (GMF) 层和多层感知机 (MLP) 层两个分支:

GMF 层将用户和物品通过嵌入层映射为低维稠密向量, 作为嵌入向量, 设用户 u 和物品 i 的嵌入向量分别是 p_u 和 q_i , 通过计算它们的点积来模拟二阶交互。计算过程如公式 2-14 所示:

$$z_{GMF} = p_u \odot q_i \dots \dots \dots \text{式 (2-14)}$$

MLP 层将拼接后的用户和物品嵌入信息输入到多层全连接网络, 从而捕捉高阶的非线性关系。该过程表示如公式 2-15 所示:

$$z_0 = [p_u; q_i], z_l = \phi(W_l z_{l-1} + b_l) \dots\dots\dots \text{式 (2-15)}$$

其中 $\phi(\cdot)$ 表示激活函数（如 ReLU）， W_l 与 b_l 分别为第 l 层的权重矩阵与偏置向量。两分支输出拼接融合后被输入到一个输出层，通过 sigmoid 函数来预测用户对该物品的偏好概率。公式如 2-16 所示：

$$\hat{y}_{ui} = \sigma(h^+[z_{GMF}; z_{MLP}]) \dots\dots\dots \text{式 (2-16)}$$

其中 $\sigma(\cdot)$ 表示 sigmoid 函数， h 为输出层的权重向量。

在训练阶段，NCF 采用交叉熵损失函数进行优化^[69]，该损失函数适用于处理隐式反馈数据，如点击、收藏、播放等行为。为提升训练效果并防止过拟合，NCF 通常采用 Adam 优化器进行参数更新，并引入 L2 正则化约束模型复杂度。

NCF 模型整体结构图如图 2-5 所示。




图 2-5 NCF 模型结构图

Fig. 2-5 NCF Model Architecture Diagram

（3）SASRec 模型

在序列化推荐领域有着关键地位的 SASRec（基于自注意力机制的序列推荐模型）^[70]，它的核心想法是运用自注意力机制来处理传统序列模型难以应对的长序列依赖问题，嵌入层和多层自注意力模块是构成该模型的主要部分^[71]，其整体架构借鉴了 Transformer 的设计理念。

SASRec 的输入为用户的历史交互序列 $\{i_1, i_2, \dots, i_t\}$ ，模型首先通过嵌入层实现向量化转换用户历史交互序列数据，并添加位置编码保留序列信息，具体过程如公式 2-17 所示：

$$E = [e_{i_1} + p_1, e_{i_2} + p_2, \dots, e_{i_t} + p_t] \dots\dots\dots \text{式 (2-17)}$$

其中 e_{i_k} 表示第 k 个物品的嵌入向量， p_k 为位置嵌入向量。

随后经过嵌入处理的序列数据被输入多层 Transformer 模块^[72]。每个 Transformer 模块均包含两个关键部分：执行动态关系建模的自注意力层和进行非线性特征增强的前馈神经网络。

1. 多头自注意力机制 (Multi-Head Self-Attention)

具有独特计算方式的自注意力层，能够在不考虑时序递进关系的前提下，通过位置间相关性分析来捕获交互依赖关系。多头自注意力机制通过对当前时刻与历史时刻的表示进行加权求和，用来捕捉用户行为序列中不同位置间的关联关系。注意力计算公式如公式 2-18 所示：

$$Attention(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d}})V \dots\dots\dots \text{式 (2-18)}$$

其中 Q, K, V 分别为查询、键、值矩阵，通常由输入嵌入序列线性变换而来， d 为嵌入维度。

2. 前馈神经网络 (Feed Forward Network, FFN)

自注意力输出随后送入前馈神经网络进行非线性转换以增强表示能力，其计算过程如公式 2-19 所示：

$$FFN(x) = \phi(xW_1 + b_1)W_2 + b_2 \dots\dots\dots \text{式 (2-19)}$$

其中 ϕ 为激活函数（如 ReLU）， W_1, W_2 为可学习参数矩阵。为了防止信息泄漏，SASRec 在自注意力层中引入了掩码机制 (Masking)，确保每个位置仅能访问自身及其之前的序列位置，从而严格遵循因果性。

在所有层的计算完成后，最终使用最近一项的位置输出向量 h_t^T （或通过池化得到的序列表示）来预测用户在下一个时刻最可能交互的物品。预测过程如公式 2-20 所示：

$$\hat{y}_i = \sigma(h_t^T e_i) \dots\dots\dots \text{式 (2-20)}$$

其中 e_i 为候选物品的嵌入向量， $\sigma(\cdot)$ 为 sigmoid 函数。

最终输出的获取方式通常采用池化操作或截取末位表征，用以预测用户对后续音乐项目的偏好分布^[73]，特别适用于隐式反馈数据的处理场景。本研究将 SASRec 作为基准对比模型予以实现，重点考察其在序列推荐任务中的排序性能表现，并与改进后的 DeepFM 模型展开系统性对比分析。具体模型架构可参见图 2-6 所示示意图。




图 2-6 SASRec 模型结构图

Fig. 2-6 SASRec Model Architecture Diagram

(4) CoseRec 模型

CoSeRec (Contrastive Self-supervised Sequential Recommendation)^[74]是一种结合序列建模与对比学习的自监督推荐模型，CoSeRec 模型于 2021 年提出，其核心目标在于会话协同信息的有效利用以实现会话推荐性能的提升。该模型的重要贡献所在是将基于图的协同过滤技术与自监督表征学习进行有机结合，使得低阶特征交互和高阶特征交互能够被同时捕获。由此形成“结构感知与语义增强相结合”的混合推荐框架式，传统推荐算法在冷启动场景以及数据稀疏情况下存在的局限性得以有效克服。

CoseRec 主要包括四个模块：嵌入层、Transformer 编码器、对比学习模块与预测层。嵌入层作为模型的起始模块，嵌入层负责将离散的用户 ID 和音乐 ID 转化为低维连续向量。Transformer 编码器在 CoSeRec 中扮演核心角色，用于对用户交互序列进行深度特征提取与建模。对比学习模块是 CoSeRec 实现自监督学习的关键，通过引入对比学习机制，增强模型对用户兴趣特征的学习能力。预测层接收来自 Transformer 编码器和对比学习模块处理后的特征信息，负责生成最终的用户对音乐的偏好预测结果。模型整体结构如图 2-7 所示。




图 2-7 CoseRec 模型结构图

Fig. 2-7 CoseRec Model Architecture Diagram

1. 输入与嵌入层

假设某个用户 u 的会话序列为 $S = \{v_1, v_2, \dots, v_t\}$ ，其中 v_i 表示第 i 个交互项目， t 为当前会话的长度。每个项目通过嵌入矩阵，映射为 d 维嵌入向量，得到嵌入序列，如公式 2-21、2-22 所示：

$$E \in R^{|I| \times d} \dots \dots \dots \text{式 (2-21)}$$

$$X = [e_{v_1}, e_{v_2}, \dots, e_{v_t}] \dots \dots \dots \text{式 (2-22)}$$

其中 $e_{v_i} \in R^d$ 表示项目 v_i 对应的嵌入向量。

2. 会话编码器模块

CoSeRec 引入 Gated Recurrent Unit (GRU) 对嵌入序列进行编码，生成表示当前会话语义的隐向量，如公式 2-23：

$$h_t = GRU(X) \dots \dots \dots \text{式 (2-23)}$$

其中 $X = [e_{v_1}, e_{v_2}, \dots, e_{v_t}]$ 为嵌入序列。

3. 自监督任务

CoSeRec 采用对比学习作为自监督目标，利用 InfoNCE 损失增强会话表示的判别

能力。定义正对为 (s_i, s_i^+) ，负对为 (s_i, s_j^-) ，其对比损失定义如公式 2-24 所示：

$$L_{contrast} = -\log \left(\frac{\exp(\sin(z_i, z_i^+)/\tau)}{\sum_{j=1}^N \exp(\sin(z_i, z_j^-)/\tau)} \right) \dots\dots\dots \text{式 (2-24)}$$

其中 $\sin(a, b)$ 表示向量相似度函数（如点积或余弦相似度）， τ 是温度系数。 z_i 由当前会话编码得到的会话表示。

4. 推荐预测层

最终的会话表示通过拼接当前会话编码 h_t 与用户长期偏好向量 p_u 如公式 2-25，用户对候选物品 v_j 的偏好得分通过点积计算如公式 2-26：

$$s = [h_t; p_u] \dots\dots\dots \text{式 (2-25)}$$

$$\hat{y}_{uj} = s^T E(v_j) \dots\dots\dots \text{式 (2-26)}$$

其中 $E(v_j)$ 表示候选物品的嵌入向量。

5. 损失函数与优化

最终的推荐损失采用常规的交叉熵损失与自监督对比损失联合训练函数如公式 2-27 所示：

$$L_{total} = L_{rec} + \lambda L_{contrast} \dots\dots\dots \text{式 (2-27)}$$

其中 λ 为超参数，用于平衡推荐目标与对比学习目标。 L_{rec} 为推荐任务损失（通常为交叉熵）； $L_{contrast}$ 为对比学习损失。

2.4 注意力机制

近年来获得广泛应用的注意力机制（Attention Mechanism-based），在自然语言处理领域及推荐系统构建过程中展现出显著价值。其核心思想体现为：通过关注权重这一概念的引入，模型得以自动判断输入序列中关键部分的存在性，上下文信息作为重要参考依据被充分考虑。由此提升特征表示的精度，语义表达能力亦获得增强效果。特别是音乐推荐场景下文本内容建模的应用实例。对于歌词文本、用户评论以及标签数据这类非结构化信息而言，注意力机制技术的采用使得核心语义片段的识别过程得到强化。用户兴趣的内在驱动因素，通过该技术被模型更为精准地捕捉到。

注意力机制通常以“查询-键-值”（Query-Key-Value）的方式运作，通过计算查询向量与键向量之间的相似度（通常采用点积或加性函数），并结合 Softmax 函数生成一组权重分布，这些权重再用于对值向量的加权求和，最终得到的上下文向量即为模型在当前输入条件下“注意到”的信息。该过程可看作是一种动态的信息筛选方法，在模型训练过程中可自适应学习出对不同输入单元的重要性评估，进而实现对语义焦点的精准对齐。

注意力机制根据权重分配方式的不同可分为三类：规则型注意力（Rule-based Attention）通常依赖人工定义的语法规则或先验知识来确定输入元素间的关联，具有一定的解释性但灵活性较差；统计型注意力（Statistical Attention）以输入与输出向量

间的相似性为基础,利用 dot-product 或加性函数计算注意力得分,并通过 Softmax 函数生成归一化权重,是现今应用最为广泛的注意力方式之一;基于网络结构的注意力 (Neural Network-based Attention),如 Transformer 中的 Self-Attention 与 Multi-head Attention,通过多层网络结构学习序列中任意两个位置之间的关系,不仅支持全局依赖建模,还能显著提升特征表达的维度感知能力。

在歌词建模任务中,注意力机制能够有效缓解 TF-IDF 这类静态词频模型在捕捉上下文关系上的不足。例如,同一个词“fire”在表达爱情热情与描述灾难情景时所代表的语义完全不同,而注意力机制则能够依据上下文自动调整对该词语的关注程度,从而准确区分其语义角色。同时,注意力机制还具有良好的可解释性与可扩展性,能够结合 Transformer 等结构进一步提升建模深度与语义抽象能力。

2.5 文本特征处理方法

在推荐系统的构建过程中,文本特征所具有的辅助作用不可忽视。尤为显著的是音乐领域这一特定场景,诸如歌词文本与曲目标题等信息能够有效弥补行为数据在语义层面上的缺失。本节将重点阐释 TF-IDF 方法、LDA 模型及其特征融合技术,为之后开展的文本建模工作奠定必要的理论根基。

(1) TF-IDF 算法

TF-IDF (词频-逆文档频率)是一种经典且应用广泛的文本特征表示方法^[75],其计算过程体现为词频指标与逆文档频率指标的乘积运算。词语在文档集合内的重要性程度以及区分能力通过该运算得以量化评估。推荐系统领域特别是音乐相关应用中,该方法被频繁使用^[76]。处理对象涉及非结构化文本数据如歌词内容、用户生成评论乃至歌曲标签等。通过该方法实现向结构化数值特征向量的转化,为后续的特征运算环节、相似度比对过程以及模型训练阶段所需的输入基础提供可靠支撑。

TF-IDF 的计算结合了词频和逆文档频率两个部分^[77]。反映特定词语在单篇文档中出现频率的是词频指标,该指标能够体现词语在当前文档中的重要性程度。衡量该词语在整个文档集合中稀缺程度的则是逆文档频率指标,其作用在于强化具有高区分度词语的权重,同时削弱常见词语的影响力。高效的关键词信息提取能力是 TF-IDF 计算方式的显著优势。以歌曲歌词分析为例,当某个词语出现频次较高时,其对应的 TF 值随之提升,由此可见该词语很可能承载着歌词内容的核心语义表达。而通过对高频词语的权重抑制,IDF 指标使得那些仅在少数文档中出现、具备较强区分能力的低频词语^[78]得以凸显其重要性。

TF-IDF 算法采用归一化处理的方式将文本转变为高维度的稀疏特征向量,结合相似度计算等度量方法^[79],可广泛用于文本匹配、聚类或相似物品的推荐计算。在实际应用中,由于 TF-IDF 具有高效性和高解释性两个特点,常常被用来提取关键词。在音乐推荐领域,它可以被用来提取歌词的关键信息,来表达歌词的情感,从而为获取用户的偏好提供初步的支持。但是 TF-IDF 同样具有一些局限性,其仅仅统计词频

信息，从而无法区分同一词语在不同语境下的深层语义信息，相对于长文本来说，TF-IDF 更适合短而富含感情的文本，长文本往往穿插着一些无意义词或噪声大的词，从而模糊了特征表示^[80]。在推荐系统的应用中，TF-IDF 常常被用作基础语义提取工作，同时结合其他工具，比如 word2vec、bert 等语义分析方法来使用，从而弥补其在语义捕捉上的不足^[81]。

（2）LDA 主题模型

LDA 是一种生成式概率模型，可以从大量的数据中发掘其潜藏的主题信息^[82]。LDA 的工作方式是：假定每一篇文档都由若干个主题构成，而每一个主题又由若干个词语构成，通过分析每个文档对应的文档—主题分布矩阵就可以找到文档对应的主题分布，从而为推荐系统提供丰富的语义补充^[83]。

LDA 模型的训练过程中的两个关键步骤是参数估计和主题推断。在建模的过程中，通过预先设定的先验分布 Dirichlet 分布，分别对文档中的主题分布以及各主题下的词语分布来进行建模^[84]。模型在训练时，利用 Gibbs 采样技术或变分推断等算法来对参数的迭代更新，直到完成收敛过程。训练完成后，每一篇文档可被表示为一个主题概率分布向量，而每个主题由一组词汇构成，表示其语义特征^[85]。

LDA 经常被用作文本建模工作，它的工作原理是将高维度的文档空间降维到的低纬度的主题空间^[86]，捕获文档的主题信息，为构建用户画像等方面提供语义支持。在进行音乐推荐时，本研究借助 LDA 来实现对用户偏好的歌曲进行主题建模，从而获取用户的主题偏好，从单一的歌曲维度扩散到主题维度，有效缓解冷启动问题^[87]，从而实现更加个性化的推荐目标。

LDA 主题建模质量受到多种因素的影响，设定合适的主题数量，合理处理文档长度问题可以让 LDA 获取更为高效的主题分布^[88]。在实际应用中，要不断结合实验结果来进一步优化参数，从而获得良好的建模效果。LDA 主题模型结构图如图 2-8 所示。




图 2-8 主题模型结构图

Fig. 2-8 Topic Model Architecture Diagram

（3）特征融合策略

在当代推荐系统研究领域内，单一特征维度对用户偏好与物品属性的刻画存在明显局限性，异构特征融合化处理由此成为学界关注焦点^[89]。常见于文献中的融合策略可划分为三类：早期型融合、晚期型融合以及混合型融合。直接于输入层面对多模态数据进行拼接操作的，是早期融合方法学，其优势在于实现简易性且能初步捕获特征间相互作用性，然而不同维度间存在的差异性可能导致信息对齐失效现象。分别训练各子模型后通过加权或排序手段实现结果整合的，属于晚期融合范畴，该方法展现出较强灵活度并能充分发挥单模态优势特性，但深层特征交互机制的挖掘仍面临挑战。混合融合方案则借助深度网络架构进行特征权重学习化处理，通常引入注意力机制模块以实现关键信息聚焦功能，在精度与效率两个维度取得平衡^[90]。实例表明特征融合技术的应用使得推荐系统性能获得显著提升化改进，本研究选取混合融合策略作为基础框架，旨在增强推荐模型的精度表现与鲁棒性能。

2.6 本章小结

本章对推荐系统领域的理论架构与技术路径进行了较为全面的梳理工作，为后续相关研究奠定了必要的理论基础。具体而言，研究内容主要涉及四个关键性维度：推荐算法的类型划分、评价指标体系的构建、基于深度学习的推荐范式以及文本特征的处理方法论。

在算法分类层面，重点考察了三种具有代表性的推荐范式。基于内容特征的推荐方法，这种方法在新物品推荐场景中表现出较强的适应性，但存在个性化程度不足的固有缺陷。协同过滤技术则依赖于用户行为数据的相似性度量，能够发现更为复杂的兴趣关联模式，然而面临冷启动问题和数据稀疏性带来的挑战。混合式推荐机制将上述两种方法进行有机整合，在提升推荐准确度的同时增强了结果多样性特征。评价指标方面详细阐释了 AUC、NDCG@k、Precision@k 等系列量化标准。实例表明，这些指标分别从排序效能、准确率表现以及用户体验等不同角度对系统性能进行综合评估。

在推荐系统领域受到广泛关注的三种深度学习模型分别是 DeepFM、NCF、SASRec 以及 CoseRec。DeepFM 模型由 FM 模块与 DNN 组件构成，实现了同时捕捉低阶特征交互与高阶特征交互，对多模态融合模型的构建具有重要参考价值。NCF 模型是通过神经网络改进协同过滤技术，显著增强了模型的非线性建模能力。SASRec 模型则依靠自注意力机制完成的，动态偏好分析场景尤为适用。CoSeRec 作为新兴的深度混合推荐模型，融合了图神经网络（GNN）与自监督学习，通过加权融合层实现“协同过滤+内容推荐”的混合推理，提升推荐结果的多样性与解释性。上述模型充分证明了深度学习技术在推荐领域的应用前景，模型选择与优化工作提供了坚实的理论依据。同时介绍了本研究中所使用到的注意力机制，在音乐推荐领域方面上的一些可能性应用。为后续 LDA 模型的改进提供了理论支持。

文本特征处理方面主要涉及 TF-IDF 算法与 LDA 主题模型。基于词频统计和逆文

档频率的关键词权重计算由 TF-IDF 方法完成，文本统计特征的快速提取较为适用，语义层面的理解存在不足。深层语义信息的挖掘则通过主题建模过程实现的 LDA 方法，推荐系统的语义补充作用显著。二者相结合的方式为多模态特征提取奠定了重要基础。关于特征融合策略的研究中，详细探讨了早期融合、晚期融合及混合融合三种方式。优势最为突出的是混合融合方法。能够完成多模态特征的有效整合，推荐系统的准确性与鲁棒性均获提升，对本研究的融合方案设计具有重要指导意义。

3 融合文本主题建模与时间加权的音乐推荐模型

本章系统阐述了一种融合歌词文本主题特征和时间加权机制的音乐推荐模型的构建过程。在个性化音乐推荐任务中，歌词文本特征可揭示音乐内容的语义信息与情感倾向，而时间加权机制则用于建模推荐特征随时间的变化趋势，以提升模型对音乐时效性的感知能力。为此，本文提出了一种基于 DeepFM 的多特征融合模型——DeepFM-T-A-LDA-T，综合利用时间衰减权重、TF-IDF 关键词特征及注意力增强的主题模型（A-LDA）提取的语义特征，实现对歌词内容的多层次建模与时间敏感性建模，从而提升推荐系统的准确性与泛化能力。

3.1 训练样本构建与时间特征提取

在基于歌词主题特征和时间加权机制的音乐推荐模型中，训练样本的构建与时间特征的提取是模型性能的基础。为实现有效的监督学习，需从音乐播放记录中提取结构化的训练样本，并提取时间相关特征用于建模兴趣的时效性。

（1）训练样本构建

本研究使用 LastFM-1K 和 30Music 数据集，其中包含用户与音乐的历史交互记录。每条记录包含用户标识、音乐标识以及交互时间戳等字段。为构建模型训练所需的正负样本集合，采用如下策略：

正样本提取：保留原始播放记录中每条实际发生的交互，作为正样本，标注标签为 1；

负样本生成：从用户未曾交互过的音乐集合中，依据音乐整体流行度进行概率加权随机采样，生成与正样本数量成比例的负样本，标注标签为 0；

字段保留：所有样本（正负）均保留音乐 ID、歌词内容等字段，为后续特征提取提供基础。

负采样策略在保证样本均衡的同时，能有效提升模型区分正负倾向的能力。最终构建的训练数据包含音乐标识、歌词文本、时间戳及正负标签等字段。

（2）时间特征提取与处理

为了捕捉用户对音乐兴趣的时效性，本研究引入时间相关特征，对播放记录中的时间信息进行处理：

标准化时间戳：将原始时间戳统一转换为标准时间格式（如 UNIX 时间），便于后续时间差计算；

时间间隔（Time Gap）计算：对每条交互记录，计算其时间戳与全局参考时间（最新播放时间）之间的时间差，作为时间衰减因子的基础；

时间衰减权重生成：依据设定的时间衰减函数，将时间间隔映射为权重系数，后续用于加权歌词主题表示，实现时间加权的兴趣建模。

该时间特征不仅用于衡量样本的“新鲜度”，也为后续文本主题表示的动态加权奠

定了基础。在推荐模型训练阶段，时间加权机制与双通道文本特征共同作用，有效提升了模型在兴趣演化与冷启动场景下的鲁棒性与适应性。

3.2 歌词文本预处理

歌词文本特征在推荐系统中扮演着不可或缺的角色，能够揭示音乐内容的语义和情感特征，有效弥补用户行为数据在冷启动和数据稀疏问题下的不足。在音乐推荐系统中，用户行为数据虽然是反映用户偏好的重要信号，但它的局限性在某些场景下尤为明显。例如，对于新用户或新加入平台的歌曲，由于缺乏足够的历史交互数据，单纯依赖行为数据的推荐效果往往不佳，甚至可能无法生成有效的推荐结果。这时基于内容的特征成为补充信息的重要来源。歌词作为音乐的核心组成部分，蕴含了丰富的语义信息和情感表达，能够帮助系统更全面地理解音乐的主题、风格和情感倾向，从而为用户提供更精准的推荐。歌词文本还可以捕捉用户潜在的兴趣偏好，通过分析用户偏爱的歌词主题，推测其对特定音乐风格或情感表达的倾向。充分利用歌词文本特征，不仅能够提升推荐系统的性能，还能在一定程度上缓解冷启动问题，为新用户或新歌曲提供更合理的推荐。

初始状态的歌词文本往往呈现出显著的复杂化特征，噪声干扰现象尤为突出。包括但不限于：非标准化的表达形式存在，重复性段落大量出现，语气词使用频率过高，以及多语言混杂问题普遍。这些干扰性因素不可避免地会影响后续建模过程与分析效果。在实施文本特征提取操作之前，必须优先完成对歌词数据的预处理化工作。通过该步骤可有效降低噪声影响程度，提升语义表达的明确性水平。同时能够为后续建模环节提供结构更为清晰、内容更为纯净的输入材料。针对补充数据集所收录的歌词信息而言，预处理流程主要涵盖以下关键性步骤：

（1）分词处理

分词是自然语言处理中的首要环节，将连续的文本内容拆解为单个词语构成的序列，便于后续的特征分析。在英文歌词中，由于单词通常以空格或标点符号作为天然边界，因此可以借助已有的工具包如 NLTK 中的 `word_tokenize()` 函数对歌词文本进行分词处理。举例来说，原始文本 “And I will always love you” 在经过分词操作后可被转换为 `['And','I','will','always','love','you']`，为后续特征提取奠定基础。

（2）去除停用词和标点符号

停用词是指在那些语义分析中贡献较少的高频词，如 “the”、“is”、“and” 等。这些词虽然在句子结构中很重要，但在特征提取时对区分歌词情感或主题的作用有限。可以使用 NLTK 的 `stopwords` 词库来对这些无用词进行过滤。而歌词中可能也包含了大量无实际意义的填充词，如 “yeah”、“ooh”、“la”、“uh”，所以需要构建额外的歌词停用词列表来清理数据。同时可以使用正则表达式来对一些标点符号进行去除。

（3）统一文本格式

在文本处理任务中,大写单词和小写单词通常会被认为是两种单词,比如:“Love”和“love”在机器眼中是不一样的,为了减少这种误差,可以同时对本进行小写转换,提高数据的一致性。

(4) 词干提取和词形还原

为了降低词语的变化所以对文本质量造成的印象,本文采用词干提取与词形还原两种技术来还原歌词。词干提取会将词语的主体部分提取,保留关键部分。比如,单词“running”在提取之后会变为“run”,单词“eating”会被还原为“eat”;而词形还原是根据词典的规则,将单词还原为对应的规范形式,例如单词“better”的规范形式是“good”。通过这两种方法可以有效地减少词汇的形态变化所带来的干扰,使模型更准确地理解文本的语义结构,从而提升后续分析与建模的效果。

(5) 过滤短词

在单词文本中,个别超短词所带来的文本信息并没有太大意义,比如:“oh”、“ah”等语气词,因此可以过滤掉长度小于等于2的单词。

通过上述文本预处理步骤,清理了歌词文本数据的无效信息,提高了特征的质量,对进一步主题建模及文本向量化等任务来说优化了文本特征。

3.3 基于双通道文本特征融合的 DeepFM 推荐模型

在音乐推荐任务中,歌词文本蕴含了丰富的语义信息,是刻画歌曲主题与风格的重要基础。为了充分挖掘歌词文本中的主题结构与关键词特征,提升基于内容的推荐效果,本节提出了一种双通道文本主题特征提取与融合建模方法。通过采用 TF-IDF 方法提取浅层的词频权重特征,反映歌词中关键词的显式重要性;同时引入注意力机制优化的主题模型 A-LDA (Attention-enhanced LDA),提取歌词的深层主题分布特征,捕捉歌曲间的语义结构相似性。基于这两个特征通道,设计融合特征输入的 DeepFM 模型,综合利用线性特征组合与高阶非线性交互能力,实现多维度语义建模,提升推荐系统在冷启动与语义泛化场景下的表现。

3.3.1 TF-IDF 特征提取

词频—逆文档频率 (TF-IDF) 是一种经典且应用广泛的文本特征表示方法,其核心理念是通过结合词频和逆文档频率的乘积,来量化单词在文档集合中的重要性及区分能力。其计算公式如式 3-1 所示:

$$TF-IDF(t, d) = TF(t, d) \times \log(N/DF(t)) \dots\dots\dots \text{式 (3-1)}$$

其中, $TF(t, d)$ 表示词 t 在文档 d 中的出现频率, N 为文档总数, $DF(t)$ 为包含词 t 的文档数。运用这样的计算方式, TF-IDF 可迅速地提取出关键词信息,举例来说,在一首歌曲的歌词里面,要是“love”这个词频繁出现,那么它的 TF 值就会比较高,该词有可能是歌词内容的核心表达。IDF 部分是依靠计算包含该词的文档数量和总文档数的比值,并且采用取对数的形式,来对常见词的权重进行压制,突出那些在少数文档中出现、有较高区分性的稀有词,比如“the”这样的高频词由于出现在几乎所有歌词

里而被赋予较低 IDF 值，而“nostalgia”这类特定的词则因为其稀有性而获得更高的权重。

在音乐推荐领域内，非结构化文本数据（如歌词或曲目标题）的转化可以借助 TF-IDF 方法学来实现词袋形式的结构化转换，比如情感信息的推断能够基于歌词文本中的关键性词语来进行。经过清洗处理的歌词文本，首先需要构建出一个全局性的词汇表格系统，随后通过 TF-IDF 技术实施词频特征的提取操作。通过降维技术应用于歌词维度的降低过程，冗余特征与额外计算开销由此得以减少。但是仅关注词语统计频率的 TF-IDF 方法学，对词语深层语义信息的忽视显而易见。实例表明，文本语义建模技术的结合运用对于推荐系统文本特征理解能力的增强具有必要性。

通过展示 TF-IDF 特征的提取直观性过程，采用若干歌曲歌词片段被选作分析样本。关键词“love”、“dream”及“the”的 TF 值与 IDF 值通过公式来进行计算，文档总数设定为 N=3。最终获得的 TF-IDF 得分情况如表 3-1 中所示。

表 3-1 TF-IDF 特征提取示例
Table 3-1 Example of TF-IDF Feature Extraction

歌曲 ID	歌词片段	关键词	TF (词频)	DF (文档频率)	IDF (log(N/DF))	TF-IDF 得分
Song1	"love love the dream"	love	2/4	2	log(3/2)	0.088
Song1	"love love the dream"	dream	1/4	2	log(3/2)	0.044
Song1	"love love the dream"	the	1/4	3	log(3/3)	0
Song2	"dream in the night"	dream	1/4	2	log(3/2)	0.044
Song2	"dream in the night"	the	1/4	3	log(3/3)	0
Song3	"love the way you smile"	love	1/5	2	log(3/2)	0.035
Song3	"love the way you smile"	the	1/5	3	log(3/3)	0

3.3.2 LDA 主题模型原理

LDA 是一种基于贝叶斯推理的主题建模方法，广泛用于从大规模文本数据中挖掘潜在的语义结构。将每篇文档视作多个潜在主题的混合体，是 LDA 方法的核心思想所在。而每个主题的表达，则依赖于词汇表上特定概率分布的建立。采用生成式框架的 LDA 方法，其独特之处在于：文档生成过程能够从统计学视角被有效建模。人工标注的依赖性被显著降低，文本中蕴含的语义规律依然可被发现。实例表明，这一特性使得 LDA 在无监督学习场景中展现出明显优势。

LDA 模型构建在三层结构之上：文档层（Document Layer）、主题层（Topic Layer）

和词汇层（Word Layer）。模型假设：每个文档是由多个主题混合生成，而每个词是由某个主题从词汇表中抽取得到的。整个建模过程忽略了词语在文档中的顺序（即“词袋模型”假设），因此词与词之间被视为独立同分布的可交换单元。

设语料库中包含 M 篇文档，每篇文档记作 $\mathbf{d}_m$ ，其中包含 N_m 个单词。LDA 模型对整个文本语料的建模过程可以分为如下几个步骤：

对于每一个主题（共 K 个主题），从一个以参数 β 为超参数的 Dirichlet（狄利克雷）先验分布中，采样得到一个该主题对应的词汇分布（记作 ϕ_k ），这表示每个主题下各个词出现的概率。

对于每一篇文档（共 M 篇）：从参数为 α 的 Dirichlet 分布中，采样得到该文档的主题分布（记作 θ_m ），也就是说每个文档中各个主题出现的概率。对于该文档中每一个单词位置（共 N_m 个）：根据文档的主题分布 θ_m ，从中随机选择一个主题（记作 $z_{m,n}$ ），即确定该位置的词是由哪个主题生成的；然后再根据这个主题对应的词分布 ϕ_k ，从词汇表中抽取一个具体的词（记作 $w_{m,n}$ ），作为这个位置的输出词。

该生成过程的贝叶斯网络结构如图 3-1 所示，其中 θ_m 、 $z_{m,n}$ 和 ϕ_k 是潜在随机变量， α 和 β 是给定的超参数。




图 3-1 LDA 模型贝叶斯网络结构图

Fig. 3-1 Bayesian network structure diagram of LDA model

文档生成的联合概率分布如公式 3-2 所示：

$$p(w, z, \theta, \phi | \alpha, \beta) \prod_{k=1}^K p(\phi_k | \beta) \prod_{m=1}^M p(\theta_m | \alpha) \prod_{n=1}^{N_m} p(z_{m,n} | \theta_m) p(w_{m,n} | \phi_{z_{m,n}}) \quad (3-2)$$

其中 w 表示所有词语的集合， z 为主题指派变量集合。通过对主题分布 θ 和词分布 ϕ 积分，并对主题指派变量求和，可得文档的边际似然函数如公式 3-3 所示：

$$p(w_m|\alpha, \beta) = \iint p(\theta_m|\alpha)p(\Phi|\beta) \cdot \prod_{n=1}^{N_m} p(w_{m,n}|\theta_m, \Phi) d\phi d_m \dots \text{式 (3-3)}$$

整篇语料库的似然函数如公式 3-4 所示:

$$p(D|\alpha, \beta) = \prod_{m=1}^M p(w_m|\alpha, \beta) \dots \text{式 (3-4)}$$

由于上述边际似然函数中包含对高维隐变量的积分与求和, 直接计算是不可行的, 因此需借助如变分推断 (Variational Inference) 或吉布斯采样 (Gibbs Sampling) 等近似推断方法进行参数估计和主题推断。

LDA 利用词频分布的协同统计特性, 捕捉文档间的语义共性, 从而实现对语料的无监督语义建模。其无序化建模方式虽然简化了建模过程, 但在大规模文本处理、主题可解释性以及与其他模型融合方面展现出强大能力, 是自然语言处理与推荐系统领域中的基础模型之一。

3.3.3 注意力机制原理

注意力机制是一种基于内容匹配的动态权重分配策略, 用于提升模型在处理长序列时对关键信息的建模能力。该机制通过计算输入序列中各部分对当前任务的相关性, 自动聚焦于最重要的内容部分, 最终形成一个加权组合的上下文表示。其基本思想是对不同的信息赋予不同的重要性。

注意力机制的计算过程可以概括为以下几个步骤: 首先, 将输入序列中的每个元素通过线性变换分别映射为三个向量: 查询向量 (Query) 表示当前关注的目标; 键向量 (Key) 表示输入序列中候选信息的特征; 值向量 (Value) 表示具体的语义表示。对于一个输入序列中的每个位置, 设查询向量为 q , 键向量为 k , 值向量为 v , 注意力机制首先计算查询与各键之间的相似度得分如公式 3-5 所示:

$$score = q \times k^T \dots \text{式 (3-5)}$$

为了防止得分值过大, 影响梯度稳定性, 通常会引入缩放因子, 最终的打分公式如公式 3-6 所示:

$$score = (q \times k^T) / \sqrt{d_k} \dots \text{式 (3-6)}$$

其中, d_k 表示键向量的维度。将所有得分经过 Softmax 函数归一化, 得到注意力权重向量如公式 3-7 所示:

$$\alpha = \text{Softmax}(score) \dots \text{式 (3-7)}$$

然后将权重与对应的值向量相乘并求和, 得到该位置最终的注意力输出结果如公式 3-8 所示:

$$\text{Attention}(q, K, V) = \sum \alpha_i \times v_i \dots \text{式 (3-8)}$$

其中, K 表示所有键向量的集合, V 表示所有值向量的集合, α_i 表示第 i 个位置的注意力权重。整个计算过程可以简写为矩阵形式如公式 3-9 所示:

$$\text{Attention}(Q, K, V) = \text{Softmax}(QK^t / \sqrt{d_k}) \times V \dots \text{式 (3-9)}$$

其中 Q 、 K 、 V 分别表示查询、键和值的矩阵形式。

3.3.4 改进的增强主题模型

LDA 是一种经典的无监督主题建模方法,能够将文档表示为若干潜在主题的概率分布。然而,传统 LDA 模型存在以下几个明显的不足之处:

主题分布完全由词袋生成: LDA 依赖词袋 (Bag-of-Words) 模型,忽略了文档之间的上下文结构与外部特征信息。主题生成缺乏“语境感知能力”: 同一个词在不同上下文中的语义可能不同,而 LDA 模型为每个主题学习一个固定的词分布,难以动态调整。静态先验限制模型表达能力: LDA 中主题分布的先验由固定 Dirichlet 参数控制,这种静态结构无法体现文档之间的个性差异与语义复杂性。在推荐系统或语义建模中,通常还拥有额外的元信息,如用户行为、文档的 TF-IDF 向量、上下文特征等,但传统 LDA 模型无法有效利用这些信息以引导更精细的主题建模。

为克服上述不足,本文引入注意力机制,提出一种注意力增强主题模型 (Attention-enhanced LDA, 简称 A-LDA), 其核心思想是用神经网络自动学习文档特征对主题分布的调节作用,从而实现上下文感知的主题建模。与传统 LDA 不同, A-LDA 模型在文档层 (即主题分布的生成过程 θ_m) 对结构进行了改进。传统 LDA 假设每篇文档的主题分布 θ_m 来源于 Dirichlet 分布,其生成过程是静态的,无法根据文档上下文进行动态调整。为此, A-LDA 模型引入一个注意力神经网络,以文档元特征 (如 TF-IDF、行为嵌入等) 为输入,生成一个文档特有的注意力权重向量 a_m ,用以调节 LDA 推断出的主题分布 θ_m 。得到文档最终的主题表示如公式 3-10 所示:

$$\hat{\theta}_m = \text{Normalize}(\theta_m \odot a_m) \dots\dots\dots \text{式 (3-10)}$$

其中,“ $\odot$ ”表示逐元素乘法, *Normalize* 表示对结果向量进行归一化处理,使其和为 1,确保其为合法的概率分布。

在原有文档生成联合概率建模公式的基础上,本研究将 $p(\theta_m|\alpha)$ 这一部分替换为基于注意力的确定性生成过程,如公式 3-11 所示:

$$\theta_m = f_attn(x_m) \dots\dots\dots \text{式 (3-11)}$$

其中, f_attn 表示注意力神经网络函数。因此, A-LDA 的文档生成联合概率如公式 3-12 所示:

$$p(w, z, \theta, \phi | \alpha, \beta) \prod_{k=1}^K p(\phi_k | \beta) \prod_{m=1}^M \delta(\theta_m = f_attn(x_m)) \prod_{n=1}^{N_m} p(z_{m,n} | \theta_m) p(w_{m,n} | \phi_{z_{m,n}}) \dots\dots\dots \text{式 (3-12)}$$

其中 δ 表示确定性赋值函数。A-LDA 用一个可学习的注意力网络生成替代原先的 Dirichlet 先验,使文档主题分布能够根据语义上下文与特征进行差异化调节。这种上下文感知建模方式不仅增强了 LDA 模型的表达能力,还显著提升了其在个性化推荐与语义建模任务中的表现,尤其适用于场景信息丰富或文档差异显著的应用环境。

A-LDA 模型贝叶斯网络结构图如图 3-2 所示。




图 3-2 A-LDA 模型贝叶斯网络结构图

Fig. 3-2 Bayesian network structure diagram of A-LDA model

3.3.5 A-LDA 特征提取

为了有效地提取歌词文本中蕴含的语义信息，本文采用了改进的增强主题模型 A-LDA 方法。A-LDA 是一种基于概率的文本建模技术，它假设每首歌词都是由若干主题共同构成，每一个主题会由一些词语组成，而 A-LDA 会通过每个文档中的词语分布，从而推断后文档的主题分布。将用户从文档维度降低到主题维度，

在推荐过程中，可以利用用户所听歌曲的主题维度，从而捕捉用户的主题兴趣偏好，为用户画像构建提供帮助。比如，用户的收藏行为或播放行为富含的歌曲信息，可以用来进行主题建模，得到歌曲的主题维度之后，再对用户进行个性化的推荐，从而大大提高推荐的相关性和一致性。

在应用中，首先要对用户收听过的歌曲的歌词进行预处理，去除一些噪声词和无意义词，方便提取语义信息，然后通过 A-LDA 来推断主题-词语分布和文档-主题分布，其中 A-LDA 在训练过程的好坏容易收到歌曲的歌词质量，预先设定的主题数量和文档的长度等因素影响，所以在训练过程中要不断通过反馈提高参数来增强模型的主题识别能力。

以下采用几首歌的歌词举例，来说明模型训练后的效果。设定歌曲的主题数为 3，每首歌的主题分布如表 3-2 所示。

表 3-2 A-LDA 主题概率分布表

Table 3-2 A-LDA Topic Probability Distribution Table

歌曲 ID	歌词片段	主题 1 (爱情)	主题 2 (梦想)	主题 3 (自然)
Song 1	"love love the dream"	0.60	0.30	0.10
Song 2	"dream in the night sky"	0.15	0.70	0.15
Song 3	"love the way you smile"	0.80	0.10	0.10

3.3.6 双通道文本特征提取方法

单一的文本特征方法往往难以充分刻画歌词文本中所蕴含的丰富语义信息。尤其是在歌词中，大量存在比喻、情感倾向、抽象表达等复杂语言结构，传统的浅层统计特征（如词频或 TF-IDF）虽然能够反映某些词语的重要性，但无法建模文本的潜在主题结构。因此，本文提出一种结合 TF-IDF 与 A-LDA 双通道的文本特征提取方法，旨在实现更深层次的文本主题建模。

其中，TF-IDF 主要用于捕捉词语在文档中的局部权重与在语料中的全局稀缺度，能够有效衡量词语在当前文本中的代表性；而 A-LDA 则通过引入文档特征驱动的注意力机制，挖掘文本中潜在的主题结构，生成上下文感知的主题分布，从而刻画词语在不同语义场景中的主题贡献。通过将 TF-IDF 提取的词频重要性与 A-LDA 推断出的主题权重进行融合，能够得到一组经过语义加权的主题特征，更加准确地区分不同主题在文本中的表达强度与语义倾向。

本文设计了一种混合融合策略：将歌词文本分别输入 TF-IDF 和 A-LDA 模型中，提取其对应的词频特征和主题特征，并将两者作为连续数值特征联合输入推荐模型中。在模型架构中，融合特征分别通过因子分解机（FM）部分与深度神经网络（DNN）部分进行联合学习。FM 结构能够高效建模特征之间的二阶组合关系，挖掘 TF-IDF 与主题特征之间的隐式交互；而 DNN 结构则进一步学习高阶非线性组合关系，从而捕捉更复杂的语义结构与上下文依赖。

虽然 TF-IDF 与 A-LDA 特征在输入层是采用双通道处理，但是 FM 与 DNN 的结构设计使得模型可以在训练过程中自动学习不同特征在预测任务中的贡献程度。FM 模块通过内积建模任意两类特征间的交互项，例如某些高权重的关键词（TF-IDF 特征）与某些主题（A-LDA 特征）之间是否频繁共同出现，是否对用户的点击行为产生显著影响，从而能够捕捉 TF-IDF 与 LDA 特征之间潜在的协同关系或冗余信息；而 DNN 将 TF-IDF 和 A-LDA 特征分别映射为嵌入向量后拼接输入，通过多层非线性网络自动学习它们之间更高阶、更复杂的组合关系。例如，DNN 可以建模“某个主题+某类高频词+某类上下文”组合对用户偏好的非线性影响，这种表达能力是传统点积难以捕捉的。DNN 模块通过非线性激活函数与层间连接进一步抽取高阶组合语义。

这种设计允许模型在联合训练中自动调整各特征的表示权重，实现隐式的特征选择和重要性建模。

这种融合策略可提升模型对于歌词语义的理解能力，还达成了多模态特征的有效协同，为下游推荐任务给予了更丰富且更具判别性的高质量输入表示，最终构建而成的特征空间，在主题表达能力以及上下文建模能力方面，都比单一特征方案更具优势，融合特征的模型结构如图 3-3 所示，完整地呈现了各模块之间的交互过程以及其在语义学习中的协同机制。




图 3-3 融合特征结构示意图

Fig. 3-3 Schematic Diagram of the Fusion Feature Structure

3.4 基于时间加权与文本特征的融合模型构建

本节在前文提取的 TF-IDF 与 A-LDA 双通道文本特征基础上，设计了一种基于时间衰减函数的主题特征加权方法，旨在建模用户兴趣随时间演化的动态特征。通过引入时间加权机制调整不同时间段交互行为对推荐结果的影响，使模型更加关注用户的近期兴趣倾向，同时兼顾其长期稳定偏好。随后，本文将该加权特征与 DeepFM 模型进行融合，构建具备时效性与语义理解能力的融合推荐模型，并进一步通过模型优化策略提升性能表现。以下将从时间加权机制设计、融合模型构建、及其优化策略几个方面展开。

3.4.1 时间加权机制设计

时间加权机制是指在推荐系统中根据用户行为发生的时间信息，对用户—物品交互赋予不同的权重，以反映时间对用户兴趣偏好的影响^[91]。该策略假设用户的兴趣具有时效性，即较新的行为更能代表当前偏好，而较早的行为对推荐的指导意义逐渐减

弱。如果用户最近频繁播放某一类型的歌曲，那么此类歌曲极有可能再次推荐给用户，而用户以往播放的歌曲，会降低推荐的比例。这个动态调整机制可以使模型更容易捕获用户的动态偏好，而非一成不变的保有固定的兴趣爱好。通过将时间加权到文本主题信息中，推荐模型可以更容易捕获到歌词中潜藏用户主题兴趣爱好，并同时获得时间维度上兴趣偏好，提升了推荐的准确性和实时性。

指数衰减函数以其数学表达简单且在生物学及行为科学中广泛验证的合理性，被广泛应用于推荐系统中处理用户兴趣时间衰减的主流方法。相比其他复杂的时间建模方法（如基于时间窗口的滑动平均、多尺度时间卷积或强化学习方法），指数衰减函数无需额外参数调优，计算开销低，易于与现有模型集成，且能直观地反映行为的重要性随时间的递减特征。研究表明，在本研究所用数据集上，指数衰减函数能够有效提升模型对用户动态兴趣的捕捉能力，增强推荐的时效性和准确度，因此被选为时间加权机制的核心方法。其计算公式如式 3-13 所示：

$$w(t) = 2^{-\frac{\Delta t}{h}} \dots \dots \dots \text{式 (3-13)}$$

其中， Δt 为时间差， h 为半衰期，控制衰减速度。指数衰减函数的核心思想是，随着时间差的不断增加，用户历史兴趣的权重比例呈现指数级下降，这能够使得模型更加关注用户的近期行为。有效提高推荐的时效性，但是时间加权策略也存在一定的局限性。如果太过强调近期的主题兴趣，从而忽视了用户长期持有的兴趣，可能会使得部分信息缺失，推荐结果偏向于临时兴趣^[92]。例如，用户长期喜好某一主题，但是最近突然想要改变一下风格，这时模型可能会认为以往的兴趣用户不再喜好，从而不再进行推荐。所以时间加权策略往往需要在动态性和稳定性之间寻找一个平衡点。本研究经过实验验证，通过调整半衰期的参数，可以使得模型同时兼顾长期兴趣和近期偏好。

3.4.2 文本主题特征的时间加权方法

为了增强模型对用户兴趣动态变化的建模能力，本文在双通道文本特征（TF-IDF 与 A-LDA）的基础上引入时间加权机制，对每条交互行为的文本特征进行时间衰减处理。该机制可以提高模型对于近期偏好的响应能力，也可兼顾到用户长期稳定的兴趣。计算过程如下：先统计每个用户的最近交互时间，接着计算每条交互记录和最近交互时间之间的时间差 Δt ，随后应用指数衰减函数生成时间权重 `time_weights`，计算得出的权重会经过归一化处理，以此保证数值范围处于合理区间之内。

随后，将时间权重分别与 TF-IDF 和 LDA 特征相乘，生成加权后的特征向量，其计算公式如式 3-14、3-15 所示：

$$TFIDF_features_weighted = TFIDF_adjusted \times time_weights \dots \text{式 (3-14)}$$

$$EnhancedLDA_weighted = LDA_features \times time_weights \dots \text{式 (3-15)}$$

其中，`TFIDF_adjusted` 和 `LDA_features` 分别是降维后的 TF-IDF 和 LDA 特征向量，

time_weights 为时间权重。通过引入时间权重，近期交互的歌词主题特征在推荐中占据更大比重，从而提升推荐结果的时效性。这种加权策略能够有效缓解长期历史数据对当前推荐的干扰，使推荐系统更贴近用户当前的音乐主题偏好。

时间加权不仅提升了推荐系统的时效性，还在以下几个方面发挥了重要作用：首先，时间加权能够动态调整特征的贡献比例，使模型更关注用户近期的兴趣倾向，例如用户近期因情感变化更倾向于抒情歌曲，而较早期的摇滚风格偏好则被适当削弱；其次，时间加权通过指数衰减的方式保留了长期交互数据的部分信息，避免完全忽略用户的历史偏好，从而在推荐中保持一定的多样性；最后，时间加权增强了模型对用户兴趣变化的适应能力，例如用户因近期生活事件临时偏好与“自然”主题相关的歌曲，加权后的特征能够快速反映这一变化，使推荐结果更具相关性。表 3-3 展示了在不同时间差下，文本特征（TF-IDF 与 A-LDA）在加权前后的向量变化情况，可观察到时间差越大，特征权重衰减越明显，从而体现了时间加权策略对近期偏好的强化能力。

表 3-3 时间加权前后特征向量对比

Table 3-3 Comparison of Feature Vectors Before and After Time Weighting

歌曲 ID	时间差 (Δt , 天)	时间权重 ($w(t)$)	特征类型	加权前特征向量(前 3 维)	加权后特征向量(前 3 维)
Song 1	5	0.953	TF-IDF	[0.50, 0.30, 0.20]	[0.477, 0.286, 0.191]
Song 1	5	0.953	A-LDA	[0.60, 0.30, 0.10]	[0.572, 0.286, 0.095]
Song 2	60	0.500	TF-IDF	[0.15, 0.70, 0.15]	[0.075, 0.350, 0.075]
Song 2	60	0.500	A-LDA	[0.20, 0.70, 0.10]	[0.100, 0.350, 0.050]
Song 3	120	0.250	TF-IDF	[0.80, 0.10, 0.10]	[0.200, 0.025, 0.025]
Song 3	120	0.250	A-LDA	[0.80, 0.10, 0.10]	[0.200, 0.025, 0.025]

3.4.3 融合模型训练与优化策略

在时间加权的文本特征基础上，本文将加权后的 TF-IDF 与 A-LDA 特征，与用户 ID、音乐 ID 等行为建模相关特征共同输入 DeepFM 模型，进行联合建模。模型输入包括两类特征：离散特征主要包括用户 ID 和音乐 ID，通过嵌入层转换为低维稠密向量；连续特征包括经过时间加权处理的 TF-IDF 和 A-LDA 文本主题向量，反映用户在不同时间点的内容偏好。模型结构包含 FM 和 DNN 两个核心部分：FM 部分通过二阶交互项学习低阶特征交叉信息，捕捉特征之间的线性关系；DNN 部分通过多层全连接网络学习高阶非线性关系，挖掘特征之间的复杂交互模式。两部分共享输入特征层，通过联合训练实现整体优化。总体模型结构图如图 3-4 所示。




图 3-4 DeepFM-T-A-LDA-T 模型结构图

Fig. 3-4 DeepFM-T-A-LDA-T Model Structure Diagram

为了提升模型性能，在模型的训练过程中本文引入了几种优化策略。DeepFM-T-A-LDA-T 模型训练过程如图 3-5 所示。




图 3-5 DeepFM-T-A-LDA-T 模型训练流程图

Fig. 3-5 Training Flowchart of the DeepFM-T-A-LDA-T Model

针对正负样本不平衡的问题,使用类别权重进行加权训练,从而提升模型对正类的识别能力。同时采用 Adam 优化器和二元交叉熵损失函数来对模型进行优化,确保模型收敛的稳定性和效率。为了防止模型过拟合,在训练过程中加入了早停策略,当验证集损失在多轮训练后不再下降时,模型会自动终止训练。还加入了正则化项和 dropout 机制来提升模型的泛化能力,以控制参数复杂度并减少对训练数据的过拟合。

3.5 本章小结

本章围绕提升音乐推荐系统的语义理解能力与时间敏感性,提出了一种融合文本主题建模与时间加权机制的推荐模型框架。

在训练样本构建阶段,基于用户—歌曲播放行为构建了包含正负样本的训练集,并提取标准化时间间隔与时间衰减权重,为后续时间加权的动态兴趣建模提供了数据支撑。歌词文本则经过标准化预处理,包括分词、去噪、格式统一与词形还原,确保后续特征提取的准确性与一致性。

在文本建模方面,提出了结合 TF-IDF 和增强主题模型 A-LDA 的双通道文本主题特征提取方法,分别从词频和主题语义两个维度刻画文本信息。特别是基于注意力机制改进 LDA 模型,强化了主题分布对重要词语的关注能力。通过双通道融合,实现了多层次、多粒度的文本语义表示,有效缓解了文本数据稀疏性问题。

在时间建模方面,设计了基于指数衰减函数的时间加权机制,该机制可引导为不同时间点的文本主题向量赋予动态权重,以此重点捕捉用户近期主题兴趣的变化走向,基于上述机制,成功构建了融合时间加权特征与文本主题特征的 DeepFM 推荐模型,此模型在统一框架内达成了离散 ID 特征与连续文本特征的联合建模。该模型借助 FM 模块捕捉低阶交互,运用 DNN 模块挖掘高阶非线性交互,并且结合类权重调整、正则化及早停策略,有效提升了模型的训练效果与泛化能力。

综上所述,本章系统提出并实现了基于双通道文本主题特征提取和时间加权机制引导的加权建模方法,为后续章节个性化推荐效果的实验验证提供了坚实的理论与技术支持。

4 实验设计与结果分析

4.1 实验环境与数据集说明

本章主要围绕本研究提出的基于多特征融合的音乐推荐模型展开实验设计与结果分析。为全面验证模型的有效性，在 LastFM-1K 与 30Music 数据集上进行了大量实验及交叉验证，并采用多种评价指标对各模型的性能进行了综合评估。整个实验过程涵盖了实验平台、数据预处理、数据划分、模型训练、超参数调优，以及基于离线指标的性能评估、消融实验以及参数敏感性分析。以下将从实验环境与数据集说明、实验设计基础、实验设计与实现、结果分析与讨论四个部分，详细介绍本章的所有内容。

本研究所有实验均在个人笔记本上完成。笔记本配置为 4 核 Intel®Core™i5-7300HQ CPU@2.50GHz 处理器，内存 16GB，采用 NVIDIA GeForce GTX 1050 独立显卡，运行 Windows10 操作系统。实验主要使用 Python3.7.6 语言进行开发，所依赖的主要第三方库包括 TensorFlow 2.6.0、Keras 2.4.3、gensim 3.8.3、scikit-learn 0.24.1、pandas 1.1.5 与 numpy 1.19.5 以及 joblib 1.0.1。环境配置如表 4-1 所示。

表 4-1 实验环境配置表

Table 4-1 Experimental Environment Configuration Table

配置类型	详细信息
笔记本电脑	惠普暗影精灵 2
操作系统	Windows 10（64 位）
处理器	Intel®Core™i5-7300HQ CPU@2.50GHz
内存（RAM）	双 8G
运行环境	Python3.7.6
代码编辑器	PyCharm2022.2 社区版

（1）Lastfm-1K 数据集

LastFM-1K 数据集最初包含 992 名用户的约 1900 万条音乐播放记录，每条记录包括用户 ID、时间戳、音乐 ID、音乐名称、艺术家信息以及部分歌词数据。记录了用户在一段连续时间内的收听记录，同时包含用户收听时间的时间戳信息，为本研究捕捉用户的序列信息变化提供了便捷。具体的关于 LastFM-1k 数据集的部分数据展示如表 4-2 所示。

表 4-2 Lastfm-1k 数据集部分展示

Table 4-2 Excerpt from the Lastfm-1k Dataset

用户 ID	歌曲 ID	歌曲名称	艺术家 ID	艺术家名称	时间戳
user_000001	fb51d2c4-cc69-4128-9	Planetary	ad0811ea-e21 3-451d-b22f-f	Beanfield	2009-05-03T
	2f5-77ec38d66859	Deadlock	a1a7f9e02269		15:04:31Z
user_000033	509efd09-6f93-4f6f-be	If I Were	8 a9965383-6bd	Stephen Lynch	2006-10-01T
	ba-914eb14f6d46	Gay (Live)	d-49a3-a4bb- 4f8008b9d80e		17:36:42Z
user_000135	aa1ad9d8-3f1f-4e8d-80	London In	14bae8d6-39b d-48c9-818a-	Variety Lab	2007-09-26T
	76-304a148dc629	The Rain	4aed72d3b01		07:58:59Z
user_000250	ef9d7565-a912-4400-8f	Waiting	9 9efff43b-3b29	The Doors	2008-02-25T
	e0-d1f47d884c03	For The Sun	-4082-824e-b c82f646f93d		04:31:17Z

原始数据中部分歌曲的歌词数据缺失，且用户交互行为分布不均，需通过预处理进行筛选和清洗。数据预处理分为以下步骤：

1.格式转换与清洗：将时间戳字段转换为标准日期时间格式，便于计算时间间隔；对用户 ID、音乐 ID、音乐名称和艺术家名称统一为小写格式，消除因大小写差异导致的噪声；

2.缺失值处理：剔除关键字段缺失的记录，并对歌词缺失的记录进行过滤；

3.用户和音乐过滤：基于交互频次统计，筛选交互歌曲数在 20 至 3000 之间的用户，并剔除低频音乐（少于 7 次交互），以减少噪声干扰；

4.歌词匹配与筛选：通过数据库匹配获取歌词数据，筛选出前 20%歌词匹配率最高的用户；

5.ID 映射：构建用户 ID 和音乐 ID 的映射字典 `user_map` 和 `music_map`，将原始字符串 ID 转换为连续数值索引，便于嵌入层处理；

6.时间特征提取：利用时间戳信息，计算用户交互的时间间隔，为后续时间加权策略提供支持。

经过预处理和筛选，最终数据集包含 106 名用户，15331 个唯一音乐 ID，2398 个唯一艺术家 ID，总样本数量为 222768 条记录。数据分析显示，用户交互行为具有显著稀疏性：平均每位用户交互约 2159 次，但分布呈现长尾效应，少数活跃用户贡献了大部分记录。这种稀疏性和长尾分布对推荐系统的建模提出了挑战，同时也验证

了引入文本特征和时间加权策略的必要性。数据经过筛选后的用户交互分布图如图 4-1 所示。




图 4-1 筛选后用户交互分布图

Fig. 4-1 Distribution of User Interactions After Filtering

(2) 30Music 数据集

30Music 数据集是由荷兰代尔夫特理工大学（TU Delft）与 SoundCloud 合作构建的一个大规模音乐推荐研究数据集，用于个性化推荐和用户行为建模，能够很好的完成此次实验任务。30Music 同时具有实体信息和交互信息，实体信息包含歌曲信息、艺术家信息、标签信息等，交互信息有用户收听信息，用户会话信息等，本次实验以 30Music 作为对比，旨在验证模型在多个数据集的有效性，因此采用数据集中的歌曲信息、艺术家信息和用户收听信息三个数据文件。其中部分数据如表 4-3 歌曲部分信息展示、表 4-4 艺术家信息部分展示、表 4-5 用户收听信息部分展示所示。

表 4-3 30Music 数据集-歌曲信息部分展示

Table 4-3 Partial Display of Track Information in the 30Music Dataset

歌曲 ID	歌曲名称	播放次数	艺术家 ID	艺术家名称
1	Californication	16	290797	Red Hot Chili Peppers
2	To The Threshold	21	428614	Hatebreed
3	Robin Hood	59	133844	Edguy
4	Born in a Burial Gown	61	414808	Cradle of Filth

歌曲信息表中存储了歌曲的所有元数据信息，包括歌曲 ID、歌曲名称、歌曲的总播放次数、艺术家 ID、艺术家名称等歌曲相关信息。

表 4-4 30Music 数据集-艺术家信息部分展示

Table 4-4 Partial Display of Artist Information in the 30Music Dataset

艺术家 ID	艺术家名称	MBID
187320	Koota Tanimura	5886a9b8-54ff-4818-80c1-25b3b85ba5cf
103135	Danny Overbea	d4bb4ce4-5439-49a3-bda6-10e8c6f61932
114070	Dimebag Darrell	bded4d70-f13f-41ec-86b9-8c4514086acf
119391	Doi Oing	cb6d3300-405a-49b2-8fad-bd36c91bee05
173291	G Spliff	9928a9c4-285b-4c37-b7f8-001bf03df97c

艺术家信息表中存储了艺术家的所有元数据信息，包括艺术家 ID、艺术家名称、以及艺术家在 MSD 上的唯一标识 MBID 等歌曲相关信息。

表 4-5 30Music 数据集-用户收听信息部分展示

Table 4-5 Partial Display of User Listening Information in the 30Music Dataset

事件 ID	用户 ID	歌曲 ID	播放时长	收听时间戳
1	41504	3351207	176	1405079768
2	41550	3351181	181	1405079944
3	41519	3351149	149	1405080125
4	41560	3351170	290	1405080273
5	41579	3351246	223	1405080497

用户收听信息表中存储了用户关于歌曲的收听记录，详细记录了收听的歌曲内容和收听时间，包括事件 ID、用户 ID、歌曲 ID、用户对当前歌曲的收听时长、用户收听的时间戳信息等，满足本研究使用时间信息构建用户行为序列的基本要求。

30Music 数据集的初始数据需要处理后才能够继续使用，需要对数据进行以下步骤的处理以满足实验的数据要求：

1. 关联收听信息

原始的用户收听行为数据仅包含了歌曲的 ID 信息，缺乏可用于建模的语义与上下文属性。为补全缺失的信息，本研究首先通过将收听日志中的歌曲 ID 与歌曲信息表进行关联，提取出歌曲的元数据信息，例如歌曲名称、艺术家 ID 及所属专辑等。获得艺术家 ID 之后，进一步与艺术家信息表进行连接，获取对应艺术家的

MusicBrainzID（MBID），该标识在多个音乐数据平台中具有通用性，有助于后续跨数据源的融合操作。通过此步骤，可以为每一条收听事件补全音乐作品的基础描述信息，从而为内容特征建模提供丰富的数据基础。

2.关联歌词信息

由于 30Music 数据集中不包含歌词字段，本研究借助百万歌曲歌词数据集（Million Song Dataset with MXM Lyrics）对其进行内容信息补充。具体实现流程如下：首先，利用前述关联得到的艺术家 MBID 作为关键索引，在 track_metadata 数据库中查询匹配的 artist_mbid 字段，锁定对应歌曲的艺术家记录；随后，基于歌曲名称进行模糊匹配，以容忍因字符编码、符号差异或版本命名造成的微小差异，从而获取每首歌的唯一标识 track_id；最后，依据 track_id 在 mxm_dataset 歌词数据库中检索相应的歌词内容，并将结果合并回主数据表中。这样实现了结构化用户行为数据与非结构化歌词文本的有效融合，为后续文本特征建模提供了必要的输入条件。

3.数据预处理

完成数据融合工作后，合并而成的数据集中出现了部分字段信息缺失以及格式不一致的状况。为保障后续建模过程能稳定且有效开展，本研究针对数据集执行了一套系统化的预处理流程。先是对所有字段展开缺失值处理，把歌词、艺术家或者时间信息缺失的样本给予剔除，以此防止模型训练阶段因异常数据而产生误导。接着为避免稀疏行为干扰模型效果，将交互次数少于 3 次的用户或歌曲记录过滤掉，提升数据质量并减少噪声。处理后的示例数据如表 4-6 所示。

表 4-6 30Music 数据集预处理后信息部分展示

Table 4-6 Partial Display of the 30Music Dataset After Preprocessing

用户 ID	歌曲 ID	歌曲名称	艺术家 ID	收听时间戳	歌词
40265	2327503	Californication	290797	2014/2/16	{love want babi away look look look...} {know want
40359	1599725	Breaking the Habit	201108	2014/10/29	want way way...} {away eye tell
40842	1069356	My Blood	137881	2014/1/21 1	dream dream...} { away heart
45109	1629233	Incantation	204348	2014/3/15	night hand light...}

针对歌词字段，因其原始形式为“词项-频率”映射表，需进一步规范化为标准文本输入格式。在此过程中，采用正则表达式对词项进行清洗，统一大小写、去除非词语字符，并删除冗余的无效标记，保证输入结构的一致性。此外，对时间戳字段进行数据类型转换，将 Unix 时间格式解析为可读性强的 `datetime` 类型，以支持后续的时间感知建模。最终，剔除多余字段，仅保留用户 ID、歌曲 ID、歌曲名称、艺术家 ID、收听时间戳及歌词字段，构建出结构紧凑、内容丰富的数据子集，为特征工程与建模训练提供高质量输入。

经过数据处理后的 30Music 数据集可以作为有效数据集进行本次研究的改进实验，最终数据集包含 152 名用户，38892 个唯一音乐 ID，5349 个唯一艺术家 ID，总样本数量为 117208 条记录。但相比 Lastfm-1k 数据集而言，此数据集交互数据数量更小，中位值远低于上一数据集，因此本研究仍以 Lastfm-1k 为主，本数据集仅作为辅助参考，以证明模型的泛化能力。30Music 用户交互分布图如图 4-2 所示。




图 4-2 筛选后用户交互分布图

Fig. 4-2 Distribution of User Interactions After Filtering

4.2 实验设计基础

4.2.1 实验评价指标

为全面考量推荐系统性能，此次实验选取离线评价指标：AUC、NDCG@k、Precision@k、Recall@k 以及 F1@k，这些指标从分类能力、推荐精度、覆盖率以及排序质量等多个方面来评价模型，给后续对比分析奠定全面基础。k 值的选定依据实际推荐场景里推荐列表长度的常见设定，同时兼顾用户对 Top-k 推荐结果的关注程度，保证评估结果与实际应用场景相符。

AUC 衡量模型对正负样本的全局区分能力，适合本实验中的隐式反馈场景，能够稳定反映模型的整体排序性能。NDCG@k 关注 Top-k 推荐列表的排序质量，适合评估推荐系统对 Top-15 推荐结果的排序效果，与 AUC 形成互补，从局部和全局角度共同评估模型性能。Precision@k 和 Recall@k 分别反映推荐的准确性和覆盖率，F1@k

综合二者表现, 适合平衡推荐的精度和全面性。这些指标共同构成了本实验的评价体系, 能够全面反映模型在不同维度的表现, 为后续模型对比提供可靠依据。

在音乐推荐这种个性化服务里, “多样性” “新颖性” 以及 “惊喜度” 等指标也是衡量用户体验的关键要素, 对提升系统的吸引力和可持续使用性有帮助, 不过由于本研究着重于结合文本主题和时间加权机制来进行推荐精度的建模与分析, 当前评估体系主要关注准确性和排序性能。未来工作会纳入上述用户体验指标, 更全面地呈现推荐系统在实际场景中的综合价值。

4.2.2 实验流程

实验流程可分为五个主要阶段: 数据预处理、特征提取、模型训练、参数调优和离线评估。每个阶段的具体内容如下:

(1) 数据预处理

数据预处理阶段对 LastFM-1K 数据集进行清洗和规范化。删除不完整的记录, 确保每条记录包含用户 ID、音乐 ID 和时间戳等关键信息。处理缺失值, 采用适当的策略填补这些缺失值。将时间戳转换为标准日期时间格式, 并统一所有文本字段为小写, 去除标点符号和其他噪声字符。对歌词文本进行分词处理, 过滤掉停用词和无意义的语气词, 确保数据的质量和一致性。

(2) 特征提取阶段

根据不同模型的需求, 从数据集中提取相应特征。DeepFM 模型仅使用用户 ID 和音乐 ID 作为离散特征输入。TF-IDF 模型通过 TF-IDF 方法提取歌词文本的统计特征, 并通过降维技术简化这些特征。LDA 模型利用 LDA 主题模型提取歌词的主题特征, 反映歌曲的主题分布。LDA+TDF 模型在 LDA 特征基础上引入时间衰减因子, 突出近期交互的重要性。结合 LDA 和 TF-IDF 特征的 DeepFM 模型也引入时间衰减因子, 以捕捉用户动态偏好。

(3) 模型训练阶段

模型训练阶段根据选定的模型架构进行操作。离散特征用户 ID 和音乐 ID 通过嵌入层转换为低维稠密向量。连续特征 TF-IDF 和 LDA 特征以及时间加权特征直接输入深度网络。构建多层全连接层的深度神经网络, 用于捕捉特征间的高阶非线性关系。为防止过拟合, 引入早停策略, 监控验证集损失, 确保模型不过度拟合。针对正负样本不平衡问题, 采用负采样或调整正负样本权重的方法, 提升模型的判别能力。同时, 为增强模型评估的稳定性与泛化能力, 训练过程中引入 5 折交叉验证策略, 从而获取更具鲁棒性的性能指标评估结果。

(4) 参数调优

参数调优是为了找到模型的最优参数, 通过设置不同的实验来验证各个参数对模型的实验数据所造成的影响。本研究采用多个不同的主题数来寻找综合指标达到最优的最佳主题数, 同时对时间衰减因此, 通过实验确定最佳半衰期值。整个调优过程通

过系统性实验完成，确保模型性能达到最优。

（5）离线评估

离线评估阶段使用了多种评价指标来量化推荐系统的性能。包括 AUC、Precision@k、Recall@k、F1@k 和 NDCG@k，用来评估推荐列表 Top-k 的质量。通过这些指标全面的评估模型在推荐准确性和排序质量方面的表现，验证模型的有效性。

4.2.3 数据划分策略

训练过程中采用基于时间划分的 5 折交叉验证策略，与传统的随机划分 5 折交叉验证不同。根据数据的时间戳，将数据集按时间顺序划分为五个连续的互斥子集，每一子集包含按时间排序的用户一项目交互记录。交叉验证的五折划分采用前向累积方式，在每一折中，验证集始终为时间上晚于训练集的数据，严格确保训练集不得包含未来时间点的交互记录，以防止“时间穿越”。这种基于时间划分的前向累积策略能够真实模拟推荐系统在实际场景中基于历史数据预测未来交互的任务，反映模型在动态时序环境中的预测能力。通过对五折验证结果取平均值，获得更具鲁棒性的性能指标，有效降低因时间分布差异导致的评估偏差，提升模型在未知数据上的泛化性能。

4.3 实验设计与实现

为了评估改进模型的性能，本研究实现了三种深度学习推荐模型作为对比基准：NCF、NeuMF、SASRec 和 CoseRec 模型。同时设计了基于 DeepFM 的多种变体模型，逐步引入文本特征和时间加权策略，验证多特征融合对推荐效果的提升作用。以下分别介绍各模型的实验设计与实现。

4.3.1 对比实验：NCF、NeuMF、SASRec 和 CoseRec 的推荐性能

（1）NCF 模型

NCF 融合矩阵分解和神经网络，旨在捕捉用户-音乐交互的非线性关系。实验基于训练集构建用户-音乐交互矩阵，输入为正负样本对。模型包含两个分支：GMF 通过嵌入层计算用户和音乐的点积，模拟低阶交互；MLP 将嵌入向量拼接后输入两层全连接网络，学习高阶非线性特征。两分支输出经拼接后，送入 sigmoid 层预测偏好概率。训练采用交叉熵损失函数，优化器为 Adam，初始学习率设为 0.001，批量大小为 512。为处理正负样本不平衡，引入类权重调整，正样本权重为负样本的 5 倍。为防止过拟合，引入 L2 正则化和早停策略。嵌入维度和网络结构通过初步调优确定，确保模型在稀疏数据上的收敛性。NCF 的设计兼顾线性分解和非线性学习，为深度模型提供了基准。

（2）NeuMF 模型

NeuMF 是 NCF 的增强版本，通过预训练 GMF 和 MLP 分支，进一步提升推荐性能。实验设置与 NCF 一致，输入为正负样本对，用户和音乐嵌入维度为 32。NeuMF 首先分别预训练 GMF 和 MLP 分支，然后将两分支的嵌入层参数初始化后联合训练。GMF 分支计算用户和音乐嵌入的点积，MLP 分支通过两层全连接网络学习高阶特征。

两分支输出拼接后, 通过一个全连接层融合, 最终经 sigmoid 层预测偏好概率。训练采用交叉熵损失, 优化器为 Adam, 学习率为 0.001, 批量大小为 512, 类权重调整为正样本权重 5 倍, L2 正则化系数为 0.01, 早停策略与 NCF 相同。NeuMF 通过预训练和联合训练结合了 GMF 和 MLP 的优势, 旨在提升推荐的准确性和排序能力。

(3) SASRec 模型

SASRec 是一种基于自注意力机制的序列推荐模型, 旨在捕捉用户交互序列中的长期依赖关系。实验中, 用户的历史交互序列通过嵌入层映射为 32 维向量, 输入 Transformer 模块。Transformer 包含两层自注意力模块, 每层后接前馈神经网络。自注意力机制通过计算序列中每个位置与其他位置的相关性, 动态捕捉交互依赖关系。模型输出取最后一个位置的表示, 经全连接层预测下一首音乐的偏好概率。训练采用交叉熵损失, 优化器为 Adam, 学习率为 0.001, 批量大小为 512, 早停策略与 NCF 相同。SASRec 专注于序列建模, 适合捕捉用户偏好的动态变化, 但在全局排序能力上可能受限。

(4) CoSeRec 模型

CoSeRec 是一种结合序列建模与对比学习的会话推荐模型, 旨在同时捕捉用户当前兴趣与长期偏好。实验设置基于时间划分的训练集构建用户-会话序列数据, 输入为用户的历史多个会话及当前目标会话。

模型由三个关键模块组成: 首先, 嵌入层将用户历史行为序列中的音乐项目映射为低维向量; GRU 编码器对当前会话序列建模, 生成反映即时偏好的会话表示; 同时, 聚合用户过去多个会话的表示, 得到其长期偏好向量, 通过拼接形成最终用户会话表示。

在训练目标方面, CoSeRec 引入 InfoNCE 对比损失作为自监督任务, 使用数据增强策略构造正负样本对, 提升会话表示的判别能力。同时结合推荐预测任务采用点积方式计算用户对候选音乐的偏好分数, 优化目标为推荐任务的交叉熵损失与对比学习损失的加权和。

实验中, 优化器采用 Adam, 初始学习率设为 0.001, 批量大小为 256, 嵌入维度设为 64。温度系数 τ 设为 0.07, 对比损失权重 λ 设置为 0.1, 所有超参数均通过网格搜索优化。为防止过拟合, 引入 Dropout、L2 正则化及 Early Stopping 策略。

CoSeRec 同时建模短期兴趣与长期偏好, 并利用对比学习增强表示学习, 在复杂场景下表现出更强的泛化能力, 成为本实验对比方法中唯一具备自监督特征的推荐模型。

对比实验旨在为改进模型提供性能基准, 验证深度学习模型在音乐推荐任务中的表现。NCF 和 NeuMF 侧重于用户-音乐交互的非线性建模, SASRec 则强调序列依赖关系的捕捉, CoseRec 强调自监督特征的混合推荐。四种模型的实现和参数设置保持一致, 确保对比的公平性。

4.3.2 改进实验：DeepFM 模型及其变体的实现

基于 DeepFM 的改进实验旨在验证多特征融合的效果，共设计五种模型，逐步融合不同特征模块：

- (1) 基础 DeepFM，仅使用用户 ID 和音乐 ID；
- (2) DeepFM+TFIDF，融合歌词的 TF-IDF 特征；
- (3) DeepFM+A-LDA，融合歌词的 A-LDA 特征；
- (4) DeepFM+A-LDA+TDF，结合时间加权的 A-LDA 特征；
- (5) DeepFM+TFIDF+A-LDA+TDF，融合歌词的 TF-IDF 和 A-LDA 特征，并加权时间信息。

所有模型共享相同的网络结构和超参数设置，以确保对比的公平性。实验基于预处理后的 LastFM-1K 数据集包含 106 名用户，15973 首音乐，228852 条样本，训练集为 183082 条记录，测试集为 45770 条记录。离散特征用户 ID 和音乐 ID 通过嵌入层映射为 32 维向量，连续特征 TF-IDF、A-LDA 和时间加权特征直接输入深度网络。FM 模块学习低阶特征交互，DNN 模块捕捉高阶非线性关系。训练采用交叉熵损失，优化器为 Adam，初始学习率为 0.001，批量大小为 512。为处理正负样本不平衡，引入类权重调整，正样本权重为负样本的 5 倍。训练过程中使用早停策略，若验证集损失连续 3 个 epoch 未下降则停止，确保模型收敛。以下分别介绍各模型的设计和实现：

(1) DeepFM 模型

作为对比基准，基础 DeepFM 仅利用离散特征用户 ID 和音乐 ID，不引入文本特征或时间加权。用户 ID 和音乐 ID 首先通过嵌入层转换为 32 维稠密向量，分别输入 FM 模块计算二阶交互和 DNN 模块提取高阶特征。模型训练基于预处理后的正负样本对，验证集用于监控训练过程，评估模型的初步性能。基础 DeepFM 依赖用户-音乐直接交互，旨在验证离散特征的基线效果。

(2) DeepFM 融合 TF-IDF 文本特征模型

在基础 DeepFM 上引入歌词的 TF-IDF 文本特征。歌词经过预处理后，使用 TF-IDF 向量化，最大词汇量为 500，生成高维特征向量，并通过 TruncatedSVD 降维至 10 维，消除量纲差异后作为连续特征输入深度网络，与离散特征共同参与特征交互。TF-IDF 特征通过词频-逆文档频率统计，捕捉歌词中的词级信息，增强模型对音乐内容表层属性的理解，弥补行为数据的语义不足。

(3) DeepFM 融合 A-LDA 主题特征模型

引入歌词的 A-LDA 主题特征，进一步挖掘文本的语义结构。A-LDA 模型通过训练生成 10 个主题，每首歌词映射为 10 维主题概率向量，反映其在不同主题上的分布权重，例如“抒情”或“摇滚”主题。生成的主题向量作为连续特征直接输入深度网络，与离散特征结合，旨在通过语义信息提升模型对用户偏好的建模能力。A-LDA 特征侧重于捕捉隐藏的主题模式，丰富推荐的语义表达。

(4) DeepFM 结合 A-LDA 与时间衰减特征模型

在 A-LDA 主题特征基础上, 加入时间衰减机制以突出近期偏好。时间衰减借助计算每条交互记录和用户最新交互时间的差值得以实现, 生成权重 $w(t)=2^{-\text{days}/\text{half_life}}$, 其中半衰期设定为 60 天, 以此保证近期数据能有更大贡献, 权重经归一化处理后与 A-LDA 主题向量相乘, 生成加权后的特征向量。加权后的 A-LDA 特征作为连续特征输入到模型中, 提高了对用户动态兴趣的捕捉能力, 在排序任务里呈现出其优势。

(5) DeepFM 加权融合 TF-IDF 与 A-LDA 文本特征模型

综合融合歌词的 TF-IDF 和 A-LDA 特征, 并引入时间加权, 构建最完整的多模态模型。歌词经过预处理后, 分别提取 TF-IDF 向量和 10 维 A-LDA 主题向量。时间加权分别应用于 TF-IDF 和 A-LDA 特征, 生成动态特征表示, 公式同上。TF-IDF 和 A-LDA 特征作为连续特征, 与用户 ID 和音乐 ID 的离散特征共同输入 DeepFM, 联合训练捕捉多源信息的交互关系。融合过程通过 DeepFM 模型内部的特征交叉机制优化特征表达, 旨在最大化模型对语义和动态偏好的理解。

改进实验通过逐步加入特征模块, 验证了文本特征和时间加权对推荐效果的贡献, 提出了一种多模态融合的 DeepFM-T-A-LDA-T 模型, 为音乐推荐任务提供了更优性能。

4.4 实验结果分析

为了深入分析各模型的优势与不足, 本文对所有实验模型进行了综合比较, 并设计了消融实验和最优参数分析, 探讨各模块在整体模型中的贡献。

4.4.1 Lastfm-1k 数据集上各模型性能对比分析

为了验证模型的效果是否具有普遍性效果, 本次实验采用多轮 K 值校验的方式来验证模型的有效性, 设置 K 值为推荐系统中常用指标@3、@5、@10、@15、@20, 对比模型在不同 K 值下的提升效果。本次采用 Precision 指标和 NDCG 指标来直观展示各模型的变化趋势, 具体如下图 4-3、4-4 所示。




图 4-3 不同 K 值下的 Precision 变化

Fig. 4-3 The variation of Precision under different K values

图 4-3 呈现出 LastFM 数据集上各模型在不同 k 值状况下 Precision@K 的变化走向。从图中可看出，随着 k 值的不断增大，各模型的 Precision@K 总体呈现出一种轻微下降的态势，这体现出在较长的推荐列表当中维持高精度所面临的挑战。DeepFM-T-A-LDA-T 在所有 k 值的情况下都明显比其他对比模型更具优势，当 $k=10$ 的时候，DeepFM-T-A-LDA-T 的 Precision@K 达到了峰值 0.8673，它在中等长度推荐列表里的优化成效格外突出。和 DeepFM 相比较，DeepFM-T-A-LDA-T 在 $k=3$ 时相对提升了约 4.02%，在 $k=5$ 时提升了约 5.83%，并且随着 k 的增大始终保持着更高的稳定性。其他模型像 ncf、neumf 以及 sasrec 虽然在特定 k 值时表现还可以，但是整体上没办法和 DeepFM-T-A-LDA-T 的精确性相抗衡，突出了它在短列表以及中长列表推荐方面的强大能力。




图 4-4 不同 K 值下的 NDCG 变化

Fig. 4-4 The variation of NDCG under different K values

图 4-4 呈现了 LastFM 数据集上各模型在不同 k 值下的 NDCG@K 变化情况。NDCG@K 指标衡量推荐列表的排序质量，随着 k 值的增大，各模型的 NDCG@K 普遍呈现缓慢下降趋势，反映了长列表推荐中排序优化的复杂性。DeepFM-T-A-LDA-T 在所有 k 值下均保持领先，其 NDCG@K 在 $k=10$ 时为 0.8710，显著优于其他模型。与 DeepFM 相比，DeepFM-T-A-LDA-T 在 $k=5$ 时提升约 2.4%，在 $k=10$ 时提升约 3.1%，显示出更优的排序质量。尤其在小 k 值时，其优势更为明显，表明模型能有效将用户最感兴趣的项置于推荐列表前列。DeepFM-T-A-LDA-T 的 NDCG@K 在 $k=10$ 达到峰值 0.8710，并在 $k=15$ 和 $k=20$ 保持较高收敛性，证明其在长列表推荐中仍能维持稳定的排序能力。相比之下，sasrec 在 $k=10$ 时表现较好，NDCG@10 为 0.8215，但随 k 增加下降明显， $k=20$ 为 0.8027；ncf 和 neumf 的 NDCG@K 则始终较低，难以与 DeepFM-T-A-LDA-T 竞争。这进一步验证了 DeepFM-T-A-LDA-T 在排序优化方面的显著优势。

表 4-7 呈现出对比实验中 DeepFM、NCF、NeuMF、SASRec、CoseRec 模型以及改进模型 DeepFM-T-A-LDA-T 在 LastFM-1K 数据集上, K 值设定为 10 时的各项性能指标, 其中覆盖了 AUC、Precision@10、Recall@10、F1@10 以及 NDCG@10 等方面。

表 4-7 各模型在数据集 Lastfm-1k 上的性能对比表

Table 4-7 Performance Comparison of Various Models on the Lastfm-1k Dataset

算法名称	AUC	Precision@10	Recall@10	F1@10	NDCG@10
DeepFM	0.8249	0.8146	0.1098	0.1935	0.8446
NCF	0.8405	0.7907	0.1095	0.1908	0.8001
NeuMF	0.8359	0.7919	0.1070	0.1873	0.7917
SASRec	0.7022	0.8095	0.1065	0.1869	0.8215
CoseRec	0.8266	0.8041	0.1059	0.1858	0.8087
DeepFM-T-A-LDA-T	0.8549	0.8673	0.1176	0.2057	0.8710

本次研究中所采用神经网络模型 NCF 与 NeuMF 利用用户-物品的历史交互进行建模, 可以很好的捕捉用户偏好, 因此在全局排序能力上表现较优, 适用于用户历史行为较为完整, 偏好稳定的场景。SASRec 模型采用自注意力机制可以刻画用户短期的兴趣演化, 对于高频短期的用户行为善于捕捉, 因此在 NDCG@k 上表现良好, 反映了其衡量前列排序质量的优势。但是 SASRec 对数据稀疏性较为敏感, 在缺乏足够数据时容易出现过拟合现象, 限制了在长尾用户数据中的表现。

CoSeRec 作为一种融合会话建模与对比学习机制的先进推荐方法, 能够有效结合用户短期行为和长期偏好, 提升对兴趣迁移的建模能力。其通过 GRU 对用户会话进行编码, 同时引入历史偏好表示, 在精度和排序质量上均具备竞争力。在本实验中, CoSeRec 的 Precision@10 为 0.8041, NDCG@10 为 0.8087, 优于 NCF 和 NeuMF 等传统深度模型, 尤其在排序质量上表现优异, 验证了其对于上下文行为的建模能力。

相比于其他对比模型, 本次研究所采用的 DeepFM-T-A-LDA-T 模型通过补充两类重要特征: 一是引入时间信息(T), 通过建模用户和物品的交互时间序列信息, 有效增强模型对于用户兴趣随时间变化的适应能力。二是利用提取的双通道主题特征(A-LDA-T), 通过对歌词文本信息进行主题建模, 从而提高了模型对语义层次的理解, 增强了模型的语义理解和对主题兴趣的变化捕捉能力。

从表 4-7 可以看出, 改进模型 DeepFM-T-A-LDA-T 在所有指标上表现最佳, 其 AUC 为 0.8549, Precision@10 为 0.8673, Recall@10 为 0.1176, F1@10 为 0.2057, NDCG@10 为 0.8710, 在排序质量 (NDCG@10) 和准确性 (Precision@10) 上均显著优于其他模型。这表明多特征融合显著提升了推荐效果。

以基础 DeepFM 模型作为基准,AUC 高于 SASRec 和 CoSeRec,略低于改进模型。改进模型通过逐步引入特征,显著提升了性能,对比 DeepFM 和 DeepFM-T-A-LDA-T,AUC 提升了 3%, Precision@10 提升了 5.27%, NDCG@10 提升了 2.64%, 进一步验证了时间和语义特征融合策略对推荐性能的促进作用。

4.4.2 30Music 数据集上各模型性能对比分析

表 4-8 呈现出对比实验中 DeepFM、NCF、NeuMF、SASRec、CoseRec 模型以及改进模型 DeepFM-T-A-LDA-T 在 30Music 数据集上, K 值设定为 10 时的各项性能指标, 其中覆盖了 AUC、Precision@10、Recall@10、F1@10 以及 NDCG@10 等方面。

表 4-8 各模型在数据集 30Music 上的性能对比表

Table 4-8 Performance Comparison of Various Models on the 30Music Dataset

算法名称	AUC	Precision@10	Recall@10	F1@10	NDCG@10
DeepFM	0.7920	0.6225	0.2086	0.3124	0.6323
NCF	0.8133	0.6922	0.2259	0.3407	0.7026
NeuMF	0.8145	0.6770	0.2195	0.3315	0.7094
SASRec	0.6939	0.5860	0.1752	0.2700	0.5206
CoseRec	0.7769	0.6509	0.2074	0.3148	0.5638
DeepFM-T-A-LDA-T	0.8203	0.7190	0.2341	0.3530	0.7323

根据表 4-8 各模型在数据集 30Music 上的性能对比表的实验数据, 改进模型 DeepFM-T-A-LDA-T 在各项评估指标中表现最为突出,其 AUC 为 0.8203, Precision@10 为 0.7190, Recall@10 为 0.2341, F1@10 为 0.3530, NDCG@10 为 0.7323, 全面优于其他对比模型, 表明多特征融合策略在提升推荐质量方面具有显著效果, 尤其在推荐准确性和排序质量方面表现尤为突出。

在对比模型中, NeuMF 的 AUC 值为 0.8145, 全局排序能力较强, 但其 Precision@10 为 0.6770, Recall@10 为 0.2195, 略低于 DeepFM-T-A-LDA-T; NCF 的 AUC 为 0.8133, Precision@10 为 0.6922, Recall@10 为 0.2259, 较为均衡, 显示出稳定的推荐能力; 而 SASRec 的 AUC 最低, 仅为 0.6939, 其 F1@10 为 0.2700, NDCG@10 为 0.5206, 也处于较低水平, 说明其在序列推荐任务中尽管能一定程度建模用户兴趣变化, 但整体排序与准确性表现有限。CoseRec 作为融合会话建模与对比学习的代表模型, 其在 Precision@10 和 Recall@10 上表现良好, F1@10 为 0.3148, NDCG@10 为 0.5638, 在捕捉用户短期兴趣与长期偏好方面表现优于 SASRec, 显示了其在多样性行为建模方面的潜力。

以基础 DeepFM 模型为基准,改进模型 DeepFM-T-A-LDA-T 通过逐步引入特征,实现了关键指标的显著提升:AUC 提升了 2.83%,Precision@10 提升 9.65%,NDCG@10 提升 10%。上述数据充分验证了多特征融合策略在增强推荐系统性能中的有效性。通过在两个数据集上的性能指标,可以充分证明改进模型的有效性及泛化性。

4.4.3 文本特征与时间加权对推荐效果的贡献

为了分析文本特征 TF-IDF 和 A-LDA 以及时间加权 TDF 对推荐效果的贡献,本文从基础 DeepFM 模型开始,逐步引入特征模块,观察性能变化。模型性能对比表如表 4-9 所示。

表 4-9 改进模型性能对比表

Table 4-9 Performance Comparison of the Improved Model

算法名称	AUC	Precision@10	Recall@10	F1@10	NDCG@10
DeepFM	0.8249	0.8146	0.1098	0.1935	0.8446
+ (TFIDF)	0.8167	0.8184	0.1086	0.1921	0.8527
+ (A-LDA)	0.8168	0.8210	0.1101	0.1942	0.8514
+ (A-LDA+TDF)	0.8206	0.8432	0.1126	0.1987	0.8649
+ (T-A-LDA-T)	0.8549	0.8673	0.1176	0.2057	0.8710

A-LDA 特征通过主题建模捕获歌词的语义结构,相比 TF-IDF 特征在 NDCG@10、Precision@10 和 Recall@10 上表现更优,说明 A-LDA 更适合推荐任务,能够提取更具语义区分度的特征。A-LDA 特征通过挖掘歌词的主题信息,增强了模型对音乐内容的深层语义理解,显著提升了推荐的准确性和排序质量。然而,A-LDA 特征对全局排序能力 AUC 的提升有限,可能是因为主题特征更侧重于语义表达,而非交互关系的直接建模。

时间衰减特征 TDF 在 A-LDA+TDF 模型中显著提升了推荐性能,NDCG@10 从 0.8514 提升至 0.8649,Precision@10 从 0.8210 提升至 0.8432,Recall@10 从 0.1101 提升至 0.1126。时间衰减通过加权近期交互,有效捕捉了用户兴趣的动态变化,近期交互的权重更高,提升了推荐的准确性和排序质量。AUC 从 0.8168 提升至 0.8206,表明时间衰减对全局排序能力也有一定的正向贡献。

T-A-LDA-T 模型结合 A-LDA 和 TF-IDF 特征,进一步提升了性能,AUC 达到 0.8549,相比基础 DeepFM 提高了 3%,NDCG@10 达到 0.8710,相比基础 DeepFM 提高了 2.64%,Precision@10 达到 0.8673,相比基础 DeepFM 提高了 5.27%,Recall@10 达到 0.1176,相比基础 DeepFM 提高了 0.78%。TF-IDF 特征提供了词频信息,作为 A-LDA 主题特征的补充,增强了模型的语义表达能力。TF-IDF 和 A-LDA 的互补性以

及时间衰减的动态加权共同作用，显著提升了模型对用户偏好和音乐内容的建模能力。

4.4.4 最优参数分析

参数敏感性分析探讨关键超参数对推荐系统性能的影响，以此来确定最优参数配置。本研究重点关注参数为：A-LDA 模型的主题数量、负采样的比例、正负样本的权重、半衰期的设定以及 DeepFM 模型的超参数。经过对这些参数的敏感性分析，得出了最优超参数配置，为实际系统的部署给出了理论依据。

(1) A-LDA 主题数的影响

A-LDA 主题数是基于歌词特征建模的核心参数，直接影响文本特征的语义表达和推荐性能。为确定最优主题数，测试了主题数范围[5,10,15,20,25]，实验中使用主题一致性指标（coherence_cv）和困惑度（perplexity）来确立最佳主题，主题一致性衡量主题内部词语的语义相关性，数值越高说明主题更具语义聚合性和可解释性。困惑度衡量模型对数据的拟合程度，数值越低表示模型拟合效果越好。

根据实验结果，主题一致性指标和困惑度表现出明显的变化趋势。当主题数较小时（5 和 10），一致性得分较高，分别达到 0.4532 和 0.4607，表明模型能够较好地捕捉文本语义结构，主题质量较优。同时，困惑度在这两个点较低，分别为 110.38 和 108.29，显示出模型对训练数据的拟合效果较好。

随着主题数进一步增加（15、20、25），一致性分数逐渐下降，而困惑度显著上升，表明模型的主题分布变得更加分散且不稳定，可能引入了噪声或过拟合。结合一致性和困惑度两个指标，主题数为 10 时取得了最佳的平衡点，因此本研究选择该主题数作为后续模型训练的参数。各主题下评价指标参数如图 4-5 所示。




图 4-5 A-LDA 主题选择图

Fig. 4-5 A-LDA Topic Selection Chart

(2) 负采样比例的影响

负采样比例 `neg_ratio` 控制正负样本的比例，直接影响模型的训练和推荐性能。本研究测试了 `neg_ratio` 在[1,3,5,7]范围内的值。实验结果表明，`neg_ratio`=5 时推荐性能

最佳, 此时 AUC 为 0.8145, NDCG@k 为 0.7276, Recall@k 为 0.1720, Precision@k 为 0.7210。当 neg_ratio 减小至 3 时, AUC 降低至 0.8064, NDCG@k 降至 0.7193, Recall@k 为 0.1668, 且 Precision@k 下降至 0.6951。这可能是由于负样本数量不足, 导致模型对正负样本的区分能力有所下降, 进而影响了 Top-k 推荐的质量和第一个正确推荐项的排序。

而当 neg_ratio 增加至 7 时, AUC 略有提升达到了 0.8150, NDCG@k 却下降到 0.7204, Recall@k 降低到了 0.1691, 同时 Precision@k 也略有下降至 0.7068。说明过多的负样本可能导致模型偏向预测负样本, 从而影响了 Top-k 推荐的质量和第一个正确推荐项的位置。综合考虑, neg_ratio=5 在推荐性能和样本平衡之间达到了较好折中, 因此本研究采用此值。实验数据对比如下图 4-6 所示。




图 4-6 负采样比例选择图

Fig. 4-6 Negative Sampling Ratio Selection Chart

(3) 正负样本权重的影响

DeepFM 模型的正负样本权重 (class_weight), 其作用是平衡正负样本不均衡的分布情况。在本研究中, 正负样本的比例为 1 比 5, 一开始设置的 class_weight 等于 {0:1,1:neg/pos}, 意思就是正样本的权重是 5, 实验得出的结果显示, 把正样本权重设为 5 的时候, 模型的表现最优, AUC 能达到 0.8193, NDCG@k 是 0.7491, Recall@k 为 0.1766, Precision@k 为 0.7217。在这样的设置之下, 模型在整体分类准确性方面表现不错, 对于 Top-k 推荐的质量也有一定提升。当正样本权重降低到 3 时, 模型的各项指标出现了下降: AUC 下降到 0.8148, NDCG@k 下降到 0.7295, Recall@k 为 0.1668,

Precision@k 为 0.7016。这或许是因为模型对正样本的关注不够，使得它没办法有效区分正负样本，对推荐效果产生了影响。

而当正样本权重增加至 7 时，虽然 AUC 略微上升至 0.8138，但其他关键指标如 NDCG@k 降至 0.7130，Recall@k 进一步降低至 0.1682，Precision@k 也略有下降至 0.7107。这可能是因为模型过分关注正样本，导致对负样本的预测能力下降，进而影响了整体推荐质量。实验数据对比如图 4-7 所示。




图 4-7 正负样本权重选择图

Fig. 4-7 Class Weight Selection Chart

(4) 时间衰减半衰期的影响

在引入兴趣衰减机制后，为进一步分析时间因子对推荐性能的影响，本研究设置了不同的半衰期，包括 30 天、60 天、90 天和 120 天，并分别记录模型的各项评估指标。

实验结果显示，当半衰期设置为 60 天时，模型整体性能最优：AUC 达到 0.8691，Precision@k 为 0.8401，在所有实验组中最高。这说明以 60 天为界的时间衰减机制，能够较为平衡地保留用户近期行为的重要性，同时不过度忽视中期行为，从而提高了推荐的准确性和相关性。

相比之下，当半衰期设置为 30 天时，虽然 NDCG@k 和 Recall@k 略高，分别为 0.8638 和 0.1985，但 Precision@k 与 MRR@k 略低，表明模型更偏重于非常近期的行为，可能忽视了部分中期偏好，导致推荐的多样性或泛化能力不足。

而当半衰期进一步扩大至 90 天或 120 天时，模型的各项指标整体下降，说明时

间衰减过缓会使得用户历史行为被平均对待，减弱了对新近兴趣的响应能力，从而影响了模型的推荐效果。实验结果如表 4-8 所示。




图 4-8 时间半衰期实验指标对比图

Fig. 4-8 Evaluation Metrics Comparison under Different Time Decay Half-Life Values

基于上述参数敏感性分析，本研究确定了最优超参数配置：A-LDA 主题数 $\text{topicNum}=10$ ，负采样比例 $\text{neg_ratio}=5$ ，正样本权重为 5，半衰期设置为 60 天，这一配置在推荐性能和模型稳定性之间达到了较好平衡，为模型的部署提供了理论依据。较小的主题数避免了主题之间的语义稀释，同时保留了足够的主题区分度，有效提升了歌词文本特征的表达能力；较高的负采样比例扩大了模型对负类样本的判别训练，有助于提升排序性能；而正样本权重的提高则弥补了数据集中正负样本比例失衡所带来的偏差，使得模型更加关注用户真实的点击或偏好行为。该超参数组合在 5 折交叉验证下表现出较强的鲁棒性，标准差较小，表明模型对不同数据划分的泛化能力良好。

4.5 本章小结

通过前述各项实验和对比分析，可以得出以下几点主要结论：在仅使用基础离散特征的情况下，DeepFM 模型虽然能够捕捉部分用户行为信息，但在排序效果和预测准确性方面存在较大提升空间。而引入文本特征后，无论是采用 TF-IDF 还是 A-LDA 进行文本建模，都能够在一定程度上改善模型性能，其中 A-LDA 主题特征相比 TF-IDF 特征在排序指标 NDCG@k、Precision@k 上具有明显优势。通过结合时间加权机制，模型能够更好地捕捉用户近期的兴趣变化，从而进一步提高推荐准确率。综合利用

TF-IDF 与 A-LDA 特征,通过加权融合构建多模态文本特征,使得模型在各项指标上均取得了显著提升,最终在 AUC、Precision@k、Recall@k、F1@k 和 NDCG@k 等指标上均超越了其他方法。从改进实验和最优参数分析的结果来看,各特征模块和动态权重分配机制在提升模型性能方面均发挥了重要作用。实验结果不仅证明了多特征融合的有效性,也为如何进一步优化模型提供了有价值的启示。

5 总结与展望

5.1 全文总结

在数字化时代,音乐资源的爆炸式增长使得用户很难在海量音乐库中找到符合个人兴趣的音乐。音乐推荐系统应运而生,旨在根据用户的历史行为、音乐内容特征及时间信息,为用户提供个性化推荐。推荐系统能够从海量的音乐库中,找到用户最可能感兴趣的项目推荐给用户,从而提高用户满意度和平台留存率。

本文首先介绍了研究的背景和意义,并分析了国内外在推荐系统、个性化推荐以及音乐推荐相关研究的进展。针对当前推荐系统在音乐推荐领域面临的挑战,提出了本文的研究目标。接着详细介绍了推荐系统的相关理论与技术,包括推荐系统的基本概念、推荐算法分类、评价指标以及现有的深度学习推荐模型如 DeepFM、NCF、SASRec、CoseRec 和注意力机制。还介绍了文本特征处理方法 TF-IDF、A-LDA 以及时间加权机制,为后续研究提供了理论支持。

当前传统的推荐系统面临着数据稀疏性、用户偏好建模不足以及动态兴趣捕捉不足等问题。数据稀疏性是指音乐流媒体平台中,用户与歌曲的交互行为较为有限,导致用户—歌曲交互矩阵呈现高度稀疏的特性。例如,在一个拥有百万级歌曲库的推荐系统中,单个用户实际交互的歌曲可能只有几十首,占比极小。这种稀疏性直接影响了协同过滤等依赖用户行为数据的推荐算法,使得相似性计算不准确。尤其是在新用户或新歌曲的场景下,由于缺乏足够的交互信息,系统难以进行有效推荐,导致冷启动问题的出现。用户偏好建模不足问题是指推荐系统在刻画用户兴趣时存在信息缺失或不准确的问题,基于隐式反馈的数据难以准确反映用户的真实兴趣,同时用户偏好也是动态变化的。动态兴趣捕捉不足是指推荐系统在用户对音乐的兴趣随着时间变化的趋势上没有深入挖掘,影响了推荐的时效性。

针对这些问题,本文提出了一种融合文本主题建模与时间加权机制的音乐推荐方法。首先基于用户—歌曲播放行为构建正负样本训练集,并提取标准化时间特征与衰减权重,为动态兴趣建模奠定基础。随后提出结合 TF-IDF 与注意力增强主题模型 A-LDA 的双通道文本特征提取方法,从词频与主题语义两个层面建模歌词内容。同时设计基于指数衰减函数的时间加权机制,引导文本主题特征按时间敏感性动态加权。最后将双通道文本特征与时间加权机制融合到 DeepFM 模型中,实现离散 ID 信息与连续语义特征的联合建模,从而提升推荐的个性化与时效性表现。

最后设计并实施了实验,验证所提出方法的有效性。使用数据集 LastFM-1K 和 30Music,通过 AUC、Precision@k、Recall@k、F1@k、NDCG@k 等指标,对比分析了基准模型 NCF、NeuMF、SASRec、CoseRec 和改进模型 DeepFM-T-A-LDA-T 上的不同效果。实验结果表明,本文提出的方法在推荐准确性和用户兴趣动态建模方面均优于对比模型,特别是在 NDCG@k 指标上取得了显著提升。

5.2 主要创新点

本文的主要创新点与贡献包括以下三个方面：

(1) 提出注意力增强的主题建模方法 **A-LDA**：改进传统 **LDA** 模型，利用注意力机制增强主题分布对重要词语的关注能力，实现对歌词文本中深层语义信息的更精准建模。该方法有效缓解了行为数据稀疏带来的影响，提升了推荐系统对用户兴趣的理解能力。

(2) 构建 **TF-IDF** 与 **A-LDA** 结合的双通道文本特征提取方法：设计并实现了从词频统计与主题语义两个维度提取歌词文本特征的策略，**TF-IDF** 用于捕捉关键词权重，**A-LDA** 用于建模全局主题分布，共同丰富了内容表示，有效提升了模型的推荐精度与语义判别能力。

(3) 设计基于时间衰减函数的主题兴趣加权建模机制：提出主题层面的时间加权策略，对双通道文本主题特征进行时间敏感性建模，构建主题兴趣衰减机制，动态刻画用户兴趣演化过程，从而增强模型对用户近期偏好的响应能力，提升了推荐的时效性与个性化效果。

实验结果表明，基于 **DeepFM** 的多模态融合模型 **DeepFM-T-A-LDA-T** 模型在 **AUC**、**NDCG@k** 等指标上优于基线模型，充分体现了融合多模态文本特征与时间动态建模策略在提升音乐推荐性能方面的有效性和先进性。

5.3 论文不足之处

尽管本文提出的融合模型在推荐效果上取得了显著提升，并在多个基准指标上优于现有方法，但仍存在以下几点不足，有待后续进一步研究与优化：

(1) 语义特征质量依赖于歌词数据完整性。所用 **LastFM-1K** 数据集中部分音乐缺失歌词或存在较多噪声，影响了 **TF-IDF** 与 **A-LDA** 文本特征的表达准确性。同时，模型仅利用歌词文本作为单一内容模态，未融合旋律、节奏、曲风、用户评论等其他模态信息，限制了对用户多维兴趣的全面建模能力。

(2) 时间建模方式相对单一，缺乏个性化设计。目前时间加权机制采用统一的指数衰减函数建模用户兴趣的时效性，未充分考虑用户间对“时间敏感度”的差异，可能无法适应复杂多变的个体行为模式，影响个性化推荐的效果。

(3) 特征处理以及模型训练所涉及的计算成本相对较高，双通道文本建模将 **TF-IDF** 与 **A-LDA** 相结合，虽然提升了语义表达能力，然而也给予了额外的计算负担，在大规模数据或者在线推荐场景当中，可能会面临训练时间较长、资源消耗较大的问题，需要在维持性能的基础上，优化计算效率以及模型部署方案。

5.4 展望

本文提出的模型是在已有模型的基础上提出，并经过大量实验证明了改进方法的有效性，通过与其他深度神经网络模型的对比，证明了本模型可以取得不错的效果。但是，由于时间的局限性以及视野的局限性，仍存在一些尚待解决的问题，以供后续

研究进一步研究扩展，相关内容如下：

（1）探索在线推荐系统的部署与评估。当前研究是基于离线数据来评测的，使用了历史数据来训练模型，并在测试集上进行性能验证，未来可尝试在实际推荐系统中进行 A/B 测试，以验证模型的在线推荐效果。

（2）优化特征融合策略。本文提出模型是结合了歌词文本和时间加权机制来进行特征建模的，未来可进一步考虑引入社交网络信息、音乐音频特征或情感分析结果，以提升推荐系统对用户兴趣的理解。

（3）提升模型的可解释性。本研究所使用模型为黑盒模型，难以向用户解释推荐的原因，可能导致用户信任度降低。未来可结合图神经网络（GNN）、注意力可视化等机制，揭示模型在做出推荐时的关键特征和推理路径，实现可解释推荐。同时结合用户行为反馈，优化模型的自适应能力与交互体验。

综上所述，本研究通过实验证明了改进模型 DeepFM-T-A-LDA-T 的有效性，验证了融合文本语义与时间动态机制在推荐任务中的有效性，未来将进一步优化模型，提升推荐的准确性和有效性。

6 参考文献

- [1] Mokoena N, Obagbuwa C I. An analysis of artificial intelligence automation in digital music streaming platforms for improving consumer subscription responses: a review[J]. *Frontiers in Artificial Intelligence*, 2025, 71515716-1515716.
- [2] 郑映杰. 基于深度学习的网易云音乐推荐研究[D]. 中国地质大学(北京), 2023.
- [3] 邓小凤. 网易云音乐APP品牌营销优化研究[D]. 重庆交通大学, 2024.
- [4] Haraburda S S. Global Data Shock: Strategic Ambiguity, Deception, and Surprise in an Age of Information Overload[J]. *Parameters*, 2020, 50(3): 148-149.
- [5] 齐光鹏. 基于多信息融合分析的客户精准画像与推送算法设计[J]. *现代电子技术*, 2025, 48(06): 175-179.
- [6] Ramírez J C, Julia M F, Philippe L. Predicting Spotify Audio Features from Last.fm Tags[J]. *Multimedia Tools and Applications*, 2023, 83(16): 48311-48330.
- [7] 华康民, 殷旭颂. 基于Python的网易云音乐评论数据分析系统的设计与实现[J]. *现代信息科技*, 2024, 8(24): 72-76.
- [8] Huang H, Li J, Lu F, et al. Augmenting Sparse Behavior Data for User Identity Linkage with Self-Generated by Model and Mixup-Generated Samples[J]. *Neural Networks*, 2025, 187: 107295-107295.
- [9] Mo Y, Chen J, Xie X, et al. Cloud-Based Mobile Multimedia Recommendation System with User Behavior Information[J]. *IEEE Systems Journal*, 2014, 8(1): 184-193.
- [10] Yang L. Deep Learning-based User Behavior Data Mining in Precise Recommendation of E-commerce Platforms[J]. *Applied Mathematics and Nonlinear Sciences*, 2025, 10(1).
- [11] 刘津京. 基于在线评论情感分析的影视平台用户兴趣推荐模型研究[D]. 哈尔滨理工大学, 2024.
- [12] Wang K, Xiong L, Liu A, et al. A Self-adaptive Ensemble for User Interest Drift Learning[J]. *Neurocomputing*, 2024, 577: 127308.
- [13] Cheng Q, Zhang S, Yang L. A Text Feature Extraction Model for Hazardous Chemical Recovery Identification and Attribute Classification Embedded in Domain Knowledge Graph[J]. *Environmental Monitoring and Assessment*, 2025, 197(4): 415.
- [14] 程一峰. 基于TF-IDF的音频和歌词特征融合模型的音乐情感分析研究[D]. 重庆大学, 2012.
- [15] Lee H J, Ostwald J M. Latent Dirichlet Allocation (LDA) topic models for Space Syntax studies on spatial experience[J]. *City, Territory and Architecture*, 2024, 11(1):

3-3.

- [16] 顾淳. 基于语义及文本特征的无监督关键词提取研究[D]. 浙江理工大学, 2023.
- [17] Xiaoli L, Lei X, Zhengbiao J. Integration of Network Teaching Resources of a Political Theory Course Based on the Collaborative Filtering Algorithm[J]. Wireless Communications and Mobile Computing, 2022, 2022.
- [18] Yin Y, Ling R, Xu Y, et al. A Collaborative Filtering Recommendation Method Based on Emotional Evaluation Relations[J]. Soft Computing, 2024, 28(13): 8167-8181.
- [19] Olubusola F I. Matrix Factorization in Recommender Systems: Algorithms, Applications, and Peculiar Challenges[J]. IETE Journal of Research, 2023, 69(9): 6087-6100.
- [20] Wang G, Chen M, Wu J, et al. An Improved Constrained Bayesian Probabilistic Matrix Factorization Algorithm[J]. Soft Computing, 2023, 27(9): 5751-5767.
- [21] Xiaochen Y, Qicheng L. Improved FunkSVD Algorithm Based on RMSProp[J]. Journal of Circuits, Systems and Computers, 2022, 31(08).
- [22] Mengyu W, Hanyu L. SVD-based Algorithms for Fully-connected Tensor Network Decomposition[J]. Computational and Applied Mathematics, 2024, 43(5).
- [23] 郭志强. 基于用户行为分析的个性化推荐[D]. 华中科技大学, 2024.
- [24] 谢海迪, 周云, 李彤岩. 一种基于社交网络的非负矩阵分解算法[J]. 成都信息工程大学学报, 2024, 39(01): 50-55.
- [25] Cheng H T, Koc L, Harmsen J, et al. Wide & Deep Learning for Recommender Systems[C]. Proceedings of the 1st Workshop on Deep Learning for Recommender Systems, 2016: 7-10.
- [26] Ren L, Wang T, Laili Y, et al. A Data-Driven Self-Supervised LSTM-DeepFM Model for Industrial Soft Sensor[J]. IEEE Transactions on Industrial Informatics, 2021, 18(9): 5859-5869.
- [27] Xiaoxia J. A Factorization Deep Product Neural Network for Student Physical Performance Prediction[J]. Computational Intelligence and Neuroscience, 2022, 2022.
- [28] Ren R, Liu Z, Li Y, et al. Sequential Recommendation with Self-attentive Multi-adversarial Network[C]. Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, 2020: 89-98.
- [29] Sun F, Liu J, Wu J, et al. BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer[C]. Proceedings of the 28th ACM International Conference on Information and Knowledge Management, 2019: 1441-1450.
- [30] Van den Oord A, Dieleman S, Schrauwen B. Deep Content-based Music Reco-

- mmendation[J]. *Advances in Neural Information Processing Systems*, 2013, 26.
- [31] Betello F, Purificato A, Siciliano F, et al. A Reproducible Analysis of Sequential Recommender Systems[J]. *IEEE Access*, 2024.
- [32] Lu Y, Gao Z, Cheng Z, et al. Session-based Recommendation with Transformers[M]. *Proceedings of the Recommender Systems Challenge 2022*, 2022: 29-33.
- [33] 侯亚飞, 荀亚玲, 杨海峰, 等. 基于时序感知和长短期兴趣融合的序列推荐[J]. *计算机工程与设计*, 2025, 46(03): 804-811.
- [34] 强敏杰, 王中卿, 周国栋. 基于预训练模型的用户评分预测[J]. *软件学报*, 2025, 36(02): 608-624.
- [35] Sánchez-Moreno D, Zheng Y, Moreno-García N M. Time-Aware Music Recommender Systems: Modeling the Evolution of Implicit User Preferences and User Listening Habits in A Collaborative Filtering Approach[J]. *Applied Sciences*, 2020, 10(15).
- [36] Gong Z, Shao X. A Music Recommendation System Based on Multi-modal Fusion[J]. *Nanjing Xinxing Gongcheng Daxue Xuebao*, 2019, 11(1): 68-76.
- [37] 袁涛, 牛树梓, 李会元. 一种基于CW-RNN的多时间尺度序列建模推荐算法[J]. *中文信息学报*, 2020, 34(06): 97-105.
- [38] Zhang P, Zhang Z, Tian T, et al. Collaborative Filtering Recommendation Algorithm Integrating Time Windows and Rating Predictions[J]. *Applied Intelligence*, 2019, 49(8): 3146-3157.
- [39] 王紫萱, 张凯涵, 蔡江辉, 等. 融合多模态特征的可解释推荐算法[J]. *计算机系统应用*, 2025, 34(03): 62-71.
- [40] Jinghui P, Zhen W, Shizhe W. Similarity calculation method for images based on the scene graph[J]. *Signal, Image and Video Processing*, 2023, 17(5): 2395-2403.
- [41] 冯婷婷. 面向稀疏数据的协同过滤相似度计算研究[D]. 河南理工大学, 2023.
- [42] Min L L, Xiang P Z, Le L, et al. Research of Data Sparsity Based on Collaborative Filtering Algorithm[J]. *Applied Mechanics and Materials*, 2013, 462-463: 856-860.
- [43] 赵森. 基于多元用户偏好建模的个性化对话推荐算法研究[D]. 华中科技大学, 2024.
- [44] Yichen W. Research on recommendation algorithm based on collaborative filtering of fusion model[J]. *Journal of Physics: Conference Series*, 2021, 1774(1):012058.
- [45] Zhao R, Zhang Y, Ju S, et al. Adaptive User Multi-level and Multi-interest Preferences for Sequential Recommendation[J]. *World Wide Web*, 2025, 28(1): 20.
- [46] 唐宏, 金哲正, 张静, 等. 融合时间感知和多兴趣提取网络的序列推荐[J]. *重庆邮电大学学报(自然科学版)*, 2024, 36(04): 807-818.

- [47] 贾丽云, 佟玉军, 李雪, 等. 融入时间间隔的跨序列推荐方法[J]. 计算机工程与设计, 2025, 46(03): 819-825.
- [48] Zhao Y, Hua X. Application of Collaborative Filtering Algorithm Based on Time Decay Function in Music Teaching Recommendation Model[J]. PeerJ Computer Science, 2024, 10: e2533.
- [49] Hassan Y A, Fadel E, Akkari N. Exponential Decay Function-Based Time-Aware Recommender System for e-Commerce Applications[J]. International Journal of Advanced Computer Science and Applications (IJACSA), 2022, 13(10).
- [50] Alshbanat I H, Benhidour H, Kerrache S. A Survey of Latent Factor Models in Recommender Systems[J]. Information Fusion, 2025, 117: 102905.
- [51] 卡祖铭, 赵鹏, 张波, 等. 面向大语言模型的推荐系统综述[J]. 计算机科学, 2024, 51(S2): 11-21.
- [52] 于蒙, 何文涛, 周绪川, 等. 推荐系统综述[J]. 计算机应用, 2022, 42(06): 1898-1913.
- [53] Tenti P, Thomas J, Peñaloza R, et al. ContReviews: A Content-based Recommendation System for Updating Living Evidences in Health Care[J]. Knowledge-Based Systems, 2025, 311: 112981.
- [54] 刘帅. 基于深度学习的音乐流派分类和标签自动标注研究[D]. 广州大学, 2022.
- [55] Govindarajan P, Shanmugam D S. Hybrid Recommendation System Based on Collaborative and Content-Based Filtering[J]. Cybernetics and Systems, 2023, 54(4): 432-453.
- [56] 陈宸, 成蓉, 宋彬. 端到端异构图信息协同过滤推荐[J]. 西安电子科技大学学报, 2025, 52(01): 163-180.
- [57] 魏雁飞. 融合知识图谱和协同过滤的推荐算法研究[D]. 内蒙古大学, 2024.
- [58] 陈剑峰. 基于协同过滤的中药推荐系统研究与应用[D]. 电子科技大学, 2024.
- [59] Sun Y, Liu Q. Collaborative Filtering Recommendation Based on K-nearest Neighbor and Non-negative Matrix Factorization Algorithm[J]. The Journal of Supercomputing, 2025, 81(1): 79.
- [60] Parthasarathy G, Sathiya Devi S. Hybrid Recommendation System Based on Collaborative and Content-Based Filtering[J]. Cybernetics and Systems, 2023, 54(4): 432-453.
- [61] Guo W, Liu F. Research on Personalized Hybrid Recommendation Algorithm Based on Deep Learning[C]. Proceedings of 2019 9th International Conference on Management and Computer Science (ICMCS 2019), 2019: 50-55.
- [62] Zengguang W, Deyong W. Research on Recommendation Algorithm Based on Neural Network Fusing User Behavior Sequence[C]. Xinjiang University (China); XinJiang Lianhai INA-INT Information Technology Co., Ltd. (China), 2023.

- [63] Madhusree K, Puspanjali M. Assessment Methods for Evaluation of Recommender Systems: A Survey[J]. Foundations of Computing and Decision Sciences, 2021, 46(4): 393-421.
- [64] 王瑞平, 贾真, 刘畅, 等. 基于DeepFM的深度兴趣因子分解机网络[J]. 计算机科学, 2021, 48(01): 226-232.
- [65] Bing G, Wen Z, Li P D. A Service Recommendation Algorithm Based on Self-Attention Mechanism and DeepFM[J]. International Journal of Web Services Research (IJWSR), 2023, 20(1): 1-18.
- [66] 郁豹, 李振华, 张凯, 等. 基于DeepFM模型的广告推荐系统研究[J]. 计算机应用与软件, 2019, 36(07): 307-310+316.
- [67] 杨琳. 基于改进DeepFM模型的广告点击率预测研究[D]. 山东大学, 2022.
- [68] Bsoul Q, Zawaideh F, Alqadi S B, et al. From User Preferences to Accurate Predictions: Enhancing Movie Recommendation Systems with Neural Collaborative Filtering and Sentiment Analysis[J]. SN Computer Science, 2025, 6(3): 257.
- [69] Fayçal M, Manal L. E-commerce Personalized Recommendations: a Deep Neural Collaborative Filtering Approach[J]. Operations Research Forum, 2024, 5(1).
- [70] 冯健. 基于用户长短期兴趣的自注意力序列推荐[J]. 计算机应用与软件, 2023, 40(06): 103-111.
- [71] Yihu Z, Bo Y, Haodong L, et al. A Time-aware Self-attention Based Neural Network Model for Sequential Recommendation[J]. Applied Soft Computing Journal, 2023, 133.
- [72] 贝天石, 成卫青. 融合用户兴趣度的基于自注意力的序列推荐模型[J]. 南京邮电大学学报(自然科学版), 2022, 42(01): 90-100.
- [73] Dantong L, Cui Z. Cross-Domain Sequential Recommendation Based on Self-Attention and Transfer Learning[J]. Journal of Physics: Conference Series, 2021, 2010(1).
- [74] Liu Z, Chen Y, Li J, et al. Contrastive self-supervised sequential recommendation with robust augmentation. arXiv 2021[J]. arXiv preprint arXiv: 2108.06479, 2021.
- [75] 金燕, 黄杰. 基于信息熵与词长信息改进的TFIDF算法[J]. 浙江工业大学学报, 2021, 49(02): 203-209.
- [76] 刘思新, 高琨, 田一龙, 等. 基于改进TFIDF-Logistic Regression微博暴力文本分类[J]. 吉林大学学报(信息科学版), 2021, 39(06): 751-757.
- [77] 季旺, 夏振宇. 基于改进TFIDF算法的情感分析模型研究[J]. 计算机与数字工程, 2022, 50(08): 1671-1675.
- [78] Zhou Z, Qin J, Xiang X, et al. News Text Topic Clustering Optimized Method Based on TF-IDF Algorithm on Spark[J]. CMC: Computers, Materials & Continua, 2020,

- 62(1): 217-231.
- [79] 吴远云. 基于改进TFIDF和LSTM的中文文本分类算法研究[D]. 江西财经大学, 2023.
- [80] Yu Y C, Shan J. Research on the Web Chinese Keywords Extraction Algorithm Based on the Improved TFIDF[J]. Applied Mechanics and Materials, 2015, 727-728: 915-919.
- [81] Sun F H, Hou W. Study on the Improvement of TFIDF Algorithm in Data Mining[J]. Advanced Materials Research, 2014, 1042: 106-109.
- [82] Hou Z, Tong W, Deng J, et al. Research on Emotion Analysis Based on a Topic Emotion Fusion Model: The Case of the "Post-holiday Symptoms of Pharyngitis" Event on the Weibo Platform[J]. Research in Health Science, 2024, 9(3).
- [83] Gao L, Cui F, Zhang C. Library Similar Literature Screening System Research Based on LDA Topic Model[J]. Journal of Information & Knowledge Management, 2024, 23(05).
- [84] Chen L. Mining and Teaching Design of Civics Topics in English Courses Based on LDA Topic Modeling[J]. Applied Mathematics and Nonlinear Sciences, 2025, 10(1).
- [85] 孙阳. 基于改进LDA模型的微博用户兴趣挖掘系统的设计与实现[D]. 北京邮电大学, 2021.
- [86] Gao R, Xu J, Chen Y, et al. Heterogeneous Feature Fusion Module Based on CNN and Transformer for Multiview Stereo Reconstruction[J]. Mathematics, 2022, 11(1): 112.
- [87] 刁驰. 基于LDA主题模型的舆情情感分析的个股交易策略设计[D]. 上海师范大学, 2022.
- [88] 高嘉霖. 基于LDA-Word2vec的新闻传播领域主题识别演化及发展趋势研究[D]. 山西财经大学, 2023.
- [89] Li F, Zhang C. A Deep Learning-Based Recommender Model for Tourism Routes by Multimodal Fusion of Semantic Analysis and Image Comprehension[J]. Journal of Circuits, Systems and Computers, 2024, 34(01).
- [90] 谢永华, 厉涛, 柏勇. 结合注意力特征融合的路面裂缝检测[J]. 计算机工程与设计, 2025, 46(01): 307-313.
- [91] 张岐山, 朱猛. 融合时间加权信任与用户偏好的协同过滤算法[J]. 计算机工程与应用, 2022, 58(03): 112-118.
- [92] 邹凌君, 陈峻, 李娟. 时间加权的混合推荐算法[J]. 计算机科学, 2016, 43(S2): 451-454.